

可判性的到来

发现还是发生？

缺的从来不是论据，是一台能把过程重跑的装置

王 德 生

DEMAI INTERNATIONAL PRESS

可判性的到来

——发现还是发生？

王德生

Demai International Press

版权信息

书名	可判性的到来——发现还是发生？
副题	“知识是被发现的，还是被造成的”何以悬置两千年，又何以在大语言模型处第一次成为实验问题
作者	王德生 (Desheng Wang)
出版	Demai International Press·新加坡德麦国际
丛书序号	德麦国际专著第 124 号
ISBN	979-8-90690-092-0
定价	US \$25.00
开本	A5 (148 × 210 mm)
字数	机检约 233,925 汉字
版次	2026 年 9 月第 1 版第 1 次印刷

内容提要

“知识是被发现的，还是被造成的”——这道题自《美诺》以来悬置两千年。本书主张它不可判有一个结构性的原因：判决所需的干预，在知识的形成过程上从来无法施加；缺的不是论据，是一台能把形成过程整体重跑的装置。

本书论证这台装置已经出现，并把待判的命题翻译成可测形式：固定语料、架构与判准，只改变训练路径，问所到达的结果是否同一处。全书交出一个承重区分、三条条款、四个量、六条写死的败绩条件、一份预注册，以及一次已执行的首跑。

首跑的结论是“未能分辨”。本书不交出结论，只交出判据、读数与一份修订清单；并用整章写明本书接不住的那一记。

版权声明

本书的预注册文本、探针集、原始读数与全部分析脚本随书公开，任何人可以重跑并核对。正文内容的引用与讨论不受限制；若引用本书的读数，请连同其判负条件一并引用——这是本书自己写下的纪律，也是本书唯一的请求。

作者介绍

王德生 (Desheng Wang)，博士。

1990 至 1997 年就读湘潭大学数学系，本科与硕士；1997 至 2001 年于中国科学院数学研究所获博士学位，博士工作为组合网格与网格自动生成；2001 至 2003 年在中国科学院计算数学研究所从事博士后研究。

2003 至 2005 年任英国威尔士大学斯旺西分校高级研究员。2005 年起任新加坡南洋理工大学数学系助理教授、博士生导师，后任资深研究科学家，至 2018 年。在职期间培养毕业博士六名、指导博士后九名，获该校青年科研奖与教学奖，主持与参与多项科研基金项目，曾任国际期刊编委。在计算数学与计算机图形学领域发表国际期刊论文四十七篇，集中于重心 Voronoi 网格与 Delaunay 网格、变分表面重建、波崩塌模拟三个方向。

2015 年起回国讲学，在各地高校讲授三视角方法论数百场。2024 年提出 SIO 本体论与意义三律，后凝练为 SDE 发生学。现为新加坡德麦国际创始人、董事长，主持德麦国际专著出版体系与 SDE Universes 平台。

关于这本书，作者想说明一件与履历有关的事。

本书的实验部分——探针的构造、距离的计算、预注册的冻结与执行——用的是一套此前二十年做网格生成与数值计算时养成的习惯：先把判据写死，再动手；跑出来的数不合心意，照登。那套习惯在计算数学里是常识，在哲学讨论里不是。

这本书试图做的事，可以看成把那套常识搬到一个它此前没有被使用过的问题上。搬得对不对，本书交出的是可以被别人核对的材料，而不是一个结论。

前言

一、这本书为什么会存在

我不是从哲学问题开始的。

二十多年前我做的是网格生成——给一个三维形体填进几百万个四面体，让它们尽可能规整，好让后面的数值计算稳定。这是一件很具体的工作：有输入（形体与边界条件），有输出（一套网格），有判准（单元质量的若干个数），中间是一条算法路径。

做久了，会注意到一件在那个行当里人人知道、而很少被当成问题的事：同一个形体，同一套判准，换一种生成次序，得到的网格不一样。

不是差一点，是结构上不一样——哪里密、哪里疏、哪里出现难看的薄单元，随着你先插哪个点、先处理哪个面而变。而这些网格在质量指标上可以同样好。

当时我们的处理方式是工程性的：固定随机种子以便复现，调整策略以减少差异，选表现最好的那一个交付。没有人问过一个问题：如果把算力、点数、迭代次数一直加上去，这些差异会不会消失？

不是没人想得到，是这个问题没有用。工程要的是一套能用的网格，不是一个关于差异极限的答案。

这本书就是那个没有用的问题，在二十年后被换到另一个对象上重新问了一遍。

二、写给三类读者

这本书有三类可能的读者，而他们各自会在不同的地方被卡住。把这件事写在前言里，是为了让每一类人知道哪些章节是为他写的、哪些可以跳过。

第一类关心这道哲学题的人。

你们会发现这本书的哲学部分——第一、二、三、九编——全部是为一个具体的判决服务的，而不是独立的思辨。这可能让人失望。这里没有对柏拉图或康德的新解释，第三编那二十六章只问一件事：他缺哪台装置。

对你们的提醒是：这本书的结论比你们期待的弱得多。它不证明人类知识是被造成的，它只取消了一条原则的先天地位。

第二类做机器学习的人。

你们会发现这本书用你们熟悉的材料在问一个陌生的问题。种子差异、表征相似度、缩放律、彩票假说——这些在你们那里是工程话题，在这里是判据。

对你们的提醒有两条：其一，全书不使用“理解”“意识”“智能”这三个词，因此那些关于模型懂不懂的争论在这里不出现；其二，这本书对读数的要求比通行实践严——比值、基线、双通道、事先冻结——而第八十章第七节说明那套要求对两侧同等有效，不是单方面的苛求。

第三类做实验方法学的人。

对你们，这本书最有用的部分可能不是结论，是第五十九章、第六十五章与附三：一次真实的预注册，它在执行中被自己证伪了一项冻结条款，而那个过程被完整记录下来。

据我所知，这类记录很少见——不是因为这种事很少发生，是因为发生之后通常没有人把它写出来。

三、从“没有用的问题”到一桩两千年的悬案

2024年起，我把主要精力转到一套关于“发生”的理论上。在那个框架里，反复撞到同一个结构：一个东西是本来就在那里被找到的，还是在过程中被做成的。

这个问题不是我提出来的。它至少可以追到《美诺》里那个两难——你怎么能去寻找你根本不知道的东西？柏拉图的回答是回忆说，而两千多年来，这个回答与它的对手从未分出过胜负。

我关心的不是谁对，是为什么判不了。

读了一阵之后，我得到一个诊断，它构成了本书的脊梁：

两千年判不了这道题，缺的从来不是论据，是一台能把过程重跑的装置。

这个诊断的来处，恰恰是网格生成那段经历。在那里，“换一条路径会不会到达同一处”是一个可以动手的问题——你真的可以换一种次序再跑一遍，把两套网格摆在一起比。而在知识形成这件事上，从来没有人能够这样做：一段历史只发生一次，没有第二个十七世纪的欧洲，没有清空记忆再学一遍的学生。

判决所需的那个动作，在对象上施加不了。

四、装置到了

大约两年前，这件事变了。

大规模语言模型的训练，同时满足四条此前从未同时满足过的性质：它可以被从头再跑一次；可以只改变路径而保持材料与判准不变；可以删掉某一部分材料再跑；中间状态被完整保存而不是被推测。

更要紧的是第五条：它的产物具有知识主张的形式——可以被评价为对或错，可以与世界上的事情对照，可以在对照失败时被修改。

我不主张这些模型拥有知识，也不主张它们理解任何东西。本书通篇不使用“理解”“意识”“智能”这三个词，而且第四十五章专门论证了为什么不使用它们反而使论证更强。

本书主张的只有一件很冷的事：它是一台实验设备。

而有了这台设备，那个两千年的问题第一次可以被写成一个带量、带判负条件的形式：固定语料、架构与判准，只改变训练路径，问所到达的结果是不是同一处。

五、这本书没有做到的事

写到这里，按通行的写法，下一段应该讲这本书判出了什么。

它什么也没判出来。

我按书里写死的判据跑了一次，结论是“未能分辨”。

具体说：内部表征上，路径差异在一个数量级的规模跨度上不衰减；输出行为上，路径差异单调下降，但在最大规模上仍是噪声基线的两倍以上。两条通道给出相反的方向，而预注册在执行之前就写着：两通道结论不一致，判未能分辨。

这不是一次失败的实验，但它也确实什么都没证明。

我在书里用了整整一章（第六十四章）论证为什么“未能分辨”是一个结论而不是一次弃权。这里只说一件事：那一跑里，有两种写法都能成文——只报表征通道，它是一次漂亮的通过；只报行为通道，它是一次清楚的败绩。两种写法里的每一个数字都是真的。

而两种都是作弊。

挡住这两种写法的，不是我的自律，是执行之前写死的那一条规则。

六、还有一处，我自己把自己判错了

比“未能分辨”更难堪的是另一件事。

预注册里有一条冻结项——噪声基线用“同一训练轨迹内相邻检查点之间的距离”。我为这个选择写过一整段论证，论证的逻辑没有错：它偏保守，因而对我不利，若比值仍然很大，结论就更可信。

跑完之后才发现，这条基线跨规模不可比。它在三个较小规模上稳定，到最大规模跳了近三倍；而归一化后的曲线在那里的坍塌，主要不是分子变了，是分母变了。

由此得到一句话，它是这本书在方法上最实在的一句：

预注册保护的是“事后不许改判据”，它不保护“事前把判据写错”。

前者是意志问题，制度挡得住；后者是知识问题，制度挡不住——在执行之前，没有人知道那条基线会跨规模伸缩，包括写下它并为它做过正确论证的人。

我把这个错误连同它的全部细节写进了第六十五章，而没有回头去改首跑的读数。读数按原定义照登。

七、这本书交出什么

清点一次，不多不少。

一个承重区分：计算性路径依赖与构成性路径依赖——“你还没走到”与“从这条路走过去，那里没有那个东西”。

三条条款、四个量、六条写死的败绩条件。

一份预注册与它的冻结摘要值，以及全部脚本与原始读数。

一次未能分辨的首跑。

一份修订清单，六条，其中第一条是首跑自己把自己的判据证伪的产物。

一记接不住的反击——语境内临时形成的程序，究竟是形成还是激活，我给不出界限，并且在第七十八章写明了为什么这一记恰好绕开了我换现场的全部三个理由。

六件本书不主张的事。

没有交出的是结论。

八、为什么这样交付

有人会问：一本什么也没判出来的书，为什么要写二十多万字？

我的回答有两层。

第一层：这道题不是学院内务。教育按“所有人学到的是同一个东西”设计评估，科学史按“逐步逼近加人事噪音”讲述进展，法律按“自然规律不可专利”划归属，人工智能研究按“逼近那个唯一最优模型”分配算力。四个领域都按其中一侧的答案行事，而那一侧从未被检验过。

一个从未被检验的前提支撑着四件有后果的事，那么把它变成一个可以被检验的形式，本身就值得做——哪怕检验的第一次什么也没测出来。

第二层，也是我更在意的一层：一个悬置了两千年的问题，不应该被任何人用一本书宣布解决。它应该被交给一台能判它的装置，并且事先说清楚，怎样算输。

这句话里有三个部分，正好对应这本书的三段工序：交给一台装置（第四编）、能判它（第五、六编）、事先说清怎样算输（第七、九编）。

三段做完之后，剩下的事不归这本书管。剩下的事是跑。

九、为什么把最薄的地方写在最前面

上一节说这道题不是学院内务，本节回答另一个更直接的疑问：既然书里到处是“本书不知道”，读者凭什么读完？

我的判断是反过来的：正因为到处是这句话，它才值得读完。

一本论辩的书通常这样处理自己薄弱的地方：略过、降格为脚注、或者用一句“这超出了本书的范围”打发掉。这样做的后果不是书变强了，是它能被推翻的方式变得不可预料——它会在一个作者从未设想过的地方垮掉，而那时连哪一部分还站得住都说不清。

这本书走的是相反的路。第六章第七节在全书第一编就列了我认为自己最可能出错的五处，逐条写明哪几处可修、哪一处不可修；第七十八章整章写我接不住的那一记，并且写明它为什么恰好绕开了我换现场的全部三个理由；第八十章第六节把首跑那个已经很难看的“未能分辨”又下修一层。

这样写的代价是真实的：它让这本书读起来不像一本有把握的书。

而收益也是真实的：如果有一天它被推翻，推翻它的人多半会落在那几处已经被标出来的位置上。那时至少能知道，哪一部分跟着倒了，哪一部分还立着。

第八十一章附三那句话可以放在这里：一本书能被推翻的方式，应当是它自己写下的那几种。

十、这本书是怎么写出来的

方法上的事写在第五十九章与增订卷里，这里只说工序。

其一，骨架先行。每一编在动笔之前先出一张施工骨架：每章一张卡，写明承重句、节次、硬规定、与别处的分工。第三、六、八编的骨架随书封装公开，可以对照正文看哪些地方按骨架浇了、哪些地方走样了。

其二，零术语。全书不使用我自己那套理论的专有词汇，一个也不用。理由很实际：一本要跟别人争论的书，若靠自造的词来表述主张，对手连反驳的着力点都找不到。全书写完之后做过逐字扫描，命中为零。

其三，判据先于读数。首跑的预注册写定、计算摘要值、公开，然后才下载模型。这一条在第六十章有完整记录，包括执行前的一处修订与执行后的三处偏离。

其四，不利读数照登。第六十二、六十三两章是并排的，一章对我有利，一章对我不利，长度相当。这不是姿态，是执行前写死的规则。

其五，每一处薄弱当场写明。全书里“本书不知道”“本书给不出”“本书接不住”这类句子出现了几十次。它们不是修辞上的谦虚——每一处后面都跟着具体是什么、为什么、以及需要什么才能解决。

十一、一件关于署名的事

这本书的写作过程中，大量的成文工作由一个语言模型完成：按我定的骨架与纪律起草、按我的裁定修改、执行扫描与机检。命题、判据、败绩条件、以及每一处“本书接不住”的认定，出自我；而把它们写成二十多万字的，不全是我是我。

我认为这件事应当被写出来，而不是留在工序里。

理由不是风度，是本书自己的主张。第八十五章讨论归属时指出：归属判断所需要的“常规组合与非显而易见”之间的界线，与第七十八章“激活与形成”之间的界线是同一条——而我在那一章明确承认，我给不出这条界线。

一个在书里承认自己划不出创造与组合之界线的人，不应当在封面上假装那条界线很清楚。

因此本书的署名问题，我把它留在明处：这本书是在人与机器的合作中写成的，而合作中各自贡献多少，按本书自己的框架，是一个目前还没有判据可以裁决的问题。

这不是一句漂亮话。它是第八十五章第四节那个“不判性质，判贡献”的转向在本书自己身上的一次应用——而那一节的结论是：那个转向在研究上可行，在制度上不可行。署名是制度。

十二、致谢

感谢那批公开了多种子检查点的研究者。他们制作那套材料是为了研究训练的稳定性，而我拿它来问了一个他们没有问的问题。第七十四章用了一整节说明这样重读的正当性，以及我欠他们的那个交代。

感谢在书稿成形过程中读过片段并提出异议的朋友。有几处我接受了，有几处没有——没有接受的那几处，我把异议本身写进了正文。

感谢德麦国际的同事完成了排版、校对与出版事务。

最后要感谢的是这道题本身。它让我在二十年之后，重新回到当年做网格生成时那个“没有用的问题”上，并且第一次发现它可以被真的问出口。

十三、关于这本书的书名

书名里“可判性”三个字，不是一个哲学术语，是一个很具体的状态。

一道题可判，不等于它被判了。可判的意思是：存在一个动作，做完之后会得到一个结果，而那个结果可以与两个答法中的某一个相冲突。

按这个意思，两千年来这道题一直不可判——不是因为没人努力，是因为那个动作做不出来。一段知识形成的历史只发生一次，而判它需要的是同一段过程的第二次。

“到来”两个字指的就是那个动作第一次变得可做。

不是答案到来了，是可判性到来了。这两件事差得很远，而书名有意只说前一件。

我知道这个书名有一个风险：它听起来像是在宣告什么。而这本书恰恰什么也没判出来。

我仍然用它，理由是：如果连“这道题现在可判了”这句话都不敢说，那么这本书就没有主张。一本书可以什么也没判出来，但它必须有一个可以被反驳的主张——而“这道题现在可判了”正是一个可以被反驳的主张。

反驳它的方式在第四编与第五编：指出那四条性质并未同时满足，或者指出本书的翻译不忠实。两条路我都写明了，包括它们各自成立时我要交出什么。

十四、给不打算读完的人

这本书二十多万字，八十八章。我知道多数拿起它的人不会读完。

因此把最要紧的三章列在这里，它们分别对应我最想立的、最想守的、最想承认的：

第五十二章 承重区分——计算性路径依赖与构成性路径依赖。这是全书的柱子，拆不干净后面全部作废。

第六十四章 为什么“未能分辨”是一个结论。这是全书方法学的核心，也是我认为这本书最值得被别人拿去用的一节。

第七十八章 本书接不住的那一记。这是全书最薄的地方，我把它写成了整整一章。

读这三章大约需要一小时。读完之后，你会知道这本书主张什么、靠什么撑住、以及在哪里会倒。其余八十五章都是这三件事的展开与佐证。

十五、一句留给读者的话

这本书里有很多我不确定的东西，它们都被写在了正文里而不是脚注里。第六章第七节列了五处我认为自己最可能出错的地方，第三十六章末尾补了第六处；第七十八章整章写我接不住的那一记；第八十章第六节把首跑那个“未能分辨”又下修了一层——它目前无法与“两把尺子量了不同的东西”区分开。

把这些写出来不是谦虚，是自利。

一本书能被推翻的方式，应当是它自己写下的那几种，而不是别人替它想象的那几种。我宁愿这本书死在第五十八章那四条败绩条件里的某一条上，也不愿它在一场关于措辞的争论里被慢慢忘掉。

如果你读完之后，决定去跑第二次——按增订卷里那份预注册，或者按你自己重写的一份——那么这本书就算做到了它能做的全部。

王德生 2026 年 9 月

导读

这本书有二十多万字、八十八章。本节说明怎么读它，包括不必全读的读法。

一、一句话的内容

固定语料、架构与判准，只改变训练路径，问所到达的结果是不是同一处。若不是，而且这个“不是”不随规模增加而消失，那么被知道的东西就有一部分是在寻找中被做成的。

这就是全书。其余的篇幅，是把这句话变成可判的形式，以及说明为什么它此前两千年不可判。

二、三种读法

读法一·只读三章（约一小时）。

- 第五十二章 承重区分：计算性路径依赖与构成性路径依赖。全书的柱子。
- 第六十四章 为什么“未能分辨”是一个结论。全书方法学的核心。
- 第七十八章 本书接不住的那一记。全书最薄的地方。

三章分别对应本书最想立的、最想守的、最想承认的。读完这三章，你会知道这本书主张什么、靠什么撑住、以及在哪里会倒。

读法二·读判据与读数（约一天）。

第五编（翻译）→第六编（三条款）→第七编（首跑）。

这条路径跳过全部哲学史，直接看命题怎么被翻成可测形式、判据怎么写、以及实际跑出了什么。做实验的人应当走这一条。

配合增订卷《第二跑》的第十章（预注册全文），可以直接动手复现或重做。

读法三·从头读（约一周）。

十编的分工：

编	内容	它回答什么
一	悬案的形状	题目是什么
二	三道闸	为什么判不了
三	两千年的谱系	每个人各缺哪台装置

编	内容	它回答什么
四	实验台	为什么是这台装置
五	翻译	命题怎么变成可测的
六	三条条款	怎么判
七	首跑	实际跑出了什么
八	对手	对方的武器，以及它赢 件
九	反击与边界	本书接得住什么、接不 么
十	后果与更长的观察	两侧各自的后果

三、四条阅读提示

提示一·不要在前三编等结论。

前三编（第一至十三章、第十四至三十九章）全部是诊断与谱系，不含任何本书自己的主张。一个急于看到结论的读者，可以从第四编开始，需要时再回头。

提示二·第三编不必按顺序读。

那二十六章按“缺哪台装置”重排了两千年的谱系，每章三节，彼此独立。挑你熟悉的那几个人读即可——柏拉图、康德、库恩、哈金、皮亚杰是最常被查阅的五章。

提示三·凡带数字的地方，都要看它旁边的判负条件。

本书的纪律是：每一处读数与它的判负条件写在同一页。若你看到一个数而没有看到“什么情况下这个数说明本书错了”，那说明你读漏了，或者本书那一处写坏了——两种都值得回头看一眼。

提示四·不利读数与有利读数篇幅相当。

第六十二章（表征通道，对本书有利）与第六十三章（行为通道，对本书不利）是并排的两章，长度相当。这不是平衡的姿态，是执行前写死的一条规则。若你觉得某一章读起来别扭，那很可能正是它被这条规则压住的地方。

四、本书不做事，先说在前面

其一，它不主张大模型拥有知识、理解或认识主体性。全书不使用这三个词，理由在第四十五章。

其二，它不主张人类知识与模型训练是同一类过程。本书的论证是反例结构而非类比结构，区别在第五十一章。

其三，它不主张已经完成判决。首跑的结论是“未能分辨”，四条败绩条件一条都没有被触发。

完整的六条“不主张”在第八十一章。建议在开始读正文之前先翻一遍那一章，它能省掉大量误读。

五、符号与记号

全书只用五个记号，在第五编第四十八章定义，此处先列出以便查阅：

- **C** 材料（语料）
- **A** 装置（架构与优化器族）
- **L** 判准（损失与评估）
- **P** 路径（种子、数据次序、课程等一切不改变前三者的变量）
- **Reach(C, A, L)** 可达集：一切路径所能到达的结果的集合

全书要判的，就是这个集合是不是一个点。

四个量（路径散度、不可消解度、可归约份额、标定不可达）的完整定义汇总在附一。

六、与增订卷的关系

本书另有一卷《第二跑：设计与预注册》，约三万九千字。

正卷交出判据与一次未能分辨的读数；增订卷把正卷欠下的那份修订清单，做成了一份可以直接冻结执行的预注册。

两卷的分工是：正卷回答“这道题为什么可判、怎么判、第一次跑出了什么”；增订卷回答“第二次该怎么跑、花多少钱、什么情况下停手”。

只读正卷是完整的。增订卷是给打算动手的人准备的。

七、最后一件事

这本书里最要紧的一句话，在第五十二章第三节：

计算性路径依赖说的是“你还没走到”；构成性路径依赖说的是“从这条路走过去，那里没有那个东西”。

其余八十七章，都是在把这一句变成可以被读数分开的两件事。

如果你只记住一句，请记这一句。

目录

卷 前

作者介绍 5

前言 5

导读 14

导 论 22

第一编 悬案的形状 28

第一章 美诺的角落 35

第二章 回忆说的骨架为什么活了两千年 39

第三章 另一条线：造成论的家谱与它始终的弱势 56

第四章 这道题不是学院内务 56

第五章 一个被当作解决的误判 56

第六章 本书要判什么、不判什么 56

第二编 为什么判不了：三道闸 58

第七章 闸一观察等价：产物层不留下不同痕迹 59

第八章 三类零分辨力证据之一：多重发现 63

第九章 之二：独立可重复性 68

第十章 之三：技术的成功 72

第十一章 闸二普遍性自伤：康德的先验形式如何与先在论观察等价 77

第十二章 同一处自伤的四次重演 82

第十三章 闸三干预不可施加 86

第三编 两千年的谱系：按缺哪台装置重排 91

第十四章 柏拉图 92

第十五章 亚里士多德 94

第十六章 奥卡姆与唯名论之争的可判性形式 95

第十七章 培根 97

第十八章 笛卡尔 99

第十九章 维柯：第一次正面的造成论 100

第二十章 休谟 102

第二十一章 康德 104

第二十二章 黑格尔 106

第二十三章 马赫 108

第二十四章 彭加勒：约定论离判据最近的一次 110

第二十五章 杜恒 112

第二十六章	蒯因	113
第二十七章	波普尔：证伪何以不触及本案	115
第二十八章	库恩	117
第二十九章	拉卡托斯	119
第三十章	费耶阿本德	121
第三十一章	布鲁尔与强纲领	123
第三十二章	拉图尔	125
第三十三章	哈金：干预主义的锋利与它的射程	127
第三十四章	卡特赖特	129
第三十五章	皮克林：实践冲撞与它无法重跑的困境	131
第三十六章	伍德沃德：因果的干预定义如何直接给出本书的语法	133
第三十七章	皮亚杰	135
第三十八章	维果茨基：路径进入结果的第一份经验材料	137
第三十九章	古尔德与康威莫里斯	139
第四编 实验台 142		
第四十章	判决需要的四条性质	143
第四十一章	为什么不是量子测量	146
第四十二章	为什么不是实验演化	150
第四十三章	为什么不是早期人工生命与遗传算法	155
第四十四章	大模型训练的四条工程事实	159
第四十五章	本书不使用的三样：理解、意识、智能	164
第四十六章	实验台的代价：它自己也是被造出来的	169
第五编 翻译 174		
第四十七章	把形而上学命题翻成可测命题的一般要求	175
第四十八章	可达集：定义与它的三种误读	179
第四十九章	分歧的最终形式	183
第五十章	三处翻译陷阱	188
第五十一章	判一个实例不等于判全称	192
第六编 三条款 198		
第五十二章	承重区分：计算性路径依赖与构成性路径依赖	199
第五十三章	案例的天花板：为什么此前的造成论只做到第一种	204
第五十四章	条款一·规模消解检验与不可消解度 κ	208
第五十五章	条款一的三条硬规定，与首跑之后补上的第四条	212
第五十六章	条款二·语料可归约性与可归约份额 ρ	216
第五十七章	条款三·可达集不足与资源标定的不可达	220

第五十八章	阶梯关系与四条写死的败绩条件	224
第五十九章	预注册方法学：冻结什么、何时冻结、怎样防作弊	227
第七编	首跑	154
第六十章	首跑的预注册全文与冻结	233
第六十一章	材料与实现	237
第六十二章	读数（一）：表征通道——不向零衰减	237
第六十三章	读数（二）：行为通道——单调下降	245
第六十四章	“未能分辨”是一个结论	245
第六十五章	首跑暴露的方法论缺陷：归一化基线跨规模不可比	254
第六十六章	一条探索性读数，与下一跑的清单	258
第八编	对手	199
第六十七章	先在论今天有实证武器，而且很硬	264
第六十八章	旗舰一表征收敛与柏拉图表征假说	267
第六十九章	趋势不是极限	271
第七十章	旗舰二彩票假说	275
第七十一章	线性模式连通与置换对齐：标号与实质的边界	280
第七十二章	缩放律：它支持哪一侧，以及它默认了什么	284
第七十三章	grokking 与相变：同一批现象的两种读法	289
第七十四章	欠规定性与多种子基准：被当作工程缺陷的那批材料	293
第九编	反击与边界	299
第七十五章	第一记极小点集合本来就在那里	300
第七十六章	向它要一个地址	304
第七十七章	第二记这只是表征的形成，不是知识的形成	308
第七十八章	第三记语境内的临时程序只是激活——本书接不住的那一记	311
第七十九章	第四记这是在给相对主义开门	316
第八十章	第五记不可消解度可能只是度量的产物	320
第八十一章	本书不主张的六件事	325
第十编	后果与更长的观察	329
第八十二章	若倒向造成论科学史的说明模式	330
第八十三章	若倒向造成论教育与评估	333
第八十四章	若倒向造成论人工智能研究自身的目标	337
第八十五章	若倒向造成论归属与权利	341
第八十六章	若倒向先在论本书承认什么	346
第八十七章	更长的一条：可判性本身是历史的	350

结 语

结语 美诺问题的实验回答 356

卷 后

参考书目 (择要) 361

附一 量的定义汇总表 364

附二 结果距离 d 的构造规范 366

附三 预注册模板 367

附四 复现清单 370

附五 与相邻立场的分界 372

导论

一、问题

知识是被发现的，还是被造成的？

这个问题有两个答法，而两千多年来它们从未分出胜负。

第一个答法说：被知道的东西在被知道之前已经以某种方式在那里，形成过程是接近它的通道。本书称之为先在论。

第二个答法说：被知道的东西的某些规定，是在特定条件与特定路径中才获得的；换一条路径则那些规定不同或不存在。本书称之为造成论。

两个答法的分歧不在措辞上。当一位科学家说“我发现了 X”，先在论读作“X 在被说出之前就以某种方式存在”，造成论读作“在这套仪器、这套记法、这条路径被建立之前，X 所指的那个可稳定重认的东西并不作为这一个而存在”。

而两种读法对科学家的实验室行为、对论文的写法、对后续技术的可用性，不给出任何不同的预测。

这是本书的起点。

二、诊断

通行的解释有两种，本书都不采纳。

第一种：这是一个哲学问题，而哲学问题本来就没有答案。这个回答把“没分出胜负”当成了原因，而那正是要被解释的东西。

第二种：论证还不够好，或者材料还不够多。这个回答可以被检查，而检查的结果是它不成立——两千年里论证一直在变好，材料一直在变多，而分歧的位置一步没动。

本书的诊断是：有三道具体的闸门关着。

闸一-观察等价。所有可供检查的东西都是产物，而过程已经消失了。在产物层上，“被发现”与“被造成”是两个不同的起源假设，但它们不留下不同的痕迹。三类被反复援引的证据——多重发现、独立可重复性、技术的成功——不是弱证据，是零分辨力的证据：它们所证明的东西，与本案所争的东西不是同一件。

闸二-普遍性自伤。历史上分量最重的几次造成论，都用自己的方式取消了自己的可判性。一个造成论若把它的构成装置设定为普遍的、唯一的、必然收敛的，它就与先在论给出相同的经验预测。康德如此，皮亚杰、乔姆斯基、

进化心理学、结构主义各自重演了一次。这道闸不是外部的限制，是造成论自己关上的。

闸三干预不可施加。判决这个问题需要对知识的形成路径施加干预，然后看被形成的知识是否随之改变。而这要求四条性质：可重跑、可干预、可消融、可观测。对人类知识史，四条一条也做不到。

三道闸合起来，给出本书的脊梁：

两千年判不了这道题，缺的从来不是论据，是一台能把过程重跑的装置。

三、装置

大约两年前，这件事变了。

大规模语言模型的训练同时满足那四条性质：训练是一个确定的计算过程，可以被从头再跑一次；可以只换随机种子或数据次序而保持语料、架构、判准不变；可以从语料中精确删除某一子集再跑；成千上万个中间状态被完整保存而不是被推测。

更要紧的是第五条：它的产物具有知识主张的形式——可以被评价为对或错，可以与世界上的事情对照，可以在对照失败时被修改。

本书不主张这些模型拥有知识，不主张它们理解任何东西。全书不使用“理解”“意识”“智能”这三个词，而且这个设限使论证变强而不是变弱：一个不需要模型懂什么的论证，不会因为模型不懂而倒。

本书主张的只有一件很冷的事：它是一台实验设备。

选它的理由全部是工程性的，而不是“它像人脑”。同样按这四条性质，本书排除了三个更常被援引的候选：量子测量（被干预的不是形成过程）、实验演化（对象是生物性状不是知识）、遗传算法与人工生命（产物不构成知识主张，且材料与判准合一）。

四、翻译

装置本身不判任何事。要用它，必须先把待判的命题翻译成它能回答的形式。

翻译的落点是可达集：

Reach(C, A, L) = { R : 存在路径 P 使训练到达 R }

其中 C 是材料（语料），A 是装置（架构与优化器族），L 是判准（损失与评估），P 是路径（种子、数据次序、课程等一切不改变前三者的变量）。

四个符号里，只有 **P** 不出现在括号里。这就是定义的要害：若路径不进入结果的规定，这个集合退化成一个点；若路径进入规定，它就是一个有内部结构的集合。

于是两个答法得到两个判然不同的形式：

先在论： $R = \Phi(C, A, L)$

造成论： $R = \Phi(C, A, L, P)$ ，且 **P** 不可消去

判决的问题变成一个具体的问题：**P** 能不能被消去？

“消去”有三种含义，而三条条款各对应一种：量上的消去（差异随资源趋于零）、描述上的消去（差异可由不提路径的描述写出）、集合上的消去（不存在只有某条路径才到得了的结果）。

五、承重区分

翻译之后，还有一件必须先做的事，而它是全书的柱子。

两侧都拿得出“路径依赖”的证据，而它们说的不是同一件事。这个词在先在论嘴里指求解过程的有限性，在造成论嘴里指结果的存在条件；两者都会在实验里表现为“换一条路，结果不一样”，而且在中间规模上表现得几乎一模一样。

因此必须拆词：

计算性路径依赖说的是“你还没走到”；构成性路径依赖说的是“从这条路走过去，那里没有那个东西”。

两侧各有三条判别特征：差异随资源加上是衰减到零还是趋于正常数；不存在一个只以材料、装置、判准为自变量的统一描述；可达集是不是满的。

由此得到一句对本书自己不利、却必须写在最前面的话：

计算性路径依赖是先在论的自家话，不是造成论的战利品。

迄今为止机器学习里报告过的绝大多数路径依赖，在结构上都属于前一种。靠它赢下来的判决，对手一夜之间就能收回去。

六、判据

三对判别特征落成三条条款，各带一个量：

条款	量	先在论预测	造成论预测
一-规模消解检验	不可消解度 κ	$\kappa = 0$	$\kappa > 0$

条款	量	先在论预测	造成论预测
二.语料可归约性	可归约份额 ρ	$\rho - 1$	$1 - \rho$ 稳定为正
三.可达集不足	标定不可达	不存在	存在

三条不是并列的三个论点，是先在论的三道退守防线。每一道被守住，本书作出一次事先写明的让步。

四条败绩条件在任何读数产生之前写死，另有两条在正文中补入。其中最重的一条要求：条款一若判负，本书不但放弃核心命题，还要把失败的后果推广出去，交给对手一条比他原本主张的更清楚的结论。一条不会带来真实损失的败绩条件不是败绩条件。

判据之外还有四条硬规定，用来堵住四种把结论塞进度量的做法：不得用任务分数作结果距离；必须消去已知对称性；必须包含分布外行为；两通道不得合成。

七、首跑

本书执行过一次真跑。

材料是一组公开的多种子检查点：四个规模、每个规模五条只在路径上不同的运行；112 条探针在执行之前冻结并公开摘要值。

读数分两个通道。

表征通道：路径间距离在四个规模上依次为 0.352、0.445、0.441、0.411，先升后持平，没有向零衰减的迹象；作为对照，同一轨迹内相邻检查点之间只有 0.031。所用度量对神经元置换、正交变换与各向同性缩放不变——这些差异不是标号差异。

行为通道：路径间距离依次为 0.263、0.221、0.171、0.116，单调下降；但在最大规模上仍是噪声基线的两倍以上，未落入不可区分的程度。

两通道结论不一致。按执行前写死的第三款：

未能分辨。

这个结论是本书最要紧的一件产出，理由不在它说了什么，在它挡住了什么。

只报表征通道，这一跑是条款一的一次漂亮通过；只报行为通道，它是一次清楚的败绩。两种写法里的每一个数字都是真的，而两种都是作弊。

八、首跑把自己的判据证伪了一条

比”未能分辨”更难堪的是另一件事。

预注册的冻结项第二条规定噪声基线取”同一训练轨迹内相邻检查点之间的距离”，并为这个选择做过一整段逻辑正确的论证。执行之后发现它跨规模不可比——它在三个较小规模上稳定在 0.011 至 0.013 之间，到最大规模跳到 0.031；归一化后的比值在最大规模处从 40.4 掉到 13.4，主要不是分子变了，是分母变了。

本书没有回头改读数，按原定义照登。由此得到一句：

预注册保护的是”事后不许改判据”，它不保护”事前把判据写错”。

前者是意志问题，制度挡得住；后者是知识问题，制度挡不住。而正因为这条基线被写死并在四个规模上统一使用，它的毛病才显形——若它是每个规模随手取的，这个问题会被平滑掉，永远浮不出来。

九、边界

本书不主张六件事，列在此处以免误读：

不主张大模型拥有知识、理解或认识主体性；不主张人类知识与模型训练是同一类过程；不主张数学是发明而非发现；不主张已经完成判决，也不主张首跑判出了任何东西；不主张路径依赖是好事；不主张先在论是愚蠢的立场。

本书的论证结构是反例式而非类比式。先在论在其最一般的形态上主张的是一条全称命题——任何以材料为输入、以判准为约束的知识形成过程，其结果由材料与判准唯一决定。要削弱一条全称命题，不需要类比，只需要一个落在其范围内的实例。

于是本书能取得的最大收获可以一句写定：

普遍性一旦破了，先在论就必须为它想主张的每一个领域单独举证——而这正是它两千年来从未做过的事。

它不证明人类知识是被造成的。它确实取消了”知识必然由材料唯一决定”这一原则的先天地地位，把它从公理降为待证的经验假设。

十、接不住的那一记

本书有一记接不住的反击，用整章写明。

条款三的第三类性质候选是“语境内临时形成的程序”——模型在推理时形成一个训练时并不存在的、针对当前任务的临时程序。反击说：那只是把权重里已有的能力按语境组合起来激活了一次。

本书给不出“形成”与“激活”之间的界限。

而更难堪的是：这一记恰好绕开了本书换现场的全部三个理由——它不需要重跑（组合与形成的区别不随重跑次数改变），不需要缩放（它在任何规模上都同样成立），也不需要出示地址（权重就在那里，只是不知道该往里面找什么）。

换现场在这里没有帮到本书。

十一、这道题不是学院内务

四个领域每天按其中一侧的答案行事，而那一侧从未被检验过。

教育按“所有人学到的是同一个东西”设计评估；科学史按“逐步逼近加人事噪音”讲述进展；法律按“自然规律不可专利”划归属；人工智能研究按“逼近那个唯一最优模型”分配算力。

四栏全部倒向先在论，而这不是它被证实的证据——主要是“按它行事更便宜、且不按它行事的问题没人提出”的证据。

本书不主张哪一侧的后果更可取。若判决倒向造成论，它的后果里有相当一部分是坏消息：依赖分数的选拔与认证会遇到结构性的麻烦；不可复现性变成结构性的而非工程性的；科学史上的一些结论失去“迟早会被发现”这层保险。

十二、这本书交出什么

一个承重区分、三条条款、四个量、六条写死的败绩条件、一份预注册与它的冻结摘要值、全部脚本与原始读数、一次未能分辨的首跑、一份六条的修订清单、一记接不住的反击、六件不主张的事。

没有交出结论。

一个悬置了两千年的问题，不应该被任何人用一本书宣布解决。它应该被交给一台能判它的装置，并且事先说清楚，怎样算输。

三段工序做完之后，剩下的事不归本书管。

剩下的事是跑。

第一编 悬案的形状

本编不给出任何论证上的进展。它做的是把题目摆清楚，包括摆清楚它为什么两千年来没被摆清楚过。

六章的分工：第一章把美诺悖论的形式写准，并为两个答法命名；第二章追回忆说那副骨架——对象先在、方法中立、知识累积——为什么去掉形而上学外衣之后还能用两千年；第三章写造成论的家谱与它始终的三条弱势；第四章指出这道题不是学院内务，四个领域每天按其中一侧行事；第五章拆掉一个被广泛当作解决的误判；第六章把本书要判什么、不判什么、可能错在哪里一次写清。

本编最要紧的一句在第一章第六节：当一位科学家说“我发现了 X”，两种读法对他的实验室行为、对论文的写法、对后续技术的可用性，不给出任何不同的预测。那一句是全书的起点，也是下一编那道闸的雏形。

第一章 美诺的角落

一、那个角落

苏格拉底在《美诺》里被逼到一个至今没有被真正解决的角落。

美诺问：一个人怎么可能去寻找他根本不知道的东西？

如果他知道自己要找什么，他就不必找；如果他不知道，他连自己找到了没有都判断不了。

这就是所谓美诺悖论，也叫探究者悖论。

它看起来像一个诡辩，而两千多年来没有人能把它当作诡辩打发掉。原因在于它不是一个关于词语的把戏，它触到了“探究”这个活动的一个结构性前提。

二、把它的形式写准

把这个两难写成三步，看清它的每一步各需要什么。

步骤一：探究是有方向的。一个人去找某物，而不是随便乱翻。

步骤二：方向来自对所找之物的某种规定。若对它一无所知——连它是什么类的东西都不知道——那就没有方向，因而没有探究，只有随机遭遇。

步骤三：而若已有那个规定，那么所找之物在探究开始之前就已经被规定了，于是找到它不是获得了新的规定，只是确认了已有的规定。

两难的精确形式因此是：

探究要有方向，方向要靠规定；而规定若在探究之前就有，探究就不产生规定；规定若在探究之后才有，探究就没有方向。

这个形式有一个特点值得注意：它不涉及任何关于世界的经验假设。它只用到“有方向的活动需要某种关于目标的规定”这一条，而这一条几乎无法被否认。

于是它不能靠经验去解决，只能靠对“规定”这个词作某种安排。而两千年来的全部答法，都是对这个词的不同安排。

三、柏拉图的安排：规定在前，只是被忘了

柏拉图给的答案是回忆说：灵魂在出生前见过全部真理，学习只是把已有的东西重新想起来。

这个答案怎样解开了那个两难？

它选的是第三步那一侧：规定在探究之前就有。于是方向有了着落。

而“探究不产生规定”这个看起来荒谬的后果，被一个巧妙的补充化解：规定虽然在，却不在当下的意识里。它被遗忘了。于是探究有事可做——它要把已有的东西从遗忘中取回来。

这个安排的代价很重：它需要灵魂前生，需要一个在出生之前就见过全部真理的认识者。

而它的结构极轻。

轻到什么程度？轻到把“灵魂前生”这一条去掉，剩下的骨架仍然可用，而且被后世几乎所有认识论用了两千年。

那副骨架是三条：对象先于知识而存在；方法是中立的通道；知识是逐次逼近的累积。

第二章整章处理这副骨架。

四、另一种安排

还有第二种安排，它选的是另一侧：规定不在探究之前完整地有，它有一部分是在探究中被获得的。

这一侧要解决的是“方向从哪来”这个问题，而它的回答是：方向不需要完整的规定，只需要部分的规定；探究从部分的规定出发，而在过程中那个规定被补全、被修改、甚至被改写。

这个安排的代价与柏拉图的正好相反：它不需要灵魂前生，不需要任何形而上学的重负；但它的结构不轻——它要解释“被补全的那部分规定”从哪来，以及它凭什么算数。

这条线的起步要晚得多，而且一直没能取得与第一条同等的地位。第三章整章处理它的家谱与它始终的弱势。

五、两个名字

为了行文统一，本书称第一条为先在论，称第二条为造成论，并在需要区分强弱时加限定。

先在论：被知道的东西在被知道之前已经以某种方式在那里，形成过程是接近它的通道。

造成论：被知道的东西的某些规定，是在特定条件与特定路径中才获得的；换一条路径则那些规定不同或不存在。

两个名字都要防一种误读。

“先在论”不是说一切都被写好——它可以完全承认探究是艰苦的、可能失败的、需要创造性的。它只主张那个被到达的东西先于到达而存在。

“造成论”不是说想怎么造就怎么造——它主张的是在约束下被造成，而且它的全部论证都建立在约束极强这个前提上（第七十九章第三节）。

本书选这两个词，是因为它们把分歧落在“那个东西是不是先在”这一点上，而不落在“过程重不重要”这一点上。后一种问法会立刻得到两方都同意的回答，因而是第四十七章第六节所说的“翻译不足”。

六、两个读法，零个不同预测

分歧不是措辞上的。两方对同一句话给出相反的读法。

当一位科学家说“我发现了 X”：

- 先在论读作：X 在被说出之前就以某种方式存在，科学家的工作是使之为人所知。
- 造成论读作：那个被叫作 X 的东西，要成为一个可以被反复认出的“这一个”，得先有一套仪器、一套记法、一条把它固定下来的做法；在这些就位之前，它没有作为这一个而存在。

而两种读法对科学家的实验室行为、对论文的写法、对后续技术的可用性，不给出任何不同的预测。

这一句是全书的起点。它不是一句感慨，它是第二编第七章要论证的那道闸——观察等价。

七、三种常见的打发方式，以及它们各自漏掉了什么

这个悖论有三种流行的打发方式。它们都不完全错，而且各自指出了一件真的事；但它们各自漏掉了第二节那个形式里的一步。本节逐条处理，因为漏掉哪一步，决定了一个人会站到哪一侧。

打发一：这是一个假两难，因为“知道”有程度。

回答是：一个人可以部分地知道——知道它是一类什么东西，不知道它具体是什么。于是他有方向（靠部分的知），也有事可做（补全其余）。

它指出的真事：知识确实有程度，探究确实是从部分走向完整。

它漏掉的那一步：它没有回答“补全的那一部分从哪来”。若补全的内容本来就被那个部分的规定所蕴含，那么它仍然是先在的，探究只是展开；若不被蕴含，那么它是在探究中被获得的——而那正是本案所争的。这个打发方式把问题往后推了一步，没有取消它。

打发二：这是一个语言问题，“寻找”这个词被用得太紧。

回答是：日常的“找”从来不要求先知道被找者的全部规定，我们说找一份工作、找一个解释，都不预设那个东西已被完整规定。

它指出的真事：日常语言确实宽松，把悖论套在日常用法上会显得迂腐。

它漏掉的那一步：本案关心的不是日常的“找”，是“被找到的那个东西，在被找到之前是不是已经是这一个”。日常语言的宽松恰恰把这个问题掩盖了，而不是解决了。

打发三：这是一个被科学实践反驳掉的伪问题——科学天天在发现新东西。

它指出的真事：科学确实在产出新的、稳定的、可用的东西。

它漏掉的那一步：它把“产出了新东西”直接读成“那些东西本来就在”。而第一章第六节那两种读法说明，同一批产出对两种读法给出相同的预期。这个打发方式实际上是在用先在论的读法来证明先在论。

三种打发方式的共同点值得记一句：它们都在第二节那三步里跳过了第三步——“规定若在探究之前就有，探究就不产生规定”这一步的后果。跳过它，两难就消失了；而跳过它的理由，每一次都是本案的答案。

八、为什么从美诺开始，而不从今天开始

一本讲大模型的书从两千四百年前的一段对话开始，需要一句理由。

理由不是致敬，是定位。

若从今天开始——从种子差异、从多种子基准、从表征收敛——那么本书看起来像是在处理一个机器学习的方法学问题：训练结果为什么不稳，能不能稳下来。

而那不是本书要判的题。那个问法落在第四十七章第六节所说的“翻译不足”上——它把一个关于知识的问题，缩成了一个关于可靠性的问题，而后者两方都同意。

从美诺开始，是为了把问题的身份钉住：本书测的那些距离、那些探针、那些比值，全部是为了回答“被寻找的东西在被找到之前是不是已经是这一个”。

这个定位有一个实际的后果：它决定了第五十五章那四条硬规定为什么必须那么严。若问题是“训练稳不稳”，用任务分数当结果距离完全合理；而若问题是美诺的那一个，用分数就等于事先判了案（第五十章第一处陷阱）。

反过来说也成立：一个不打算判美诺那道题的人，不需要本书这套麻烦的判据。判据的严格程度，是由题目的身份决定的。

九、这一编要做的事

本编六章的分工：

- 本章：把悖论的形式写准，并给两个答法命名。
- 第二章：回忆说的骨架为什么能活两千年。
- 第三章：造成论的家谱，以及它始终的弱势出在哪里。
- 第四章：这道题不是学院内务——它决定四个领域里的四件实事。
- 第五章：一个被广泛当作解决的误判。
- 第六章：本书要判什么、不判什么。

本编不给出任何论证上的进展。它做的是把题目摆清楚，包括摆清楚它为什么两千年来没被摆清楚过。真正的诊断在第二编，那里给出三道闸；出路在第四编与第五编；判据在第六编。

有一句话要先说在这里，它是全书的脊梁，在第十三章第五节会被正式提出：

两千年判不了这道题，缺的从来不是论据，是一台能把过程重跑的装置；装置到了，题就换了类型。

本编的作用，是让读者在读到那句话时，已经知道“这道题”究竟是哪一道。

第二章 回忆说的骨架为什么活了两千年

一、外衣与骨架

回忆说的形而上学外衣——灵魂前生、理念世界——早就没有人穿了。

而它的骨架一直在用。

骨架是三条：

其一，对象先于知识而存在。其二，方法是中立的通道。其三，知识是逐次逼近的累积。

这三条不必一起出现，也不必被明说。它们更多地以预设的方式存在——不是被主张的东西，是被默认的东西；不是论证的结论，是论证得以进行的背景。

本章逐条检查这三条：各自说什么、各自为什么好用、以及各自在本案上处在什么位置。

二、第一条：对象先于知识而存在

这一条是三条里最核心的，另外两条都依赖它。

它说什么：被知道的那个东西，作为一个可被重认的对象，在它被知道之前就已经在那里。

它为什么好用：它给探究提供了一个目标。有了目标，“对”与“错”就有了意义——对就是与那个对象相符，错就是不符。整个真之符合论建立在这一条上。

它在两千年里的各种外衣：亚里士多德的潜能与实现；经院哲学的“事物与理智的符合”；近代经验论的“自然之书”——世界是一本已经写好的书，我们的任务是读它；乃至二十世纪的科学实在论。

外衣换过无数次，骨架没换。

它在本案上的位置：这一条就是先在论本身。本案要判的正是它。

三、第二条：方法是中立的通道

它说什么：方法影响你走得快不快、稳不稳、远不远，但不影响你到达的那个东西是什么。

它为什么好用：它使方法论成为一门可以独立发展的学问。若方法会改变结果本身，那么“哪种方法更好”这个问题就无从问起——因为两种方法得到的不是同一个东西的不同精度，而是不同的东西。

这一条比第一条更少被明说，也更少被质疑。它几乎是“方法”这个词的一部分：一把尺子若会改变被量的长度，我们不会叫它尺子。

它在本案上的位置：这一条是本案的直接靶心。第四十九章那两个函数式—— $R = \Phi(C, A, L)$ 对 $R = \Phi(C, A, L, P)$ ——就是这一条的形式化。“方法中立”翻译过来，就是“P”可以被消去”。

要写明它的一个弱化版本，因为那是多数人实际持有的立场：方法不中立，它会影响结果，但那些影响原则上可以被更多的努力、更好的方法、更长的时间抹平。

这个弱化版本仍然在先在论一侧，而且它正是第五十二章所定义的计算性路径依赖。本书要判的，是它与构成性路径依赖之间的那条线。

四、第三条：知识是逐次逼近的累积

它说什么：后来的知识包含先前的知识，或者至少在同一个方向上更接近。历史是单向的，尽管可能有曲折。

它为什么好用：它使科学史成为一个可以讲述的故事，也使“进步”这个词有意义。

它在二十世纪受到的挑战最大——范式转换、不可通约、科学革命中的损失，这些工作把“累积”这一条动摇得相当厉害。

但要注意一件事：动摇累积，并不动摇前两条。一个主张科学史有断裂、有损失、有不可通约的人，完全可以仍然认为那些不同时期的理论各自在接近某个先在的东西——只是接近的方式不同、路线不同、有时走错。

因此第三条是三条里最松的一条，它的松动不构成对先在论的威胁。这件事值得单独指出，因为二十世纪有大量工作被认为是对先在论的打击，而它们实际上只打到了第三条。第三章第五节会把这一点说得更细。

五、为什么这副骨架能活两千年

三条讲完，问一个更要紧的问题：这副骨架凭什么活了两千年？

本书给三个理由，它们的分量依次递增。

理由一：它与日常语言重合。

“发现”这个词的日常含义里，已经包含了“那个东西本来就在”。我们说发现一座岛、发现一个错误、发现他在撒谎——每一次都预设了被发现者的先在。

一个与日常语言重合的立场，不需要被论证就能被接受；而它的对手每次都要先解释自己不是在说胡话。

理由二：它与实践的自我理解重合。

研究者在工作时，几乎必然把自己理解为在找某个东西。这不是一个哲学立场，是一个工作状态——你要去找，你就得把它当作在那里。

一个与实践的自我理解重合的立场，会被实践本身不断地再生产。

理由三，也是最重的一条：它从未被任何观察反驳过，因为它从未被任何观察触及过。

这正是第一章第六节那句话的后果，也是第二编第七章那道闸：两种读法对一切可观察的东西给出相同的预期。

一个不会被观察反驳的立场，在时间上有巨大的优势——它不需要赢，它只需要不输，而不被触及就等于不输。

六、这副骨架今天最硬的形态

要公道地看待这副骨架，必须承认它今天有比两千年前强得多的形态。

第八编处理了四件在役武器：表征收敛、彩票假说、线性模式连通、缩放律。它们不是叙事，是可复现的实验。

这件事对本章的意义是：先在论不再只靠日常语言与实践自我理解活着，它有了经验材料。

而这对本书是好消息而不是坏消息。一个有经验材料对手，是一个可以被判决的对手——它可以赢，也可以输。第六十七章第三节那条“不许把对手写弱”的纪律，其根源就在这里。

七、骨架的第四条：它从不被单独提出

三条骨架之外，还有一条，它从不被单独提出，因为它藏在“对象”这个词里。

第四条：那个先在的对象，是这一个。

不是“有某种结构在那里”，而是“有这一个东西在那里，而我们找到的就是它”。

为什么这一条要被单独指出来？

因为它承担了一件另外三条承担不了的工作：它使“同一个发现”这句话有意义。

若只主张“有某种结构在那里”，那么两条路径各自达到的两个结果，可以都是那个结构的实现，而彼此不同。这在先在论内部是完全可以接受的——但它已经离造成论很近了，因为它承认路径决定了到达的是哪一个实现。

而日常的先在论主张的是更强的东西：两条路径到达的是同一个。第八章那一类多重发现的证据，其全部力量都建立在这第四条上；而第八章第三节指出，“同一个”这个判定往往是事后作出的。

第四条在本书里的对应物是什么？

是第四十八章那个可达集是不是一个点的问题，以及第七十一章那条变换群的界线。“是不是这一个”，翻译过来就是“可达集的元素在所允许的变换群下是不是同一个等价类”。

把这一条挑明，有一个实际的用处：它使先在论内部的两个版本分开。

- 强版本：可达集是一个点（或一个等价类）。
- 弱版本：可达集不是一个点，但它的全部元素由 C、A、L 决定，路径只在其中选。

弱版本就是第四十九章第五节那个“第三种可能”——路径是选择器。它仍在先在论一侧，而它比强版本容易守得多。

本书要判的主要是弱版本，因为强版本几乎没有人今天还坚持。而条款二，正是为弱版本准备的。

八、三条骨架各自的现代形态

三条骨架今天仍在用，而它们的现代形态与两千年前的表述差得很远。把对应关系列出来，因为后面几编处理的正是这些现代形态。

骨架	古典表述	现代形态	本书在哪里处理
一·对象先在	理念、实在、自然之书	损失景观的极小点集合先定；中奖彩票在初始化时就在	第七十五、七十六章；第七十章
二·方法中立	方法是通道	路径差异随规模衰减；表征在趋同	第五十四章；第六十八章
三·知识累积	逐次逼近	缩放律：更多算力给出更好的模型	第七十二章

这张表有两处值得说明。

其一，第一条的现代形态最具体。古典表述里“对象在那里”无法被指认；而彩票假说指认了一个可以被取出、被单独训练的对象（第七十章第二节）。这是先在论两千年来第一次给出地址，也是第七十六章那一整章“向它要一个地址”之所以可能的前提。

其二，第三条的现代形态最不相干。缩放律是关于损失的规律，而损失是判准的投影，因此它对本案不构成证据（第七十二章）。三条骨架里，第三条在古典时期就最松，到了现代形态上更是落在本案之外。

由此得到一条对读者的提示：本书真正要判的，是第二条的现代形态；而第一条的现代形态是第二条的哲学后盾。第三条可以不必管。

九、这一章留下的问题

三条骨架，第三条已经松动，第一条与第二条仍然立着。

本案要判的是第二条——方法是不是中立的通道——因为它是第一条在经验层面的可测形式。

而判它需要什么？需要能改变方法而保持别的不变，并看结果是否跟着变。这是第十三章那条干预主义判据的要求，而那一章会指出：这件事在人类知识史上一条也做不到。

下一章先看另一条线——那条试图否认第二条的线，以及它两千年来为什么始终处在弱势。

第三章 另一条线：造成论的家谱与它始终的弱势

一、名字并不冷僻

造成论这条线上的名字并不冷僻：

维柯的“真理即制作”；康德的哥白尼转向；黑格尔的概念自我展开；皮亚杰的发生认识论；库恩的范式内构成；哈金的“现象的制造”；强纲领；皮克林的实践冲撞。

这不是一份边缘名单。其中几个人在各自的领域里是无法绕开的。

而这条线始终没有取得与先在论同等的地位——它从未成为默认立场，从未进入日常语言，从未被实践的自我理解所再生产。

本章要问的是为什么。而本书的回答不是“因为它错了”，也不是“因为学界保守”。回答有三条，分别在第四、五、六节。

二、维柯：第一次正面的造成论

维柯的“真理即制作”是这条线上第一个正面的、非派生的主张。

它说的是：我们能真正认识的，是我们自己做出来的东西。数学之所以可被确知，因为它的对象是人造的；历史之所以可被理解，因为历史是人做的。而自然之所以难以被完全认识，因为它不是我们做的。

这一步的力量在于它把“做”与“知”连了起来，而且连得很具体——不是说知识是主观的，是说被做出来的东西才可被彻底知道。

而它的局限也在这里：它把这个原则的适用范围限制在人造物上，于是自然科学的知识仍然留在先在论那一侧。

这个局限决定了这条线后来的走法：要让造成论成为一个关于知识一般的主张，必须把“做”的范围扩大——扩大到包括我们对自然的认识。而把它扩大，正是康德做的事。

三、从康德到实践冲撞：三次扩大

这条线此后的发展，可以读成三次扩大。

第一次·康德：把“做”从人造物扩大到经验一般。对象要符合我们的认识形式；经验对象是在这些形式中被构成的。

这是这条线上最有力的一步，第十一章用整章处理它。

第二次·十九与二十世纪前期的经验化：把构成装置从先验层面拉到可经验研究的层面。黑格尔的历史化是一个方向，皮亚杰的发生认识论是另一个方向——后者不满足于哲学声明，而是去看儿童如何一步步构造出守恒与可逆运算。

第三次·二十世纪下半叶的实践化：把构成装置进一步拉到具体的实验室、具体的仪器、具体的共同体。库恩、哈金、强纲领、皮克林各自的工作，使“构成”不再是一套普遍的形式，而是一组历史的、地方的、可变的安排。

三次扩大的方向是一致的：让构成装置越来越具体、越来越可变、越来越接近可被研究的东西。

而这个方向是对的——第十一章第六节会论证，它是造成论走出普遍性自伤的唯一途径。

四、弱势之一：它必须论证，对手不必

第一条弱势出在举证责任上。

先在论与日常语言重合、与实践的自我理解重合（第二章第五节），因而它是默认立场。默认立场不需要论证，它只需要不被推翻。

造成论每一次出场都要先解释自己不是在说胡话——不是在说知识任意，不是在说真理由多数决定，不是在说科学只是一种信仰。

这个解释的成本是真实的：它占掉了论证的很大一部分篇幅，而且它必须在每一次出场时重做一遍。

本书也在付这笔成本：第七十九章整章、第八十一章那六条不主张，做的正是这件事。

五、弱势之二：它的胜利常常只打到第三条骨架

第二条弱势更隐蔽，而且它解释了一个长期令人困惑的现象。

二十世纪下半叶，造成论一侧取得了大量看起来重大的胜利——范式转换、不可通约、实验室研究、科学争论的社会学分析。这些工作改变了整整一代人对科学的理解。

而先在论没有因此退却。

原因在第二章第四节写过：那些工作主要打到的是第三条骨架（知识是逐次逼近的累积），而第一条与第二条不受影响。

一个主张科学史有断裂、有损失、有不可通约的人，完全可以仍然认为那些不同时期的理论各自在接近某个先在的东西——只是接近的路线不同，有时走错。

于是出现了一个奇特的局面：造成论一侧觉得自己赢了很多次，先在论一侧觉得自己从未被真正触及，而两边都没说错。

这一节是本章最要紧的一节，因为它指出了那些胜利为什么不累积成一次判决。

六、弱势之三：它拿不出极限

第三条弱势是技术性的，也是最致命的。

造成论一侧的全部实证工作，其形式都是案例：这一次，在这些条件下，路径如何塑造了结果。

而案例这种证据形式有一个天花板——第五十三章整章论证它：

一段只发生过一次的过程，不含有区分“你还没走到”与“那里没有那个东西”所需要的信息。

于是面对任何一个精彩的案例，先在论只需要说一句：“换一条路径最终也会走到那里，只是更慢或更绕。”而案例无法回答这句话。

这条弱势解释了一件长期令人困惑的事：这条线交出了大量精彩的个案，而对手一步也没有退。原因不在个案的质量上——一个案这种证据形式本身就不含那个区分，第五十三章会把这一点论证完。

三条弱势的性质各不相同：第一条是修辞环境的，第二条是打击点错位的，第三条是证据形式的。只有第三条可以靠换现场解决，而那正是本书要做的事。

七、一条必须替这条线说的话

本章列了三条弱势。写完之后必须补一句，否则这一章会被读成对造成论的清算。

这条线做成了一件先在论从未做成的事：它使“过程”成为一个可以被研究的对象。

在这条线出现之前，知识形成的过程不是一个研究对象——它是“发现的语境”，是心理学的残渣，是可以略去的人事噪音（第五章）。是造成论一侧的工作，把仪器、记法、共同体、实验室的日常、争论的收束方式，一件件变成了可以被认真研究的东西。

没有这批工作，本书连自己要测什么都说不出来。

具体到本书：

- “路径”这个概念本身，是这条线的产物。先在论不需要这个概念，因为它在那里路径只影响快慢。
- 第五十二章那个承重区分，其两侧都来自这条线的经验材料——库恩的范式、皮克林的冲撞，都是在展示路径如何塑造结果，而本书要做的只是把“塑造”分成两种。
- 第五编那个可达集，是“不同的路径可能到达不同的地方”这个念头的形式化，而那个念头是这条线的。

因此本章三条弱势的正确读法是：它们说的是这条线为什么没能判决，不是它为什么没有贡献。

而这两件事的区别，正是本书全书的主题。第五十三章那一章的标题是“案例的天花板”，而那一章的第一节叫“先把话说公道”——它用整节写库恩、皮克林、强纲领做对了什么，然后才说它们缺什么。

本节是那一节在第一编的预告，并且要把话说到底：一个证据形式不足以判决，与一批工作没有价值，是两件完全不同的事。把前者说成后者，是本书要避免的第二种不公平——第一种是把对手写弱（第六十七章第三节），第二种是把同侧的前人写成失败者。

八、这条线与本书的关系，一句写清

本章的三条弱势与第七节那句公道话，合起来给出本书与这条线的准确关系，值得单独写一句，免得读者把本书归错位置。

本书在结论上站在这条线一侧，在证据要求上站在它的对面。

站在一侧：本书主张的核心命题就是造成论的一个受限版本。

站在对面：本书拒绝这条线迄今为止的全部证据形式。案例不算（第五十三章）；欠规定性那批材料只能作理由不能作读数（第七十四章第八节）；实验演化的外推不用（第四十二章第四节）。

这个双重位置有一个代价，写明：本书在两边都不讨好。

对先在论一侧，本书是对手。对造成论一侧，本书把他们最引以为傲的材料一件件判为不足。

而这个位置是必需的，理由在第三节那三次扩大里：这条线的方向一直是对的——让构成装置越来越具体、越来越可变、越来越接近可被研究的东西。本书做的只是把这个方向再推一步：推到可被测量。

推到可被测量，就要接受测量的纪律；而那套纪律会判掉这条线此前的大部分证据。这不是背叛，是同一个方向走到下一站所必须付的过路费。

九、这条线今天的处境

最后说一句今天的处境，因为它与三十年前不同。

造成论一侧今天有了一批实证材料：欠规定性、多种子基准、次序效应（第七十四章）。这些材料不是案例，它们是在可重跑系统上做的测量。

而它们被当作工程缺陷提出，而不是被当作本体论证据。

第七十四章第八节论证过这件事的机制：造材料的人问的是“这会不会给我添麻烦”，而本案问的是“这会不会消失”；后一个问题从未被提上日程，不是因为它难，而是因为没有人需要它的答案。

于是这条线今天的处境可以写成一句：

它第一次有了不是案例的材料，而那批材料的正确读法还没有人去要。

本书要做的，就是去要那个读法。下一章先说明为什么值得去要——这道题不是学院内务。

第四章 这道题不是学院内务

一、一个必须回答的问题

读到这里，一个合理的反应是：就算这道题两千年没判，那又怎样？

科学照常做，技术照常有效，教育照常进行。一个从未被判决、而世界照常运转的问题，看起来正是那种可以留给专业哲学家的问题。

本章要回答这个反应。

回答的方式不是论证这道题“深刻”，而是指出四个具体的地方：在那里，人们每天都在按某一侧的答案行事，而那个答案从未被检验过。

四个地方是：教育、科学史、法律、人工智能研究。

二、教育把什么当作学习

先在论下的教育有一个理所当然的做法：把结果当作评估对象。

学生是否掌握了那个本来就在那里的东西——掌握了多少，掌握得多牢，能不能在新题上用出来。

这个做法的全部合理性依赖于一个前提：存在一个“那个东西”，而所有学会了的人学到的是同一个。

若造成论成立，这个前提要加限定：学生所到达的东西的规定本身依赖于他走过的路，于是两个分数相同的学生可能持有结构上不同的知识。

而现行评估在设计上看不见这一差别——它测的是结果在判准上的投影，而投影正是被设计来压平差异的。

这不是一个遥远的推论。它有一条可立刻执行的检验：同一门课程、同一批材料、不同的学习次序，测分布外迁移上的系统差异而不是总分。第八十三章给出这条检验的完整设计与它的四处困难。

本节要指出的只有一点：这件事每天在发生，按其中一侧的答案在做，而那一侧从未被检验过。

三、科学史把什么当作进步

科学史有一个标准的说明模式，通行到常常不被察觉：

科学史 = 逐步逼近真相的过程 + 可以略去的人事噪音。

在这个模式里，真正有说明力的是那条逼近的主线；而某位教授碰巧读了哪本书、某个学科碰巧先发展了哪种仪器、某个国家的资助结构碰巧偏向哪一类问题，这些是叙事花边。

若造成论成立，这些东西就不再是花边，而是规定的一部分。

而这个转变不是“历史变得更重要”这样一句含糊的话。它的精确形式是：说明一个结论为什么是这样而不是那样，必须包含它是从哪条路上的；不包含这一项的说明是不完整的，而不只是不详细。

第八十二章处理这一栏，并给出反事实科学史从消遣变成方法所需要的四样东西。

四、法律把什么当作发现

专利制度里有一条很老的界线：自然规律不可专利，技术方案可专利。

理由是直白的：自然规律本来就在那里，发现它不构成创造；技术方案是被做出来的，做的人可以主张权利。

这条界线的全部重量，压在本案待判的那一句上：有些东西本来就在那里，有些东西是被做出来的。

这不是一个类比，它就是同一句话。先在论与造成论之争，若有一个地方已经被写进了制度，就是这里。

第八十五章处理这一栏，并指出一件更要紧的事：归属判断所需要的“常规组合与非显而易见”之间的界线，与第七十八章那条“激活与形成”的界线是同一条——而本书在那一章承认自己给不出这条界线。

五、人工智能研究把什么当作目标

这一栏最直接，却最少被提。

这一栏的隐含目标是：存在一个由数据与目标共同定死的最好答案，而工程的任务是想办法更快、更稳、更省地走到它跟前。数据加大、规模加大、优化器改进，三件事都朝这一个方向。

“那个”两个字是关键。

在这条路线里，路径被当作工程噪音。三件常规做法都以抹平路径为方向：种子要固定以便复现；次序要打乱以便无偏；课程要设计以便加速。

若构成性路径依赖为真，这个方向在原则上就是错的，而不只是不够好。

第八十四章给出三条具体的改法（多样性是资产不是方差；路径是设计对象不是噪音；评估要增设“到达的是哪一种”那一栏），以及三条各自的成本，以及一件更深的事——判准的设定不仅决定了什么算好的结果，还决定了什么问题会被提出来。

六、四栏的共同结构

把四栏并排，会看出它们有同一个形状：

领域	按哪一侧行事	看不见什么
教育	先在论	同分而结构不同
科学史	先在论	路径进入说明
法律	先在论	界线的地基未定
人工智能	先在论	路径是资产还是噪音

四栏全部按先在论行事，而且都不是因为先在论被证实了。

它们这样做，是因为第二章第五节那三条理由：它与日常语言重合、与实践的自我理解重合、且从未被任何观察触及因而从未被反驳。

一个从未被检验的答案被四个领域当作操作前提，这件事本身就是这道题不是学院内务的证明。

七、为什么四栏都倒向同一侧

四栏全部按先在论行事，这件事本身值得解释一句，因为它不是四次独立的巧合。

解释有三层，由浅入深。

第一层：默认立场的惯性。第二章第五节那三条理由——与日常语言重合、与实践自我理解重合、从未被观察触及——在四个领域里同样成立。一个不需要被论证就能被接受的前提，会在任何一个需要前提的地方被采用。

第二层：操作上的便利。按先在论行事，可以只测结果；按造成论行事，要测结果加上到达结果的那条路。后者的成本高出一个量级。

一个更便宜的前提，在实践中会胜出，而不论它是否为真。

这一层有一个直接的后果：即使本案判给造成论，四栏也不会立刻改——因为改的成本是真实的，而第八十三章与第八十四章各自列出的那些困难与成本，不会因为一个哲学判决而消失。

第三层，最深的一层：判准的设定决定了什么问题会被提出来。

这是第七十四章第八节与第八十四章第五节那条观察。在教育里，评估测总分，于是“两个同分的人是否持有结构不同的知识”这个问题不会被提上日程；在人工智能里，基准测性能，于是“到达的是哪一种”那一栏是空的。

不是被否定，是被漏过。

三层合起来给出一个不舒服的推论，写在这里：

四栏倒向同一侧这件事，本身不是先在论为真的证据，甚至不是人们相信它的证据——它主要是“按它行事更便宜、且不按它行事的问题没人提出”的证据。

这个推论对两侧都不客气：它既说明不能拿四栏的现状为先在论作证，也说明不能拿四栏的现状为造成论鸣不平。它说明的只是一件事：这四栏都建立在一个从未被检验的前提上，而检验它的成本至今没有人愿意付。

本书付的，是这笔成本的第一个零头。

八、四栏之外的一栏：日常生活

四栏都是建制性的领域。还有一栏不属于任何建制，却可能是这道题最常被实际使用的地方。

那就是日常语言里的“发现”。

我们说发现一个错误、发现他在撒谎、发现自己其实不喜欢这份工作。每一次，这个词都预设了被发现者的先在——那个错误本来就在那里，只是没被看见。

而这些说法里，有多少经得住本案的追问？

“发现自己其实不喜欢这份工作”——那个不喜欢，是在意识到它之前就已经在那里，还是在反复的思量、比较、与人交谈中被造成的？两种读法对这个人此后的行为不给出不同预测，这正是第六节那道闸的日常版本。

本书不打算处理日常语言，也不主张它用错了。提这一栏只有一个用处：

说明先在论不是一个学派的立场，它是一种默认的说话方式；而默认的说话方式最不可能被检验。

这与第二章第五节那条理由一是同一件事，但放在这里更实在：一个人可以完全不知道有这道哲学题，却每天几十次地按其中一侧的答案说话。

而这一栏与前四栏的区别在于：本书不建议改变它。日常语言不需要为一个未判的哲学问题负责；而教育、科学史、法律、人工智能研究这四栏不同——它们是在用一个未检验的前提做出有后果的决定。

九、一个必须先挡住的误读

本章最容易引出的误读是：既然后果这么重，那么判决应当倾向于后果更好的那一侧。

本书拒绝这个推理，而且拒绝得很硬。

第八十一章第五条写明：本书不主张路径依赖是好事。若判决倒向造成论，它的后果里有相当一部分是坏消息——依赖分数的选拔与认证会遇到结构性的麻烦；不可复现性变成结构性的而非工程性的；科学史上的一些结论失去“迟早会被发现”这层保险。

本章列出四栏，不是为了说明某一侧的答案更可取，是为了说明这道题值得被判。

一个值得被判的问题，与一个答案更可取的问题，是两件事。把后者当成前者，正是本书全书在反对的那种做法。

下一章处理一个被广泛当作已经解决的误判。

第五章 一个被当作解决的误判

一、那个切分

有人会说，这个问题早就被处理掉了。

处理的方式是一个切分：发现的语境与辩护的语境。

赖辛巴赫与后来的逻辑经验论者把两件事切开：

- 知识如何被想到——某人在什么情境下、受什么启发、经过什么曲折，想出了某个念头。这是心理学与历史学的事。
- 知识凭什么成立——那个念头有什么证据支持、能不能被检验、与别的已知命题是什么关系。这是逻辑的事。

而认识论只管后者。

按这个切分，本书前四章所讨论的东西——路径、次序、条件、来路——全部落在前一个语境里，因而与“知识是什么”无关。那么本案就不是一个认识论问题，它是一个关于知识社会学的问题，而且是一个已经被安置好的问题。

二、这个切分为什么如此有效

要指出它是误判，必须先承认它为什么这么好用。

用处一：它保护了一件该被保护的东西。

一个念头的来源确实不决定它的对错。一个在梦里想到的化学结构，可以是对的；一个经过严密推理得到的结论，可以是错的。把“怎么想到的”与“凭什么成立”分开，挡住了一大批真正的谬误——诉诸出身、诉诸动机、以人废言。

这一条本书完全接受，而且认为它是二十世纪认识论的一项真实成就。

用处二：它使认识论可以成为一门独立的学问。

若每一个知识主张的评价都要牵涉它的全部历史，认识论就无法与历史学分开，也就无法有自己的方法。

用处三：它与实践的分工吻合。评审一篇论文的人不需要知道作者是怎么想到的。

三条加起来，这个切分是一件有用的工具，而且用得很好。

三、误判在哪里

误判不在这个切分本身，在于用它来宣布本案不存在。

那一步是这样的：既然来路只属于发现的语境，而认识论只管辩护的语境，那么“来路是否进入知识的规定”这个问题就不必问。

而这一步的前提，正是待判的那一条。

把前提写出来：

被辩护的那个内容，其身份不依赖于它是怎么来的。

这句话就是先在论。它不是这个切分的结论，是这个切分成立所需要的条件。

若造成论成立，这个前提就不成立——来路进入了内容的规定本身，于是“被辩护的那个内容”在不同的来路下不是同一个内容，切分就切错了地方。

用一个预设了结论的切分去宣布问题不存在，是把悬案改判为免审。

四、这不是一个技术性的挑刺

上一节的论证看起来像是一个逻辑上的细节。本节说明它不是。

一个切分所依赖的前提，决定了切分的位置。

若内容的身份不依赖来路，那么把来路切出去不损失任何东西——一切在那里是对的。

若内容的身份部分地依赖来路，那么切出去的那一部分里，有一部分属于内容本身。此时切分仍然可以做，但它切下来的不是“心理学的残渣”，是内容的一个成分。

两种情形下，同一个切分做的是完全不同的事。而判断它在做哪一件，需要先知道本案的答案。

因此这个切分不是解决，它是一次记账方式的选择——而且是一次把争议项直接记入某一方账下的选择。

五、这个切分本身可以被翻译

本书对这个切分的态度不是拒绝，是把它也翻译成可测的形式。

用第四十九章那两个函数式来写：

- 切分成立的条件： $R = \Phi(C, A, L)$ 。内容由材料、装置、判准决定，路径不进入，因而可以被切出去。
- 切分不成立的条件： $R = \Phi(C, A, L, P)$ 且 P 不可消去。路径进入内容，因而切出去的那一部分含有内容的成分。

于是这个切分的正当性，与本案是同一个问题。

这一点有一个实际的后果：若条款一或条款二判负，这个切分获得一个它此前从未有过的支持——一个在可控系统中的实验支持，而不只是一个方法论上的约定。

第八十六章第三节写过这件事：若判决倒向先在论，被建立的东西比本书想建立的更重要。这个切分的正当性，正是那批“更重要的东西”之一。

因此本书与这个切分的关系不是对立：本书要的是让它从一个被默认的约定，变成一个被检验过的结论。

六、还有两个类似的免审

这种“用一个预设了结论的区分来宣布问题不存在”的做法，在本案上出现过不止一次。再举两个，因为识别出这个模式比记住这一个例子更有用。

其一：把它划给“心理学”。说路径如何影响思考是心理学的事，与知识的内容无关。这与本章处理的那个切分是同一个形状，只是换了一个学科名字。

其二：把它划给“实用问题”。说不同路径得到的东西在实际使用中没有差别，因而差别不重要。这一条更隐蔽，因为它听起来像是经验观察。

而它同样预设了结论：它用“在现行判准下测不出差别”来论证“没有差别”，而那正是第五十章第一处陷阱——用判准的投影当结果。第七编第六十三章那批分组读数说明了这个做法会漏掉什么：种子差异在训练分布上被压得很平，在分布外探针上大得多。

三个免审的共同结构是：

先划一条线，把争议项划到线外，然后说线外的东西与本问题无关；而那条线划在哪里，恰恰依赖于本问题的答案。

七、一个反问：本书自己是不是也在做同样的事

本章指控了一种做法：用一个预设了结论的区分，宣布问题不存在。

那么本书自己有没有做同样的事？

这个反问必须被正面答，因为本书确实划了不少线。

本书划过的线至少有三条。

线一：第四十五章把“理解、意识、智能”划出讨论范围。

这条线是不是一次免审？本书认为不是，理由是它的方向相反：免审的做法是把争议项划出去，而本书划出去的是本书不需要的东西。第四十五章第二节论证过，不使用这三个词使论证变强而不是变弱——因为反例结构不需要它们。

但要承认一处：若有人主张那三个词恰恰是本案的核心，那么本书这条线就是一次免审。本书对此的回答在第四十五章第五节，而那一节的结论是这笔账未结。

线二：第四十二章把实验演化排除在外。

理由是它的对象不是知识。这条线更危险，因为它是本书为了保护自己的合法性而划的——第四十二章第六节明写：本书拒绝实验演化的外推与本书自己的合法性，靠的是同一条线。

线三：第五十五章那四条硬规定。

它们把一批做法排除在判据之外。这一条本书认为最稳，因为四条全部是排除“会自动出某个结论”的做法，而且其中两条（不得用分数、必须消去对称性）排除的恰恰是对本书有利的那类做法。

三条线合起来，给出一个判别办法，它比逐条辩解有用：

一条线是不是免审，看它排除的东西对划线者有利还是不利。

按这个标准：线三是安全的（排除了对己有利的做法）；线一处在中间（排除了对己无用也无害的东西）；线二有风险（排除了一个对己有利但会连累自己的案例）。

本书把这三条摆出来，不是为了证明自己清白，是为了让别人能用同一把尺子量本书。第五章第七节那个要求——一个区分若其正当性依赖于本案的答案，就不得被用作宣布本案不存在的理由——首先适用于本书自己。

八、为什么这个误判值得用一整章

一个被广泛接受的切分被指出预设了结论，这件事在哲学讨论里并不罕见。为什么本书要用一整章？

理由是：这个切分是本案至今未被认真处理的主要原因。

一个问题要被研究，首先要被承认是一个问题。而这个切分做的事情，恰恰是把本案从认识论的议程上取消——它不说本案的答案是什么，它说本案不属于这里。

取消议程比给出错误答案更有效，也更难被发现。

一个错误答案会引来反驳，反驳会引来讨论，讨论会把问题保留下来。而一次议程上的取消不引来任何东西——它使问题静悄悄地不再被问。

这与第四章第七节、第七十四章第八节所说的那个机制是同一个：判准的设定决定了什么问题会被提出来。区别在于，那里说的是学科的实践关切造成的漏过，这里说的是一次明确的、被写进教科书的切分。

后者更强，因为它有理据。一个因为没人关心而被漏过的问题，任何时候都可能被重新捡起；而一个被一条广为接受的区分正式安置过的问题，重新捡起它要先推翻那条区分。

本书用一整章推它，而推的方式很有限：本书不主张这条切分无效，只主张它的正当性与本案是同一个问题，因而在本案被判之前，它不得被用作宣布本案不存在的理由（第七节）。

这个要求低到几乎不可拒绝——而它足以把本案重新放回议程上。本书要的就是这个。

九、本书要求的是什么

本章不要求废除任何一个区分。

本书要求的只有一件事：一个区分若其正当性依赖于本案的答案，那么在本案被判之前，它不得被用作宣布本案不存在的理由。

这是一个很低的要求，而且它对两侧对称——若判决倒向造成论，造成论一侧也不得反过来用它去宣布这些区分全部作废。第七十九章第四节那条“可比较性不需要唯一性”就是在防这一手。

下一章把本书要判什么、不判什么一次写清。

第六章 本书要判什么、不判什么

一、全书的那一句

全书有一句脊梁，在第十三章第五节被正式提出，这里先摆出来：

两千年判不了这道题，缺的从来不是论据，是一台能把过程重跑的装置；装置到了，题就换了类型。

这句话有三个可被推翻的爪。把它们与各编的对应关系写清，本书的结构就清楚了。

爪一·不可判有结构性原因，不是“哲学问题天生如此”。原因是产物层观察等价，加上过程层不可干预。由第二编支撑。

爪二·造成论历来普遍性自伤——把构成装置设为普遍必然，就与先在论给出相同预测，自我取消可判性。康德、皮亚杰、乔姆斯基、进化心理学、结构主义同犯。由第二编第十一、十二章支撑。

爪三·判决的条件已经到位而判决尚未做出。本书交出判据、量、判负条件与首跑读数，不交出结论。由第四编至第七编支撑。

三爪各自可被推翻的方式也要写明：爪一被推翻，若有人指出产物层其实留下了不同痕迹；爪二被推翻，若有人指出那五例中有哪一例并未自伤；爪三被推翻，若有人指出四条性质并未同时满足，或翻译不忠实（第五十一章第七节）。

二、本书要判的那一件事

正面主张一句，一字不改地写在这里：

在大规模语言模型的训练中，存在构成性路径依赖——即存在结果层面的差异，它由路径单独引起，并且不随规模、算力与数据量的增加而衰减为零；因而不存在只以语料、架构与判准为自变量的函数能够唯一地决定所到达的结果。

它的否定同样清楚：

一切被观察到的路径差异都是计算性的，随规模衰减，可被对称性消去或被统一描述归结。

若否定成立，本书判负，先在论在这个现场取胜。

三、本书交出的与不交出的

交出的：

- 一个承重区分：计算性路径依赖与构成性路径依赖（第六编第五十二章）。
- 三条条款、四个量（第六编，附一）。
- 六条败绩条件（第五十八章四条，第五十五章与第七十一章各补一条）。
- 一份预注册与它的冻结值，以及全部脚本与原始读数（第七编，附三、附四）。
- 一次首跑，结论是“未能分辨”。
- 一份修订清单，六条（第六十六章）。

- 一记接不住的反击（第七十八章）。

不交出的：结论。

四、本书不主张的六件事

完整版在第八十一章，这里列标题，以免读者在前十章里走错方向：

1. 不主张大模型拥有知识、理解或认识主体性。
2. 不主张人类知识与模型训练是同一类过程。
3. 不主张数学是发明而非发现。
4. 不主张已经完成判决，也不主张首跑判出了任何东西。
5. 不主张路径依赖是好事。
6. 不主张先在论是愚蠢的立场。

第四条在本编要特别强调一次，因为本书有读数，而有读数的书最容易被读成有结论的书。

首跑的结论是“未能分辨”。它不记在四条败绩条件中的任何一条名下——它不是一次败绩，也不是一次通过，更不是一次部分胜利。尤其不主张的是：表征通道那一列不向零衰减构成对条款一的支持。

五、本书的现场，以及它的边界

现场是大模型训练。选它的理由全部是工程性的——可重跑、可干预、可消融、可观测（第四编），加上产物具有知识主张的形式。

理由不在于它“像人脑”。本书完全不需要这个类比，而且明确拒绝它（第四十五章）。

论证结构是反例式而非类比式（第五十一章）。要削弱“任何以材料为输入、以判准为约束的知识形成过程，其结果由材料与判准唯一决定”这条全称命题，不需要类比，只需要一个落在其范围内的实例。

边界三条，逐条写明：

- 它不证明人类知识是被造成的。
- 它确实取消了“知识必然由材料唯一决定”这一原则的先天地地位，把它从公理降为待证的经验假设。
- 它确实为造成论提供了此前从未有过的东西：一个可重跑的实例。

第二条是本书的主要收获，而且它即使在最弱的读法下也是真实的。

六、全书的读法

十编的分工：

编	内容	它回答什么
一	悬案的形状	题目是什么
二	三道闸	为什么判不了
三	两千年的谱系	每个人各缺哪台装置
四	实验台	为什么是这台装置
五	翻译	命题怎么变成可测的
六	三条条款	怎么判
七	首跑	实际跑出了什么
八	对手	对方的武器，以及它赢 件
九	反击与边界	本书接得住什么、接不 么
十	后果与更长的观察	两侧各自的后果

若只读三章，本书建议读第五十二章（承重区分）、第六十四章（为什么”未能分辨”是一个结论）、第七十八章（本书接不住的那一记）。

这三章分别对应本书最想立的、最想守的、最想承认的。

七、本书可能错在哪里

一本书若只写自己主张什么，读者无从判断该在哪里用力检查。本节把本书自认为最可能出错的五处列出来，并注明各自的位置。

其一，翻译可能不忠实。最可能的失败形态是：“产物具有知识主张的形式”这条线站不住。若翻译被判为不忠实，本书的全部读数作废，而不是被重新解释（第五十一章第七节）。

其二，标号与实质的界线可能划错。本书把界线划在”严格保持函数不变”那一层，而这是一个约定。若有人指出一类此前未被消去的对称性，且消去之后条款一的读数落入噪声，条款一判负（第七十一章第六节）。

其三，两通道的不一致可能不是世界的事。首跑那个”未能分辨”，目前无法与”两把尺子量了不同的东西”区分开（第八十章第六节）。这是本书对第七编的一处主动下修。

其四，判据可能事前就写错了。首跑已经发生过一次：噪声基线跨规模不可比，而那是冻结项第二条（第六十五章）。预注册保护的是“事后不许改判据”，它不保护“事前把判据写错”。

其五，那一记接不住的可能是决定性的。第七十八章承认本书给不出“激活与形成”的界限，而第七十八章第七节指出：这一记正好绕开了本书换现场的全部三个理由——它不需要重跑、不需要缩放、不需要出示地址。

五处里，前四处是可修的，第五处不是。

前四处各自有明确的修法：翻译可以被重做，界线可以被重划，尺子可以被增加，判据可以被修订（第六十六章那份清单里有三条就是在修它们）。

第五处没有修法，只有一个方向：需要一个非平凡的、可操作的、对两侧同样适用的界限，而本书不知道它长什么样。

把这五处写在第一编，是有意的。一个读者若从头读起，在读到第六编那些条款之前，就应当知道这本书最薄的地方在哪里——否则他会把力气花在那些本书已经守得很牢的地方。

八、这本书写给谁

最后一节说明读者对象，因为本书的写法对不同的读者有不同的门槛。

写给三类人。

第一类关心这道哲学题的人。他们会发现本书的哲学部分（第一、二、三、九编）是为一个具体的判决服务的，而不是独立的思辨。对他们的提醒是：本书的结论比他们期待的弱得多（第五节那三条边界）。

第二类做机器学习的人。他们会发现本书用他们熟悉的材料在问一个陌生的问题。对他们的提醒是：本书不使用“理解”“意识”“智能”这三个词（第四十五章），因此那些关于模型懂不懂的争论在本书里不出现；而本书对读数的要求（比值、基线、双通道、事先冻结）比通行实践严，第八十章第七节说明那套要求对两侧同等有效。

第三类做实验方法学的人。对他们，本书最有用的部分可能不是结论，是第五十九章、第六十五章与附三——一次真实的预注册，它在执行中被自己证伪了一项冻结条款，而那个过程被完整记录下来。

三类读者共用一条提醒，它也是本书最后一句话的预告：

本书没有把这道题判掉。它把这道题变成了一道可以输的题，并且已经输过一次判读的机会——那一次什么也没判出来，而本书知道为什么。

下一节写本书自己的来路，然后第一编结束。

九、最后一件事：本书自己也有来路

本书所依赖的那台装置，它自己也是被造出来的——被一条特定的技术路径、特定的产业结构、特定的资助方式造出来（第四十六章）。

若判决倒向造成论，那么这个判决本身也在它所主张的范围之内：它是从这条路径上得到的判决。

这不是一个自我瓦解的悖论，而是本案的一个可预期的特征。任何把自身包含在内的主张都要接受这一层。

本书对此的处理不是回避，而是把它写进判据——判负条件事先写死、读数公开、预注册在接触数据之前完成。

一句话，它是本书全部方法学的根：

一个承认自身有来路的立场，靠程序而不是靠超然来维持可信。

十、第一编到此结束

把本编六章交出的东西清点一次。

第一章：悖论的精确形式，两个答法的命名，以及两种读法对一切可观察的东西不给出不同预测这一起点。

第二章：回忆说的三条骨架（对象先在、方法中立、知识累积），它们各自的现代形态，以及它们活了两千年的三理由。

第三章：造成论的家谱、三次扩大、三条弱势，以及本书与这条线的双重位置——结论同侧，证据要求对立。

第四章：四栏加一栏，它们全部按一个从未被检验的前提行事；以及为什么这不构成任何一侧的证据。

第五章：一次被广泛接受的免审，以及本书自己划过的三条线该用什么尺子去量。

第六章：本书要判什么、不判什么、可能错在哪里、写给谁。

本编没有给出任何论证上的进展，这是设计。它做的是把题目摆清楚，包括摆清楚它为什么两千年来没被摆清楚过。

而摆清楚之后，下一步就是诊断：为什么判不了？答案不是“哲学问题本来就判不了”这种敷衍。判不了有三个具体的原因，它们是三道关着的闸门。

下一编逐道打开它们看。

第二编 为什么判不了：三道闸

上一编写了悬案的形状。本编回答一个更靠前的问题：为什么没分出胜负？本书的回答是：有三道具体的闸门关着，而它们不是并列的三个困难，是递进的。

闸一·观察等价（第七至十章）说明为什么看产物看不出来，并逐一处理三类被反复援引的证据——多重发现、独立可重复性、技术的成功。三类的错位各不相同，因此补上其中一处，另外两处仍在。

闸二·普遍性自伤（第十一、十二章）说明为什么连造成论自己都没能把分歧拉到可看的位置上。这道闸不是外部的限制，是造成论自己关上的。

闸三·干预不可施加（第十三章）说明要把它拉到那个位置需要什么——四条性质，而人类知识史一条也给不出。

第十三章第七节把那四条定成一份检验清单，第四编全部的工作就是拿它去卡候选。

一、这一编要做的事

第一编写了悬案的形状：一个问题，两个答法，两千年没分出胜负。

本编要回答的是另一个问题，而且它比“谁对”更靠前：

为什么没分出胜负？

通行的回答有两种，本书都不采纳。

第一种回答：因为这是一个哲学问题，而哲学问题本来就没有答案。这个回答什么也没说——它把“没分出胜负”当成了原因，而那正是要被解释的东西。

第二种回答：因为论证还不够好，或者材料还不够多。这个回答是可检查的，而检查的结果是它不成立：两千年里，论证一直在变好，材料一直在变多，而分歧的位置一步没动。

本书的回答是：有三道具体的闸门关着。

- 阐一·观察等价：产物层不留下不同痕迹。本章与第八至十章处理。
- 阐二·普遍性自伤：造成论历来用自己的方式取消自己的可判性。第十一、十二章处理。
- 阐三·干预不可施加：判决所需的干预，在知识的形成过程上从来无法施加。第十三章处理。

三道闸不是并列的三个困难，它们是递进的：阐一说明为什么看产物看不出来；阐二说明为什么连造成论自己都没能把分歧拉到可看的位置上；阐三说明要把它拉到那个位置需要什么，而那样东西两千年里不存在。

第三编的二十六章，就是按“缺哪台装置”把谱系重排一遍；而“哪台装置”这个提法的依据，全部在本编。

二、观察等价是什么

两个理论若对一切可观察结果给出相同预测，就没有任何观察能在它们之间做判决。

这是欠决定性论题的标准形态。而先在论与造成论的关系，比通常的欠决定性还要糟一层：

它们甚至不是两个关于同一现象的竞争理论，而是关于同一批事实的两种叙事语法。

这个区别值得说清楚，因为它决定了这道闸有多难开。

通常的欠决定性，说的是两个理论在现有证据下无法区分，但它们在原则上可能有不同的经验后果——只是那些后果暂时测不到。这种情形有出路：等技术进步，或者找一个更巧的实验。

叙事语法层面的等价没有这条出路。两种语法不是对同一批事实作出不同预测，它们是把同一批事实用不同的方式复述。复述之间不存在“哪个预测对了”的问题，因为它们预测的是同一件事。

三、互译的无损性

上一节是抽象的说法。把它落到实处，办法是做一次翻译，然后检查有没有东西丢失。

考察任何一件成熟知识的实际历史。哈维与血液循环；门捷列夫与周期律；沃森、克里克与双螺旋。

每一件都可以被换一种句式写出来：在那一套解剖手法、那一套计量习惯、那一批衍射照片与当时通行的建模约定之下，一组可以被反复认出的规定被做成了，并且稳住了。

改写之后，没有任何一个经验命题被否认。所有的实验、所有的数据、所有的后续应用，原封不动。

反过来同样成立。任何一份造成论的案例研究，也可以被改写回先在论：那些条件与路径不过是接近的手段，被接近的东西本来就在那里，手段的偶然性不污染被接近者的必然性。

两个方向的翻译都是无损的。

这种无损性不是偶然，它有一个结构上的原因：

所有可供检查的东西都是产物，而过程已经消失了。

留在我们手上的是论文、数据、仪器、后续技术——每一样都是已经稳住之后的东西。这两个起源假设在逻辑上确实不同；而落到这些已稳住的东西上，它们不留下可以分开的痕迹。

四、石雕

一个日常的例子可以把这件事说得比任何抽象论证都清楚。

一块已经成形的石雕。

一种说法是：雕刻者释放了石头里本就沉睡的形体。这不是外人替他说的，米开朗基罗自己就这样说过。

另一种说法是：那个形体是凿子的路径造出来的——不同的凿法会得到不同的形体，而这一个是一条路径的产物。

看着石雕本身，这两句话无法被分开。

要注意这个例子在哪里恰好贴合，又在哪里不贴合，因为不写清楚它就会被用过头。

贴合之处：产物是唯一可检查的东西，而产物对两种起源假设是中立的。这一点完全贴合。

不贴合之处有两处，都要写明。

其一，石雕的情形其实可以被判——只要你有许多块同样的石头，让同一个雕刻者或不同的雕刻者各凿一次，看得到的形体是不是同一个。这恰恰说明问题不在于“看产物”这个动作本身，而在于只有一件产物。

其二，石头与形体的关系，与语料和知识的关系并不相同。石头的物理性质对形体的约束是局部的；语料对知识的约束是什么性质，正是本案要判的。

第一处不贴合尤其重要：它把闸一的真正内容点了出来——不是产物不含信息，而是只有一件产物时产物不含分辨力。这一点在第十三章会成为闸三的引子，在第四编会成为换现场的理由。

五、这道闸的一个更精确的形式

上面的论证够用了，但它有一个更精确的形式，值得单独写，因为后面几章要用到它。

先在论与造成论不是两个理论，它们是两个起源假设。

一个理论对现象作出预测，因此可以被现象检验。一个起源假设说的是某物从何而来，而它对那物此后的行为可以完全不作预测。

举一个最干净的例子：一块石头，它是从山上滚下来的，还是被人搬下来的？这两个假设对石头此刻的一切物理性质——重量、形状、成分、温度——给出完全相同的预期。要区分它们，必须找别的东西：山坡上的痕迹、搬运的工具、目击者。

而在本案里，那些“别的东西”就是过程；而过程已经消失了。

这个形式化有三个用处，逐条写出来，因为它们各自在后面被用到。

用处一：它解释了为什么积累证据没用。一个起源假设与另一个起源假设，若对产物的一切性质给出相同预期，那么再多的产物性质也区分不了它们。这与“证据不够”完全不同——证据不够可以靠积累解决，方向不对不能。第八至十章那三类证据，全部是关于产物性质的，因此全部落在这个诊断下。

用处二：它指出了唯一可能的出路。既然起源假设只能靠过程的痕迹区分，那么出路只有一条：让过程留下痕迹。而过程之所以不留痕迹，不是因为它没有痕迹，是因为它只发生一次且没有被记录。于是问题从“找更好的证据”变成了“造一个会留下记录的过程”——这正是第四编那台装置的全部意义。

用处三：它给出了本案与别的欠决定性问题的分界。通常的欠决定性说的是两个理论在现有证据下无法区分；那类问题可以靠更巧的实验解决，因为两个理论在原则上有不同的经验后果。起源假设的等价不是这一类，它在产物层上是原则性的，不是暂时的。因此指望“某一天出现一个巧妙的实验设计”是没有根据的——除非那个设计触及过程本身。

这一节也给出了本书对自己的一个限制：若本书的实验台最终也只能提供产物层的观察，那么它与两千年来的处境没有区别。第四十四章那四条工程性质里，最要紧的一条就是可观测——中间状态被保存，而不只是最终产物。没有那一条，换现场换了个寂寞。

六、一个反问：这道闸是不是被夸大了

本章的论证若成立，两千年的僵局有了一个干净的解释。干净的解释总是可疑的，因此本节自问一次。

反问是：真的什么痕迹都没有吗？过程虽然消失了，但它留下了大量二阶痕迹——手稿、通信、草稿、实验记录、被放弃的路线。这些不正是过程的残留？

这个反问有力，本书的回答是有限度的。

那些材料确实是过程的残留，而且它们极有价值——科学史上最好的工作大量依赖它们。本书不打算把它们说成无用。

但它们在本案上的分辨力，受两件事限制。

第一件：它们是被保存下来的那一部分。被丢弃的草稿、没写下来的念头、说出口而没有记录的讨论，全部缺失。而路径大量地由这些东西构成。一份有偏的抽样可以告诉我们很多事，唯独不能可靠地告诉我们“没被记下来的那些是否重要”。

第二件，更硬：即使记录完整，它仍然只是一次。一份完整的过程记录能告诉我们这一次是怎么走的，不能告诉我们换一条路会怎样。而两种起源假设的分歧，恰恰落在后一个问题上。

把这两件合起来，得到本章诊断的精确边界：

这道闸的成因不是“过程不留痕迹”，而是“过程只发生一次”。

这个修正很重要，它改变了出路的方向。若成因是不留痕迹，出路就是更好的档案工作；而若成因是只发生一次，那么再好的档案也没有用，出路只能是让过程发生第二次。

第四编那台装置之所以是出路，不在于它记录得更细，而在于它可以重跑。记录得细是第四条性质，可重跑是第一条；而第一条才是这道闸的解药。

七、三类被反复援引的证据

有三类证据常被拿来说明这道闸其实是开着的。接下来三章逐一处理，这里先把它们的共同点写出来。

- 多重发现：同一件东西被不同的人独立做出来。（第八章）
- 独立可重复性：一个结果能被不同实验室重复出来。（第九章）
- 技术的成功：飞机会飞，疫苗有效，芯片能算。（第十章）

三类证据的共同点是：它们都很强，而且都不在这道闸的方向上。

“很强”是真的——它们各自都是科学实在论手上有分量的材料，本书不打算把任何一条说成软弱。

“不在这道闸的方向上”是本书要论证的：它们所证明的东西，与本案所争的东西不是同一件。三章各自要指出那个错位在哪里。

由此得到一个说法，它是本编的第一个结论：

这三类不是弱证据，是零分辨力的证据。

弱证据与零分辨力证据的区别不是程度。弱证据可以靠积累变强——多做几次、多几个实验室、多几个案例。零分辨力证据积累一万次仍然是零，因为它的问题不在数量上，在方向上。

这个区别本身，是本编要立的第一块东西。它在第五十三章还会以另一种形式出现：那里说的是案例这种证据形式的天花板，而本章说的是天花板的第一个来源。

第八章 三类零分辨力证据之一：多重发现

一、这一类证据的形式

牛顿与莱布尼茨的微积分。达尔文与华莱士的自然选择。贝尔与格雷在同一天递交的电话专利申请。孟德尔定律在一九〇〇年被三个人各自重新做出来。

同一件东西被不同的人在互不知情的情况下几乎同时做出来——这不是强有力地说明它本来就在那里吗？

这一类证据的直觉力量很大，值得先把它说足。

若一件东西是被特定的人、特定的路径造出来的，那么另一个人走另一条路，凭什么会造出同一件？几个人独立地走到同一处，最自然的解释就是那一处本来就在，而他们各自从不同方向抵达了它。

这个论证在形式上很干净，而且它有大量的历史实例。默顿的工作系统地整理过这类案例，并指出多重发现在科学史上不是例外，而是常态。

本章要说明的是：它证明的不是“那一处本来就在”，而是另一件事。

二、第一层回答：趋同的路径造出趋同的产物

多重发现说明的第一件事是：当时的条件与路径在相关共同体中高度趋同。

同样的数学工具、同样的读物、同样的产业压力、同样的实验技术、同样一批悬而未决的问题。

两个人在这样的条件下各自工作，得到相似的结果，这件事有两种解释：

- 解释一：趋同的路径接近了同一个先在者。
- 解释二：趋同的路径造出了趋同的产物。

两种解释在观察上不可分辨。这就是第七章那道闸的又一次显形——多重发现是一批产物，而产物对起源假设中立。

要让这一类证据有分辨力，需要的是它的反面：条件与路径不趋同的情况下，结果是否仍然趋同。而这恰恰是多重发现案例所不能提供的——它们之所以被记录下来、之所以被认为值得注意，前提正是那些人处在同一个共同体、同一个时代、同一批工具之中。

这一层回答有它的限度，必须写明。有人可以反驳说：有些多重发现跨越了相当不同的传统，条件并不那么趋同。这个反驳是有效的，而且本书认为它值得被认真对待——若能找到条件差异极大而结果仍然趋同的案例，这一类证据的分量会显著上升。

本书的立场是：这类案例值得被系统地找出来并按条件差异排序。第八十二章第五节把它列为一项可以现在就开始、不需要等判决、对两侧同等可能不利的工作。

三、第二层回答：被判为“同一个发现”是事后的归类

上一层是关于解释的。这一层更麻烦，它关于证据本身是怎么被构造出来的。

多重发现要成立，必须先判定两件事是“同一个发现”。而这个判定不是当时做出的。

牛顿的流数与莱布尼茨的微分，在概念语法上的差别大到让十八世纪整整一代人为之争吵。争的不只是优先权，也包括哪一套记法与哪一套概念是对的。它们被算成“同一件事”，是后来的事——是在两套记法都被翻译成第三套语言、并且其中一套因为形式上更顺手而胜出之后的事。

第五十三章讲过这个案例，那里用它说明计算性路径依赖的样子；这里用它说明另一件事：

判定“同一个”所用的那把尺子，是被后来造出来的。

而那把尺子造出来的方式，正是造成论所说的那种方式——在特定的条件下、特定的路径上、被特定的共同体接受下来。

于是这一类证据有一个结构上的麻烦：

判据本身是被造出来的，这就使它不能拿来当判据。

这不是一句巧辩。它的精确形式是：要用多重发现来证明“结果与路径无关”，必须先一把尺子判定两个结果是同一个；而若那把尺子本身是路径的产物，那么“结果相同”这个观察就已经包含了待判的那一条。

四、孟德尔那一例更清楚

一九〇〇年，三位研究者各自重新做出了孟德尔的工作。这是多重发现里最常被引用的案例之一，而它恰好把上一节的问题摆得最清楚。

三人所“再发现”的，是否真的就是孟德尔在一八六五年写下的那个东西？

这件事在史学上是有争议的。有研究指出，一九〇〇年的框架与一八六五年的框架并不完全重合——“再发现”这个词本身带有事后整理的痕迹，它把后来被认为重要的部分挑出来，把不重合的部分归为表述差异。

而这个争议判不了。判它需要的是：把一九〇〇年那三条路径各自重跑一遍，看它们究竟到了哪里。而那做不到。

这一例的价值在于它让人看见：多重发现这类证据的强度，取决于“同一个”这个判定有多硬；而那个判定的硬度，恰恰是无法独立检验的。

五、这一类证据真正有分辨力的那个版本

前面几节都是否定。本节写一个肯定：多重发现这一类材料，在什么条件下会真的有分辨力。

条件有两个，都苛刻，但都不是不可能。

条件一：两方的条件差异必须可测量，且必须大。

第二节说多重发现的标准案例里条件高度趋同。那么反过来：若能找到条件差异极大而结果仍然趋同的案例，这一类证据的分量会显著上升。

“条件差异可测量”这一点是关键。不能只凭印象说“这两个传统很不一样”，必须能指出具体的差异项——可得的工具、可读的文献、所受的训练、所在共同体的接受标准——并且能说明在哪些项上不同、不同多少。

条件二：“同一个”的判定必须不依赖后来的整理。

第三节指出这一类证据最大的毛病是判据被造出来了。要避开它，需要一个当时就可用的判定：两方的结论是否对同一批情形作出相同的预期，而这批情形是当时双方都能检验的。

满足这两个条件的案例，本书认为存在，只是从未被系统地找过。

而把它们找出来，正是第八章末尾那项编目工作的目的。这项工作的产出应当是一张按条件差异排序的表：条件差异越大而结果仍越一致的那些案例，排在越前面。

这张表对两侧都有杀伤力，这正是它值得做的原因。

若表的前端密集——大量条件差异极大的案例仍然给出高度一致的结果——那么先在论得到一份此前没有的正面材料，而且是一份能扛住第二节那个反驳的材料。

若表的前端空着——所有一致的案例都集中在条件相近的那一端——那么多重发现作为先在论证据的地位就要重估，而且重估的依据不是哲学论证，是一张表。

这项工作不需要等本案的判决，不需要新技术，也不依赖本书的任何主张。本书把它列出来但不做——它需要科学史的专门能力，本书没有。第八十二章第五节把它记为本书所提的三项可执行工作之一。

六、一个不对称：多重失败从不被记录

这一类证据还有一个结构性的毛病，它与前面几节说的都不同，而且它对两侧的伤害不对等。

多重发现被记录，多重失败不被记录。

几个人独立地做出同一件事，这件事会被注意到、被写下来、被当作一个值得解释的现象。而几个人独立地在同一个问题上走上不同的路、其中若干条后来被放弃——这不构成一个“现象”，它只是常态，不会被单独记录。

于是我们手上的这批材料，是被一个筛选程序挑出来的，而那个筛选程序恰好只保留支持先在论的那一类。

这一点要说准，因为它容易被读得太重。

它不说明多重发现是假的。被记录下来的那些案例是真的，趋同也是真的。

它说明的是：我们无法从这批材料估计“独立工作的人走到同一处”的比例。而本案需要的恰恰是这个比例——若大多数独立工作都走到同一处，先在论得到一份强材料；若只有少数走到，而正是那少数被记录为多重发现，那么这批材料的证据力就完全不同。

要修正这个不对称，需要的是一个分母。

具体说：在某个时期、某个领域里，有多少组人在同一个问题上独立工作？其中多少组得到了后来被判为“同一个”的结果？剩下的那些，各自走到了哪里？

这个分母在原则上是可以估计的——有些领域的申请记录、资助记录、会议记录保存得相当完整。而它至今没有被系统地估过，理由与第七十四章第八节那个观察同源：没有人需要这个分母，因为没有人问这个问题。

这是本章第五节那张表之外的第二项可做工作，而且它比第一项更便宜——它不需要判定“同一个”，只需要数有多少组人在做同一件事。

七、这一类证据的正确位置

本章不主张多重发现是假的，也不主张它不重要。它是真的，而且它对某些问题有很强的证据力。

它能证明的：在相近的条件下，不同的人会得到相近的结果。这一点几乎没有争议，而且它对于理解科学共同体如何运作极有价值。

它不能证明的：那个相近的结果先于任何一条路径而存在。

两句话的差别，就是第七章那道闸的宽度。

还要补一句对本书不利的：本章的全部论证只说明多重发现不能判这道题，它没有说明多重发现指向造成论。若有人据此认为本章是在为造成论加分，那是误读——一个零分辨力的证据对两侧同等无效，它不为任何一侧加分。

这句话在本编三章里都适用，写在这里一次，后两章不再重复。

最后指出一条可做的工作，它是本章唯一具体的产出：

把每一组多重发现，按“当时两方的差别”重新编目——各自能做什么预测、各自认为什么算证据、各自的版本在后来被保留了多少、被丢弃了多少。

这项工作不需要任何新技术，只需要档案与耐心。它的产出在两个方向上都有用：若差别系统地很小，先在论得到一份新的正面材料；若差别系统地不小、只是被后来的整理抹平了，那么多重发现作为先在论证据的地位就要重估。

这是本书在本编里唯一提出的可执行工作，它不依赖本书的任何主张。

第九章 之二：独立可重复性

一、这一类证据的形式

一个结果能被不同的实验室、不同的仪器、不同的国家重复出来。

这难道不说明它独立于任何一条特定路径吗？

这一类证据比上一类更硬，理由有两条。

其一，它不依赖“同一个发现”这种事后的归类——可重复性是当下就能检验的，不需要等一百年。

其二，它是科学实践自己设的门槛。一个不能被重复的结果，在实践中根本不被接受。也就是说，这一类证据不是事后拿来辩论用的，它内建在这个行业的运作里。

本章要说明的是：可重复性所证明的那件事，恰好把待判的那一部分排除在外了。

二、可重复性证明的是什么

把它的内容写准：

可重复性证明的是：在现行共同体所承认的操作等价类内部，结果稳定。

“操作等价类”这个说法需要解释。做一次重复实验，不可能把原实验的每一个细节都复制——仪器不是同一台，试剂不是同一批，操作者不是同一个人，室温不一样，时间不一样。

因此每一次“重复”，实际上都是在说：这些差异可以忽略。

而“哪些差异可以忽略”，就是操作等价类的边界。

现在把这个边界与本案对上：

这个等价类的边界——什么算“同样的实验”，什么算“可以忽略的差异”——正是造成论说被造出来的那一部分。

于是可重复性的论证有一个循环的形状：它证明“在被认为无关的差异范围内，结果稳定”，而争的恰恰是那个范围是怎么被定下来的。

三、这不是一个思辨的问题

上一节读起来像是一个哲学上的挑刺。它不是。这个边界在实践中被认真追问过，而追问的结果是有材料的。

复制危机的文献在这一点上提供了大量实例：当边界被认真追问——当有人真的去检查那些被认为可以忽略的差异——大量曾被当作路径无关的结果，表现出对操作细节的敏感依赖。

一批结果在原实验室稳定，换一个实验室就不稳定；换一个试剂批次就不稳定；换一套分析流程就不稳定。

这些材料应当被怎么读？

这是本章最需要小心的一处，因为它同时诱惑两侧。

造成论一侧的诱惑是把它读成胜利：看，结果依赖于操作路径。

先在论一侧的诱惑是把它读成技术问题：那些不稳定的结果本来就不够好，稳下来的那些才是真的。

两种读法都成立，而这正是问题。复制危机的材料既不判先在论有罪，也不判造成论有罪。它们只是再一次显示：分不开。

这一点与第七十四章那批欠规定性材料的处境完全相同——那里说的是模型，这里说的是实验室，而结构是同一个：差异被观察到了，但“它是否会随努力消失”这个问题没有被问，也没有办法在那个现场被问。

四、“重复”与“复制”：两种含义要分开

处理这一类证据时，有一个术语上的区别常被略过，而它对本案很要紧。

含义一直接重复：用尽可能接近原实验的条件再做一次，看是否得到同样的结果。这测的是原结果是不是偶然。

含义二·概念复制：用不同的方法、不同的材料、不同的测量方式去检验同一个结论，看是否仍然成立。这测的是原结论是不是只在那一套具体做法下成立。

两者所提供的证据不同，而在本案里它们的位置也不同。

直接重复完全落在第二节那个循环里：它按定义在等价类内部做，因而测不到等价类边界的问题。

概念复制看起来能跳出去——它正是在换一条路径。若一个结论能被完全不同的路径到达，这不就是路径无关的证据吗？

这是本章要处理的最有力的一个版本，而它仍然不成立，理由有二。

理由一：概念复制成功时，“同一个结论”的判定回到了第八章第三节那个问题上。用不同方法得到的两个结果，要被算作“同一个结论”，需要一把尺子；而那把尺子是共同体给的。两条路径得到的东西在多大程度上真的相同、在多大程度上是被一个共同的描述框架抹平的，这件事本身无法在那个框架内部检验。

理由二，更硬：概念复制失败时，它不被报告。当一个结论在概念复制中不成立，通行的处理不是“路径影响了结果”，而是“其中一次做错了”，或者“两者其实测的不是同一个东西”。两种处理都合理，而且多数时候是对的。但其后果是：概念复制的成功率，不是一个可以被读出来的量。

一个只在成功时被记录的检验，不提供关于失败率的信息；而本案恰恰需要那个失败率。

这一节留下一项可做的工作，与第八章那项同类：系统地记录概念复制的失败，并区分“做错了”与“测的不是同一个东西”这两类处理各占多少。这项工作本书同样不做，理由同样是能力所限。但它值得被记下来——在这三类证据里，它是唯一一个有现成数据来源的。

五、为什么这道闸在这里特别紧

多重发现那一类证据，至少还有一条可能的出路：去找条件差异极大而结果仍然趋同的案例（第八章第二节）。

可重复性这一类没有这条出路，原因在于它的定义。

一次重复实验，按定义就是在被认可的等价类内部做的。若一个人故意在等价类之外做——换一套完全不同的操作、不同的原理、不同的测量方式——那么得到相同结果时，人们会称之为“独立验证”而不是“重复”；而得到不同结果时，人们会说“那不是同一个实验”。

两种情形都不构成本案所需要的对照。

于是这道闸在这里特别紧：可重复性这个概念自身的结构，就保证了它测不到路径效应。它是一个被设计来排除路径效应的程序——这是它的目的，不是它的缺陷。

这句话与第五十五章第一条硬规定是同一个形状：一个被设计来压平差异的量，不能用来测量差异。那一条说的是任务分数，第七十二章说的是缩放律，第八十三章说的是考试成绩。本章是它的第四次出现，而且是最早的一次——它在实验科学的基本程序里就已经在了。

六、这道闸在近年有一个新的实例

复制危机那批材料是这道闸的经典实例。近年还有一个新实例，它出现在一个意外的地方，值得记下来，因为它把这道闸的机制显示得比任何历史案例都清楚。

那就是模型训练本身的可复现性实践。

在这个领域里，“复现一个结果”的标准做法是：固定随机种子、记录超参数、公开代码与数据。做到这些，结果被认为是可复现的。

而固定种子这个动作，恰恰是把路径消掉。

于是这个领域的复现标准，与第二节所说的那个循环是同一个形状：它把“路径不同”划进了“需要被消除的差异”，然后报告说在消除之后结果稳定。

这个实例的价值在于它是当下的、可查的、且机制完全透明。

历史上的等价类边界是怎么被定下来的，我们只能从档案里推测；而这个领域的边界是明文写着的——复现指南里就写着要固定什么。任何人都可以去查看那份清单，看“哪些差异被认为可以忽略”。

它也给出了一个对照：第七十四章那批多种子材料，做的正是不固定种子、看差异有多大。那批工作之所以显得特别，不是因为它测了什么难测的东西，而是因为它做了一件与通行的复现实践方向相反的事。

由此得到本章最实在的一个结论：

一个领域的“可复现”标准，同时也是它关于“什么算路径无关”的一份现成声明；而那份声明从来不是被论证的，是被约定的。

这句话对本案有直接用处：要检查一个领域里“路径无关”这个假定有多硬，最快的办法不是读它的理论文献，是读它的复现指南。

七、要让它有分辨力，需要什么

本章不停在否定上。把“需要什么”写出来，因为那正是本书后面要做的事。

要让重复性这一类观察获得分辨力，需要的不是更多次重复，而是一次结构不同的重复：

- 固定材料与判准。
- 只改变操作路径中的某一项，其余全部对齐。
- 观察结果是否系统地改变。
- 并且能把这件事做很多次，在不同的资源水平上做。

这就是第六编条款一的形状，而它在人类实验室里做不到——理由与第十三章要讲的完全一样：不能只改变一项而其余全部对齐，因为实验室的各项彼此牵连；不能在不同资源水平上重复做，因为没有那个可调的资源轴。

所以这一章的结论与上一章相同，理由不同：

独立可重复性不是弱证据，是零分辨力的证据。它所稳定的东西，正是被定义为与路径无关的那一部分；而它所不能触及的，正是本案所争的那一部分。

下一章处理三类里最有力、也最常被当作终结论证的一类。

第十章 之三：技术的成功

一、这一类证据的形式

飞机会飞。疫苗有效。芯片能算。

这难道不是世界在为先在论作证吗？

这是所谓“不容否认的论证”的日常版本，而且它是三类里最有力的一类——不是在逻辑上最有力，是在说服力上最有力。它几乎不需要论证就能被接受：如果我们关于世界的知识不是关于世界本身的，那些东西凭什么能用？

本章必须先承认它的分量，而且承认得彻底。

这个论证不是外行的直觉。它是科学实在论最主要的支柱之一，被仔细地表述过、辩护过、修正过。它的核心是一个关于说明的要求：若理论的成功不能由“它大体上是对的”来说明，那么这个成功就成了一件无法说明的巧合，而且是一件规模巨大、反复出现的巧合。

要回应它，不能靠说它不重要。

二、造成论从不主张知识是任意的

回应从一个澄清开始，而这个澄清本身就化解了这一记的大半力量。

造成论从不主张知识是任意的。

它主张的是：知识是在约束下被造成的。

而约束的强硬，正好解释了为什么造出来的东西能用。

把这一点说透：一架飞机能飞，说明设计它所依据的那套理解与材料世界的约束对得上——空气的行为、材料的强度、燃烧的效率，每一样都在那里，每一样都不容商量。造成论完全承认这些约束的实在性；它甚至比通常的说法更强调约束，因为它的全部论证都建立在“固定材料、固定判准”这个前提上（第七十九章第三节）。

于是这一记的力量落在哪里，就清楚了：

可用性是对约束的实在性的证明，不是对被造物的先在性的证明。

把两者混为一谈，是这场争论里最常见的一次偷换。

三、把偷换的位置指准

上一节那句话容易被当作一句口号。把它拆成三步，看清偷换发生在哪一步。

第一步（成立）：某套理解在实践中有效。

第二步（成立）：因此它与世界的某些约束对得上。

第三步（偷换）：因此它所描述的那个东西，先于这套理解而存在，并且这套理解是唯一对得上的那一个。

从第二步到第三步，加进了两样第二步里没有的东西：先在性与唯一性。

关于唯一性：有效不蕴含唯一。两套不同的理解可以都与同一批约束对得上，并且各自在自己的适用范围内有效。第七十九章第四节用演化中的不同飞行方案说明过这件事——不同的骨骼结构、不同的翼面，各自都能飞，各自都受同一套空气动力学约束，而它们不是同一个解。

关于先在性：这一步更隐蔽。说“这套理解与约束对得上”，只是说约束在那里；它不说“这套理解本身”在那里。约束是世界的，理解是被做出来的；一个被做出来的东西与一个先在的约束对得上，这件事不需要那个被做出来的东西也是先在的。

石雕的例子在这里再用一次，而且用得比第七章更准：石头的纹理、硬度、承重极限都在那里，不容商量；雕刻者必须顺着它们做，否则石头会裂。这些约束的实在性，丝毫不说明那个形体是先存在的。一个受强约束的制作，仍然是制作。

四、把这一记的最强形式写出来

前两节处理的是这一记的通行版本。它还有一个更严格的版本，必须写出来，否则本章就是在打弱化过的对手。

最强形式是一个关于说明的论证：

若我们关于世界的理解不是大体上真的，那么它所支持的技术为什么能成功？把这种成功归于巧合，需要一个规模巨大、反复出现、涉及无数独立领域的巧合。而拒绝一个能说明现象的假设、转而接受一个无法说明该现象的立场，是不合理的。

这个形式比“飞机会飞”强得多，因为它不诉诸直觉，它诉诸一条方法论原则：能说明的胜过不能说明的。

本书对它的回应分两步，两步都是让步。

第一步让步：本书承认这个论证对“约束实在”是有效的。技术的成功确实需要说明，而最好的说明就是：那些被依赖的约束是真的。本书不与之争。

第二步让步，而且更大：本书承认这个论证对“某些结构被正确把握”也是有效的。不只是约束实在，而且我们关于约束的描述在相当程度上对上了。一架飞机不是靠碰运气飞起来的。

那么本书在哪里不让？

在第三步：从“这套描述对上了”到“这套描述是唯一能对上的、并且它先于被做出来而存在”。

这一步需要的不是说明力，是唯一性。而无奇迹论证不提供唯一性——它论证的是“不可能全是巧合”，它没有论证“只有一种非巧合的可能”。

两个让步加一个不让，可以压成一句：

成功说明了我们没有瞎猜，它没有说明我们猜的那一个是唯一能中的。

还要补一处对本书不利的：有人可以进一步论证，成功的精确程度支持唯一性——若有多条同样有效的路线，我们应当看到它们并存，而实际上多数成熟技术领域高度收敛。

这个反驳有力，而且本书没有现成的回答。本书能说的只有：技术领域的收敛有大量非认识论的原因（标准化、规模经济、路径锁定、监管），要把这些因素与“只有一条路线有效”分开，需要的正是下一节所说的那项工作。本书把这个反驳记为一处未结的账。

五、成功的另一半：失败去哪了

这一节处理一个常被略过的方面，它对这一类证据的强度有实际影响。

“技术的成功”这个说法，采样的是成功的那些。而每一项成功的背后有大量失败的路线：被放弃的设计、被证伪的理论、被抛弃的工艺传统。

这不构成对成功论证的反驳——一个筛选过程留下能用的东西，这正是它该做的。

但它对本案有一层具体的含义：我们看到的技术图景，是一个被判准筛选过的产物集合。而判准筛掉的是“不能用的”，不是“与另一条路径不同的”。两条都能用而彼此不同的路线，在这个筛选下会同时存活；而它们各自的存在，在“技术的成功”这个说法里被合并成了一件事。

要让技术史对本案有分辨力，需要的是：系统地检查那些同时存活的不同路线，看它们的差异是随着技术成熟而收敛，还是稳定地保留下来。

这是一项可做的历史工作，它与第八章第五节那项按条件差异编目多重发现的工作是同一类，而且同样不依赖本书的任何主张。本书把它列出来，但不做——它需要技术史的专门能力，本书没有。

六、为什么这一记在日常场合特别有效

本章处理的是这一记的论证内容。还有一层要处理，它不属于论证，但它决定了这一记在实际讨论中的分量。

这一记在日常场合的有效性，远超它的逻辑强度。

原因不难看出：它诉诸的是一个每个人都有的经验。飞机确实在飞，药确实在起效。任何一个看起来在质疑这件事的立场，都会立刻被归入“不讲道理”那一类。

于是这一记的实际功能，常常不是论证，是划界——它把对手划到常识之外，而一旦被划出去，对手说什么都不再被听。

本书要指出这一点，有两个理由。

理由一，防守性的：本书的立场从不否认技术有效。第二节写过，造成论主张的是知识在约束下被造成，而约束的强硬正好解释了有效性。若有人用这一记来把本书划到常识之外，那是误伤。

理由二，更要紧：一个在讨论中特别有效、而在逻辑上并不更强的论证，值得被特别小心地对待——因为它的有效性会遮住它的漏洞。

第三节指出的那个偷换——从“与约束对得上”到“先在且唯一”——之所以能反复通过，部分原因就在这里：没有人愿意在一个听起来像是否认飞机会飞的位置上停下来细究。

这一节顺带解释了本编三章的排序。多重发现最弱，可重复性次之，技术的成功最后——不是按逻辑强度排，是按在讨论中的分量排。本书把最有说服力的放在最后，正是因为它最需要被仔细拆开，而仔细拆开需要前两章先把“零分辨力”这个概念立住。

七、这一类证据的正确位置

三类证据到此处理完毕。本章的结论与前两章相同，理由是第三种：

技术的成功不是弱证据，是零分辨力的证据。它证明约束是实在的，而本案争的不是约束是否实在，是结果是否唯一被约束决定。

三章合起来，第七章那道闸的宽度就量出来了：

证据	它证明的	本案争的	错位在哪
多重发现	相近条件给出相近结果	结果是否先于路径	条件本身是趋同的
独立可重复性	等价类内部结果稳定	等价类边界怎么定的	边界是被定的
技术的成功	约束是实在的	结果是否唯一被约束决定	实在不蕴含唯一

三处错位不是同一个，这一点值得强调：它们不是同一个错误犯了三次，而是三个独立的证据各自在不同的地方与本案擦肩。这使得“补上其中一处”的希望落空——补上任何一处，另外两处仍在。

本编第一道闸至此说完。它的内容可以压成一句：

只要可供检查的东西只有产物，先在论与造成论就不留下不同的痕迹。

下一章转到第二道闸。那一道更难堪，因为它不是外部的限制，而是造成论自己造成的。

第十一章 闸二·普遍性自伤：康德的先验形式如何与先在论观察等价

一、这一章处理整桩悬案的关节

第一道闸是外部的：产物层不留下不同痕迹，这不是任何一方的过错。

第二道闸不同。它是造成论自己关上的。

历史上分量最重的几次造成论，都用自己的方式取消了自己的可判性。

本书认为这是整桩悬案的关节，而它很少被指出来——原因大概是，指出它需要同时对造成论抱有同情和对可判性抱有要求，而这两样通常不在同一个人身上。

本章处理这道闸最重要的一例，下一章处理它的四次重演。

二、哥白尼转向：造成论最有力的一击

先把康德这一步的分量说足。

在他之前，认识的标准图景是：对象在那里，知识要去符合对象。知识的正确性在于它与对象相合。

康德把这个关系倒过来。对象要符合我们的认识形式。空间与时间不是外在于我们的容器，而是直观的形式；因果、实体这些范畴不是从经验中归纳出来的，而是知性的形式；经验对象是在这些形式中被构成的。

这一步之强，在于它不是关于某个科学门类的主张，而是关于经验一般的主张。它不说“某些知识是被构成的”，它说：凡是能成为我们经验对象的东西，都已经经过了构成。

这是造成论在哲学史上最有力的一击。本书不打算用任何方式削弱它——第三编第二十一章会用两节的篇幅处理康德，本章只取它与可判性相关的那一面。

三、这一步的代价

现在看康德为这一步付出的代价，而这个代价正是这道闸。

他的工程有一个明确的目的：让构成出来的知识具有普遍必然性。这不是附带的愿望，它是整个批判哲学要解决的问题——如果知识是被我们的形式构成的，它凭什么还能是普遍必然的、而不是某个人的主观安排？

回答是：构成装置必须是一切有限理性存在者共同的、不可变更的。

先验形式不因人而异，不因时代而异，不因技术而异。它是使经验成为可能的条件，因此不可能有人在它之外去经验。

这一步保住了普遍必然性，同时关上了可判性的闸门。

理由是直接的：

如果构成装置对所有认识者都是同一套，那么经过它构成出来的对象，在一切经验中就表现得恰如一个先在秩序。

两种说法——“对象是被一套普遍不变的形式构成的”与“对象是先在的秩序”——对任何可能的经验都给出相同的预测。

康德本人当然明白自己在说不同的话。他说的不同落在先验层面：一个说对象的形式来自主体，一个说对象的形式来自对象自身。这是一个真实的、重大的差别。

但那个差别落在先验层面，而先验层面按定义不可经验地分辨。

于是：

普遍必然的构成装置，与先在的对象，是观察等价的。

四、物自体是这一处的结算

有一个著名的地方，可以看作此处等价的结算。

物自体：那个刺激我们感官、而我们永远不能认识的东西。它被宣布为不可知。

这道闸门做的事情，是把“来源”这个问题封起来。

若物自体可知，那么就可以问：我们构成出来的对象，与物自体是什么关系？符合得如何？这个问题一旦可问，两种说法就有了分开的可能——至少在原则上。

物自体不可知，意味着这个问题不可问。于是：

分歧被封住，而不是被解决。

这一节要写得克制，因为对物自体的讨论有一整套复杂的文献，而本书没有资格参与那场讨论。本书只取它与可判性相关的那一面：无论物自体在康德体系内部承担多少别的功能，就本案而言，它的效果是使“构成出来的东西与先在的东西有什么不同”这个问题失去了提问的位置。

五、普遍性自伤

把这一例抽出来，得到一条一般的教训。本书称之为普遍性自伤：

一个造成论，若把它的构成装置或构成路径设定为普遍的、唯一的、必然收敛的，它就与先在论给出相同的经验预测，因而自我取消了被判决的可能。

这个名字里的“自伤”要按字面理解：伤口不是对手造成的，是自己为了另一个目的（普遍必然性）付出的代价。

要写清这条教训不是什么。

它不是说康德错了。普遍必然性是一个正当的、重要的目标，而康德为它给出的方案在哲学上极有力量。本书不评价那个方案的成败。

它不是说造成论不该追求普遍性。一个只适用于某些情形的造成论，其解释力会小得多。

它说的只有一件事：这两样东西之间有一个交换——普遍性越强，可判性越弱。而两千年来，造成论一侧反复选择了前者。

六、康德那一步留给本书的正面遗产

本章前几节写的是代价。但这一步不只有代价，它留下了两样本书直接在用的东西，不写出来对它不公平。

遗产一：把“构成”这件事提到了可讨论的层面。

在哥白尼转向之前，“被知道的东西可能是被构成的”这个念头几乎无法被严肃提出——它听起来像是在说知识是任意的。康德那一步做的第一件事，就是把“构成”与“任意”分开：对象被形式构成，而正因为形式是普遍必然的，被构成的知识才是普遍必然的。

这个分离是本书第七十九章第三节的祖先。那一节论证“路径进入规定不蕴含任意性”，用的是同一个结构——约束极强，而争的只是约束是否唯一决定结果。没有康德那一步，这个论证的位置根本不存在。

遗产二：它指出了构成装置是可以被追问的对象。

一旦承认有一套装置在起作用，“那套装置是什么样的”“它能不能不同”这些问题就有了提问的位置。康德自己把答案钉死为普遍必然，但问题被留了下来，而且后来被一代代人重新打开——先是在经验科学里（第十二章那四例），再是在历史与实践层面（第七节）。

本书的三条条款，本质上就是这个问题的一个可测版本：装置与路径能不能不同，不同到什么程度，差异是否随资源消失。

由此得到一个对本章语气的校正。

前面几节说康德关上了可判性的闸门，这是真的。但要同时说：是他把这扇门装上的。在此之前没有门，因为没有屋子——“构成”这个念头还没有被建成一个可以讨论的立场。

一扇被装上又被锁住的门，与一堵墙，不是一回事。本书要做的是找钥匙，而不是拆墙。

七、这条教训给出的形式条件

这道闸的价值不在诊断，在于它直接给出了判决所需要的形式条件。

要让造成论成为一个可判的主张，它必须承诺某种路径的实质性：

不同的路径要导致不同的结果，而且这种不同不能只是暂时的、
可被更多努力抹平的。

这句话里有两半，两半都是必需的。

前半（不同的路径导致不同的结果）排除了普遍必然的构成装置——若装置对所有人相同，路径就不产生差别。

后半（不同不能只是暂时的）排除了一类更隐蔽的自伤：承认路径造成差异，但主张差异终将被抹平。那仍然是一个收敛到唯一终点的图景，因而仍然与先在论观察等价。

这两半，就是第五十二章那个承重区分的来处：

- 前半对应“路径差异存在”。
- 后半对应“差异不随资源衰减”——即构成性而非计算性。

于是本章与第五十二章接上了：那一章给出的区分不是一个技术上的方便，它是这道闸逼出来的唯一出路。造成论若不做出这个区分，它就只能在两种自伤之间选一种。

八、这条教训在本书里被用了几次

普遍性自伤这条教训，在本书后面被反复用到，而且每一次的对象都不同。把它们列出来，是为了说明这不是一条只在哲学史上有效的观察。

第一次第十二章：用它诊断二十世纪四个经验纲领，发现自伤不随经验化而消失。

第二次第六十八章：用它审视表征收敛假说里的一条选择压力论证。那条论证说，当模型被要求同时做好越来越多的任务时，可行的表征就越来越少，在极限下收缩为一。这是普遍性自伤的镜像——它主张的不是构成装置普

遍，而是判准被加强到极限；两者的共同点是，都让可达集收缩为一点，因而都使路径无从产生差别。

第三次·第七十七章第五节：用它处理“判准不会变”那一记。反方说真实的知识形成里判准在变，因此本书的实例不是反例。那一记的结构与本条教训相反——它指出的是把判准钉死所带来的代价，而不是把装置钉死。两者合起来给出一条更一般的东西：

钉死任何一项（装置、序列、判准），都会使路径的效应消失或无从提问。

第四次·第八十六章第五节：用它读条款二判负的含义。若那个先在的集合真的可以被写出来，那么本书就落在与康德同一个位置上——构成的产物与先在的秩序不可分辨——只不过是经验一侧落进去的。

四次的对象分别是：哲学体系、经验纲领、对手的实证假说、本书自己可能的失败。同一条教训能同时切到这四样，说明它不是一个历史观察，是一条结构性的约束。

而这条约束的正面形式，就是第五十二章那个承重区分：要让路径的效应可被提问，必须同时保证装置可变、判准固定、且差异可被推到极限。三个条件缺一不可，而本编三道闸恰好说明了三个条件各自为什么在历史上没有被同时满足过。

九、二十世纪的转向及其未竟之处

二十世纪下半叶的库恩、哈金、皮克林与强纲领，正是往这个方向走的：他们把构成装置从先验层面拉回历史与实践层面，使之可变。

装置可变了，路径就有了实质性——不同的时代、不同的共同体、不同的仪器传统，构成出来的东西可以不同。这一步是对的，而且它是造成论走出普遍性自伤的唯一途径。

可变了，就可判了吗？

没有。

这里出现了第三道闸门——即便构成装置可变，你仍然无法对它施加干预并观察结果。第十三章处理这一道。

而在那之前，下一章先看这道闸是怎么被反复踩中的：康德不是孤例，同一处自伤在二十世纪至少重演了四次，而且每一次都发生在一个把造成论做得更经验、更具体的纲领里。

第十二章 同一处自伤的四次重演

一、为什么要看四次而不是一次

上一章那条教训，若只在康德一例上成立，可以被解释为一个哲学体系内部的特殊安排。

本章要说明它不是。

同一处自伤在二十世纪至少重演了四次，而且每一次都发生在一个把造成论做得更经验、更具体的纲领里。

最后这半句是要害。若自伤只发生在思辨哲学里，那么经验化就是出路——把构成装置从先验层面拉到经验层面，问题就解决了。而四次重演说明：经验化本身并不解除自伤。只要构成的序列或装置被设定为普遍的，自伤就照常发生，无论它是被思辨得出的还是被田野调查得出的。

四例按与本案的相关度排列，每例三段：它主张什么、它在哪里把普遍性钉死、钉死之后它与先在论有什么经验差别。

二、重演之一：皮亚杰的阶段序列

它主张什么。发生认识论是造成论在经验科学中最认真的一次落地。皮亚杰不满足于哲学声明，而是去看儿童如何一步步构造出客体永久性、守恒、可逆运算。知识在他那里明确是被建构的，不是被接收的。

这一点要说足：他做的是观察、是实验、是对具体儿童在具体任务上的具体反应的记录。这与康德那种从概念出发的论证完全不同。

它在哪里把普遍性钉死。建构的序列被设定为普遍的：感知运动期、前运算期、具体运算期、形式运算期，次第固定，跨文化不变。

跨文化研究后来对速率提出了质疑——不同文化下儿童到达各阶段的年龄不同。但对次序的质疑要弱得多；次序的普遍性在这个纲领里基本被保住了。

钉死之后的经验差别。一旦序列普遍，那个被建构出来的终点结构——守恒、可逆、形式运算——就和“人类理性的自然目标”再次不可分辨。

于是得到一句可以概括这一例的话：

建构论若主张所有正常路径都收敛到同一个终点，它在经验上就是先在论的一个实现机制，而不是它的对手。

“实现机制”这个说法是准确的：在这个图景里，建构不是与发现对立的东西，建构是发现的执行方式——那个终点在那里，而建构是走到它的过程。

三、重演之二：乔姆斯基的普遍语法

它主张什么。语言能力不是从经验中归纳出来的，儿童所接触的语料不足以支持他们最终掌握的那套规则。因此必须假定一套先天的语言能力，它限制了人类语言可能的形式。

这一例在本章里的位置需要先说明，因为它看起来像是先在论而不是造成论。确实如此——普遍语法通常被归入先天论一侧。但它在本章里有它的位置，理由是：它给出的是一台构成装置的最清楚的现代版本。语言经验被这台装置加工成语法知识，而这台装置是普遍的。

它在哪里把普遍性钉死。那套先天能力被设定为物种共有、不因文化与个体而异；可变的只是参数的取值，而参数的集合本身不变。

钉死之后的经验差别。若装置普遍、参数集合固定，那么被习得的语法在可能性上就已经被事先划定。于是“语法知识是在语言经验中被构成的”与“语法知识的可能形式先于任何经验而存在”，在经验上不可分辨——因为后者本来就是前者的前提。

这一例与康德的结构最接近，只是它把先验形式换成了一个被认为是生物学的对象。换了载体，自伤照旧：一个不因经验而异的构成装置，其产物看起来必然像是被发现的。

四、重演之三：进化心理学的通用模块

它主张什么。心智不是一块通用的白板，而是由大量在演化中形成的专用机制构成的；每一个机制针对某一类反复出现的适应问题。

它在哪里把普遍性钉死。这些机制被设定为人类共有——它们是物种在演化史上形成的，因此跨文化不变。文化差异被处理为同一套机制在不同输入下的不同输出。

钉死之后的经验差别。与前两例同构：若加工机制是物种共有的，那么在相同输入下它们产生相同输出；于是“这些认知内容是被机制构成的”与“这些认知内容对应着稳定的实在结构”，给出相同的经验预期。

这一例值得补一句，因为它有一个前两例没有的特点：它把构成装置的普遍性建立在一个可检验的来源上——演化史。这比先验演绎或阶段观察都更结实。

但对可判性而言，来源更结实反而使闸门更紧：一个有演化来源的普遍装置，比一个被假定的普遍装置更难被设想为可变，因而更难让路径产生实质差别。

五、重演之四：结构主义的深层结构

它主张什么。表面上千差万别的文化现象——神话、亲属制度、烹饪、仪式——底下有一套共同的结构，而表面的差异是这套结构在不同材料上的变换。

这是造成论的一个强形态：意义不是事物自带的，它是在结构中的位置所赋予的。

它在哪里把普遍性钉死。那套深层结构被设定为人类心智共有的。不同社会的差异被处理为同一组变换的不同取值。

钉死之后的经验差别。若深层结构共有，那么在任何社会里被造出来的意义体系，都落在同一组变换所生成的范围内。这个范围先于任何具体社会而存在——于是又一次，构成的产物表现得恰如一个先在秩序的不同投影。

六、四次重演的共同形状

把四例并排：

纲领	构成装置	被钉死为普遍的是	结果
皮亚杰	建构活动	阶段序列	终点唯一
乔姆斯基	语言习得装置	装置与参数集合	可能形式被预划
进化心理学	专用认知机制	机制集合（演化来源）	相同输入相同输出
结构主义	结构性变换	深层结构	意义空间被预划

四例的载体各不相同——发展心理学、语言学、演化生物学、人类学。四例的方法各不相同——纵向观察、语言分析、适应论证、跨文化比较。

而它们在本案中的位置完全相同。

这个相同不是巧合。它出自第十一章那条教训的逻辑：只要构成装置或构成序列被设定为普遍的，产物就与先在秩序观察等价。载体和方法不影响这个推论，因为这个推论不依赖装置是什么，只依赖它是不是普遍的。

七、第五次重演？二十世纪下半叶的造成论避开了吗

第十一章第七节说，库恩之后的那一批工作把构成装置从先验层面拉回历史与实践层面，使之可变。

那么它们避开了自伤吗？

本节的回答是：大体避开了，但代价是另一样东西，而那样东西也让它们判不了。

它们确实避开了。范式是历史的，不是先验的；实验室的实践是地方性的，不是普遍的；共同体的裁定标准随时间变化。这些纲领没有把构成装置设定为普遍必然，因此第十一章那条教训不直接适用于它们。

但它们付出了另一种代价：放弃普遍性之后，它们的每一个结论都只覆盖它所研究的那一个案例。

于是它们陷入第五十三章所说的那个天花板：案例可以展示历史路径如何塑造了结果，但无法排除“换一条路径最终也会走到那里，只是更慢或更绕”。

把两种代价并排，本编的诊断就完整了：

	装置普遍	装置可变
与先在论的关系	观察等价	不等价
结论的覆盖面	普遍	逐案
为什么判不了	自伤（阉二）	缺极限（案例天花板）

两条路各走各的死胡同，而死因不同。

这个对照有一个直接的后果，它是本编通向全书的那一句：

造成论要可判，必须同时做到两件此前从未同时做到的事——装置可变，且结论可被推到极限。

装置可变要求路径能造成实质差异；结论可被推到极限要求能在不同资源水平上重复测量。

前一件，二十世纪下半叶已经做到了。后一件，需要一台能把过程重跑且可缩放的装置。

第五十二章那个承重区分，第五十四章那条规模消解检验，全部是为这一句服务的。而本编的价值，就是把“为什么必须是这两件”这个问题回答清楚——不是因为本书偏好实验，是因为别的路都已经被走过并且走死了。

八、为什么会反复踩中

最后问一句：为什么这么多认真的纲领，都在同一处踩中？

本书给一个解释，它是猜测而不是论证，因此明写为猜测。

一个造成论若想被当作科学而不是相对主义，它几乎必须主张某种普遍性。否则它的结论就只适用于它所研究的那一个案例，而不适用于别处——那样的纲领很难被建立起来，也很难被资助、被传授、被延续。

于是压力是系统性的：要成为一门学科，就要有普遍的规律；而对造成论来说，普遍的规律恰好是自伤的形式。

若这个解释成立，它有一个与本案直接相关的推论：自伤不是这些人的疏忽，是一个结构性的代价。而要避免它，不能靠更小心，只能靠换一个能让路径差异被实际测量的现场——在那里，“不同路径导致不同结果”可以作为一个读数被报告，而不必作为一条普遍规律被主张。

这正是第四编换现场的第二个理由。第一个理由是干预不可施加（下一章），第二个理由就在这里：在一个可以报告读数的现场，造成论不必再为了成为学科而把自己钉死在普遍性上。

第十三章 阐三·干预不可施加

一、二十世纪最有成果的一次判据改革

前两道阐说的是为什么判不了。第三道阐不同：它同时说明了要判需要什么，因此它是本编通向第四编的那一道门。

这道门的形状来自二十世纪一次判据改革。

哈金的那一步。在关于实在论的长期争论里，通行的做法是比较理论：哪一个更融贯、更简单、更能说明现象。哈金提出一条朴素而锋利的标准：使我们相信电子实在的，不是任何一个关于电子的理论有多成功，而是我们能用电子去干预别的东西——能拿它当工具去喷、去打、去改变另一件事物。

这一步把判据从“哪个叙事更好”移到了“你能不能动手”。

伍德沃德随后把干预提升为因果概念的核心： X 是 Y 的原因，当且仅当存在对 X 的适当干预会改变 Y 。

这一步的意义在于它给了“原因”一个操作性的定义——不再靠恒常联结、不再靠反事实直觉，而是靠一个可以被执行的动作。

干预主义为什么对本案特别合适？

因为本案的两方在叙事层面已经打了两千年，而第七章证明了叙事层面没有分辨力。干预主义提供的正是叙事之外的东西：不是问哪个说法更好，而是问你它能够改变它，并看着结果跟着变。

二、把这条判据对准本案

现在把干预主义对准我们的问题。

要在先在论与造成论之间做判决，需要对知识的形成路径施加干预，然后看被形成的知识是否随之改变。

具体说，需要做到四件事：

1. 可重跑：同一个形成过程能被从头再跑一次。
2. 可干预：能只改变路径而保持材料与装置不变——这是对照组的定义。
3. 可消融：能删掉过程中的某一部分再跑，看缺了它会怎样。
4. 可观测：过程的中间状态被完整记录，而不只留下最终产物。

四条各有用处，不可互相替代：

- 没有可重跑，就只有一件产物，回到第七章那道闸。
- 没有可干预，就无法把路径的效应与别的因素分开。
- 没有可消融，就无法追问某一部分是否必需。
- 没有可观测，就只能看到起点与终点，看不到中间发生了什么——而中间正是路径所在。

三、把四条对准人类知识史

结论是刺眼的：四条一条也做不到。

可重跑：历史不能倒带。一段知识形成的历史只发生一次。这不是技术困难，是它的性质。

可干预：没有对照组。没有两个在其余一切条件相同、只有探究次序不同的十七世纪欧洲。要构造这样的对照，必须有两个欧洲，而且它们必须在其余一切上相同——这句话连设想都困难，因为“其余一切”包括了那个时代的全部。

可消融：不能删掉一段历史再跑。哈维的血液循环不能删掉盖伦的解剖传统再跑一遍，看它是否还会出现、以什么形式出现。“没有盖伦会怎样”这个问题在科学史上是可以问的，但只能被推测地回答。

可观测：中间状态没有全程记录。留下的只是已经成形的论文与仪器。研究者的手稿、通信、草稿本是极有价值的材料，但它们是抽样，而且是被保存下来的那一部分抽样——被丢弃的、未写下的、说出口而没有记录的，全部缺失。而路径恰恰大量地由这些东西构成。

四条里最要命的是第一条。后三条在原则上还可以想象某种替代（更细的档案、更好的反事实推理），第一条没有替代：一件只发生一次的事，无论被记录得多完整，都不提供第二次。

四、反事实推测为什么不能救场

科学史学家能做的最好工作是反事实推测——“如果当年……会怎样”。

这条路看起来能绕过第一条：既然不能重跑，就推理出重跑的结果。

它不能救场，而且理由是循环。

要推测“换一条路会怎样”，必须先有一套关于“路径如何影响结果”的理解。而那套理解正是本案所争的内容：先在论认为路径不影响结果的规定，因此换一条路仍会到达同一处；造成论认为会不同。

于是任何一次反事实推测，都已经预设了两方中的一方。用它做判据是循环的。

这一点要说得比通常更准，因为它容易被误读为“反事实推测没有价值”。

反事实推测有价值，而且价值不小——它能把一段历史里的关键节点标出来，能显示某些结论在多大程度上依赖某个偶然事件。第八十二章把它列为一条具体的研究纲领，并给出了它成为方法所需的四样东西。

它不能做的只有一件：充当本案的判据。一个工具可以在很多地方有用，而恰好在某一处不能用——本章指出的是这一处。

五、本书对悬案的诊断

三道闸说完，诊断可以用一句话写出：

“知识是被发现的还是被造成的”两千年不可判，不是因为论证不足，而是因为判决这一问题所需的干预，在知识的形成过程上从来无法施加。缺的不是论据，是实验台。

这句话是本书的脊梁。它有三个可被推翻的爪，第一编第六章已经列过，这里只标明它们与本编的对应：

- 不可判有结构性原因——由本编三章（第七、十一、十三章）支撑。
- 造成论历来普遍性自伤——由第十一、十二章支撑。
- 判决的条件已到位而判决尚未做出——由第四编至第七编支撑。

六、这个诊断有一个可检验的推论

诊断若只能解释过去，它就是一个事后的说法。本节指出它的可检验之处。

如果诊断成立，那么一旦出现某种装置，使得知识的形成过程第一次可重跑、可干预、可消融、可观测，这个问题就应当立刻从形而上学掉进实验科学。

注意这句话的形式：它预言的不是“问题会被解决”，而是“问题会改变类型”——不是被更好的论证解决，而是被一台机器改变了它所属的类别。

第八十七章第三节把这条推论推到了它的一般形式，那里的表述是完整的，此处不预支；只指出它的方向——不可判若来自过程不可重跑，那么解药就不在论证这一侧。

本编在这里交出的是那条一般观察的第一个实例。

七、有人会提议的第五条，以及为什么本书不加

在把清单定稿之前，处理一个常被提出的补充。

提议的第五条是：可比较性。即，除了能重跑、能干预、能消融、能观测之外，还应当要求不同次运行的结果之间存在一个公认的比较标准——否则即使跑了一百次，也说不清它们是不是“同一处”。

这个提议是有道理的，而且它指出了一件真实的困难。第七十一章整章处理的正是这件事：标号差异与实质差异的界线，等于所允许的变换群，而那条界线不是自然事实。

本书不把它加进清单，理由有三条。

理由一：它不是装置的性质，是判据的性质。前四条说的是一台装置能做什么；比较标准说的是研究者带了什么尺子去量。把两类东西混进同一份清单，会使清单无法被用来排除候选——一个装置不会因为“研究者还没想好用什么尺子”而不通过。

理由二：它属于第五编，而不是第四编。把命题翻译成可测形式，其中就包括定义“实质不等价”。第五编第四十七章明写这一步的一般要求，第五十章处理三处翻译陷阱。清单管必要条件，翻译管可行性，两者分工写死。

理由三，也是最实际的一条：若把它加进清单，四个候选的评判会被搅乱。遗传算法那一类系统在“比较标准”上其实相当清楚——适应度就是标准；而它恰恰是本编要排除的候选之一（第四十三章）。一条会让被排除者得分更高的标准，说明它量的不是该量的东西。

但这个提议留下了一条本书接受的修正：清单的使用规则里要写明，四条是必要而非充分条件。第四十章第七节的规则三就是为此而立。

还要记一句对本书不利的：若比较标准的问题最终无法解决——即第七十一章那条界线始终划不定——那么四条全通过也判不了本案。这不是一个假想的风险：第八十章第六节已经指出，首跑那个“未能分辨”目前无法与“两把尺子量了不同的东西”区分开。清单能保证的只是装置合格，保证不了判据合格。

八、四条性质的清单在这里定稿

最后一件事：把四条性质作为一份检验清单定下来，因为第四编全部的工作就是拿它去卡候选。

任何一个宣称可以判本案的现场，必须逐条通过这四条；缺一条，它就只是一个有趣的类比。

第四编将用这份清单排除三个常被援引的候选——量子测量、实验演化、早期人工生命与遗传算法——并说明大模型训练为什么四条同时满足。

而那一编还会补上一条本编没有提到的代价：满足四条的那台装置，它自己也是被造出来的。这个自指问题在第四十六章第一次出场，在第八十七章第七节作结。

本书主张四条同时满足这件事已经发生了，装置是大规模语言模型的训练。下一编说明为什么是它。

第三编 两千年的谱系：按缺哪台装置重排

本编把两千年的谱系重排一遍，而重排的依据不是学派、不是年代、不是立场，是缺哪台装置。

二十六章，每章三节：他的位置／他实际缺的那台装置／若装置到手他的主张会变成什么可测命题。第三节是本编存在的全部理由——没有它，这一编就是一份读书笔记。

一条纪律写在最前面：本编不把任何一个人写成失败者。缺一台尚未被发明的装置，不是任何人的过错。

本编另有两处循环，都写明而不消除：它用一种由库恩确立的史学方法处理包括库恩在内的二十六人；它用一把由伍德沃德给出的尺子去量包括伍德沃德在内的二十六人。两处都出自同一个事实——本书没有一个站在外面的位置。

本编的产出是二十六条“若装置到手”。把它们排在一起会看见：本书那三条条款，是二十六个人各自停下来的那个位置的公因式。

体例：每章一人（少数合章），三节——他的位置／他实际缺的那台装置／若装置到手他的主张会变成什么可测命题。不作评述式综述。

一条纪律写在开头：本编不把任何一个人写成失败者。缺一台尚未被发明的装置，不是任何人的过错。

第十四章 柏拉图

一、他的位置

柏拉图是先在论的源头，而且是最纯粹的一次。

在《美诺》里，面对“一个人怎么可能去寻找他根本不知道的东西”这个两难，他给出的回答是回忆说：灵魂在出生前见过全部真理，学习只是把已有的东西重新想起来。

他还给了一段演示：苏格拉底不教那个童奴任何东西，只用提问，让他自己说出正方形倍积的作法。这段演示的用意很清楚——若那个孩子从未学过而能说出，那么它一定原本就在他里面。

在《理想国》里，这个结构被推到极致：可感事物是不完全的，而理念完全；认识就是从前者上升到后者。

他的位置因此可以一句写定：被知道的东西完整地先在，探究的全部工作是接近它、认出它、把它取出来。

这是第二章那三条骨架的第一次完整表述，而且是唯一一次连形而上学外衣一起给足的表述。

二、他实际缺的那台装置

四条性质，他一条也没有。

可重跑：一段学习只发生一次。那个童奴不能被清空记忆再教一遍。

可干预：无法构造两个在其余一切上相同、只有提问次序不同的童奴。

可消融：无法删掉苏格拉底的某一句提问再看结果。

可观测：孩子说出答案之前心里发生了什么，只能被推测。

而那段演示恰恰需要这四条中的至少两条才能成立。

演示要证明的是“他原本就知道”，而它实际能证明的只是“在这些提问之下他说出了这个答案”。要把前者与后者分开，必须能换一组提问再跑一次——看他是否仍然到达同一处，还是到达别处。

这是四条性质第一次被需要，而且是在全书谱系的第一章里。

要说公道话：柏拉图不是没有意识到提问的作用，他把它称作助产。助产这个比喻本身就承认了提问者在场；争的只是助产士是否改变了被产者。而判断这一点，需要的正是同一个母亲在不同助产士手下生产若干次——这件事在任何意义上都做不到。

三、若装置到手

把回忆说翻成本书的记号，它是一句极清楚的话：

Reach(C, A, L) 是一个点。

材料是那些提问，装置是这个孩子，判准是“算不算说对了”。回忆说主张：无论怎么问，只要问得下去，到达的是同一处——因为那一处原本就在。

这不是一个隐喻式的翻译，它就是强版本的先在论（第二章第七节）。

装置到手之后，它变成一条可判的命题：固定材料与判准，改变提问的次序与方式，反复跑，看到达的地方是不是同一处。

条款一测它的第一层（差异是否随资源衰减），条款二测它的第二层（差异能否被材料写出来），条款三测它的最强形式（是否存在只有某条路才到了的地方）。

柏拉图会输在哪里，也很清楚：若差异不随资源衰减，回忆说的强版本就完了。而他会赢在哪里同样清楚：若可达集确实收缩为一点，那么两千四百年前那段演示，就第一次得到了它一直缺的那样东西。

最后补一件与本编体例有关的事。

柏拉图排在第一章，不是因为他最早，是因为他的主张在本书的记号里最简单——一个点。此后二十五人所做的，几乎全部是在这个点上加结构：亚里士多德把它加成一条可排序的列（第十五章），康德把它加成一台可指认的装置（第二十一章），彭加勒把它加成一个可量的余地（第二十四章）。

于是本编有一个可以事先说出的形状：二十六章是同一个对象——可达集——被逐步加上结构的过程；而每一次加结构，都使它离“可以被量”更近一步，同时使原来那个干净的主张更难被守住。

这个形状本身是一条读数：一个立场若在两千年里被不断加结构才能守住，那不是它强的证据，也不是它弱的证据——那是它一直没有被测过的证据。

第十五章 亚里士多德

一、他的位置

亚里士多德把先在论做了第一次经验化。

他不接受一个与可感世界分离的理念界。形式在事物之中，认识从感觉开始，经由记忆、经验、上升到对普遍的把握。

而“被认识的那个东西”仍然先在——它是事物的形式，在被认识之前就是那个形式。

潜能与实现这一对概念，把这件事说得最清楚：橡实潜在地是橡树，它的实现不是被造出来的，是被展开的。认识的结构与此同构：可知者潜在地在那里，认识使之实现。

他的位置因此是：先在论去掉了分离的理念界，换成了内在的形式；结构不变，形而上学负担轻了很多。

二、他实际缺的那台装置

他缺的是可重跑，而且他比柏拉图更接近需要它。

理由在于他的经验化本身：一旦认识从感觉开始、经由归纳上升，那么“从哪些感觉开始”“按什么次序归纳”就成了可以问的问题。

而这个问题他问不了，因为他手上没有第二次。

一个人从这批经验上升到这个普遍，另一个人从那批经验上升到那个普遍——这件事在他的框架里要么被归为其中一人错了，要么被归为两人看的是同一个形式的不同方面。两种归法都可以，而分开它们需要重跑。

潜能这个概念在这里最吃紧。说橡实潜在地是橡树，依据是什么？依据是所有橡实都长成橡树。而这是一个统计事实，它成立的前提是那些橡实的发育路径大体相同。若把发育路径大幅改变，橡实是否仍然潜在地是同一棵橡树——这个问题他无法提问。

三、若装置到手

他的主张翻成本书的记号，是一个比柏拉图弱、也因此更难判的命题：

Reach(C, A, L) 中的元素，是同一个形式在不同程度上的实现。

这不是“可达集是一个点”，而是“可达集里的元素可以按接近程度排成一列”。

这正是第四十九章第五节那个“第三种可能”的古典版本——路径影响到达的是哪一个成员，而那个成员集合由材料与形式决定。

装置到手之后要测的是：那些元素能不能被排成一列。

具体说，若存在一个只由 C、A、L 决定的描述，使得每个到达的结果都可以被写成它的一个近似，那么亚里士多德对；若不存在——若不同路径到达的东西不是同一件事的不同精度，而是不同的组织方式——那么他的潜能概念在这个现场上不适用。

这就是条款二。亚里士多德在本编二十六人里，是第一个其主张直接落到条款二上的人。

还要补一句他与柏拉图的分界，因为这条分界在后面反复出现。

柏拉图主张可达集是一个点，亚里士多德主张可达集里的元素可以按接近程度排成一列。

前者被否认只需要一个反例——找到两个实质不等价的结果即可。后者被否认难得多：必须证明那些结果不能被排成一列，即不存在一个不提路径的统一描述把它们归结。

于是从柏拉图到亚里士多德，先在论的可反驳性下降了一个量级。

这件事在本编会重复发生：每一次先在论被加结构，它就变得更难被反驳一点。而到了现代形态——彩票假说、表征收敛、缩放律（第八编）——它已经需要整整一编来处理。

本书对这个趋势的态度是接受：一个更难被反驳的对手，不是一个更可疑的对手，是一个更值得认真对待的对手（第六十七章第三节）。

第十六章 奥卡姆与唯名论之争的可判性形式

一、这一章的位置与处理方式

本章不按人物写，按争论写，因为可判性的问题在这里第一次以一个干净的形式出现。

争论是：共相——“人”“白”“树”这些普遍者——是在事物之外真实存在，还是只是名称？

实在论一侧主张共相有其实性；唯名论一侧主张只有个别事物存在，共相是名称。

奥卡姆把唯名论推到了最彻底的形态：普遍者不在事物之中，也不在事物之外；它是心灵中的一个记号，其普遍性在于它能指代许多个别。

二、这场争论缺的那台装置

它缺的是可干预。

把争论的经验后果写出来，就看得很清楚：若共相实在，那么“人”这个类的边界由事物本身决定；若共相是名称，那么边界由命名的实践决定。

两种主张对任何一次具体的分类，都给出相同的预期——因为无论哪一侧成立，我们实际使用的那套分类都是眼前这一套。

要分开它们，需要的是：改变命名的实践，看类别的边界是否跟着变。

具体说：在两个在其余一切上相同、只有分类实践不同的共同体里，最终稳定下来的类别是否相同。

这件事在十四世纪不可能做，在今天的人类共同体上也不可能做——理由与第十三章第三节完全一样：没有两个其余一切相同的共同体。

三、若装置到手

这场争论翻成本书的记号，是一个关于可达集的粒度的问题：

在固定材料与判准之下，不同的路径是否稳定下来同一组类别？

而这个问题在本书的现场上有一个直接的对应物：模型内部形成的表示，其切分方式是否随路径而变。

装置到手之后，这场争论第一次有了一个可跑的形式：固定语料与判准，换路径，检查所形成的内部区分是否对齐。

- 若对齐——不同路径切出同一组类别——实在论一侧得到一个它从未有过的经验支持。
- 若不对齐，且不对齐不随资源衰减——那么“类别的边界由实践决定”这句话，第一次从一个哲学主张变成一份读数。

要写明一处限制：本书的现场上所形成的区分，与人类语言中的共相是不是同一类东西，这件事本书不主张（第八十一章第二条）。本章给出的是同构，不是等同。

本章还留下一件本编其余各章都没有的东西：一个关于这场争论为什么会平息的观察。

唯名论与实在论之争没有被判决，它是退场的——后来的哲学把问题重新表述，争论失去了原来的形状。

而退场与判决在效果上很像，在性质上完全不同。

第五章处理的是同一件事的另一个版本：一个切分把问题从议程上取消。这里是另一种取消方式——问题被改写成别的问题，原来那个就不再被问。

本编要记下这件事，是因为它是本案的一种可能命运。

若本案始终测不出来，它最可能的结局不是被判负，是被改写——被改写成训练稳定性或表示对齐度这类工程问题，然后原来那个问题静悄悄地不再被问。

第七十四章第八节那个机制，在这里有了一个十四世纪的先例。

第十七章 培根

一、他的位置

培根是方法中立论的奠基者。

《新工具》的纲领是：人的心灵有四类假象（族类、洞穴、市场、剧场），它们扭曲认识；而一套正确的方法——有序的、逐级上升的归纳，配合排除表——可以把这些扭曲挡在外面，使自然的“形式”如其所是地呈现出来。

这里有两件事同时被主张：其一，方法可以排除主观的干扰；其二，排除之后所得到的东西，是自然本身的形式。

第二件就是第二章那第二条骨架——方法是中立的通道。而培根是第一个把它当作纲领而不是默认前提来写的人。

二、他实际缺的那台装置

他缺两条：可干预与可消融。

他的方法要求排除干扰项，而排除本身就是一种消融——从材料中去掉某一部分，看结果是否改变。他设计了这个动作，却没有执行它的条件。

具体说，他的排除表是在观念上做的：列出出现该性质的场合、不出现的场合、程度不同的场合，然后比较。这是一次思想上的消融，而不是一次实际的消融——他不能把那些场合中的某一类真的删掉，再让整个认识过程重跑一遍。

而这件事在他的纲领里是承重的。“正确的方法给出自然的形式”这句话若要被检验，必须能比较：用方法 A 与用方法 B，得到的形式是否相同。

要把话说公道：培根清楚地知道观察者会带进东西，四类假象正是这个认识的产物。他缺的不是这个念头，是把念头变成对照实验的设备。

三、若装置到手

他的纲领翻成本书的记号，是一句非常干净的话：

$R = \Phi(C, A, L)$ ，其中 A 就是他所说的方法。

培根主张：只要 A 取对了，R 就由 C 决定，而不受认识者的偏见影响。

装置到手之后，这句话变成一条可测的命题：固定 C 与 L，固定 A 为同一个架构族，只改变 P——而培根的纲领恰好没有 P 这一项。

这是本编里最清楚的一次对照：培根把方法提到了第一位，却把“同一套方法的不同执行”当作不存在的东西。而本书要测的正是那一项。

他会赢在哪里：若路径差异随资源衰减到噪声，那么“方法对了结果就定了”这句话在这个现场上成立，培根的纲领第一次得到实验支持。

他会输在哪里：若那个差异不衰减，那么“正确的方法”就不足以定下结果——还需要指定执行它的那一条路。而那一条路，在他的四类假象里没有位置：它不是偏见，也不是错误，它只是一次具体的走法。

最后一句留给那四类假象本身，因为它们与本书有一处出人意料的对应。

培根列出族类、洞穴、市场、剧场四类假象，其用意是把它们从认识中清除出去。

而在本书的记号里，这四类里有三类不是路径，是材料或装置的性质：族类假象来自人的共同构造（近于 A），市场假象来自语言（近于 C），剧场假象来自既有学说（也近于 C）。

只有洞穴假象——来自每个人各自的经历、教育、偏好——落在 P 上。

而培根对洞穴假象的处理方式是：靠方法把它消掉。

于是本章的诊断可以说得更准：培根不是没有看见路径，他看见了，并且把它归入了应当被消除的那一类。他与本书的分歧不在于路径是否存在，在于路径是不是噪声。

这个分歧，就是第八十四章第一节那个“路径被当作工程噪音”的四百年前的版本。

一、他的位置

笛卡尔把方法提到了比培根更高的位置，同时把结果的唯一性锁得更紧。

《谈谈方法》里那四条规则——不接受未经明证的东西、把困难分解、由简到繁、周遍复查——是一套程序。《第一哲学沉思集》则给出了这套程序的起点：普遍怀疑之后剩下的那个不可怀疑者。

他的结构是这样的：从一个唯一的起点出发，按一套唯一正确的程序推进，到达唯一的结果。

这里的“唯一”出现了三次，而且三次是互相支撑的。起点唯一，因为怀疑到底只剩那一个；程序唯一，因为那是理性自身的次序；结果因此唯一。

他的位置可以一句写定：方法被提到了第一位，而结果的唯一性不但没有被松动，反而被方法保证了。

二、他实际缺的那台装置

他缺的是可重跑，而且他的整个论证结构使这个缺失特别刺眼。

理由是：他的方法要求“周遍复查”——最后一条规则就是回过头把全部环节检查一遍，确保没有遗漏。

复查是一次重跑，只是它在同一个人的头脑里做。

而同一个人的复查有一个结构性的限制：他带着第一次的结果去复查。他不可能忘掉自己上一次到达了哪里，因而不可能检验“若不曾到达那里，我还会到达那里吗”。

这正是本案所需要的那种重跑：清空，换一条路，再来一次。

要说公道话：笛卡尔对这个问题有相当敏锐的感觉。他反复担心自己是否被欺骗，是否有某个从一开始就渗进来的错误。那个担心的形式，正是“我这条路径本身是否可靠”。而他解决它的办法是诉诸一个不欺骗的保证者——一个在结构上起着“保证不同路径到达同一处”作用的东西。

于是可以把他缺的说得再准：他需要一个能证明路径可靠的东西，而他手上唯一能拿出来的是一个形而上学的保证，不是一次对照。

三、若装置到手

他的主张翻成本书的记号：

给定 **A**（那套规则）与 **L**（明证性），无论从哪个 **P** 出发，**Reach** 收缩为一点。

注意这与培根的不同：培根强调 **A** 要取对，笛卡尔强调起点也唯一。在本书的记号里，笛卡尔实际上主张连初始化都被锁定了。

装置到手之后，他的命题变成一条特别好测的东西：

同一套规则、同一批材料，从不同的起点出发，是否收敛到同一处？

这就是第七十章那件武器所处理的问题的古典版本——彩票假说的原始形式主张中奖彩票由初始化给定，而修复后的形式把先在性的时点挪到了训练开始之后（第七十章第六节）。

于是笛卡尔在本编里有一个特殊的位置：他是唯一一个其主张直接对应到“初始化是否要紧”这个现代问题上的人。

他会赢在哪里：若不同初始化在充分训练后收敛，他的第三条规则得到支持。

他会输在哪里：若不收敛，那么“由简到繁的次序是理性自身的次序”这句话就要加一个限定——它是从某个起点出发的那一条次序。

还要补一处，因为它是本编里少见的一次“他自己已经走到门口”。

笛卡尔的普遍怀疑，实际上是一次清空的尝试——把一切可疑的东西都撤掉，看还剩什么。

清空正是重跑的前半段。一次真正的重跑要做两件事：清空，然后换一条路重走。笛卡尔做了第一件，而第二件他做不了——因为清空之后他只能按同一套规则重走一次。

于是他得到的是一个不动点，而不是一个分布。

这个区别在本书的记号里很清楚：不动点是“重走一次到达同一处”，分布是“重走很多次，看到达的地方散成什么样”。前者可以由一个人在头脑里完成，后者需要一台机器。

本编二十六人里，笛卡尔是距离“重跑”这个动作最近的一个——他缺的不是这个念头，是把一次清空变成很多次清空的条件。

第十九章 维柯：第一次正面的造成论

一、他的位置

维柯是这份谱系里第一个正面的造成论者。

《新科学》的那条原则——真理与制作可互换——说的是：我们能真正认识的，是我们自己做出来的东西。

这一步的力量在于它把“做”与“知”连了起来，而且连得很具体：数学之所以可被确知，因为它的对象是人造的；历史之所以可被理解，因为历史是人做的；而自然之所以难以被完全认识，因为它不是我们做的。

他不是在说知识主观。他是在说：被做出来的东西才可被彻底知道，因为在做的过程中，做者掌握了它的全部规定。

他的位置因此是：造成论第一次不是作为对先在论的修正出现，而是作为一条正面的原则出现。

二、他实际缺的那台装置

他缺两条：可重跑与可缩放。

缺可重跑：他的原则要靠比较来检验——人造物与非人造物，我们对它们的认识是否真的不同类。而这个比较无法执行，因为不能把同一个对象既当作人造的又当作非人造的来认识一遍。

缺可缩放：这一条更要紧。他的原则把“人造”当作一个二值的性质——要么是我们做的，要么不是。而本案所争的是程度：路径进入结果的规定有多少，那部分是否随资源变化。

一个二值的原则，不需要一个可以逐级加上去的资源轴；而没有那个轴，“造成的成分会不会消失”这个问题提不出来。

这一处缺失决定了他的原则后来的命运：它被当作一条关于认识类型的划分（人文与自然），而不是一条关于知识形成的可测命题。划分不需要读数，而本案需要。

三、若装置到手

他的原则翻成本书的记号，会得到一个此前没有人提过的问题：

人造物的可达集与非人造物的可达集，形状是否不同？

维柯主张不同：对人造物，我们掌握全部规定，因而可达集是我们做出来的那个；对自然，我们不掌握，因而认识只能是近似。

装置到手之后，这个问题第一次可以被试着问。

本书的现场，语料是人写下的——它是人造物；而语料所关于的那些事情，大部分不是。若维柯对，那么模型在“语料自身的结构”上的可达集，应当比它在“语料所关于的那些事”上的可达集窄。

这是一条可以设计的检验，而本书没有做，也不打算做——它需要把探针按“关于语料本身”与“关于世界”分组，而这个分组本身极难划清（第五十五章第三条那类自由参数问题在这里更严重）。

本节因此以一句诚实的话结束：维柯的原则在装置到手之后可以变成可测命题，而本书没有把它变成。它是本编二十六章里留下的一张空支票，写明在这里，供后来者取用。

还要补一句关于维柯这条原则的适用范围，因为它比通常被认为的要窄。

“真理即制作”若按字面理解，会得出一个本书不接受的推论：既然大模型是人造的，那么关于它的知识就是可彻底的；于是本案在这个现场上不成问题。

这个推论错在一处：本案要判的不是“我们对模型的知识”，是“模型所形成的那个东西的规定是否依赖于路径”。做出一台机器，与知道那台机器会到达哪里，是两件事。

而这两件事在本书的现场上被拉开得特别远：训练的每一行代码都是人写的，而训练到达的那个结果，没有任何人能事先写出来。

这件事本身对维柯的原则是一个反例，而且是一个他不可能设想的反例——一个完全由人造出来的过程，其产物的规定不能由造它的人给出。

本章因此以一句话收尾：维柯把“造”与“知”绑在一起，而本书的现场第一次把它们分开了。

第二十章 休谟

一、他的位置

休谟把必然性从对象移到了习惯上。

《人性论》与《人类理解研究》里那条著名的论证是：我们在经验中找不到必然联系，只找到恒常的相继；而“必然”这个观念的来源，是心灵在多次观察之后形成的一种过渡的倾向。

这一步是本编里最接近造成论的一次非造成论。

它把一个看起来属于世界的规定（必然性），说成了认识者一侧的产物。就形式而言，这与康德的哥白尼转向只差一步。

而他没有走那一步。他的结论是怀疑论的：必然性不是世界的，也不因此是被构成的知识对象；它是一种心理事实，而我们关于因果的信念因此没有理性的根据。

他的位置因此是：把一项规定移到了认识者一侧，却没有把它算作结果的一部分。

二、他实际缺的那台装置

他缺的是可干预。

他的论证里，习惯由“恒常的相继”造成。那么可以立刻问一句他没有问的问题：

恒常相继的呈现次序不同，形成的习惯是否不同？

这是一个经验问题，而且是一个在他的框架内完全合法的问题——既然习惯由经验造成，那么经验的安排方式就应当影响它。

他提不出这个问题，不是因为没想到，是因为提了也无从回答：无法构造两个其余一切相同、只有经验次序不同的心灵。

而这个缺失有一个具体的后果：它使他的结论停在怀疑论上。

若能测到“次序不同则习惯不同”，那么因果观念就不只是一个心理事实，它是一个被特定路径造成的、可以不同的东西——而那已经是造成论了。若测到次序不同而习惯相同，那么必然性虽然在心灵一侧，却仍然由材料唯一决定，这与先在论相容。

两条路他都走不了，于是只能停在“没有理性根据”这个否定性的结论上。

三、若装置到手

他的主张翻成本书的记号：

因果判断是 $\Phi(\mathbf{C}, \mathbf{A}, \mathbf{L}, \mathbf{P})$ 的一个分量；而休谟只论证了它不是 $\mathbf{C}$ 的直接读出，没有论证 $\mathbf{P}$ 是否可消去。

装置到手之后，这变成一条可跑的检验，而且它恰好是条款二形式三的一个实例：

同一批材料，改变呈现的次序，所形成的判断是否可交换？

第五十六章第五节那条实验规格，用在这里几乎不需要改动——把“语料的段落次序”换成“相继事件的呈现次序”即可。

而第六十六章那条探索性读数与这一章直接相关：在最大规模上，只换数据次序所造成的行为差异，不小于两者都换（0.138 对 0.116）。

那条读数不能当结论（三对样本、组内共享条件不齐），但它有一个属于本章的意义：休谟两百多年提出而无法回答的那个问题，今天已经有了一个粗糙的、方向正确的近似读数。

第二十一章 康德

一、他的位置（上）：哥白尼转向

康德是造成论在哲学史上最有力的一击，也是普遍性自伤的原型。第十一章已经处理了后一面；本章处理前一面，以及一件第十一章没有写的事。

在他之前，认识的标准图景是：对象在那里，知识要去符合对象。

《纯粹理性批判》把这个关系倒过来：对象要符合我们的认识形式。空间与时间是直观的形式，范畴是知性的形式，经验对象是在这些形式中被构成的。

这一步的分量第十一章第二节已经量过，本章不再量一遍。这里只取它与本编体例相关的那一点：他不是在某一个学科内部提出一条主张，他是在为一切经验立规矩。

第十一章没有写的那件事在这里补上：康德给出的不只是一个主张，还有一套构成的细节。图型论、统觉的综合统一、先验演绎——这些是关于“构成如何进行”的具体说明。

而那套细节，是本编最接近“一台装置的说明书”的东西。在他之前没有人写过这样的东西；在他之后，那批写构成装置的人（皮亚杰、乔姆斯基、结构主义）都在做同一类工作，只是把装置换成了可经验研究的。

二、他的位置（下）：为什么必须普遍

他为那一步付出的代价，第十一章第三节已经写过：为了让构成出来的知识具有普遍必然性，构成装置必须是一切有限理性存在者共同的、不可变更的。

本章要补的是：这个代价不是一时的疏忽，它是那个工程的目的本身。

康德要解决的问题是：如果知识是被我们的形式构成的，它凭什么还能是普遍必然的、而不是某个人的主观安排？

若装置可变，这个问题无解。装置可变意味着不同的认识者构成出不同的经验对象，而那正是他要避免的后果——在他的语境里，那等于取消了科学知识的客观性。

因此他把装置钉死，不是因为他没看见可变的可能，是因为可变会毁掉他要保住的东西。

这一点值得写清，因为它决定了第十一章那条教训的性质：普遍性自伤不是一个错误，是一个交换。康德用可判性换了普遍必然性，而在他的处境下，那是一笔合理的交换——因为可判性当时无论如何也拿不到。

三、他实际缺的那台装置

他缺的是可干预，而且缺得比本编任何人都彻底。

前面几位缺可干预，是因为没有设备。康德缺得更深：在他的体系里，那个要被干预的对象在原则上不可干预。

先验形式是使经验成为可能的条件，因而不可能有人站在它之外去改变它再看结果。这不是设备问题，是位置问题。

物自体那道闸门是这一处的结算（第十一章第四节）：来源者被宣布为不可知，于是分歧被封住而不是被解决。

要说得更准一些：康德不缺一个能做实验的仪器，他缺的是一个构成装置可以被当作对象来看的位置。而这个位置直到构成装置被拉到经验层面（第三章第三节那三次扩大）之后才出现，又直到它被拉到可重跑的人工系统上之后才可用。

四、若装置到手

他的主张翻成本书的记号，是本编里最直接的一次翻译：

构成装置能否不同——这就是 **P** 是否可变，以及它变了之后结果是否跟着变。

装置到手之后，康德的两个主张分开了，而它们在他那里是捆在一起的：

- 主张甲：对象是被构成的。
- 主张乙：构成装置普遍必然。

甲是可判的，乙在这个现场上为假。

为假的理由很平常：在本书的现场上，构成装置显然可以不同——换一个架构、换一套优化器、换一条路径，构成的方式就不同。这不需要论证，它是工程事实。

于是一件有意思的事发生了：装置到手之后，康德那个交换的两头都松开了。乙不再需要被保住（因为普遍必然性不再是构成论的前提），甲因此可以被单独拿去判。

而把甲单独拿去判，正是本书第六编在做的事。

最后一句要说给康德：他为了保住普遍必然性而封上的那道闸，在一个他不可能预见的现场上被绕开了——不是被更好的论证绕开的，是被一台可以把构成装置摆在桌面上的机器绕开的。第八十七章那条一般观察，在本编里的最强实例就是他。

五、附：康德与本书的三处直接对应

本章加倍，末尾把三处对应列出来，因为康德是本编唯一一个在全书三编里都出场的人。

对应一·第十一章：普遍性自伤的原型。那里取的是他为保住普遍必然性所付的代价。

对应二·本章：构成的细节。他给出的是本编最接近“装置说明书”的东西，而那套说明书的现代后裔在第十二章的四例里。

对应三·第八十六章第七节：若条款二判负，本书就落在与康德同一个位置上——构成的产物与先在的秩序不可分辨——只不过是经验一侧落进去的。

第三处最要紧，值得单独说一句。

康德是从先验一侧走到那个位置的：装置普遍，因而产物看起来像先在。而本书若失败，是从经验一侧走到同一个位置：那个先在的集合真的可以被写出来，因而路径只是选择器。

两条路不同，落点相同。

这件事对本书是一个提醒：普遍性自伤不是一个只会发生在思辨哲学里的错误。它是一个位置，而任何一条主张构成的路线，都可能以自己的方式走到那个位置上去。第十一章第五节那句“伤口不是对手造成的”，本书要对自己再说一遍。

第二十二章 黑格尔

一、他的位置

黑格尔把构成历史化了。

在他那里，认识不是一个固定的主体用固定的形式去加工材料，而是概念自身的展开——每一个阶段的规定都不完整，它的不完整推动它过渡到下一个阶段，而下一个阶段把前一个包含在内并加以改造。

这一步相对康德的进展是明确的：构成装置不再是一套不变的先验形式，它自己有历史。

而他同时做了一件与康德同类的事：那个展开有一个终点，而且展开的次序是必然的。每一步的过渡不是可以这样也可以那样，它是由前一步的不完整所规定的。

他的位置因此是：把装置历史化，却把历史本身规定为唯一的一条路。

二、他实际缺的那台装置

他缺的是可重跑，而在本编二十六人里，他缺得最明显——因为他的主张直接就是一个关于重跑的主张。

“展开的次序是必然的”这句话，等价于说：重跑一次，会走同一条路。

而他手上没有任何办法检验它。他能做的只有事后重构：把已经发生的思想史按逻辑次序排一遍，并说明每一步为什么必须如此。

事后重构与必然性的关系，正是本案的老问题：一段只发生过一次的过程，可以被重构成必然的，也可以被重构成偶然的，而两种重构对那段过程本身给出相同的预期。

要说公道话：黑格尔并非不知道历史里有偶然。他把偶然处理为必然性借以实现自身的材料。而这个处理方式恰恰是不可检验的——它对任何具体的偶然事件都适用，因而不排除任何东西。

三、若装置到手

他的主张翻成本书的记号：

无论 P 如何， $\text{Reach}(C, A, L)$ 中的元素按同一次序排列，并到达同一个终点。

注意这比亚里士多德的主张强：亚里士多德只要求元素可以按接近程度排成一列，黑格尔还要求到达的次序也相同。

装置到手之后，这变成两条可分的检验：

其一-终点：不同路径是否到达同一处。这是条款一。

其二-次序：不同路径经过的中间状态，是否按同一次序排列。这一条需要可观测——需要中间状态被保存，而不只是终点。

第二条是本编里唯一一处主张直接落在“可观测”这条性质上的地方，而本书的现场恰好提供了它：公开的多检查点系列把成千上万个中途状态放在那里（第四十四章第五节）。

这一条本书没有测。它不在三条条款之内，也不在第六十六章那份清单里。本章把它记为第二张空支票：训练轨迹的中间状态是否跨路径地按同一次序排列，这是一个可跑而未跑的问题，而黑格尔的主张在这个现场上第一次有了一个字面的检验形式。

还要补一句关于“终点”这个概念，因为它在本编后面还会出现两次。

黑格尔的终点是绝对知识；皮亚杰的终点是形式运算（第三十七章）；康威·莫里斯的终点是某些反复被找到的解（第三十九章）。

三个终点的来源完全不同，而它们在本书的记号里是同样东西：可达集收缩为一点。

这说明“终点”这个概念在本案中的地位：它不是一个形而上学的装饰，它是一条可测的主张。凡主张有终点者，都主张 $\kappa = 0$ 。

而这一点对造成论一侧是一条纪律：一个造成论若也主张某种终点——哪怕那个终点被说成实践的收敛或最终的稳定——它就在这一条上与先在论合流了。第十一章第六节那句“不同不能只是暂时的”，说的正是这件事。

第二十三章 马赫

一、他的位置

马赫把对象化为要素之间的函数关系。

在他那里，所谓物体不是一个实体，而是颜色、声音、压力等要素的相对稳定的复合；科学的任务不是发现隐藏在现象背后的实在，而是以最经济的方式描述要素之间的依赖关系。

这一步对先在论是一次真实的松动：被认识的“对象”不再先在，它是一个描述上的构造。

而松动止于此：那些要素本身，以及它们之间的函数关系，仍然是给定的。经济性原则要求我们选最简的描述，而那个“最简”被默认为唯一。

他的位置因此是：对象不先在，关系先在。

二、他实际缺的那台装置

他缺的是过程层的可观测。

他的经济性原则要求比较不同的描述：哪一个更省。而“省”这件事本身需要一个衡量，而衡量依赖于用什么语言来写描述。

用不同的记法，最经济的描述可能不同。这一点他不会否认——他对记法的作用相当敏感。

而他无法追问的是：那个记法是从哪来的？

记法是在一段具体的历史里被造出来的。要问“换一套记法，最经济的描述是否不同”，必须能观察到记法形成的过程，并在其中做干预。

而他看到的只有已经成形的记法。过程层的观察在他那里完全缺失——这与第七章那道闸是同一件事：可供检查的只有产物。

三、若装置到手

他的主张翻成本书的记号：

在固定 **C**、**A**、**L** 之下，经济性原则唯一地选出一个描述——即 **Reach** 中的元素可由“最经济”这一判准排出唯一的最优者。

装置到手之后，这变成一条相当尖锐的检验：

不同路径所形成的内部表示，若都被要求压缩同一批材料，它们是否收敛到同一种组织方式？

这与第六十八章那件武器直接相关：表征收敛假说所主张的，恰好是一个现代版的马赫命题——不同的模型在向同一个关于世界的统计表征靠拢。

而第六十八章第五节那一节在这里有用：任何一个对齐度都只看见它所用的那个核能看见的差异。马赫的“经济性”与今天的“相似性核”是同一类东西——一个必须先被选定、而选择本身不由自然给出的衡量。

因此马赫在本编里的位置是：他第一个把“描述的选择”提成了核心问题，而他缺的是把那个选择本身摆到桌面上的条件。

最后补一处马赫与本书在方法上的欠账。

马赫对记法的敏感，在本编二十六人里是最高的。他反复指出，一个概念之所以看起来自然，往往只是因为我们习惯了某种记法。

而本书的整套判据，其最脆弱的地方恰恰是同一类东西：结果距离依赖于度量（第八十章），标号与实质的界线依赖于变换群（第七十一章），行为距离依赖于探针（第五十五章第三条）。

三处都是“用什么记法来写”的问题。

于是马赫在本编里的位置有一个反转：他缺装置，所以主张停在原地；而本书有了装置，却发现装置并不解除他所指出的那个困难——它只是把困难从“哪种描述最经济”换成了“用哪把尺子量距离”。

这一条要写在本编里，因为它是对第四编那句“换现场”的一处限制：换现场解除的是不可重跑，不解除记法的自由度。第八十七章第三节那条限制二说的就是这件事。

第二十四章 彭加勒：约定论离判据最近的一次

一、他的位置

彭加勒的约定论，是这份谱系里离可判性最近的一次。

他主张：几何学的公理既不是先验综合判断，也不是经验事实，而是约定——我们选择欧几里得几何，不是因为它真，而是因为它方便。

关键在于“方便”这个词。它不是任意：在他那里，选择受到极强的约束——它要与经验相合，要简单，要能被实际使用。约定的余地是有限的，而且有限得很厉害。

他的位置因此是：在一个被强约束的范围内，仍然存在一个不由事实决定的选择。

这句话几乎就是本书的核心命题，只是它说的是几何学的公理，而本书说的是训练的结果。

二、他实际缺的那台装置

他缺的是可缩放。

把他的主张写成一个可判的形式，需要问：

那个约定的余地，随着经验的增加而收缩吗？收缩到零吗？

这正是第五十二章那个承重区分地问法。若余地随资源收缩为零，那么约定只是暂时的——它是“你还没走到”；若余地稳定为正，那么它是“从这条路走过去，那里没有那个东西”。

彭加勒提不出这个问题的量化形式，因为他没有一个可以逐级加上去的资源轴。

他能做的是指出余地的存在（通过构造不同几何的可能性），不能做的是量它随资源的行为。

这一处缺失决定了约定论后来的处境：它被当作一个关于“理论选择不唯一”的主张，而它本来可以是一个关于“不唯一是否持久”的主张。前者两方都能接受，后者才是本案。

三、若装置到手

他的主张翻成本书的记号，是本编里最精确的一次对应：

约定的余地 = 可达集的直径。

余地随经验收缩为零 = $\kappa = 0$ 。

余地稳定为正 = $\kappa > 0$ 。

装置到手之后，约定论第一次成为一条带量的命题。

而本书的首跑，实际上就是这条命题的第一次测量尝试——表征通道上余地不向零收缩，行为通道上余地单调收缩但未收缩到噪声，两通道不一致，判未能分辨（第六十四章）。

因此彭加勒在本编里有一个特殊的地位：二十六人中，他是唯一一个其主张与本书的量一一对应的人。柏拉图对应可达集是不是一个点，康德对应 P 是否可变，而彭加勒直接对应 κ 。

要补一句他与本书的分界：彭加勒讲的是理论选择，本书讲的是结果的规定。两者是否同一件事，本书不主张（第八十一章第二条）。本章给出的是同构，不是等同——与第十六章末尾那句话同一个处理。

最后补一件关于彭加勒的事，它对本书的语气有直接影响。

彭加勒并不认为约定论会导致相对主义。相反，他反复强调约定受到极强的约束——一个方便的约定不是一个任意的约定。

这与第七十九章第三节那一整节是同一个论证，隔了一百多年。

而他当时没有的，是把“极强”量化的办法。

“约束极强”这句话在他那里是一个判断；在本书里它是一个数——可归约份额的主体部分（第五十六章第四节）。

两者的差别，就是本书这一整套麻烦判据的全部产出。

本书不比彭加勒更有洞察力，本书只是能把他那句判断变成一个带区间的量——而且到目前为止，连那个量都还没有报告出来（附一那条纪律：本书全书不出现 κ 的任何数值）。

写明这一点，是本编对二十六人应有的态度：他们缺设备，本书有设备而尚未用出结果。在这件事上，本书没有资格居高临下。

第二十五章 杜恒

一、他的位置

杜恒的整体论说的是：物理学中的实验检验，从来不是对单个假说的检验。

一个预言之所以能被导出，依赖的是一整束东西——被检验的假说、辅助假说、仪器理论、数据处理的规则。预言与观察不合时，被否定的是这一整束，而逻辑本身不告诉你该改哪一条。

这一步的意义在于它把“检验”这个动作的边界打开了。在他之前，检验被理解为假说与事实的一次直接对照；在他之后，检验是一整套安排与一次观察之间的关系。

他的位置因此是：结果不由单个假说决定，而由一束东西共同决定；而那束东西里有哪些、各自占多少，逻辑不管。

二、他实际缺的那台装置

他缺的是可消融，而他的主张恰恰是一个关于消融的主张。

整体论说：你不知道该改哪一条。

而“该改哪一条”这个问题，有一个直接的实验形式：把其中一条拿掉，重跑，看结果如何变。

这正是第四十条第四节所定义的可消融——能删掉过程中的某一部分再跑，看缺了它会怎样。

杜恒提出了这个问题，而无法执行那个动作。他不能把某一条辅助假说从一次实际的物理学研究中删掉，再让整段研究重新发生一次。

于是整体论停在了一个否定性的结论上：逻辑不告诉你该改哪一条。而它本来可以是一个肯定性的纲领：去测一测改哪一条会怎样。

这是本编里“缺的是设备而不是念头”最干净的一例。

三、若装置到手

他的主张翻成本书的记号：

R 由 **C** 中的多个部分共同决定，而各部分的贡献不能由逻辑分开。

装置到手之后，这变成一条可执行的消融实验：

从语料中精确删除某一子集、某一文体、某一语言、某一段时间，然后重跑，观察缺失如何改变结果（第四十四章第四节）。

“不能由逻辑分开”在这里变成“可以由实验分开”。

要写明这个转变的限度，因为它容易被说得太满。

消融能告诉你删掉某一部分之后结果如何变。它不能告诉你那一部分“应该”被保留还是被修改——那是一个规范问题，而消融只给事实。杜恒的问题里有一半是规范的，而那一半仍然在装置之外。

还要写明一处代价：消融需要重新训练，因而是四条性质里最贵的一条。本书至今没有用到它——首跑用的是现成的公开检查点（第四十四章第四节）。杜恒的那一半在今天可执行，而本书没有执行。

还要补一句，因为它与本书的一个判据直接相关。

杜恒的“一束东西”里，有一项是仪器理论——用来解释仪器读数的那套理论。而仪器理论与被检验的假说共用同一个知识体系。

这件事在本书的现场上有一个精确的对应物：判据所用的度量，与被测量的对象来自同一个领域。表征相似度这类度量，是这个领域为别的目的发展出来的（第八十四章第五节）。

于是杜恒的整体论在本书身上又生效了一次：本书的读数不是对模型的单独检验，它是“模型 + 度量 + 探针 + 基线”这一束东西的检验；读数不对时，本书同样不知道该改哪一条。

而首跑给出了一个实例：读数两头打架，本书改的是基线（第六十五章）——而那是本书选择去改的那一条，逻辑并没有指定它。

杜恒在本编里因此有一个特别的位置：他所指出的困难，是本书在执行中真的遇到过的少数几个之一。

第二十六章 蒯因

一、他的位置

蒯因把杜恒的整体论推到了极致，并把它与另一条线接了起来。

极致的那一步：整个知识体系是一张面对经验法庭的网，边缘与经验接触，中心是逻辑与数学；任何一条陈述都可以被保住，只要在别处做足够的调整。

接起来的那条线：观察的欠决定性——同一批经验证据，可以支持不止一套整体理论，而它们之间的选择不由证据决定。

他的位置因此是：不唯一性不是局部的现象，它是知识体系的一般处境。

这是第七章那道闸的标准哲学形态，而本书第二编第七节之所以能把闸一写清楚，用的正是这条论题的形式。

二、他实际缺的那台装置

他缺的是可重跑。

欠决定性说的是“存在不止一套理论与同一批证据相容”。而这句话有两种读法，它们在经验上极不相同。

读法一·逻辑可能性：在逻辑上可以构造出另一套。这一条他论证得很好，而它的代价是那些被构造出来的替代理论往往极其人为，没有人会真的采用。

读法二·实际可达性：另一套理论是某条实际的探究路径真的会到达的。

两种读法的差别，就是本书第四十八章第四节那个“可能性空间”与“可达集”的差别。

而蒯因无法把它们分开，因为分开需要跑很多次，看哪些东西是真的会被到达的。他手上只有一次。

于是欠决定性停在了逻辑层面，而它在逻辑层面上有一个第七十六章第五节所说的毛病：它是免费的，因而是无内容的。

三、若装置到手

他的主张翻成本书的记号：

欠决定性的可测形式，是 $\text{Reach}(\mathbf{C}, \mathbf{A}, \mathbf{L})$ 含有不止一个实质不等价的元素。

而这里有一个他做不到、本书能做的关键动作：把“逻辑上可能”换成“实际可达”。

可达集的定义里写着“存在路径 P 使训练到达 R ”。“到达”这个词是实际的——它不是“在原则上可以构造出来”，是“真的跑出来过”。

因此本书的翻译，实际上是把欠决定性从读法一搬到了读法二。

这个搬动有两个后果，一好一坏。

好的：它使这个主张变得有内容。一个关于实际可达者的主张，可以被读数支持或推翻；一个关于逻辑可能者的主张不能。

坏的：它使这个主张变弱。蒯因的欠决定性覆盖一切知识体系，本书的可达集只覆盖一个具体的训练过程。从一个全称的逻辑主张，换成了一个具体的经验主张。

而这个交换正是第五十一章那条反例结构的实质：本书不要一条新的普遍原则，它要一个落在旧原则范围内的实例。蒯因在本编里的位置，就是这个交换的起点——他把不唯一性论证到了极限，而那个极限是逻辑的；本书要做的是把它挪回经验里，代价是范围。

最后补一句蒯因那条“没有第一哲学”的后果，因为它对本书的自我定位有用。

蒯因主张哲学不在科学之外，它与科学连续——没有一个更高的位置可以让人从那里审视科学。

本书的处境正是这一条的实例：本书用科学的材料、科学的工具、科学的程序去判一个哲学问题，而且承认自己也在所研究的那个机制之内（第四十六章第四节）。

第八十七章第七节那句话——一个承认自身有来路的立场，靠程序而不是靠超然来维持可信——在蒯因那里已经有了它的一半。

他给的那一半是：没有超然的位置。本书补的另一半是：那么就靠程序。

两半合起来，本书的方法学就完整了：不假装站在外面，而是把每一步都写下来，使别人可以从外面检查。这是本编二十六人里，蒯因留给本书的最实在的一样东西。

第二十七章 波普尔：证伪何以不触及本案

一、他的位置

波普尔把划界问题的重心从“如何证实”移到了“能否被证伪”。

一个理论之所以科学，不在于它被多少证据支持，而在于它禁止什么——它必须能指出一类若被观察到就会推翻它的事情。而科学的进展不是归纳的累积，是猜想与反驳的更替。

他的位置里有一件对本书极重要的事：他明确地把“一个念头从哪来”排除在认识论之外。理论的来源可以是任何东西——梦、类比、神话——这与它的科学身份无关，有关的只是它能否被检验。

这是第五章那个切分的最有力的一个版本，而且它是由一个反对逻辑经验论许多主张的人给出的。

二、他实际缺的那台装置

他缺的是可干预，而他缺得有一个特别的形状：他的判据本身把要被干预的那个东西排除在外了。

前面几位缺可干预，是因为无法构造对照。波普尔不同：在他的框架里，“来路”不是一个应当被检验的东西。

于是可以问一句他不会问的问题：

猜想的来源，是否影响被猜出来的那个内容？

按他的框架，这个问题属于心理学。按本案，这个问题就是全部。

而要指出他错了，需要的正是本案的答案。若来路进入内容的规定，那么把来路划出去就切错了地方（第五章第三节）。

要把话说公道，而且说足。

波普尔的划分保护了一件该被保护的东西：一个念头的出身不决定它的对错。这一条本书完全接受（第五章第二节）。

他的判据在本案上不成立，不是因为它错，是因为它的适用范围以本案的答案为前提。一个以争点为前提的判据，不能用来判那个争点——而这与判据本身的好坏无关。

三、若装置到手

他的主张翻成本书的记号，会得到一件有意思的事：波普尔的判据与本书的判据是同一类东西。

本书做的事情是：给出量、给出判负条件、事先写死、公开、然后跑。

这就是可证伪性在一个具体问题上的执行。第五十八章那四条败绩条件、第五十九章那三条防作弊纪律，全部是在回答“怎样算输”——而那正是波普尔要求每一个科学主张回答的问题。

于是本编对波普尔的处理有两面：

一面：他的语境切分在本案上不可用，理由见第二节。

另一面，而且更重：本书的方法学是他的。一本书若主张一件事而说不清怎样算输，按他的标准就不进入科学讨论。本书写死六条败绩条件，‘写死’未能分辨”这个第三取值，公开预注册与哈希——这些做法的正当性，追到底就是他那条判据。

装置到手之后的具体命题因此不是关于波普尔的主张，是关于他的判据的一次应用：

“路径不进入结果的规定”这句话，第一次被写成了一个能被读数推翻的形式。

在此之前它不可证伪——不是因为没有人想证伪它，是因为没有任何观察能与它相冲突（第七章）。一个两千年不可证伪的命题，在这个现场上第一次变得可证伪，这件事本身就是对他那条判据的一次兑现。

还要补一处波普尔与本书的分歧，因为它比语境切分那一处更实在。

波普尔反对归纳：理论不是从经验里归纳出来的，它是被猜出来的，经验只用来淘汰。

而本书的判据里有一步是归纳的：从有限的规模点拟合一条衰减律，外推它的渐近值（第五十四章第三节）。

这一步无法避免。极限测不到，只能拟合（第六十九章第七节）。

按波普尔的标准，这一步是可疑的。而本书对它的处理不是辩解，是把风险摆出来：冻结拟合族、报告区间、声明外推范围、并在规模点不足时拒绝报告（附一那条关于 κ 的纪律）。

于是本书与波普尔的关系可以写成一句：本书接受他的判据（写清怎样算输），不接受他对归纳的拒绝（因为极限只能靠外推）；而本书对后者的补偿，是把外推的每一处自由度都事先钉死。

第六十九章第四节那个例子——这个领域最有名的一次外推两年后被推翻——说明这个补偿是必要的，也说明它不一定够。

第二十八章 库恩

一、他的位置

库恩把构成装置从先验层面拉回了历史层面。

常规科学在一个范式之内进行；范式不只是一组理论，它包括被接受的问题、被认可的解法样例、仪器的用法、什么算一个好的解释。而科学革命是范式的更替，更替之后，研究者所面对的不是同一批问题的新答案，而是在某种意义上不同的世界。

这一步是造成论走出普遍性自伤的关键一步（第十一章第七节）：装置可变了。

而可变之后，他面对一个新的困难：不同范式之间如何比较。不可通约那条论题就是这个困难的产物。

他的位置因此是：构成装置历史化、可变化，而可比较性成了问题。

二、他实际缺的那台装置

他缺的是可重跑，而这一处在第五十三章已经论证过。本章不重复那里的论证，只写那里没写的一面。

第五十三章写的是案例的天花板——一段只发生过一次的过程，不能区分“你还没走到”与“那里没有那个东西”。

本章要写的是另一件事：库恩自己知道这个限制。

他的工作方式是史学的——他从具体的科学史材料出发，而不是从一般原则出发。而史学的自我意识里，本来就含着“历史只发生一次”这一条。

因此他缺的不是对限制的认识，是绕过限制的办法。

这一点决定了不可通约那条论题的命运：它被读成一个关于比较的论题（不同范式之间不能比较），而它本来更像一个关于可达性的论题（从一个范式出发，某些结果到不了）。

后一种读法在本书的框架里是条款三——是否存在只有某条路径才到得了的结果。而库恩无法把论题写成后一种形式，因为后一种形式需要“跑一遍看看”。

三、若装置到手

他的主张翻成本书的记号：

范式内构成 = 在固定 **A** 与 **L** 之下，结果由 **C** 与 **P** 共同决定；范式更替 = **A** 或 **L** 本身改变。

装置到手之后，两件事分开了，而它们在库恩那里是捆在一起的：

其一·范式内的路径效应。固定架构与判准，换路径，看结果差异是否随资源衰减。这是条款一，本书首跑测的就是它。

其二：范式之间的不可通约。这一条落在第七十七章第五节那个“判准本身在变”的情形上，而第八十七章第五节把它列为第三种不可判，注明“无解法”。

因此库恩在本编里的处境是分裂的：他的主张的一半（范式内构成）在这个现场上可判，另一半（不可通约）不可判，而且本书明写自己没有办法。

这个分裂值得写明，因为它对库恩公道：本书能判的那一半，恰好是他自己认为较不重要的那一半；而他认为最重要的那一半，本书判不了。

最后补一件关于库恩的事，它与本编的重排方式直接相关。

库恩是史学家出身，而本编的重排方式——按缺哪台装置——本质上是一种史学的做法：不问谁对，问各自的条件是什么。

这个做法的祖先就是他。

在他之前，处理前人的通行方式是看他们说对了多少、错了多少；而他的做法是把一个时代的科学放回它自己的条件里，问它为什么会那样看问题。

本编二十六章做的正是这件事，只是把“条件”具体化成了四条性质。

这件事要记明，因为它构成一个轻微的循环：本编用一种由库恩确立的史学方法，去处理包括库恩在内的二十六个人。

而这个循环本书不消除，只写明——与第三十六章末尾伍德沃德那一处循环（量尺子的人用的还是那把尺子）同一个处理方式。本编里有两处这样的循环，它们都出自同一个事实：本书没有一个站在外面的位置。

第二十九章 拉卡托斯

一、他的位置

拉卡托斯试图在库恩与波普尔之间找一条路。

他保留了可证伪性的精神，但把评价的单位从单个理论换成了研究纲领：一个纲领有一个不被直接检验的硬核，外面一圈可以被修改的保护带，加上正面启发法与反面启发法。纲领的好坏不看它有没有被反驳，看它是进步的还是退化的——是否不断预言新的事实并得到确证。

这一步救回了累积：科学的进展不是范式的非理性更替，而是纲领之间的竞争，而竞争有可评价的标准。

他的位置因此是：把构成装置具体化为纲领，同时给出一个不依赖范式内部标准的评价尺度。

二、他实际缺的那台装置

他缺的是可缩放。

“进步的”与“退化的”这个区分，是一个关于趋势的区分——一个纲领在一段时间里是否不断产出被确证的新预言。

而趋势与极限的差别，正是第六十九章整章的内容。

一个看起来正在进步的纲领，可能最终停下来；一个看起来退化的纲领，可能后来复活。拉卡托斯自己承认这一点——他明确说过，对纲领的评价只能是回溯的，不能用来在当下否决任何一个纲领。

而这个承认，就是缺可缩放的直接后果。

要把“进步/退化”从趋势变成极限，需要能在不同的资源水平上反复观察同一个纲领的行为。而纲领在历史上只被执行一次，而且执行它的资源由时代给定，不可调。

三、若装置到手

他的主张翻成本书的记号：

硬核 = 被固定住的那一部分；保护带 = 随路径调整的那一部分。

而他真正有趣的那个问题，在他的框架里问不出来：

硬核的选择，是路径依赖的吗？

一个纲领的硬核是被谁、按什么、在什么时候定下来的？若两个在其余一切上相同的共同体，会定下不同的硬核，那么硬核本身就是被造成的；若它们定下同一个，那么硬核由材料决定。

装置到手之后，这变成一条可跑的检验，而且它与第七十章那个“先在性生效的时点”高度同构：硬核在什么时候变得不可改，而那个时点是否随资源趋于零。

这一条不在本书的三条条款之内，也没有被跑过。它是本编的第三张空支票，与第十九章维柯那张、第二十二章黑格尔那张并列。

三张支票有一个共同点值得记一句：它们都不需要新的哲学，都需要新的实验；而三者之中，拉卡托斯那一张与第七十章那个新检验可以共用同一套设计。

还要补一句拉卡托斯那条“回溯评价”的纪律，因为本书在用它而没有说明。

拉卡托斯明确说过：对纲领的评价只能是回溯的，不能用来在当下否决任何一个纲领——一个此刻看起来退化的纲领，可能后来复活。

这条纪律在本书里有一个对应物：第六十四章那条“未能分辨”。

两者的结构相同：在证据不足以判决的时候，拒绝给出方向。

拉卡托斯拒绝的是“现在就否决这个纲领”，本书拒绝的是“现在就说倾向于支持”。

而两者面对的压力也相同：不给方向的评价看起来没有用，因而总有压力要求它给一个。第六十四章第五节论证过这种压力的来源——不明确的结果难以发表，而且几乎总能被加工成明确的。

因此拉卡托斯在本编里留给本书的，不是一条主张，是一条已经被实践过的纪律：一个允许“暂不评价”的评价体系，比一个永远能给出评价的体系更受数据约束。

第三十章 费耶阿本德

一、他的位置

费耶阿本德主张方法的多样性。

他的论证是历史性的：科学史上最重要的进展，往往是在违反当时被认可的方法规则的情况下取得的；任何一条被提出来的普遍方法规则，都能找到违反它而成功的案例。

由此他得出那个著名的口号——在方法论上，唯一不阻碍进步的原则是“怎么都行”。

这句话极易被误读，因此要写准它的实际内容：它不是说任何做法都同样好，它是说不存在一条在一切情形下都该遵守的规则。

他的位置因此是：构成装置不但可变，而且不存在一个对它的普遍规范。

二、他实际缺的那台装置

他缺的是可干预。

他的论证全部是反例式的：对任何一条规则，举出一个违反它而成功的案例。

而反例式论证在这里有一个限制：它能证明那条规则不是必要的，不能证明违反它造成了什么。

具体说：伽利略违反了某条规则而成功了，这件事可以有两种解释——违反那条规则使他到达了别处，或者违反那条规则只是让他走得更快，而他到达的仍是那一处。

分开这两种解释，需要的正是对照：同一批材料、同一个判准，一次遵守规则、一次违反，看到达的地方是否不同。

而他手上只有一次。

要说公道话：费耶阿本德对这一点并非没有感觉。他的论证策略恰恰是不断地举出更多案例——而更多案例不解决这个问题，这与第五十三章所说的案例天花板是同一件事。

三、若装置到手

他的主张翻成本书的记号，是本编里最直接的一次：

不同的 **P** 不但到达不同的结果，而且不存在一条使某个 **P** 优于其余的普遍规则。

装置到手之后，这句话分成两条可分别判的命题：

命题甲-不同的 **P** 到达不同的结果。这是本书的核心命题，条款一至三测它。

命题乙-不存在一条普遍的规则使某个 **P** 更好。这一条落在判准上——“更好”要按什么衡量。若按固定的 **L** 衡量，那么它是可测的：不同的路径在同一个判准下是否有稳定的优劣。而本书的设定恰好固定了 **L**，因此命题乙在这个现场上可以被试着测。

这里要写明一件对费耶阿本德不利的事，而且不能省：本书首跑的分组读数显示，种子差异在训练分布上被压得很平（第六十三章第四节）。也就是说，在既定判准上，不同路径的表现相当接近。

若这一点在更大规模上继续成立，那么命题乙在这个现场上为假——不同的路径确实在同一个判准下表现相当，因而“怎么都行”在判准意义上成立，但那恰恰说明判准选不出优劣，而不是说路径造成了不同的东西。

于是费耶阿本德在本编里的位置有一个反讽：他的两条命题在这个现场上可能一条真一条假，而真的那一条（甲）是造成论的，假的那一条（乙）恰恰是他最有名的那一条。

本书对此不下结论——命题甲尚未判决，命题乙也从未被正式测过。本章只指出它们是可分的，而在他那里它们是一句话。

最后补一句费耶阿本德那条被误读最多的主张，因为本编不该把它留在误读里。

“怎么都行”常被读成“任何做法都同样好”。而按他自己的论证，它说的是：不存在一条在一切情形下都该遵守的规则。

这两句话在本书的记号里差别极大。

“任何做法都同样好”是关于判准的——它主张判准选不出优劣。

“不存在一条普遍规则”是关于路径的——它主张没有哪一条 P 在所有 C、A、L 下都最优。

而第二句话，本书完全同意，且它与先在论也相容——先在论只需要主张不同路径到达同一处，不需要主张某条路径更快。

于是费耶阿本德那条最激进的口号，在本案上其实是中立的。

这件事值得记在本编里，因为它是“缺哪台装置”这个重排方式的一个副产品：按通常的排法，费耶阿本德是造成论一侧最激进的人；而按本书的记号，他那条最有名的主张落在本案之外。

第三十一章 布鲁尔与强纲领

一、他的位置

强纲领把知识社会学的适用范围推到了全部。

它的四条原则里，最有分量的是对称性：对一个信念为什么被接受的解释，与对另一个信念为什么被拒绝的解释，必须用同一类原因。

这一条挡住了一个此前通行的做法：把成功的科学归给自然与理性，把失败的归给社会与偏见。

那个做法的问题在于它预设了结论：只有先认定某个结论是对的，才会觉得它不需要社会学解释。于是社会学被派去解释错误，而对的东西被留给“事实本身”。

布鲁尔要求两边用同一套解释。这一步在方法上是干净的，而且它与本书第五十九章第二条那条“报告不利读数”的纪律属于同一类要求——不许对两侧用不同的标准。

二、他实际缺的那台装置

他缺的是可重跑，而第五十三章已经论证过案例的天花板。本章只写那里没写的一面：对称性原则本身需要什么才能被兑现。

对称性要求：成功与失败用同一类原因解释。

而“同一类”这件事怎么检验？

在一次只发生过一次的历史里，检验它的唯一办法是看叙述——两段叙述是否使用了同一类词汇。而这是对文本的检验，不是对事情的检验。

要真正检验对称性，需要的是：在同一套条件下跑很多次，其中一些成功、一些失败，然后看成功与失败的分布能否由同一组变量解释。

这件事需要重跑，而且需要很多次。

因此强纲领的对称性原则，在本编里有一个特别的位置：它是二十六章里唯一一条其兑现方式本身就是统计性的原则。它不要求某个具体案例被这样解释，它要求两类案例的解释方式相同——而“两类”这个说法已经预设了一个分布。

而分布需要样本，样本需要重跑。

三、若装置到手

对称性原则翻成本书的记号：

在固定 **C**、**A**、**L** 之下，到达不同结果的那些运行，其差异应当由同一组路径变量解释；不得对其中一部分诉诸“材料决定”，对另一部分诉诸“路径偶然”。

装置到手之后，这变成一条可执行的纪律，而且本书实际上在用它。

第七十四章第八节那个观察——多种子材料的作者识别出了“离群轨迹”——正好是对称性的一个试金石。若把表现好的运行解释为“学到了该学的东西”，把离群的解释为“训练不稳定”，那就违反了对称性。

按对称性，两者应当用同一组变量解释：它们都是在固定材料与判准下、由不同路径到达的结果，而差异的来源应当被统一地追问。

这一条本书没有专门测过，但它规定了第七十四章第六节那个处理方式：离群轨迹只能作旁证，不能被单独拿出来当证据——因为单独拿出来，就等于对离群者与非离群者用了不同的标准。

布鲁尔因此在本编里的位置是：他给的不是一条关于世界的主张，是一条关于解释的纪律；而那条纪律在一个可重跑的现场上，第一次可以被真的执行，而不只是被要求。

还要补一处强纲领与本书的分歧，因为它关系到本书的一条硬规定。

强纲领的对称性要求：对信念被接受与被拒绝，用同一类原因解释。

而它的“同一类”指的是社会学的原因。

本书不采取这一步。本书的对称性只要求同一组变量，不要求那组变量属于哪一类。在本书的现场上，那组变量是 C、A、L、P——其中没有一项是社会学的。

这个差别有一个具体的后果：强纲领的对称性是一条关于解释类型的规定，本书的对称性是一条关于统计处理的规定。

前者可以被质疑为预设了结论（凭什么解释必须是社会学的），后者不能——它只要求不对不同的样本使用不同的标准。

因此本书在这一条上比强纲领弱，而弱得有用：第七十四章第六节那个“离群轨迹只能作旁证”的处理，若按强纲领的版本，会变成一条关于那些轨迹应当被怎样解释的主张；而按本书的版本，它只是一条关于样本不得被挑选的规定。

第三十二章 拉图尔

一、他的位置

拉图尔把仪器、材料、技术物写进了结果。

在他那里，一项科学事实的稳定，不是一个命题与世界对上了，而是一张网络被搭起来并被维持住——研究者、仪器、样本、文本、资助、标准化的操作，每一样都是这张网络的一个节点。移去其中足够多的节点，那个“事实”就不再稳定。

他还做了一件更彻底的事：他不把人与非人分成两类解释来源。仪器不只是被人使用的工具，它在网络里有自己的位置。

他的位置因此是：结果的规定散布在一张网络上，而不是集中在某一个认识者或某一个对象里。

二、他实际缺的那台装置

他缺的是可消融，而他的主张几乎就是一个关于消融的主张。

“移去足够多的节点，事实就不再稳定”这句话，形式上就是一次消融实验的预言。

而他执行不了它。他能做的是追踪——跟着研究者进实验室，记录网络怎么被搭起来。追踪是观察，不是干预。

这一处缺失有一个具体的后果：他的论证依赖于已经发生的稳定。他能说明这张网络是怎么搭成的，不能说明若某个节点不在，会搭成什么。

而后一个问题才是本案要的：换一条路，到达的是不是同一处。

要说公道话：拉图尔的追踪工作提供了本编里最细的过程材料。第七章第五节那个反问——手稿、通信、被放弃的路线是不是过程的残留——在他这里得到的材料最多。而第七章第五节的结论是：那些材料再细，也仍然只是一次。

三、若装置到手

他的主张翻成本书的记号：

R 由 **C** 中的多个部分与 **A** 中的多个部件共同决定，且各部分的贡献不可先验地分开。

这与第二十五章杜恒的整体论在形式上高度相似，区别在于杜恒讲的是命题之间的关系，拉图尔讲的是异质节点的网络。

装置到手之后，两者用同一种实验来判：从语料中精确删除某一子集、某一文体、某一语言、某一时间段，然后重跑（第四十四章第四节）。

而拉图尔的版本多要一样东西，值得单独指出：他的网络里有非文本的节点——仪器、标准、操作规程。在本书的现场上，这些对应的是架构、优化器、训练配置——即 **A** 与 **P** 的一部分，而不是 **C**。

于是他的主张实际上要求一个比杜恒更广的消融：不只删材料，还要删装置的部件。

这一条在工程上完全可做（去掉某个结构、某个训练技巧、某个正则项，再重跑），而且它在机器学习里是常规操作——只是它被用来回答“这个部件有没有用”，从未被用来回答“这个部件是否进入了结果的规定”。

这又是第七十四章第八节那个机制的一次实例：同一个动作，问不同的问题，而后一个问题没人问。

最后补一处拉图尔与本书最不相容的地方，因为不写它，本章就偏向了。

拉图尔的网络里，人与非人不分成两类解释来源。

而本书的整个设定预设了一个分工：C、A、L 是被固定的，P 是被改变的；实验者站在外面做干预。

这个分工在拉图尔的框架里是可疑的——它把实验者当成了网络之外的一个点，而按他的说法，实验者也是网络的一个节点。

本书对此的回答有限：第四十六章承认这台装置自己也是被造出来的，第八十七章第七节承认本书也在它所描述的机制之内。但本书仍然保留那个分工，因为没有它就没有对照组。

于是本章以一句对本书不利的话结束：本书的判据要求一个站在外面做干预的位置，而拉图尔的框架否认这种位置存在。这个分歧本书没有解决，只是靠程序绕过——把干预的每一步写下来，使别人可以从外面检查那个“外面”是怎么被划出来的。

第三十三章 哈金：干预主义的锋利与它的射程

一、他的位置

哈金把判据从表征移到了干预。

第十三章第一节已经写过那一步，本章不重复。本章写第十三章没写的一面：他自己对那一步的射程有相当清楚的自觉。

他的工作不只是提出“能用它干预别的东西就相信它实在”。他还做了另一件事：把现象本身当作被制造的东西来研究——实验室里那些稳定的、可重复的效应，在自然界的常态中并不出现，它们是被创造并被维持住的。

这一步是造成论的，而且它出自一个在实在论问题上立场并不激进的人。

他的位置因此是：在对象层面，干预支持实在论；在现象层面，制造是真实的。两者并不矛盾，它们说的是不同层次的事。

二、他实际缺的那台装置

他缺的是可重跑，而且他缺的方式是全编最特别的一种：他的判据的射程止于对象，不及过程。

干预主义要求能操纵 X 并看 Y 是否改变。哈金用它去论证电子实在——我们能操纵电子。

而本案要操纵的是“知识的形成路径”。

这就是第四十一章第三节那个诊断在人身上的版本：在任何一个已经成形的领域里，你能干预的是该领域之内的东西，不能干预的是该领域本身的形成。

哈金能干预电子，不能干预“电子这套理解是怎么形成的”。

要说得更准一些：他的现象制造论已经走到了门口——他研究的正是“某个稳定的效应如何被造出来”。而那仍然是在一个既定的理论与仪器传统之内造效应，不是把那个传统本身重造一遍。

三、若装置到手

他的两条主张翻成本书的记号，会分开落到两处：

主张一（干预支持实在论）：翻不过来，因为它讲的是对象，而本案讲的是结果的规定。本书不使用它。

主张二（现象是被制造的）：翻成“某些稳定的可重认者，其规定依赖于造它的那条路径”——这就是本书的核心命题，只是范围被限制在实验室现象上。

装置到手之后，主张二第一次可以被推到极限。

哈金能说的是：这个效应是被造出来的。他不能说的是：换一条路造，会不会造出别的。

而本书的条款一至三，测的正是后者。

因此哈金在本编里的位置可以一句写定：他给了本书判据的形式（干预），也给了本书命题的内容（现象被制造），而他缺的是把两者接起来所需要的那样东西——一个形成过程可被重跑的现场。第四编换现场，换的就是这个。

最后补一件对哈金公道的事。

哈金那条判据的锋利，在于它把判断的负担从“理论有多好”移到了“你能不能动手”。而这个移动有一个常被忽略的后果：它使一个立场可以被实践所检验，而不只是被论证所检验。

本书的全部程序都是这个后果的执行：写死败绩条件是“你能不能动手判自己输”，公开预注册是“别人能不能动手查你”，报告分母是“别人能不能动手拆开你的量”。

三件事都是干预，只是干预的对象是本书自己。

因此哈金在本编里留下的不只是一条判据，还有一种态度：一个主张的可信度，取决于它给别人留下了多少可以动手的地方。

而按这个标准，本书最该被检查的地方已经列在第六章第七节那五处——其中四处可修，一处不可修。

第三十四章 卡特赖特

一、她的位置

卡特赖特主张物理学的定律并不普遍地为真。

她的论证是：那些被写下来的基本定律，之所以能被说成真的，是因为它们描述的是理想情形；而它们一旦被用于具体的、混杂的实际情形，要么需要大量的修正，要么根本不适用。真正在具体情形中起作用的，是局部的、有边界的因果知识。

这一步对第二章那第三条骨架是一次打击：知识不是一张覆盖一切的网，它是一块块各有适用范围的补丁。

而它对本案的意义在另一处：若定律是局域的，那么“某个定律在那里等着被发现”这句话就要问——在哪里？在哪些情形里？先在性被局域化了。

二、她实际缺的那台装置

她缺的是可缩放。

局域性这个主张，有一个自然的追问：随着知识的增加，那些补丁会不会拼成一整张网？

若会，那么局域性是暂时的——它是“你还没走到”。若不会，那么局域性是结构性的。

这正是第五十二章那个承重区分在她的主张上的应用，而她无法做这个区分，因为她没有一个可以逐级加上去的资源轴。

她能给出的是现状：今天的物理学确实由许多有边界的模型拼成。她不能给出的是趋势的极限。

这一处缺失决定了这条主张在争论中的位置：它被当作对科学统一性的一个质疑，而对手总可以回答“还早着呢”。而“还早着呢”这句话，正是计算性路径依赖的日常表述。

三、若装置到手

她的主张翻成本书的记号：

不存在一个单一的 Φ 覆盖所有情形；实际有效的是一族局部的 Φ_i ，各有其定义域。

装置到手之后，这变成一条与条款二直接相关的命题。

条款二问的是：路径间的结果差异能否由一个只以 C、A、L 为自变量的描述覆盖。

而卡特赖特的主张可以被读成一个关于那个描述的形状的主张：即使存在这样的描述，它也不是单一的，而是分片的。

这里有一个对本书重要的细节：一个分片的描述，仍然是只以 C、A、L 为自变量的描述。因此卡特赖特的局域性本身不推出路径进入规定。

换句话说：她的主张与先在论的弱版本相容——解集由材料与装置决定，只是那个决定是分片的而不是整体的。

这一点要写明，因为它防住一次误用：有人可能把“定律是局域的”当作造成论的支持。不是。局域性说的是描述的形状，路径依赖说的是描述里有没有 P 这一项。两件事可以各自独立地成立或不成立。

而她给本书留下的是一个更窄、也更有用的问题：若可达集确实需要一个分片的描述才能覆盖，那么分片的边界是由什么决定的——由材料，还是由路径？这个问题在本书的框架里是可问的，而本书没有问。

这一问要补一句它的分量，因为它比看起来更靠近本书的核心。

若分片的边界由材料决定，那么条款二仍然可以通过——只是那个覆盖可达集的描述是分片的。

若分片的边界由路径决定，那么情况就完全不同了：不同的路径不只到达不同的点，它们还切出不同的分片方式。

而后一种情形，是本书所能想到的构成性路径依赖的最强形态——比第五十二章那个定义还要强一层：不是“从这条路走过去那里没有那个东西”，而是“从这条路走过去，那里的分类方式本身不同”。

这一形态在本书的三条条款里没有位置。条款一量直径，条款二问覆盖，条款三问是否满，三者都假定了可达集的元素可以被一致地比较，而这一形态恰恰质疑那个假定。

于是卡特赖特在本编里留下的是第四张空支票，而且是四张里最难兑的一张：它需要一条本书没有的判据，而不只是一次本书没跑的实验。

第三十五章 皮克林：实践冲撞与它无法重跑的困境

一、他的位置

皮克林把科学实践写成了一场冲撞。

研究者带着目标去操作物质世界，物质世界以阻力回应；研究者调整目标、调整仪器、调整对结果的解释，直到阻力被容纳。他称这个过程为阻力与容纳的辩证，而结果是突现的——它不由研究者的意图单独决定，也不由物质世界单独决定。

这是造成论里最容易被误读为主观主义的一个版本：物质世界的阻力是真实的、不由人安排的；而结果仍然不是先定的。

他的位置因此是：结果在一个双向的过程中被造成，而这个过程的时间性是本质的——阻力何时出现、以什么方式被容纳，进入了结果。

二、他实际缺的那台装置

他缺的是可重跑，而第五十三章已经用他作过例子。本章写那里没写的一面：他的主张比别人更需要重跑。

理由在“突现”这个词上。

若结果是突现的——不由任一侧单独决定——那么唯一能支持这个说法的证据形式，是重跑之后得到不同的东西。

因为：若重跑得到同一个，那么它是由双方共同决定的，而“共同决定”仍然是决定——结果仍然由材料与装置的组合唯一定下，只是定下的方式复杂。那是先在论的弱版本，与他要说的不是一回事。

于是他的主张有一个特别的处境：它比库恩、比强纲领、比拉图尔都更依赖重跑，而它拿不到。

要说公道话：皮克林的记述细到令人惊讶——他能把一段研究里每一次调整、每一次挫折、每一次重新定义目标都记下来。而这些材料越细，第五十

三章那个天花板就越刺眼：一份极完整的单次记录，仍然不含有区分两种读法的信息。

三、若装置到手

他的主张翻成本书的记号：

在固定 **C**、**A**、**L** 之下，不同的 **P** 到达实质不等价的结果；而“实质不等价”包括它们各自所容纳的阻力不同。

装置到手之后，冲撞这个概念有一个字面的对应物：训练过程中的损失下降不是平滑的，它有停滞、有突变、有相变（第七十三章）。

而那些停滞与突变，形式上正是阻力与容纳。

因此皮克林的主张在这个现场上有一条可跑的检验：不同路径所遇到的停滞与突变，是否出现在同一处、以同一方式被跨过。

这一条与第二十二章黑格尔那张空支票是同一张——训练轨迹的中间状态是否跨路径地按同一次序排列。

两人隔着一百五十年，缺的是同一台装置，而且装置到手之后要跑的是同一个实验。这件事值得在本编记一笔：它说明“缺哪台装置”这个重排方式，确实把此前不相干的人排到了一起。

最后补一句皮克林那条“突现”与本书核心命题的分界，因为两者很像而不相同。

皮克林的突现说的是：结果不由研究者的意图单独决定，也不由物质世界单独决定。

而本书的核心命题说的是：结果不由材料、装置、判准三者共同决定——还需要路径。

两句话的差别在于“共同决定”这四个字。

皮克林所否认的是单方决定，而单方决定本来就没有人主张。先在论主张的是材料与装置共同决定，而这与皮克林的突现完全相容。

于是皮克林那条最有特色的主张，其实比本书的核心命题弱。

要让它达到本书的强度，必须再加一句：那个双向过程的具体进行方式，进入了结果的规定，而且这个进入不随资源消失。

这一句他没有说，而且按第二节，他也说不了——说它需要重跑，而重跑正是他缺的那台装置。

本章因此以一句话收尾：皮克林把过程写得比任何人都细，而他的结论比他的材料所能支持的要弱一档；缺的那一档，恰好是本书要去量的那一档。

第三十六章 伍德沃德：因果的干预定义如何直接给出本书的语法

一、他的位置

伍德沃德把干预提升为因果概念的核心。

第十三章第一节已经引用过那条定义，本章不重复。本章写第十三章没写的一面：那条定义对被操纵的那个变量提出了什么要求。

按他的框架，一次干预不是随便的改动。它要满足若干条件：它要直接作用于被干预的变量；它不能通过别的路径影响结果；它要切断该变量原有的一切致因。

这套条件的用意很清楚：只有这样的改动，才能把“X变了 Y 跟着变”读成“X 是 Y 的原因”，而不是读成“有第三个东西同时影响了两者”。

他的位置因此是：因果不是一个形而上学的关系，它是一个关于“如果这样动它会怎样”的关系；而要问这个问题，必须有一个可被这样动的变量。

二、他实际缺的那台装置

他缺的不是一台仪器，是一个对象。

这是本编二十六章里唯一一处“缺的装置”与“他自己的判据”直接对撞的地方，值得写清。

他的定义要求一个可被操纵的变量。而本案要操纵的那个变量是“知识的形成路径”。

在他写作的时候，那不是可被操纵的变量。

- 它不能被直接作用——你不能把一段研究的路径拿过来改一改。
- 它不能被切断原有致因——一段研究的路径是由整个时代决定的。
- 它不能被单独改变而保持其余不变——第十三章第三节那句“没有两个其余一切相同的十七世纪欧洲”说的就是这件事。

于是出现一个精确的情形：他给出了本案所需要的全部语法，而那套语法在本案上没有宾语。

要说公道话，而且要说足：这不是他的疏忽，也不是他的主张有缺陷。一条要求可操纵变量的定义，在没有可操纵变量的地方不适用——这恰恰说明那条定义是有内容的。一条在任何地方都适用的因果定义，反而什么也不排除。

三、若装置到手

装置到手之后，那个缺失的宾语出现了。

第四编第四十四章第三节写的那三件事——只换随机种子而保持其余一切不变；只换数据的呈现次序而保持数据集不变；只换课程安排而保持总量不变——逐条满足他对“干预”的要求：

- 直接作用于路径变量本身。
- 不通过别的路径影响结果（因为材料、架构、判准逐位对齐）。
- 切断该变量原有的一切致因（种子由实验者指定，不由别的东西决定）。

于是本书的整套判据，可以被读成他那条定义在一个新出现的宾语上的第一次应用。

四条性质（可重跑、可干预、可消融、可观测）不是本书发明的，它们是那条定义在本案上的展开（第四十章第七节）。三条条款是那次展开的操作化。

而这带来一个本书必须承担的依赖，第四十章第七节写过，这里再确认一次：

本编的全部排除结论，都以“判决需要干预”为前提。这个前提本身不是本书论证的，它是借来的。

因此伍德沃德在本编里的位置是最特别的一个：其余二十五人是被本书的判据去量的对象，而他是那把尺子的来源。量尺子的人用的还是那把尺子——这一处循环本书无法消除，只能写明。

还要补一句这处循环的实际后果，因为它不是纯形式的。

若干预主义本身是错的——若因果关系不必以可操纵变量为核心——那么本书的四条性质就不是判决本案所必需的，而第四编据此排除三个候选的理由也就相应变弱。

具体会变弱到什么程度？

量子测量那一章（第四十一章）的排除理由是“被干预的不是形成过程”；实验演化那一章（第四十二章）是“对象不是知识”。后者不依赖干预主义，前者依赖。

于是若干干预主义倒了，第四十一章的排除要重做，第四十二章的不用。

这件事要写明，因为它是本书可能出错的第六处——第六章第七节列了五处，这是第六处，而它比前五处更靠前：它不在判据里，在判据所依赖的因果观里。

本书对它的处理只能是写明依赖，不能是论证它成立——论证一条因果观，超出本书的能力，也超出本案的范围。

第三十七章 皮亚杰

一、他的位置

第十二章第二节已经处理过他的阶段序列与那处自伤。本章不重复，只写那里没写的一面：他的方法本身。

皮亚杰做的事情，在本编二十六人里是独一份的：他去看过程。

不是去看知识的成品，不是去分析概念，而是坐下来看一个具体的孩子在一个具体的任务上做什么、说什么、什么时候改主意。守恒任务、三山任务、钟摆任务——每一个都是一次设计好的观察。

而他还做了一件更要紧的事：他把中间状态当作有意义的东西来记录。一个孩子过渡期里给出的那些“错误”回答，在他那里不是噪声，是结构。

他的位置因此是：造成论第一次有了一套观察过程的方法。

二、他实际缺的那台装置

他缺的是可干预。

而这一处缺失的形状很特别，因为他离干预只差一步。

他的方法已经是准实验的——设计任务、控制条件、记录反应。他甚至做过训练研究：教一个尚未达到守恒的孩子，看能不能加速。

而他做不到的是本案所要的那一种干预：

改变建构的路径，而保持材料与判准不变，然后看到达的结构是否不同。

具体说：让两个孩子接触同一批经验，只改变呈现的次序，看他们最终构造出来的守恒概念是否在结构上不同。

做不到的原因有三条，逐条写明，因为它们在第八十三章会原样复现：

其一，没有“同一个孩子重来一遍”这回事（缺可重跑，因而缺噪声基线）。

其二，换了次序，别的东西就跟着变——讲法变、例子变、孩子的提问变（干预不是外科式的）。

其三，判准在教育现场不固定，而且它的不固定是被追求的。

这三条在第八十三章第三节被列为那条课堂检验的困难，而它们的原型在这里。

三、若装置到手

他的主张翻成本书的记号：

在固定 **C**、**A**、**L** 之下，不同的 **P** 到达同一个终点结构，只是速率不同。

这是先在论的一个实现机制（第十二章第二节那句话），而它现在可以被判了。

装置到手之后，皮亚杰的主张变成条款一的一个实例：路径差异是否随资源衰减到噪声。他预言是；本书的核心命题预言否。

而他留给本书的，不是这条主张，是那套方法。

第六十二章要求保留逐层读数、第六十三章要求分组报告、第六十五章要求报告分母——这些做法的共同祖先是“把中间状态当作有结构的东西来记录”，而那是他的。

因此本章以一句对他的话结束：他的结论在这个现场上很可能被判负，而他的方法在这个现场上正在被使用。两件事都要记。

还要补一处皮亚杰与本书在“错误”这件事上的共同点，因为它在方法上是本编最实用的一条。

皮亚杰把孩子的错误回答当作结构来读，而不是当作噪声。一个在过渡期里的孩子，其回答既不是对的也不是随便的——它有自己的组织方式。

本书第八十三章第五节那三样要测的东西里，第二样是“失效的模式”：出错时错在哪里，是同一类错还是不同类错。

这一条直接来自他。

而它的理由也与他一致：正确的回答被判准压平了——所有答对的人在分数上相同；错误的回答没有被压平，因此它携带更多关于结构的信息。

这是第五十五章第一条硬规定（不得用任务分数）的一个正面版本：那一条说不要用被压平的量，而这一条说去用没被压平的那一部分。

本编二十六人里，皮亚杰是唯一一个给出了这种正面方法建议的人。其余各位给的是问题、判据或困难；他给的是一个可以照着做的动作。

第三十八章 维果茨基：路径进入结果的第一份经验材料

一、他的位置

维果茨基主张高级心理机能是在社会互动中、通过中介工具形成的。

关键是“中介”这个概念：人不是直接与对象打交道，而是通过工具——语言、符号、计数系统、记忆术。而这些工具不是中性的传输通道，它们改变所形成的那个机能本身。

一个用手指计数的孩子与一个用算珠的孩子，形成的不是同一个数概念的两种表达；按他的说法，形成的是结构不同的机能。

他的位置因此是：这份谱系里第一个明确主张“工具进入结果的规定”、并且拿出经验材料的人。

这一句要说准：康德主张构成装置进入对象，但装置普遍；皮亚杰主张建构，但序列普遍。维果茨基主张的那个中介工具，是历史的、文化的、可以不同的。

他因此是本编里唯一一个没有踩中普遍性自伤的人。

二、他实际缺的那台装置

他缺的是可重跑。

他的主张有一个天然的检验形式：两群人使用不同的中介工具，形成的机能是否在结构上不同。

而跨文化比较正是这种检验的近似形式，他与同事也做过这方向的工作。

近似形式的毛病是：两群人不只中介工具不同，别的也全都不同——生活方式、语言、生计、教育制度。干预不是外科式的。

而更要命的是第二条：没有办法把同一群人用另一套工具再养一遍。

于是他的主张停在一个强有力但无法收尾的位置上：材料显示工具与机能之间有系统的关联，而“这个关联是否会随资源消失”这个问题提不出来。

要说公道话：维果茨基工作的时间很短，他的许多主张是纲领性的。本章不把“他没做完”算作缺陷——本编第一条纪律在这里适用：缺一台尚未被发明的装置，不是任何人的过错。

三、若装置到手

他的主张翻成本书的记号，是二十六人里最直接的一次：

中介工具 $\subset P$ 。换工具即换路径；而他主张换了之后结果的规定不同。

这就是本书的核心命题，只是他说的是人，本书说的是模型。

装置到手之后，这条命题第一次可以被推到极限。

维果茨基能给出的是：工具不同，机能不同。他不能给出的是：这个不同是否随资源衰减。

而条款一测的正是后者。

还有一处对应值得指出。他的中介工具是外部的、可以被指定的——你可以规定一个孩子用算珠而不是手指。在本书的现场上，与之最接近的是数据的呈现方式与次序：它同样是外部的、可以被逐位指定的。

因此第五十六章形式三（次序可交换性检验），在概念上是他那条主张的直接后裔：同一批材料，不同的中介安排，最终形成的东西是否可交换。

而第六十六章那条探索性读数（只换数据次序造成的行为差异 **0.138**，不小于两者都换的 **0.116**），是这条线上第一份来自可重跑现场的读数——三对样本，不能当结论，但方向正确。

本编二十六章里，维果茨基是与本书核心命题最近一个人。写明这一点，是因为按通常的排法，他不会出现在一份关于“知识是被发现还是被造成”的谱系里。而按“缺哪台装置”重排，他排在最前面的位置之一。

最后补一处维果茨基与本书的分界，因为他与本书太近，不划反而危险。

他主张中介工具进入所形成的机能。而他没有主张、本书也不替他主张的是：那个进入是否随资源衰减。

这正是第五十二章那个承重区分。

一个用算珠长大的人与一个用手指长大的人，其数概念的差别，会不会随着两人各自学得更多、更久、更深而消失？

若会，中介工具的效应是计算性的——它影响到达的快慢与途径，不影响到达的那个东西。这与先在论完全相容。

若不会，它是构成性的——而这才是本书的核心命题。

维果茨基没有回答这个问题，而且按第二节，他回答不了。

因此本章要写明：维果茨基是本编与本书核心命题最近的一个人，而“最近”不等于“相同”。他主张路径进入结果，本书主张路径进入结果且不随资源消失；后一句多出来的那一半，正是本书全部判据要去量的那一半。

把这条分界划清，是本编对他最大的尊重——不把一个没说过那句话的人说成说过。

第三十九章 古尔德与康威·莫里斯

一、他们的位置

第四十二章第一节已经写过那个思想实验，本章不重复。本章写那里没写的一面：这场争论的证据结构。

古尔德主张：把地球史倒回寒武纪再跑一次，得到的生物圈将完全不同。他的材料是伯吉斯页岩的动物群——那里有大量此后没有留下后代的身体构型，而幸存与灭绝之间看不出系统的优劣。

康威·莫里斯主张：会大致相同。他的材料是趋同演化——眼睛、飞行、滤食、社会性，在互不相关的谱系中被反复独立地演化出来。

两人用的是同一个现场、同一类材料，而结论相反。

二、这场争论缺的那台装置

缺的是可重跑，而本章要指出的是：双方都明确知道这一点，并且都试图用别的东西替代它。

古尔德的替代品是“偶然事件的放大”：指出那些关键分叉处的事件没有系统的原因，因而重跑会不同。

康威·莫里斯的替代品是“独立重复”：把不同谱系上的独立演化当作“已经重跑过很多次”。

两个替代品各有一个毛病，而毛病正好互补。

古尔德那个：从“这一次的分叉看不出原因”推不出“重跑会不同”——看不出原因可能只是没看出来。

康威·莫里斯那个：不同谱系不是同一次重跑——它们的起点不同、环境不同、时间不同。趋同说明某些解在很宽的条件下被反复找到，不说明在同一条条件下重跑会找到同一个。

两个毛病是同一个毛病：没有对照。

因此这场争论在本编里的位置是全书诊断的最干净的一次外部印证：一场形式完全正确、双方都很清楚自己需要什么、而材料在原则上不可得的争论。

三、若装置到手

第四十二章第四节已经写过实验演化为什么不是本案的实验台——它的对象是生物性状，不是知识。本章不重复。

本章要写的是另一件事：这场争论与本案是同构的，而同构本身有用处。

把两边的主张翻成本书的记号：

- 古尔德：Reach 的元素实质不等价，且不随资源收敛。
- 康威·莫里斯：Reach 中的元素在与功能相关的层面上彼此等价，差别至多是实现方式。

两句话与第四十九章那两个可测形式逐字对应，只需把“结果”换成“生物圈”。

这个同构有三个用处，逐条写明。

用处一它说明本案的形式不是本书生造的。同一个形式在另一个领域里被两位专家各自独立地用到，而且他们的争论至今活着。

用处二它提供了一个已被验证的实验形式。第四十二章第五节写过：重放实验与本书条款三在三处对应——回放不同时间点、标定的不可达、判负条件的形式。本书的条款三不是凭空设计的，它照抄了这场争论逼出来的实验。

用处三，也是本章的收尾：这场争论的处境说明，本书的诊断在本案之外是可检验的。

第八十七章第三节那条一般观察，说的正是这一类处境——不可判来自过程不可重跑，而解药不是更强的论证，是一台能重跑它的人工系统。

古尔德与康威·莫里斯这一对，是那条观察的第二个实例——而且在它那里，实验演化已经使争论部分地改变了类型（第四十二章第六节）。

第一个实例是本案。

于是第三编以一句话结束，它也是这二十六章的总账：

二十六个人，缺的不是同一台装置，但缺失的后果是同一个——他们各自把问题推到了一个只差一次重跑的位置上，然后停在那里。

四、第三编总账

本编二十六章交出的东西，清点一次。

其一，一张重排表。二十六人按“缺哪台装置”重排，而不按学派、年代或立场。这张表的价值不在于新奇，在于它把此前不相干的人排到了一起——黑格尔与皮克林缺的是同一台装置，装置到手之后要跑的是同一个实验（第三十五章第三节）。

其二，四张空支票。维柯（人造物与非人造物的可达集是否同构）、黑格尔与皮克林（中间状态是否跨路径同序）、拉卡托斯（硬核的选择是否路径依赖）、卡特赖特（分片的边界由什么决定）。前三张需要新实验，第四张需要新判据。

其三，两处循环。本编用一种由库恩确立的史学方法处理包括库恩在内的二十六人（第二十八章）；本编用一把由伍德沃德给出的尺子去量包括伍德沃德在内的二十六人（第三十六章）。两处都不消除，只写明。

其四，一处对本书不利的发现。费耶阿本德那条最激进的主张，按本书的记号落在本案之外；库恩那一半最重要的主张，本书判不了；而马赫所指出的记法自由度，换现场并不解除（第二十三章）。

其五，也是本编真正的产出：二十六条“若装置到手，他的主张会变成什么”。

这二十六条里，有的落到条款一（柏拉图、皮亚杰、彭加勒），有的落到条款二（亚里士多德、杜恒、拉图尔、卡特赖特），有的落到条款三（库恩的不可通约、费耶阿本德的甲命题），有的给出新的检验（笛卡尔的起点、拉卡托斯的硬核、维果茨基的次序）。

而把它们排在一起，会看见一件事：本书那三条条款，不是为了判某一个人而设计的。它们是二十六个人各自停下来的那个位置的公因式。

第四编 实验台

第二编第十三章交出了一份清单：可重跑、可干预、可消融、可观测。本编的任务只有一件——拿这份清单去卡候选。

四个候选被逐一检查：量子测量、实验演化、早期人工生命与遗传算法、大模型训练。前三个各缺至少一条或各有一处对象错位，第四个四条同时满足。

本编的结构因此是重复的，每一章一个候选，逐条对照同一份清单。重复是有意的——一份检验清单的价值，全部在于它被一视同仁地使用。

末章处理一件无法回避的事：这台装置自己也是被造出来的。它不是自然界提供的实验室，是工程界提供的；而工程界提供它的时候，想的完全是别的事。本书对这一层的处理不是回避，是把它写进程序。

第四十章 判决需要的四条性质

一、这一编的任务

第二编第十三章给出了一份清单：可重跑、可干预、可消融、可观测。

这一编的任务只有一件：拿这份清单去卡候选。

四个候选被逐一检查——量子测量、实验演化、早期人工生命与遗传算法、大模型训练。前三个各缺至少一条，第四个四条同时满足。

本编的结构因此是重复的：每一章一个候选，每一章逐条对照同一份清单。重复是有意的——一份检验清单的价值，全部在于它被一视同仁地使用。若对某个候选宽一点、对另一个严一点，清单就失去了作用。

本章把四条性质写清楚，包括每一条为什么必需、以及每一条失效时会发生什么。第四十六章处理一件本编无法回避的事：这份清单所选出的那台装置，它自己也是被造出来的。

二、性质一·可重跑

同一个形成过程能被从头再跑一次。

为什么必需。第七章那道闸的根源是“只有一件产物”。两种起源假设在一件产物上不留下不同痕迹；而在一百件由同一材料、不同路径产生的产物上，它们留下的痕迹可能不同——先在论预期那一百件彼此等价，造成论预期不等价。

因此可重跑不是四条里的一条，它是其余三条的前提：没有第二次，就没有对照可言。

它失效时会发生什么。研究退回到案例研究。第五十三章已经论证过案例的天花板：一段只发生过一次的过程，不含有区分“你还没走到”与“那里没有那个东西”所需要的信息。

要写明这一条的严格程度。“再跑一次”必须是字面意义的——同一个过程重新执行，而不是“做一件类似的事”。一个相似的实验、一个平行的案例、一个类比的系统，都不满足这一条。相似不是重跑。

三、性质二·可干预

能只改变路径而保持材料与装置不变。

为什么必需。这是对照组的定义。若在改变路径的同时材料也变了，那么观察到的结果差异无法归因——它可能来自路径，也可能来自材料。

干预主义的那条判据（第十三章）要求的正是这个：X 是 Y 的原因，当且仅当存在对 X 的适当干预会改变 Y。“适当”的全部内容，就是只动 X。

它失效时会发生什么。研究退回到相关性观察。可以看到路径不同时结果不同，但无法排除第三因素。

这一条有一个常被忽略的要求：干预必须是外科式的。不是“大致只改了路径”，而是精确地只改一项，其余逐位对齐。第五十六章第五节那条实验规格里最要命的一条——组内共享条件必须严格对齐——就是这个要求在具体设计上的形态，而首跑正是在那里栽的跟头。

四、性质三·可消融

能删掉过程中的某一部分再跑，看缺了它会怎样。

为什么必需。前两条能回答“路径是否影响结果”，这一条回答的是一个更细的问题：路径的哪一部分在起作用。

若没有这一条，即使测到了路径效应，也无法定位它。一个测到了效应却无法定位的读数，其解释空间几乎是无限的。

它还有一个本案特有的用处：它使“如果没有某某会怎样”这类问题第一次有了字面的回答方式。科学史上这类问题只能被推测（第十三章第四节），而在一个可消融的系统上，它们可以被执行。

它失效时会发生什么。研究能报告“路径有效应”，不能报告“什么样的路径差异造成什么样的结果差异”。条款二与条款三都需要这一条——条款二要检查差异能否由材料的量预测，条款三要检查某个结果是否只有某条路径到得了，两者都要求能对路径做定向的改动。

五、性质四·可观测

过程的中间状态被完整记录，而不只留下最终产物。

为什么必需。路径就是中间状态的序列。只看起点与终点，路径是看不见的。

而且这一条与第七章那道闸直接对应：那道闸的表述是“所有可供检查的东西都是产物，而过程已经消失了”。可观测这一条要求的，正是过程不消失。

“完整”这个词要说明。它不要求记录每一个瞬间——那在任何系统里都做不到。它要求的是：中间状态是被保存的，而不是被推测的；并且保存的密度足以让人看出过程的形状。

它失效时会发生什么。研究只能做输入输出分析。可以知道不同的路径给出不同的结果，但不知道分化发生在何时、以什么方式。第七十章那个“先在性

生效的时点”这类问题，完全依赖这一条——没有中间状态，那个时点无从测起。

六、四条不可互相替代

一个自然的问题：能不能用三条替代四条？比如用更多次的重跑，弥补不能消融？

不能，而且理由对每一对都不同：

- 重跑多次不能替代干预：若每次重跑时材料也在变，次数再多也归因不了。
- 干预不能替代可观测：可以知道改了路径结果变了，但不知道中间发生了什么，因而无法区分“一开始就分化了”与“最后才分化”。
- 可观测不能替代可重跑：把一段过程记录得再完整，它仍然只发生了一次。

四条是四个不同的缺口，堵住一个不会自动堵住另一个。

这一节的用处在下一章开始显现：本编排除三个候选时，用的正是这条原则——一个候选在某两条上做得极好，并不能补偿它在第三条上的缺失。

七、这份清单是从哪来的，以及它可能漏掉什么

在立使用规则之前，交代两件事，因为一份清单若不说来历，就只是四条被断言的要求。

来历：四条不是本书发明的，它们是干预主义那条判据（第十三章）在本案上的展开。伍德沃德那条判据说， X 是 Y 的原因当且仅当存在对 X 的适当干预会改变 Y 。把它对准“路径是否是结果的原因”，要能做的事就是：把过程再跑一次（可重跑），只动路径（可干预），删一段看看（可消融），并且看得见中间发生了什么（可观测）。

这个来历有一个后果，对本书不利，要写明：四条继承了干预主义的全部前提。若有人认为干预不是因果的核心——若有人主张存在某种不能被干预的因果关系——那么这份清单就不是唯一可能的清单，而本书排除三个候选的理由也就相应变弱。

本书接受这个依赖，并写明它：本编的全部排除结论，都以“判决需要干预”为前提。这个前提本身不是本书论证的，它是本书借来的。

可能漏掉什么，列两条本书想到的。

漏掉之一：路径变量的完备性。四条要求能只改变路径，却没有要求知道路径由哪些变量构成。实际中路径包括随机初始化、数据次序、批次构成、学

习率安排、硬件的数值行为，还可能包括尚未被识别的项。若有一项没被识别，“其余不变”这句话就是假的。首跑第六十六章那处组内共享条件不齐，正是这一漏洞的一次实例。

漏掉之二：观测的代价。四条把可观测当作一个二值性质，而实际上观测有密度、有代价、有取舍。第四十四章第五节会指出，公开检查点的保存间隔后来成了噪声基线定义里一个未被识别的自由参数。一条只问“能不能看见”而不问“看得多密”的性质，会漏掉这一类问题。

两条都不足以使清单作废，但它们说明一件事：清单能排除明显不合格的候选，不能保证合格者一定够用。第四十六章那一整章讲的就是合格者自身的代价。

八、清单的使用规则

最后立三条使用规则，它们约束本编其余各章。

规则一：四条必须全部通过。通过三条不是“接近”，是不通过。理由在上一节。

规则二：判断一个候选是否通过某一条，要看它对本案所关心的那个对象是否通过，而不是看它在一般意义上是否通过。这一条在下一章处理量子测量时立刻用得上一——那个现场在物理实验的意义上高度可干预，但被干预的不是本案所关心的对象。

规则三：通过四条不等于能判本案。四条是必要条件，不是充分条件。还需要第五编那一步——把待判的命题翻译成这台装置能回答的形式，而翻译本身可能失败。本编只负责必要条件。

下一章开始逐一检查候选。第一个是最有名的一个。

第四十一章 为什么不是量子测量

一、这个候选为什么看起来最合适

量子测量是被援引得最多的候选，而且它的表面吸引力极大。

玻尔学派的主张听起来像现成的判决：被测量的属性在测量之前没有确定值；测量装置参与了属性的构成；问“电子在被测量之前究竟在哪里”这个问题，是把一个在那个语境中无意义的问题当作有意义的。

这不正是造成论？而且不是一个哲学声明，是一个被实验反复确认、被整个物理学接受的结论？

要先承认这个候选的分量。

它不是一个粗糙的类比。它提供的是一个真实的、可操作的现场：装置的选择改变了被观察到的东西，而且这种改变不能被解释为“我们原本就不知道，测量只是揭示了它”——各种检验实验的结果明确排除了那一类解释。

若本案能在这里被判，那将是最省事的结果：本书不必去找一台新装置，物理学已经提供了。

二、按四条清单逐条检查

可重跑：通过。同一个实验可以被跑无数次，而且这正是量子实验的常态——单次结果是随机的，结论建立在大量重复之上。

可干预：通过，而且极好。可以改变测量装置、改变基的选择、改变测量的时序，并且可以做得非常精确。这是物理实验的强项。

可消融：通过。可以去掉某个元件、某条路径、某个屏障，看结果如何改变。双缝实验的全部变体就是在做这件事。

可观测：部分通过。中间状态在特定的意义上不可观测——这恰恰是这个现场的核心内容之一。但实验装置的全部配置、时序、统计分布都是被完整记录的。

四条里有三条半通过。按第四十章的规则一，这个候选应当不通过。但问题不在那半条上——真正的问题在规则二。

三、被干预的不是形成过程

规则二说：判断一个候选是否通过某一条，要看它对本案所关心的那个对象是否通过。

现在问：在量子测量实验里，被干预的是什么？被构成的是什么？

- 可干预的是测量装置。
- 被构成的是单次结果。

而两者之间的统计规律——波函数、算符、玻恩规则——在整个实验中被当作给定的、不受干预的。

换言之，量子力学提供的是：

在给定的先在结构下，个别结果如何被装置共同决定。

而争论的焦点恰恰是那个结构本身是不是被造成的。

这个错位可以用一句话说清：

物理学家从不重跑量子力学的形成史，他们在量子力学之内做实验。

在量子力学之内做实验，能判的是量子力学之内的问题。要判“量子力学这套结构是被发现的还是被造成的”，需要的是另一种实验——把那套结构的形成过程重跑一遍，换一条路径，看得到的是不是同一套结构。

那个实验没有人做过，也没有人知道怎么做。

四、这个错位有一个可检验的后果

上一节的诊断若成立，它有一个后果：玻尔与爱因斯坦的争论，在近百年后应当仍然是解释学争论，而不是判决。

这正是实际情况。

关于量子力学该如何理解，今天仍有若干互不相容的立场并存，而它们在经验上等价——它们对一切实验结果给出相同的预测。这与第七章所描述的那种局面完全同构：不是证据不够，是两种叙事对同一批事实各说各的。

要把这个论证说得公道，必须补两句。

其一，近几十年的一系列实验确实在若干具体问题上做出了判决——某些类型的替代解释被实验排除了。这是真实的进展，本书不打算把它说成没有。

其二，那些被排除的，是关于量子力学之内某些解释假设的；而不同的整体解释立场之所以仍然并存，正是因为它们在那一层是等价的。

这两句合起来，反而加强了本章的诊断：在一个现场里，能被判的是那个现场内部的问题；那个现场自身结构的起源问题判不了。

五、一个更接近的量子候选，以及它为什么也不行

上面处理的是标准的量子测量现场。有一个更接近本案的变体值得单独处理，因为它绕开了第三节那个诊断。

变体是这样的：不看单次测量，而看一套物理描述本身如何在实验传统中被确定下来——测量基的约定、可观测量的选取、什么算一次“测量”的判准。这些不是由自然界给定的，它们是在具体的实验实践中被固定下来的。

这个变体确实更接近本案：它把注意力从“在结构之内做实验”移到了“结构本身怎么被定下来”。

它仍然不行，理由有两条，都落在四条清单上。

理由一：不可重跑。那一套约定只被确定了一次。物理学史与知识史在这一点上处境相同——第十三章对人类知识史的诊断原样适用。

理由二：不可干预。无法构造一个“其余一切相同、只有约定次序不同”的物理学共同体。

于是这个变体的处境不是量子力学特有的，它就是本案本身——它只是把本案换了一个领域重述了一遍。

这一节的用处在于它把第三节那个诊断推广了：

在任何一個已经成形的科学领域里，你能重跑的是该领域之内的实验，不能重跑的是该领域本身的形成。

这句话对物理、化学、生物同样成立，因此它一次性排除了“到某某成熟科学里去找实验台”这一整类提议。

而它也解释了本编为什么要找一个新的现场：不是因为已有科学不够精密，而是因为任何已有科学都只能提供它内部的实验。要重跑一个领域的形成，需要的是一个其“领域形成”本身发生在可控条件下的系统——而那样的系统，直到很晚近才存在。

六、一件要补的公道话

本章两次说量子测量“不行”。要补一句公道话，因为这样说容易给人一个错误的印象：仿佛这个候选是被轻易打发掉的。

它不是。它是四个候选里唯一一个在概念上真正触及本案核心的。

前一节说的那个变体——测量基的约定、可观测量的选取、什么算一次测量——这些问题在物理学内部是被认真讨论过的，而且讨论的深度远超本书能达到的程度。

本书之所以能“排除”它，靠的不是比那些讨论更深的见解，而是一条很机械的清单。四条性质，逐条对照，第一条不通过。仅此而已。

这个方法有它的价值，也有它的局限，两样都要写。

价值在于它不依赖判断。一条清单可以被任何人拿去重新核对一遍，而不需要先同意本书的立场。第四十章第八节那三条使用规则，全部是为了让这份清单不被私下放宽或收紧。

局限在于清单只能排除，不能理解。本书排除量子测量，不等于本书理解了那个现场里发生的事；它只说明那个现场不满足本案所需的条件。一个被清单排除的候选，完全可能在别的问题上极有价值。

把这两句合起来，得到本编方法的一个自我描述：

本编做的是筛选，不是评价。

这一点在第四十三章会再次用到——那里被排除的那个候选，同样是在它自己的领域里做得很好的工作。

七、这一章排除的是什么，保留的是什么

排除的：量子测量不能充当本案的实验台。它在四条清单上表现优异，但被干预的对象不是知识的形成过程。

保留的，而且要保留得明白：量子测量提供了一个概念上的先例——它表明“被观察的东西在何种程度上依赖于观察的安排”这类问题，可以从思辨变成实验。这个先例对本书是有用的，第八十七章那条一般观察（可重跑的人工系统改变问题的类型）与它同族。

还要保留一条对本书不利的：有人可以主张，量子测量的教训应当被推广——既然在物理的基础层面上装置已经参与构成，那么在知识的层面上也当如此。

本书不接受这个推广，理由与第七十七章那一记相同：那是一个类比论证，而类比论证在本案上不产生判决。本书的论证结构是反例式的，它需要一个实例，而实例必须落在本案所关心的那个对象上。

把这一条写出来，是因为它是本书自己一侧最容易被使用的一个论证，而本书拒绝使用它。

下一章处理第二个候选，它比这一个更接近本案。

第四十二章 为什么不是实验演化

一、这个候选给出了本案需要的实验设计

有一个思想实验，几乎是本案所需设计的完美表述。

重放生命的录像带：把地球史倒回寒武纪，换一条随机序列再跑一次，看智人是否还会出现。

古尔德说不会——演化史充满偶然，一个微小的差别会被放大，重跑一次得到的生物圈将完全不同。康威莫里斯说会——趋同演化的证据表明，某些解会被反复发现，眼睛在不同谱系中独立演化了数十次。

这是一场关于路径依赖的实质争论，而且它的形式恰恰是本书所需要的：固定材料（同一个星球、同一套物理化学）、固定判准（生存与繁殖）、只换路径（随机序列），看到达的地方是不是同一处。

第五十二章那个承重区分，几乎可以原样搬到这场争论上：古尔德主张构成性路径依赖，康威莫里斯主张计算性路径依赖——不同的路径以不同的方式、不同的速度，到达同一批解。

因此这一章不能用“这个候选不相关”来打发它。它高度相关，而且它比大模型更早期地把问题的形式摆对了。

二、为什么它到今天仍然不可判

原因简单到令人沮丧：

录像带不能重放。

四条清单在这里的表现是：

可重跑：不通过。地球史只发生一次。这不是技术困难，是它的性质。

可干预：不通过。没有办法只改变演化的随机序列而保持其余一切不变。

可消融：不通过。不能删掉某次大灭绝再跑一遍。

可观测：部分通过。化石记录是一份真实的中间状态记录，但它是极稀疏、极有偏的抽样——保存下来的是那些恰好能被保存的生物在恰好能被保存的环境里的遗骸。

第一条不通过，其余三条就没有意义。这与第十三章对人类知识史的诊断完全同构：一段只发生一次的历史，无论被记录得多好，都不提供第二次。

于是古尔德与康威莫里斯的争论，其结构与本案两千年的僵局是同一个：双方都有材料，双方的材料都与对方的立场相容，而判决所需的那次重跑做不到。

三、实验演化：在有限尺度上真的做了这件事

上一节说的是自然演化史。而在实验室里，这件事在有限的尺度上被真的做了。

长期演化实验把同一个祖先菌株分成若干条平行的谱系，在相同的环境中培养，代代相传，持续数万代。每隔一段时间冻存样本，因而整条轨迹的中间状态被保存下来，可以随时取回。

这是一个满足前三条的现场：

可重跑：通过。冻存样本可以被复苏并重新培养——这正是“重放录像带”的字面实现，而且它被称为“重放实验”。

可干预：通过。可以从某个时间点的冻存样本出发，改变环境或随机重来，与原轨迹对照。

可消融：部分通过。可以做遗传层面的删改并重跑。

可观测：通过。冻存样本就是全程录像。

而且它给出了路径依赖为真的强证据：某些性状只在某一条谱系中出现，而且把那条谱系回放到的不同时间点再重跑，性状出现的概率明显不同——这说明在此之前发生的某些变化，是后来那个性状得以出现的前提。

这几乎就是条款三所要的那种读数：一个结果，在某条路径上可达，在另一条路径上（在相当的预算下）不可达。

四、那么为什么它仍然不是本案的实验台

理由只有一条，但这一条是决定性的：

它的对象是生物性状，不是知识。

本书的论证结构是反例式的（第七十七章第二节）：要削弱“任何以材料为输入、以判准为约束的知识形成过程，其结果由材料与判准唯一决定”这条全称命题，需要的是一个知识形成过程的实例。

一个生物性状形成过程的实例，不落在那条命题的范围内。

把实验演化的结论外推到知识，正是欠决定性最容易复发的地方。

这句话要说透。外推需要一个论证：生物演化与知识形成在相关方面相似，因此在这一点上也相似。而这是一个类比论证——而类比论证在本案上不产生判决，理由与第七十七章处理“这只是表征不是知识”那一记时完全相同：本案的两方对类比的强度有不同的判断，而这个判断本身无法被独立检验。

本书因此明确拒绝使用实验演化的结论作为本案的证据。这是一次对本书不利的拒绝——那批读数相当漂亮，而且方向对本书有利。

五、重放实验与条款三的对应

上一节说实验演化的对象不是知识。但它的实验形式与本书条款三高度对应，值得把对应关系写出来——因为本书在设计条款三时，实际上是在照抄一个已经被验证过的设计。

对应一：回放不同时间点。重放实验的做法是从轨迹上不同的时间点取冻存样本，各自重跑多次，统计某个性状出现的比例。若从晚期样本出发时出

现比例明显高于从早期样本出发，说明在那一段之间发生了某件事，它是后来那个性状的前提。

这正是第七十章第七节那个“先在性生效的时点”的实验形式。本书在那里提出的量——先在性在第几步生效、它是否随规模趋于零——其测量方式与重放实验完全同构。本书欠这一线工作的不只是灵感，是设计。

对应二：标定的不可达。重放实验报告的不是“这个性状在那条路径上不可能出现”，而是“在若干次重跑、若干代培养之内，它没有出现”。这是一个带预算标定的陈述。

第五十七章第三节那个资源标定的不可达，形式上就是它。本书在那里写的四个参数——预算 B 、比例阈值 q 与 q' 、以及十倍这个约定——都能在重放实验的报告里找到对应物。

对应三：判负条件的形式。重放实验的结论可以被更多次数、更长时间的重跑推翻：只要有人在那条路径上跑出了那个性状，原结论就作废。第五十七章第三节那句“做出来就算，本书认输”是同一条。

三处对应说明一件事：条款三不是本书凭空设计的，它是一个在别的领域已经被执行过的实验形式，换到本案的对象上。

这既是好消息也是坏消息，两面都要写。

好的一面：这个形式被验证过，它能产出可发表、可复核、可被推翻的读数。

不好的一面：在实验演化里，这个形式所需要的重跑是真的重新培养——而在本案里对应的是真的重新训练。第六十六章第六节那个成本分档里，条款三与条款二形式三正是最贵的那一档。同一个实验形式，在这里的价格高得多。

六、一个对本书不利的读法

在清点收获之前，先写一个对本书不利的读法，因为它是本章最可能遭到的反击。

反击是：既然实验演化已经在一个可重跑系统上给出了路径依赖的强证据，而本书拒绝把它外推到知识；那么反过来，本书凭什么把自己在在大模型上得到的读数，当作关于“知识形成”的读数？

这一记很硬，因为它用本书的严格性来打本书。

若“对象是生物性状不是知识”足以排除实验演化，那么“对象是模型的内部状态与输出，不是知识”是否同样足以排除大模型训练？

本书的回答在第四十三章第三节已经给过，这里要正面承认它的有限性。

回答是：模型的产物具有知识主张的形式——可以被评价为对或错，可以与世界上的事情对照，可以在对照失败时被修改；而生物性状不具有这个形式，一个翅膀没有“对不对”的问题。

这个回答划出了一条线，而这条线是本书全部现场选择的承重处。

它的有限性有两层，都要写。

第一层：这条线是本书划的，不是被公认的。有人可以主张“具有知识主张的形式”离“是知识”还差得远，而那个差距正是第七十七章那一记的内容。

第二层，更要紧：这条线若被推翻，本书没有退路。若“知识主张的形式”不足以使一个过程落进那条全称命题的范围，那么本书的现场就与实验演化处境相同——有漂亮的读数，而外推需要类比。

因此本书在这里的处境可以说得很清楚：

本书拒绝实验演化的外推，与本书自己的合法性，靠的是同一条线。这条线成立则两件事都成立，不成立则两件事都不成立。

把这句话写出来，是因为一本拒绝别人外推的书，必须说明自己凭什么不算外推——而不是只说别人不行。

七、它留给本书的三样东西

拒绝使用它的结论，不等于它对本书无用。它留下三样，都要记明。

其一，一个已经被验证的实验形式。“从某个中间状态出发重跑，看结果是否可复现”这个设计，在实验演化里已经被做出来并被接受。第七编首跑所用的多种种子检查点，其设计思路与它同源——把中间状态存下来，以便从任意一点重来。本书在方法上欠这一线工作。

其二，一个关于“路径依赖有多大”的先例。那批读数表明，在一个材料与判准都被严格固定的系统里，路径确实可以造成不可忽略且不易抹平的差异。这不是本案的证据，但它说明这类效应不是虚构的。

其三，也是最要紧的一样：它证明了第十三章那条推论。

第十三章说：一旦出现某种装置使一个过程可重跑，那个领域的争论就应当改变类型。

实验演化正是这件事的一个实例。关于演化路径依赖的争论，在有了可重跑的实验系统之后，确实从“倒带思想实验”变成了“重放实验读数”。争论没有被解决——双方仍在争——但它换了形式：现在人们争的是读数怎么读、实验设计是否公平、外推到多大尺度有效。

这正是本书希望本案发生的那种变化，而且它已经在隔壁发生过一次。第八十七章第四节那个反面检验——找一个有了可重跑系统而争论毫无变化的领域——在这里得到了一个正面的对照。

下一章处理第三个候选，它是三个里与“知识”最接近的一个，也因此最容易被误当作已经成功。

第四十三章 为什么不是早期人工生命与遗传算法

一、这个候选看起来已经把事情做完了

第三个候选与前两个不同：它是一个人工系统，而且它从一开始就是为了研究演化与适应而造的。

遗传算法、演化策略、人工生命仿真——在这些系统里，一个种群在一个被明确写下的适应度函数上演化。研究者可以：

- 从同一个初始种群出发跑很多次（可重跑）。
- 只换随机种子而保持其余一切不变（可干预）。
- 删掉某个算子、某个种群、某段历史再跑（可消融）。
- 记录每一代的全部个体（可观测）。

四条全通过，而且通过得干净利落。

不仅如此，这些系统在二三十年前就已经报告了路径依赖的现象：不同的随机种子导致不同的最终种群；某些解只在某些运行中出现；适应度相当的两个种群可以在结构上相当不同。

于是一个自然的问题：这件事不是早就做完了吗？

本章要回答的正是这个问题，而回答会比前两章更细，因为这个候选与本案的距离最近，因而它的错位也最不明显。

二、四条之外的那一条

第四十章第七节的规则三写过：四条是必要条件，不是充分条件。还需要第五编那一步——把待判的命题翻译成这台装置能回答的形式。

这个候选在四条上全通过，而在翻译那一步上卡住了。

卡在哪里？卡在一个很具体的地方：

产物不构成知识主张。

一个遗传算法跑出来的最终种群，是一组参数、一组规则、一组在适应度函数上得分很高的个体。它是一个解，而不是一个关于什么的陈述。

而本案所争的对象是知识——被知道的东西。要判“被知道的东西是被发现的还是被造成的”，需要产物是某种能被说成“关于世界如何”的东西。

一组在某个人造适应度函数上得高分的参数，不是这样的东西。

三、“可重跑但无内容”

把上一节压成一句：

这类系统可重跑，但无内容。

“无内容”这个说法要说准，因为它容易被读成贬低。它不是说这些系统不重要、不精巧、不出成果。它说的是一件特定的事：

那些系统里被优化的目标函数，是研究者为研究本身而写下的；它不指向系统之外的任何东西。于是得到的解，其“正确”只相对于那个函数而言。

对比一下本案所需要的：语料是关于世界的（它由人写下的关于各种事物的陈述构成）；模型学到的东西，可以被问“它关于世界说了什么”这个问题，而且这个问题有意义。

这个对比要小心，因为它是本章最容易被攻击的一处。

反方可以说：语料也不过是一堆符号，模型学到的也不过是符号上的统计结构；把它说成“关于世界的”，正是在偷渡一个未经论证的假设。

这个反驳有力量，本书部分接受它。本书的回答是有限度的：本书不主张模型的产物是知识（第八十一章第一条明写不主张）。本书主张的只是一个更弱的东西——那些产物是知识主张形式的：它们可以被评价为对或错，可以与世界上的事情对照，可以在对照失败时被修改。

而一组遗传算法的参数不具备这个形式：它没有“对不对”的问题，只有“在这个函数上得多少分”的问题。

这个区别是否足够，本书承认是一个开放问题。第七十七章那一记处理的正是它的一般形式，而那一章的结论是：本书的论证靠反例结构站住，而反例结构要求实例落在那条全称命题的范围内——“以材料为输入、以判准为约束的知识形成”。一个不产生知识主张形式的产物的过程，不在这个范围内。

四、另一处更技术性的错位

除了内容问题，还有一处错位值得单独写，因为它关系到第六编那三条条款能不能用。

在这类系统里，“材料”与“判准”往往是同一个东西。

遗传算法的适应度函数既规定了什么算好（判准），又是唯一的信息来源（材料）——种群除了适应度反馈之外，不从任何别处获得关于目标的信息。

而本案的设定要求 C、A、L 三者可分：材料是语料，判准是损失与评估，它们不是同一个对象。第五编第四十八章定义可达集时，这三者的可分性是前提。

若材料与判准合一，条款二就无从谈起——条款二问的是“结果差异能否由 C、A、L 的量预测”，而当 C 与 L 是同一个函数时，这个问题退化了。

这一处错位比内容问题更技术，但它更硬：它不是一个可以靠论证争的问题，它是一个设定上的不匹配。

五、一个边界案例：开放式演化

上面的排除针对的是有明确适应度函数的系统。有一类系统试图绕开这一点，值得单独处理，因为它是这个候选里离本案最近的一个。

开放式演化的目标是构造一个不预设固定适应度函数的系统——个体之间相互构成彼此的环境，“什么算好”随系统自身的演化而变，而不是由外部写死。

这个变体绕开了第四节那处错位：材料与判准不再合一，因为判准本身是内生的。

而它引入了一个新问题，这个问题对本案是致命的。

若判准是内生的、随过程而变，那么第五编那套翻译就无从应用——本书的可达集定义为“固定 C、A、L 时一切路径所能到达的结果集合”，而这里 L 不固定。

这正是第七十七章第五节那一记的形态：判准可变的过程，也许根本不是本案所处理的那一类过程。那一节的结论是，本书对此没有办法；第八十七章第五节把它列为第三种不可判，并写明“无解法”。

于是这一节给出一个整齐的两难，它比单纯的排除更有信息量：

	判准固定	判准内生
翻译能否应用	能	不能
本案能否被提问	能	无从提起
例子	遗传算法、大模型训练	开放式演化

两难的形状是：判准固定的系统落进第二节那个“无内容”的问题（除非产物具有知识主张形式），判准内生的系统落进“无从翻译”的问题。

大模型训练之所以是本书的选择，正是因为它同时避开了两边：判准固定（损失与评估是写死的），而产物具有知识主张的形式（第四十四章第七节）。

这个位置很窄。写明它有多窄，比声称它有多合适更诚实——本书所依赖的，是一个恰好落在两个失败模式之间的现场，而不是一个在各方面都理想的现场。

六、这个候选给出的一条普遍教训

在清点它留给本书的东西之前，先提一条从它身上得到的普遍教训，因为它比这个候选本身更有用。

教训是：四条清单可以被一个系统轻易满足，而满足得越轻易，越要检查翻译那一步。

遗传算法与人工生命系统满足四条，靠的是它们就是为满足四条而造的——它们本来就是研究者写出来的仿真，可重跑、可干预、可消融、可观测是它们的设计目标之一。

于是出现一个反直觉的情形：一个系统在清单上表现得越完美，它越可能是一个为清单而造的系统，因而越可能与真实的对象脱节。

这条教训有一个可操作的形式，本书称之为造物者检验：

问一句：这个系统是谁为了什么造的？若它是为研究本案而造的，那么它满足四条这件事不提供任何信息，因为那是设计出来的。

按这条检验看四个候选：

- 量子测量装置：为研究物理而造，不为本案。通过检验。
- 实验演化系统：为研究演化而造，不为本案。通过检验。
- 遗传算法／人工生命：为研究适应与搜索而造，其满足四条是设计目标。不通过。
- 大模型训练：为工程用途而造，不为本案。通过检验。

第四十六章整章所讲的那个“装置自己也是被造出来的”，在这里有了一个正面的用处：正因为这台装置不是为本案造的，它满足四条这件事才携带信息。一台为了通过检验而造的机器，通过检验不说明任何事。

这条教训也有它的限度：不为本案而造，不等于它的参数选择对本案友好。第四十四章第七节那四处不足、第四十六章第二节那三处错配，说的正是这件事。造物者检验只挡住一类问题（设计性的循环），挡不住另一类（参数的错配）。

七、它留给本书的东西

与上一章一样，排除它不等于否定它。

其一，它提供了“路径依赖在人工系统里真实存在”的早期证据。那些关于不同种子给出不同最终种群的报告，在时间上远早于本书所依赖的那批材料。

其二，它提供了一个警示，而这个警示对本书直接有用。

那些系统里的路径依赖，几乎全部被处理为需要被控制的随机性：跑多次取平均、固定种子以便复现、调参数以减少方差。

没有人问过它是否会随资源消失。

这正是第七十四章第八节与第八十四章第五节所说的那个机制——关切决定了哪些问题被提出来。而它在这里的实例比在语言模型上的实例早了二三十年：同一个问题在一个可重跑的人工系统上本来早就可以被问，而它没有被问，因为没有人需要它的答案。

其三，一条对本书不利的：既然这类系统早就满足四条，而本案并没有因此被判，那么“四条满足就会改变问题类型”这条推论（第十三章第六节）在这里遇到了一个反例——或者至少是一个需要解释的案例。

本书的解释是第二节与第四节给出的两处错位：四条满足了，但翻译失败了。而这个解释是事后的，本书承认这一点。它不是一个独立的辩护，它只是指出了失败发生在哪一步。

若有人认为这个解释不够，那么第十三章那条推论就应当被削弱成一个更谨慎的版本：四条满足是问题改变类型的必要而非充分条件。本书接受这个削弱，并把它记在这里。

下一章处理最后一个候选，也是本书主张四条全通过、且翻译可行的那一个。

第四十四章 大模型训练的四条工程事实

一、先说明理由不在哪里

本书主张大规模语言模型的训练是第一台满足四条的装置。

在给出理由之前，先排除一个不是理由的东西：

理由不在于它“像人脑”。

本书完全不需要这个类比，而且明确拒绝它。第四十五章整章处理为什么不使用“理解”“意识”“智能”这三个词，以及为什么不使用它们论证反而更强。

理由只在于四条工程性质。它们是冷的、可查的、与任何关于心智的判断无关的事实。

本章逐条给出它们，并逐条给出它在公开材料上的实现方式——按第二编所立的标准，一条性质若不能被指出它在哪里以什么形式存在，它就只是一个说法。

二、可重跑

训练是一个确定的计算过程。

给定语料、架构、优化器、随机种子与硬件的数值行为，它可以被从头再跑一遍。

这不是隐喻意义上的“再来一次”，是字面意义上的同一过程重新执行。输入的每一个词元、每一步的梯度、每一次参数更新，都由那几样东西决定。

必须写明它不完全确定的那一处：在实际的并行硬件上，浮点运算的次序可能随调度而变，因而两次“完全相同”的训练会有末位差异。这个差异很小，但它不是零。

这一处不确定性恰恰有用：它给出了噪声基线的正确定义——同种子、同数据次序、仅由数值非确定性造成的重训之间的距离。第八十章第二节论证过，这条基线是条款一得以成立的结构；而第六十五章记录了首跑没能用上它、改用代理基线所付的代价。

三、可干预，且干预是外科式的

可以只换随机种子而保持其余一切不变；只换数据的呈现次序而保持数据集不变；只换课程安排而保持总量不变。

这正是对照组的严格形式：单变量地改变路径，而不改变材料。

“外科式”这个说法在这里是字面的。数据次序是一个可以被精确指定的序列；改变它不需要改变任何一条数据。这与第四十章第三节所要求的“精确地只改一项，其余逐位对齐”完全吻合。

把这一条与人类知识史对照，差别的量级才看得清楚：你无法让同一群十七世纪的人以不同次序读同一批书。不是很难，是这个说法本身没有指称——没有两群同一的人。

这一条也有它的限制，必须写明。第七编第六十六章记录了一件事：首跑所用的那两组消融材料，三组的对内共享条件不齐——只换次序那一组共享同一个权重初始化，只换初始化那一组共享同一个数据次序。外科式干预是这台装置能做到的，但不是自动做到的；做不好，读数照样被污染。第五十六章第五节那条实验规格就是为此写的。

四、可消融

可以从语料中精确删除某一子集、某一文体、某一语言、某一时间段，然后重跑，观察缺失如何改变结果。

这是“没有盖伦会怎样”这类问题第一次有了字面的回答方式。

在第十三章那里，这类问题只能被推测地回答，而且推测是循环的（第十三章第四节）。在这里，它是一次可以执行的实验：把那一部分删掉，重跑，看结果。

这一条的代价要写明：消融需要重新训练，因而是四条里最贵的一条。首跑完全没有用到它——首跑用的是现成的公开检查点，而消融必须自己训练。条款三与条款二形式三都依赖这一条，这也是它们至今未跑的主要原因（第六十六章第六节的成本分档）。

五、全程可观测

中间状态不是被推测的，是被保存的。

一批公开发表的模型系列，把训练途中的状态成千上万地存了下来，连同当时的数据次序一并放在那里。任何人要看某一时刻的完整内部状态，取回来就是。

具体到本书所用的那一份：五个模型规模、每个规模十个种子、约七千个新增检查点，全部公开（第七十四章第三节）。检查点的密度在训练早期按二的幂次取点，此后每千步一个。

这一条与人类知识史的对照最刺眼：

人类知识史留给我们的是成品；这里留给我们的是全程录像，加上可换带重放。

限制同样要写。“全程”是相对的：每千步一个快照，意味着两个快照之间发生的事看不见。而第六十五章第三节正好证明了这个间隔不是无关紧要的

——那个间隔本身成了噪声基线定义里一个未被识别的自由参数。记录得再密，它仍然是抽样；只是这个抽样的密度可以被选择，而历史的抽样密度不能。

六、四条同时满足，这是第一次
把四条并排，与前三个候选对照：

	可重跑	可干预	可消融	可观测	对象是知 主张形式
量子测量	✓	✓ (对象错 位)	✓	部分	✗
实验演化	✓	✓	部分	✓	✗
遗传算法/ 人工生命	✓	✓	✓	✓	✗
大模型训练	✓	✓	✓	✓	✓

前三个候选在四条清单上的表现都不差——第三个甚至全通过。区别落在最后一列上，而那一列正是第四十章规则三所说的、四条之外的那一步：翻译能不能做成。

这一列在本书里的地位要说准：它不是第五条性质，它是第五编的入口。第四十七章至第五十一章处理它，包括它可能失败的三个地方。

七、这台装置的四处不足

四条全通过，不等于没有代价。把代价列出来，因为它们各自都在后面的章节里真的发作过。

不足一：规模轴是唯一的资源轴，而它很贵。

条款一要判的是差异随资源的走向，而“资源”在这里主要由模型规模与训练量承担。往这个轴上多取几个点，成本按数量级增长。首跑止步于四个规模点，正是因为这个（第六十一章第一节）。一台可缩放的装置，不等于一台你缩放得起的装置。

不足二：干预的完备性没有保证。

第四十三章第五节提到的那处漏洞在这里发作：路径由哪些变量构成，没有一份公认的完备清单。首跑用的那两组消融材料，组内共享条件不齐（第六十六章第三节），就是这一处的实例。外科式干预是这台装置允许的，不是它保证的。

不足三：观测是抽样，而抽样的间隔会变成自由参数。

公开检查点每千步一个，而那个间隔后来成了噪声基线定义里一个未被识别的自由参数（第六十五章第三节）。“全程录像”这个说法，严格说是“高频抽样”，而抽样频率不是本书选的。

不足四：材料是别人为别的目的做的。

规模点的分布、检查点的间隔、种子的数量，全部由制作者按他们自己的问题定（第七十四章第五节）。本书用它问另一个问题，刻度总有对不上的地方。第四十六章整章处理这一层。

四处不足有一个共同点：它们都不是这台装置的原理缺陷，而是它作为一件现成的、为别的用途制造的设备所带来的。这个区别很重要——原理缺陷不可修，这四处都可修，而且第六十六章那份清单里有三条就是在修它们。

但可修不等于已修。本书至今只跑过一次，而那一次四处不足全部发作了。

八、一个常见的误解：这台装置不是“模拟知识形成”

在写主张之前，先挡掉一个误解，它几乎必然会出现。

误解是：本书把大模型训练当作人类知识形成的一个模拟，然后从模拟的行为推断被模拟者的行为。

若是这样，本书的全部论证都建立在“模拟得像不像”上，而那是一个无穷无尽的争论。

本书不是这样做的，而区别落在一个具体的地方：

本书不把训练当作某件别的事情的模型，本书把它当作那条全称命题的一个实例。

先在论要论证的那条命题说：任何以材料为输入、以判准为约束的知识形成过程，其结果由材料与判准唯一决定。

大模型训练是不是以材料为输入的？是——语料。是不是以判准为约束的？是——损失与评估。它的产物是不是知识主张形式的？第四十三章第三节论证过：可以被评价为对或错，可以与世界上的事情对照，可以在对照失败时被修改。

三条都满足，它就落在那条命题的范围内。落在范围内的东西，不需要“像”任何别的东西——它自己就是一个实例。

这个区别决定了本书全部论证的强度来源，也决定了它的边界：

- 来源：一个实例足以削弱一条全称命题，而这不需要相似性判断（第七十七章第二节）。
- 边界：一个实例不给出另一条全称命题，因此本书不推出人类知识是被造成的（第七十七章第三节）。

有人会问：那么这台装置与人类知识形成有什么关系？

回答是：除了同属那条全称命题的范围之外，本书不主张任何关系。这个回答听起来很冷，而冷正是它的用处——它使本书的结论不能被“模型不像人”这句话推翻，同时也使本书的结论不能被扩大到人身上。两头都收紧，这是本书愿意付的价钱。

九、本书对这台装置的全部主张

最后把主张写死，防止它被读得太重。

本书主张的：大模型训练是一台实验设备，它同时满足四条，并且它的产物具有知识主张的形式。

本书不主张的：它是一个认识主体；它拥有知识、理解或智能；它与人类的学习是同一类过程。

这三条不主张，第八十一章列得更全。这里重申，是因为接下来的论证若被误读为“机器会思考所以知识是被造成的”，那就完全跑偏了。

本书的主张是冷的：它是一台实验设备。

下一章说明为什么把那三个词排除在外，反而使论证更强。

第四十五章 本书不使用的三样：理解、意识、智能

一、一条自我设限

本书在全部论证中不使用这三个词：理解、意识、智能。

这不是一个风格上的选择，也不是回避争议。它是一条对论证结构的设限，而且它使论证变强而不是变弱。本章说明为什么。

先把设限的内容写准：

本书不主张模型理解任何东西，不主张它有任何形式的意识，不主张它具有智能；本书也不主张它没有。这三个问题本书不处理。

后半句同样重要。本书不是站在“模型不过是统计”那一侧——那同样是一个关于心智的判断，同样需要论证，而本书同样不做。

二、为什么不使用它们，论证反而更强

理由有三条，按分量排。

理由一：它们是可争的，而四条工程性质不可争。

“这个模型是否理解它写下的句子”——这个问题今天有至少三种互不相容的回答，而且它们各有拥护者，各有论证，没有公认的判据。

“这个训练过程能否被从头再跑一遍”——这个问题没有争议。它是一个关于计算过程的事实，任何人可以去查。

一个建立在不可争事实上的论证，比一个建立在可争判断上的论证强得多，因为它不能被对手在那一处截住。

理由二：使用它们会把论证变成类比论证。

若本书说“模型理解，人也理解，因此模型的知识形成告诉我们人的知识形成如何”，那就是类比。而第七十七章第二节已经论证过：类比论证在本案上不产生判决，因为它的强度取决于相似性，而相似性的判断本身无法被独立检验。

本书的论证是反例式的。反例结构需要的是一个落在全称命题范围内的实例，而那条全称命题说的是“以材料为输入、以判准为约束的知识形成过程”，它没有说“由理解者进行的过程”。

于是：不使用这三个词，恰恰是反例结构得以成立的条件。

理由三：使用它们会引来一整批与本案无关的反驳。

一旦本书主张模型理解，反方就可以用全部关于心智的论证来回应，而那些论证无论对错，都不落在“路径是否进入结果”这个问题上。本书会被拖进一场自己不需要打、也打不赢的仗。

三、这条设限在书中的实际作用

这不是一条写在前言里然后被忘掉的原则。它在本书里有具体的执行痕迹，值得列出来。

其一，它决定了实验台的选择标准。第四十章那四条性质里，没有一条提到心智。选择大模型的全部理由是工程性的（第四十四章），而不是“它最像人”。

其二，它决定了结果距离的构造。第五十五章那四条硬规定——不得用任务分数、必须消去对称性、必须包含分布外行为、不得合成两通道——全部是关于测量的，没有一条关于模型内部发生了什么心智事件。

其三，它决定了本书如何接住第七十七章那一记。那一记说“这只是表征的形成，不是知识的形成”。若本书曾主张模型理解，它就必须在那里争辩模型确实有知识——而那是一场没有判据的争辩。因为本书从未主张，那一记打在空处，本书可以专心处理它真正有效的那一部分（反例结构的适用范围）。

其四，它决定了第七十八章那一记为什么接不住、以及接不住是什么性质的。那一记问的是“组合与形成的界限”。这是一个关于发生的问题，不是关于心智的问题——第七十八章第七节指出它在人身上有同构的版本。若本书曾把这个问题挂在“理解”上，它连那一记的形状都看不清。

四、这条设限的代价

有三处代价，写明。

代价一：本书的结论比读者期待的弱。

许多人关心这个题目，是因为他们关心人的知识、人的创造、人的认识。本书的结论落在模型上，而第七十七章第三节明写它不推出人类知识是被造成的。

这是一个真实的失望，本书不打算用任何措辞去缓和它。

代价二：本书无法使用一批有力的材料。

关于模型内部机制的研究里，有大量材料被表述为“模型学会了某个概念”“模型知道某件事”。这些表述在实践中很有用，但它们含有本书拒绝使用的那一类判断。本书只能使用它们的操作性内容——某个结构在某处被检测到，某个行为在某类输入上出现——而不能使用它们的心智性表述。

代价三：它使本书在某些争论中显得躲闪。

当别人问“那你到底认为模型懂不懂”，本书的回答是“本书不处理这个问题”。这在辩论场上听起来像回避。

本书接受这个代价，并且认为它是所有代价里最值得付的一个——因为回答那个问题所需的判据，本书一条也拿不出来；而在没有判据的地方给出立场，恰恰是本书全书在反对的做法。

五、有人会说这是鸵鸟

本章最可能遇到的反驳，是说这条设限是一种回避：真正的问题就是模型懂不懂，绕开它等于绕开了实质。

这个反驳要被认真答一次，不能靠重申设限来打发。

反驳的完整形式大概是这样的：你说你的实验台产物具有“知识主张的形式”（第四十四章第七节），可“形式”这个词做了全部的工作。一串可以被评价为对或错的符号，与一件真正的知识之间，差的正是理解；你把它叫作形式，只是给这个差距换了个名字。

本书的回答分两步。

第一步：承认这个差距存在，并承认本书没有填平它。第七十七章那一记（这只是表征的形成，不是知识的形成）说的就是这件事，而本书在那一章的回答不是“差距不存在”，是“本书的论证结构不需要填平它”。

第二步，也是关键的一步：指出反例结构在哪里生效。

先在论要论证的那条全称命题，说的是“任何以材料为输入、以判准为约束的知识形成过程”。这条命题的提出者，从来没有把“由一个理解者进行”写进条件。若有人现在要加上这个条件，那等于承认：那条原则不再是关于知识形成一般的，而是关于由理解者进行的知识形成的。

而那个承认，本身就是本书要争取的东西的一大部分。第七十七章第二节写过：普遍性一旦破了，先在论就必须为它想主张的每一个领域单独举证。把“理解者”加进条件，正是一次这样的收缩。

于是这个反驳有一个它自己不愿意要后果：用“模型不懂”来挡本书，等于把那条全称命题改小。而本书想要的，正是让它变小。

这一步不是抖机灵，但它也不是全胜。反方完全可以接受这个收缩——承认那条原则只适用于理解者，然后说：那么本书的结论与人类知识无关，我们本来关心的就是人类知识。

这个回应是有效的，而本书对它的回答只有第七十七章第三节那三条边界：本书不证明人类知识是被造成的；本书确实取消了那条原则的先天地位；本书确实提供了一个可重跑的实例。

三条都不足以让反方满意。本书接受这一点。

六、这条设限与本书别处的设限是同一类

这条设限不是孤立的。本书里有四条同类的自我限制，把它们放在一起看，会看出一个共同的做法。

限制一（本章）：不使用理解、意识、智能。限制二（第五十五章第一条）：不得用任务分数作结果距离。限制三（第五十五章第二条）：必须消去已知对称性，不许靠标号差异赢。限制四（第八十一章）：六件不主张的事。

四条的共同做法是：主动放弃一批本可以用来支持自己结论的东西。

- 不使用心智词汇，放弃的是感染力与外推空间。
- 不用分数，放弃的是与既有文献最容易对接的接口。
- 消去对称性，放弃的是一条几乎必然通过的廉价胜利。
- 六条不主张，放弃的是六个更响亮、更好传播的版本。

为什么这样做？理由在第八十一章附三写过一次，这里给出它的另一面。

一本书的结论能被相信到什么程度，取决于它不能靠什么赢。若一本书用了心智判断、用了分数、留着标号差异、并且主张了那六个更强的版本，那么读者在评估它的结论时，必须先评估这四样里每一样是否成立——而每一样都可争。

放弃它们之后，本书的结论所依赖的东西变少了，而剩下的每一样都更硬。代价是结论变弱，收益是结论所依赖的前提变少。

这个交换是否划算，取决于一件事：剩下的那个弱结论是否还值得要。

本书的判断是值得——第七十七章第三节那三条边界里的第二条，取消了一条原则的先天地地位，把它从公理降为待证的经验假设。这件事即使在最弱的读法下也是真实的收获。

但这个判断可能是错的，而且本书没有独立的办法证明它对。一本把自己削到只剩一条弱结论的书，若那条弱结论最终也被判负，它就什么也没剩下。这是本书接受的风险，写在这里。

七、一个对照

最后用一个对照把这条设限的意义说完。

设想另一本书，它主张同样的结论，但把论证建立在“模型确实在学习、确实在理解、因而它的学习告诉我们学习一般如何”之上。

那本书会更好读，更有感染力，传播得更广。

它也会在第一次遇到认真的反驳时垮掉——因为它的第一块砖是一个无判据的判断，而反方只需要拒绝那块砖。

本书的第一块砖是“训练可以被从头再跑一遍”。

这块砖很小，也很难看。它的好处是搬不动。

下一章处理这台装置的一处代价，而那处代价不能靠任何设限避开。

第四十六章 实验台的代价：它自己也是被造出来的

一、一个不能被设限避开的问题

上一章用一条设限挡掉了一批问题。本章处理的这一个挡不掉。

这台实验台自己也是被造出来的。

它不是自然界提供的实验室，是工程界提供的实验室。而工程界提供它的时候，想的完全是别的事——把模型做得更好用、更省钱、更稳定。

这件事有三层含义，一层比一层难处理。

二、第一层：材料是别人为别的目的做的

首跑所用的那批多种子检查点，是为研究训练稳定性而制作的（第七十四章第三节）。制作者关心的是：种子差异会不会影响正常使用。

本书拿它来问另一个问题：种子差异会不会随资源消失。

第七十四章第五节已经论证过这样重读的正当性——两方问的不是同一个问题，“大体稳定”与“不趋于零”可以同时为真。那个论证本书仍然认可。

但这一层有它的代价，而且代价是具体的：材料的设计参数不是按本书的需要选的。

- 规模点的分布，是按那份工作的需要定的，不是按拟合渐近值的需要定的。
- 检查点的保存间隔，是按观察训练动态的需要定的，而那个间隔后来成了本书噪声基线里一个未被识别的自由参数（第六十五章第三节）。
- 种子的数量，是按统计推断的需要定的，而十对样本在最大规模上给出的标准差达到均值的一半（第六十二章第五节）。

三处都不是错误，都是错配。别人的尺子，量本书的东西，刻度总有对不上的地方。

三、第二层：装置的存在依赖一条特定的技术路径

这台装置之所以存在，是因为一条特定的技术路线在过去若干年里得到了大量投入。若产业结构不同、资助方式不同、若干技术选择不同，今天可能没有这样一批公开的、多种子的、带完整中途状态的模型系列。

这意味着：本案得以被提上日程，本身是一件有偶然性的事。

第八十七章第二节说过，一个问题是不是“哲学问题”，可能不是它的本性而是它当下的处境。本章补上另一半：那个处境是被造出来的，而且不是为了这个问题而造的。

这一层有一个实际的后果：这台装置的可用性不受本书控制。公开模型可能被撤下、被替换、被收回；训练细节可能不再公开；多种子系列可能因为成本而不再有人制作。第六十一章第七节把这件事列为“无法复现的部分”，并要求把所用的名称、版本号与摘要值全部写明，使将来的人至少能判断手上的材料是不是同一批。

四、第三层：判决可能落在它自己的范围之内

这一层最难，而且它是前两层的自然延伸。

若本案倒向造成论，那么这个判决本身也在它所主张的范围之内：

它是从这条路径上得到的判决。

一本主张“路径进入结果的规定”的书，其结论本身是在一条特定路径上形成的——特定的材料、特定的工具、特定的时代、特定的作者。

这不是一个自我瓦解的悖论。

要说清为什么不是，需要分开两件常被混淆的事：

第一件：一个结论若是在某条路径上形成的，它是否因此为假？

不。路径进入结果的规定，说的是结果依赖于走法，不是说结果因此不对。第七十九章第六节拆过这件事：本书与真理相对主义无关——两个不同的结果可以都是关于同一个世界的，并且都可能出错。

第二件：一个结论若适用于自身，它是否因此失效？

不，但它要接受一层额外的要求。任何把自身包含在内的主张都要接受这一层。

五、本书的处理不是回避，是把它写进判据

面对第三层，有两种处理方式。

方式一：声称超然。主张本书的结论是从一个不受路径影响的位置上得出的。

这条路本书走不了，而且走了会自相矛盾——一本论证路径进入结果的书，不能给自己开一个例外。

方式二：靠程序。承认自己有来路，然后用程序使这条来路可被检查。

本书走的是第二条。具体落在三件事上，全部已经执行：

- 条款的判负条件必须事先写死（第五十八章四条，第五十五章与第七十一章各补一条）。
- 读数必须公开（第六十一章：二十四个公开检查点、112 条冻结探针、全部脚本与原始读数）。
- 预注册必须在接触数据之前完成（第五十九章、第六十章，含冻结摘要值）。

这三件事的共同点是：它们使“这个结论是从哪条路上来的”变成一件可查的事，而不是一件需要信任的事。

由此得到一句话，它是本书方法学的根，第八十七章第七节把它作了结：

一个承认自身有来路的立场，靠程序而不是靠超然来维持可信。

六、这一层在首跑中已经显形过一次

上面几节可能读起来仍然抽象。首跑提供了一个具体的实例。

首跑的噪声基线用了代理——同一轨迹内相邻检查点，而不是同种子重训。为什么用代理？因为算力不够：单核处理器、三吉字节内存，重训跑不起。

于是一条方法学上的选择，是由本书能拿到的设备决定的。而那条选择后来被证明有一个未被预见的毛病：跨规模不可比（第六十五章）。

这就是第二层与第一层在一次具体执行中的合流：装置是别人造的，本书能用到的那一部分又受本书自身资源限制，两者共同决定了判据的一个关键部件，而那个部件写错了。

第五十九章第六节那句话在这里有了实例：预注册保护的是“事后不许改判据”，它不保护“事前把判据写错”。而写错的原因之一，正是写判据的人被自己的条件限定着。

七、三层代价的一般形式

三层代价看起来是本案特有的，其实不是。把它们抽象一层，得到一条对所有“用人工系统判旧问题”的工作都适用的东西。

任何用人工系统去判一个旧问题的尝试，都要同时承受三样：材料是为别的目的造的、装置的存在有偶然性、结论可能落在自身范围之内。

三样各自有一个一般的应对，本书都在用。

对第一样（材料错配）的应对：把错配处逐条写出来，并在结论旁标明它影响了什么。第四十四章第七节那四处不足、第六十一章那份实现记录、第六十五章那处基线缺陷，都是这个应对的执行。它不解决错配，它使错配可见。

对第二样（装置偶然）的应对：把复现所需的一切公开，并接受装置可能消失。第六十一章第七节把“无法复现的部分”单列一节，正是为此。

对第三样（自指）的应对：靠程序不靠超然。上一节写的就是它。

三条应对有一个共同的形状，值得点明：它们都不消除代价，只是把代价从“隐藏的偏差”变成“公开的限制”。

这与本书全书的做法是一致的。第五十九章那套预注册方法学、第五十八章那些写死的败绩条件、第八十一章那六条不主张——每一样都不是在使本书更正确，而是在使本书的错误更可被找到。

为什么这样做值得？因为在一个自己也在过程之内的位置上，“更正确”没有独立的检验方式，而“更可被找到”有。

这一节也给第八十七章那条一般观察补上了它缺的一半。那里说：有一类问题的不可判来源于过程不可重跑，而进展来自出现可重跑的人工系统。本节补的是：那个人工系统带来的进展，必然附带这三层代价；因此“有了装置就能判”是一句过于乐观的话——第八十七章第三节那两条限制，其根就在这里。

八、这一编的结论

第四编到此结束。把它交出的东西清点一次：

一份检验清单：可重跑、可干预、可消融、可观测，加上四条之外的那一步——产物是否具有知识主张的形式。

三个被排除的候选，各自的排除理由不同：量子测量的干预对象错位；实验演化的对象不是知识；遗传算法与人工生命的产物不构成知识主张，且材料与判准合一。

一个被保留的候选，四条全通过，且翻译可行。

一处不能被避开的代价：这台装置自己也是被造出来的，而本书的处理是把这件事写进程序，不是写进辩解。

下一编做那件被留下来的工作：把待判的命题翻译成这台装置能回答的形式，并指出翻译可能失败的三个地方。

第五编 翻译

第四编交出了一台装置，但装置本身不判任何事——一台机器只能回答被问到的问题，而本案的问题目前还不是机器能听懂的形式。

本编做翻译。它的产出是第六编三条条款的输入；翻译若做错了，后面三条条款测得再干净，测的也是别的题。

五章的分工：第四十七章立五条翻译要求；第四十八章定义可达集，并处理它的三处约定与三种误读；第四十九章把两个答法代入，得到分歧的最终形式，以及两者之间那个最容易被混淆的第三种可能；第五十章写四处翻译陷阱，四处都不需要任何人说谎；第五十一章处理翻译成功之后仍然存在的范围问题。

本编对自己的定位写在第四十七章末尾：翻译是把一场判不了的争论变成一场可以输的争论，仅此而已。

一、这一编在全书里的位置

第四编交出了一台装置，并且交代了它的代价。但装置本身不判任何事——一台机器只能回答被问到的问题，而本案的问题目前还不是机器能听懂的形式。

这一编做翻译。

翻译的产出是第六编三条条款的输入。若翻译做错了，后面三条条款测得再干净，测的也是别的题。第四十章第八节那条规则三写过：四条性质是必要条件，不是充分条件；剩下的那一步就在这里，而它可能失败。

因此本编的写法与别编不同：它一半在给出翻译，一半在指出翻译可能被攻破的地方。第五十章专门写三处陷阱，第五十一章处理翻译成功之后仍然存在的那个范围问题。

二、翻译不是降格

先挡掉一个最常见的误解，因为它会使整编的工作被读成别的东西。

误解是：把形而上学命题翻成可测命题，等于承认原命题没有意义，或者等于把一个深刻的问题降格成一个技术问题。

不是。

原命题说的是“被知道的东西的规定是否依赖于来路”。翻译后的命题说的是“结果的规定是否依赖于路径”。

二者是同一句话在一个可干预系统上的实例化，不是替代。

这个区别有一个具体的后果，第五十一章整章处理：判决一个实例不自动判决全称命题。若翻译是替代，那么判了实例就等于判了原命题；而若翻译是实例化，那么判了实例只削弱了原命题的普遍性，不给出另一条普遍命题。

本书走的是后者。这使本书的结论变弱，同时使它不能被“你说的那个不是我说的”一句打掉。

三、一次合格的翻译要满足什么

本书认为一次合格的翻译要满足五条。它们不是本书发明的规矩，而是从这类工作失败的方式里倒推出来的。

其一，忠实性：翻译后的命题必须蕴含原命题的分歧点。

若原命题的两方在翻译后的命题上取相同的值，翻译就失败了——它把分歧抹掉了。检验办法很直接：把两方各自的主张代入翻译后的形式，看它们是否给出相反的值。第四十九章会做这次代入。

其二，可测性：翻译后的命题必须落在一个量上，且那个量有明确的构造方式。

“必须落在一个量上”这一条排除了大量看起来像翻译的东西。把“知识是否被造成”翻成“训练过程是否重要”，不是翻译——“重要”不是一个量。

其三，中立性：翻译所用的量，不得预先偏向任何一方。

这一条最难满足，也最容易被忽略。第五十章第一处陷阱（不能用性能代替结果）讲的正是它：用判准的投影当结果，等于事先规定“凡是判准看不出来的差别都不算差别”，而那正是一方的主张。

其四，事前性：判负条件必须在读数之前写死。

这一条属于方法学而不属于翻译本身，但它必须在翻译阶段就被满足——因为“实质不等价”这类概念若不在事前定义，事后总能找到某种差别或某种相同。第五十章第二处陷阱处理它。

其五，范围诚实：必须写明翻译后的命题覆盖原命题的哪一部分。

翻译几乎必然会缩小范围——原命题说“任何知识形成过程”，翻译后的命题说“这一类过程”。把缩小的部分写出来，是翻译的一部分，不是事后的补充说明。第五十一章做这件事。

四、两个原命题

现在把要翻译的东西摆出来。

原命题（先在论）：被知道的东西在被知道之前已经以某种方式在那里，形成过程是接近它的通道。

原命题（造成论）：被知道的东西的某些规定，是在特定条件与特定路径中才获得的；换一条路径则那些规定不同或不存在。

两句话的分歧点在哪里？不在“有没有约束”——两方都承认约束。不在“过程是否重要”——两方都承认过程有影响，先在论承认它影响快慢与顺利程度。

分歧点在一个很窄的地方：

形成过程，是不是结果之规定的一部分？

先在论说不是——过程是通道，通道的形状不进入被运送的东西。造成论说是——某些规定是在过程中才获得的。

这个窄处就是翻译要瞄准的靶心。一次好的翻译，必须把这个窄处保留下来，而不是翻成一个更宽泛、更容易测、但已经不含这个分歧的东西。

五、为什么选“可达集”作为分辨量

本书的选择是可达集。理由在这里说明，定义留给下一章。

要测“过程是否进入结果的规定”，需要一个能同时容纳两方主张的对象。

若只看单次训练的结果，两方都能解释：先在论说这是那个唯一答案的一个近似，造成论说这是这条路径的产物。单个结果不含分辨力——这是第七章那道闸在这里的重现。

若看所有可能路径所到达的结果的集合，情况就不同了：

- 先在论预言这个集合里的元素在与知识相关的一切层面上彼此等价。
- 造成论预言这个集合里存在实质不等价的元素。

两个预言对同一个对象取了相反的值。按第三节第一条，忠实性满足。

而这个集合在本案的现场上是可以被抽样的——每跑一次训练就得到集合里的一个元素，跑很多次就得到一个样本。按第二条，可测性也有了着落。

这就是选择可达集的全部理由：它是本书能找到的、唯一同时满足忠实性与可测性的对象。

六、翻译失败的两种方式

第三节那五条要求，是从失败的方式里倒推出来的。把失败的两种典型形态写出来，比逐条记要求更有用。

失败形态一·过度翻译：翻出来的命题比原命题强。

一个例子：把“路径是否进入结果的规定”翻成“不同的训练必然得到不同的模型”。后者比前者强得多——前者只主张存在不可消去的成分，后者主张差异是必然且普遍的。

过度翻译的后果是自找的败绩：测出来的读数达不到那个更强的标准，于是本方判负，而判掉的其实是一个自己加码出来的命题。

第五十八章第二条那条让步，正是为防这一手而写的：若读数落在“路径是选择器”那个图景上，本书承认判决未成，而不是硬把它说成胜利——但同样地，本书也不会因为达不到一个从未主张过的更强标准而认输。

失败形态二·翻译不足：翻出来的命题比原命题弱，弱到两方都能接受。

一个例子：把它翻成“训练过程对最终模型有影响”。这句话先在论完全同意——它承认路径影响到达的快慢与顺利程度。

翻译不足的后果更隐蔽：实验做得再漂亮，测出来的东西两方都点头，于是什么也没判。第七十四章那批欠规定性材料在本书里的处境，本质上就是这一种——它们测的是“差异存在”，而那句话两方共享。

两种失败的判别办法是同一个：把两方的主张各自代入翻译后的形式，看它们取的值是否相反。

- 若两方都取真，是翻译不足。
- 若造成论一侧取假而它本不该取假，是过度翻译。
- 若两方取值相反，忠实性满足。

第四十九章第三节做的就是这次代入。本书把它写成一道要执行的手续，而不是一个可以默认满足的条件——因为上面两种失败，都发生在没有人做这道手续的时候。

七、翻译能做什么，不能做什么

本编开头要把话说在前面。

翻译能做的：把一个无法被任何观察触及的分歧，变成一个关于可抽样集合的分歧。

翻译不能做的有三样：

其一，它不能保证翻译后的命题好测。可达集可以被抽样，但抽样需要跑很多次训练，而且需要在不同资源水平上跑——第六十六章第六节那个成本分档说的就是这件事。

其二，它不能消除“实质不等价”这个概念里的自由度。什么算实质，取决于允许哪些变换算标号，而第七十一章整章论证了那条界线是一个约定。翻译把问题变得可测，没有把它变得客观。

其三，它不能扩大结论的范围。这一条是第五十一章的内容。

三样合起来，得到本编对自己的定位：

翻译是把一场判不了的争论变成一场可以输的争论，仅此而已。

一场可以输的争论，比一场判不了的争论好——这是本书全部工作的前提，而它本身不是一个可被证明的命题，只是一个立场。本书把它明写在这里，不藏在后面。

一、定义

给定：

- 材料 **C**：语料。
- 装置 **A**：架构与优化器族。
- 判准 **L**：损失与评估。

训练过程会到达某个结果 **R**——模型的内部表征与外部能力的总和。

把所有可能的路径 **P**（种子、数据次序、课程等一切不改变 **C**、**A**、**L** 的变量）所能到达的结果的集合记作：

$$\text{Reach}(\mathbf{C}, \mathbf{A}, \mathbf{L}) = \{ \mathbf{R} : \text{存在路径 } \mathbf{P} \text{ 使训练到达 } \mathbf{R} \}$$

这就是可达集。

四个符号里，只有 **P** 不出现在括号里。这不是疏漏，是定义的要害：可达集是以材料、装置、判准为参数的对象，而路径被扫遍了。若路径不进入结果的规定，这个集合就退化成一个点（或一族彼此等价的点）；若路径进入规定，它就是一个有内部结构的集合。

整本书要判的，就是这个集合是不是一个点。

二、这个定义的三处约定

定义看起来简单，实际上藏了三处约定，每一处都可以被质疑。逐条写明。

约定一：“所有可能的路径”是什么范围。

严格说，路径变量的完备清单没有人有——第四十章第七节把这一点列为清单可能漏掉的东西之一。实践中，**P** 被理解为：随机初始化、数据呈现次序、批次构成、以及那些不改变 **C**、**A**、**L** 的训练配置。

若有一项路径变量未被识别，“扫遍所有路径”这句话就是假的，而可达集的抽样就是有偏的。首跑那处组内共享条件不齐（第六十六章第三节），正是这一处的实例。

约定二：**R** 是什么。

R 被定义为“内部表征与外部能力的总和”。这句话不是一个量，它是一个承诺——承诺 **R** 不被取成某个标量。第五十章第一处陷阱讲的就是若把 **R** 取成分数会发生什么。

约定三：“到达”要不要设一个终点。

训练可以在任何时刻停下。若在不同时刻停下算作不同的 R ，那么可达集会被训练时长撑得很大，而那个大与路径无关。实践中的约定是取充分训练后的状态，而“充分”需要一个事先指定的收敛判据——第五十六章第五节那条实验规格的第三项就是为此。

三处约定都不是数学上的必然，它们是为了让这个对象可用而做的选择。把它们写出来，是因为对手若要攻击本书的翻译，这三处是最省力的入口。

三、误读一：把可达集当成“模型能学会的一切”

第一种误读把 Reach 读成一个能力空间：这个架构在这份语料上最多能学会什么。

这不是可达集。

能力空间问的是上界——在最好的情况下能走多远。可达集问的是分布——在固定的材料与判准下，不同的走法实际会落到哪些地方。

两者的区别可以用一句话分开：能力空间与路径无关（它是所有路径的并的上界），可达集恰恰是要看路径之间的差别。

这一误读之所以常见，是因为工程语境里人们关心的通常是上界——这个架构行不行、能不能做到某件事。而本案关心的是另一件事。

四、误读二：把可达集当成“损失景观的极小点集合”

第二种误读更专业，也更危险，因为它看起来正确。

它说：Reach 就是那个损失函数的全部局部极小点。

这个读法把待判的命题塞进了定义。

理由有两层。

第一层：极小点集合是由 C 与 A 完全决定的——它不依赖路径。若把 Reach 定义成它，那么“Reach 由 C 、 A 、 L 决定”这句话就成了定义的后果，而不是一个待检验的命题。先在论不战而胜。

第二层，更实在：实际训练到达的状态未必是任何一个局部极小点。训练在有限步数后停止，落在哪里由停止条件决定；而且第七十六章第三节论证过，在实际系统中被下降的不是一个固定的函数，而是一族随路径变化的函数。

因此第七十六章那个“地址二”的检查，与这一误读是同一件事的两面：那里是对手把先在性安放在损失景观上，这里是把可达集定义成损失景观的产物。两处的回答也相同。

五、误读三：把可达集的元素当成“模型”

第三种误读最细，但它直接影响读数怎么算。

它把 Reach 的元素读成一个个训练好的模型——权重的具体取值。

问题在于：两个权重取值不同的模型，可以是同一个 **R**。

第五十五章第二条硬规定写过：神经元置换、正交变换、各向同性缩放都是标号，不是实质差别。两个在这些变换下等价的权重配置，对应同一个结果。

因此 **Reach** 的元素不是权重点，是权重点在某个变换群下的等价类。

而这里立刻接上第七十一章那条线：等价类由允许的变换群决定，而那个群的边界是一个约定。于是可达集这个对象，其“元素有多少个”这个问题，本身依赖于一个未被自然给定的选择。

这不是可达集特有的缺陷，它是本案在工程层面的最终形式（第七十一章第四节）。但它必须在定义这一章就被写出来，而不是留到第七十一章才交代——一个定义若依赖一个约定，那个依赖属于定义的一部分。

六、可达集与四个量的对应

可达集是一个抽象对象，而本书实际报告的是四个量。把对应关系列出来，因为这张表决定了每个量各自在测什么。

量	它是可达集的什 么	先在论预测	造成论预测
路径散度 $\Delta(N)$	集合在规模 N 处的直径（以样本估计）	随 N 衰减至噪声	衰减至正常数
不可消解度 κ	直径的极限	$\kappa = 0$	$\kappa > 0$
可归约份额 ρ	集合能被 C 、 A 、 L 的描述覆盖的比例	$\rho - 1$	$1 - \rho$ 稳定为正
标定不可达	集合是否“满”	不存在	存在

四个量里，前两个是同一个对象在有限与极限两处的读数，后两个各自对应一条独立的性质。

这张表有三处要说明，因为它们各自在后面被用到。

其一，四个量都是集合的性质，没有一个是单个元素的性质。这是可达集这个翻译的直接后果，也是为什么“看一个训练好的模型”永远判不了本案——第七章那道闸在这里的形式化表述就是：单个元素不携带集合的性质。

其二，直径这个说法依赖距离，而距离依赖变换群。第五节已经写过，这里再记一次：可达集的“大小”不是一个自然给定的量。

其三，“满”这个说法最难操作化。第五十七章第二节整节讲这件事——绝对不可达不可证，只能用带预算标定的相对陈述代替。于是第四个量与前三个不同：前三个是估计量，第四个是一个带条件的陈述。

这三处说明合起来，给出本书四个量的地位：它们不是四个平行的指标，而是同一个对象的三种性质在有限抽样上的四种读法。

七、一个自然的追问：可达集是不是一个空概念

本章最后处理一个针对这个翻译的根本质疑，它若成立，第五编全编作废。

质疑是：可达集是一个永远无法被完整确定的对象——路径无穷、抽样有限、边界依赖约定。用这样一个对象作翻译的落点，是不是在用一个空概念冒充一个可测对象？

这个质疑要被认真答，而且答案是有限度的。

第一步回答：它不需要被完整确定，只需要它的三个性质可被估计。第六节那张对应表说的就是这件事——直径、覆盖、是否满，三者都能在抽样上估计。一个不能被枚举的集合，其性质仍然可以被测量，这在统计里是常态。

第二步回答，也是本节要害：把这个质疑与它的替代品比较。

若不用可达集，还能用什么？

- 用单次训练的结果——第五节已论证：单个元素不携带集合的性质，两方都能解释。
- 用任务分数——第五十章第一处陷阱：把结论塞进度量。
- 用损失景观的极小点集合——第四节：把待判的命题塞进定义。

三个替代品各有一个致命毛病，而可达集的毛病是“难测”。在“塞进结论”与“难测”之间，本书选后者。

第三步，承认它没有解决的那一半：可达集的边界依赖变换群的选择（第五节），而那个选择是一个约定。因此本书的翻译把一个不可测的问题变成了一个可测但带约定的问题，而不是变成了一个客观的问题。

第四十七章第七节那句话在这里兑现：翻译把问题变得可测，没有把它变得客观。

若有人认为“可测但带约定”仍然不够，那么本书的回答只能是第四十七章第七节的最后一句：翻译是把一场判不了的争论变成一场可以输的争论，仅此而已。一场带着约定的可输的争论，与一场没有约定的判不了的争论，本书认为前者更值得进行。这是一个立场，不是一个被证明的命题。

八、可达集为什么不必被完整写出

最后处理一个实际问题：Reach 是一个不可能被完整枚举的集合——路径的数量是天文数字。那么用它做翻译有什么用？

用处在于：本书要判的不是这个集合的全部内容，而是它的一个性质。

具体说，三条条款各自问它的一个性质：

- 条款一：这个集合的直径随资源增加而如何变化？趋于零，还是趋于一个正数？
- 条款二：这个集合能否被一个只以 C 、 A 、 L 为自变量的描述覆盖？
- 条款三：这个集合是不是“满的”——是否存在只有某条路径才到得了的元素？

三个问题都可以在抽样上回答，不需要枚举。直径可以由样本间距离估计；覆盖可以由回归的可解释方差估计；不满可以由标定的不可达陈述给出（第五十七章第三节）。

这也解释了为什么本书的量是那四个而不是别的：它们是可达集的三个性质在有限抽样上的估计量。

下一章把双方的主张代入这个对象，得到分歧的最终形式。

第四十九章 分歧的最终形式

一、两个命题的可测形式

把两个原命题代入可达集。

先在论的可测形式：

Reach(C, A, L) 中的元素，在与知识相关的一切层面上彼此等价——差别至多是标号、坐标、置换，或者是可被更多算力与更大规模抹平的暂时差别。

简言之：路径不进入结果的规定。C、A、L 唯一地决定了被知道的东西，路径只决定到达它的快慢与顺利程度。

造成论的可测形式：

Reach(C, A, L) 中存在实质不等价的元素，而且这种不等价不随规模衰减为零。

简言之：路径进入结果的规定。要写出被知道的东西是什么，光给 C、A、L 不够，必须把 P 也写进去。

二、两个函数式

两句话对应两个判然不同的形式：

先在论： $R = \Phi(C, A, L)$

造成论： $R = \Phi(C, A, L, P)$ ，且 P 不可消去

这就是本书全部技术工作的靶心。判决的问题变成一个具体的问题：

P 能不能被消去？

“消去”这个词要说准，它有三种含义，而三条条款各对应一种。

含义一量上的消去：P 造成的差异随资源增加而趋于零。若如此，P 在极限上不出现在函数里。这是条款一。

含义二描述上的消去：P 造成的差异虽然不为零，但可以被一个只以 C、A、L 为自变量的描述写出来。若如此，P 仍然可以从函数式里消掉——它只是选择器，不是自变量。这是条款二。

含义三集合上的消去：不存在只有某个 P 才到得了的结果。若存在，那么 P 在最强的意义上不可消去。这是条款三。

三种含义是递进的，不是并列的。第五十八章第一节那张阶梯表，其逻辑根源就在这里：三条条款不是三个独立的检验，是“消去”这个词的三层含义各自的检验。

三、把分歧的窄处保住了吗

第四十七章第三条要求忠实性：翻译后的命题必须蕴含原命题的分歧点，而分歧点是“形成过程是不是结果之规定的一部分”。

现在检查。

先在论一侧： $R = \Phi(C,A,L)$ 这个式子里没有 P 。这正好对应“过程是通道，通道的形状不进入被运送的东西”。

造成论一侧： $R = \Phi(C,A,L,P)$ 且 P 不可消去。这正好对应“某些规定是在过程中才获得的”。

两方在同一个对象上取了相反的值，而且那个对象正是分歧所在的位置。忠实性满足。

但要立刻补上它的不完整之处。

原命题说的是“任何知识形成过程”，翻译后的命题说的是“以这份语料为材料、这个架构族为装置、这套损失与评估为判准的训练过程”。

范围缩小了，而且缩小得很厉害。这一处由第五十一章处理，而那一章的结论是：缩小之后的命题仍然有用，但它的用处是反例式的而不是全称式的。

四、“实质不等价”这个词必须事先定义

上面那两句可测形式里，有一个词承担了全部重量：实质不等价。

先在论说差别“至多是标号”，造成论说存在“实质不等价”。两方对同一个词的用法相反，而这个词本身没有自明的含义。

若不事先定义它，事后总能找到某种差别或某种相同。

- 想找差别？任何两个独立训练的模型，权重都不同，随便取一个指标都能测出差异。
- 想找相同？任何两个训练得当的模型，在多数常规任务上表现都接近，随便取一个基准都能测出一致。

于是结论完全由事后的指标选择决定，而这就是循环论证。

本书的处理是把定义推到第六编，并且用三条硬规定把定义的自由度锁住（第五十五章）：不得用任务分数；必须消去已知对称性；必须包含分布外行为；不得合成两通道。

这四条不是在定义“实质”，它们是在排除四种把定义做坏的方式。这是一个诚实的做法，但它有一个后果要写明：

本书没有给出“实质不等价”的正面定义，只给出了一组排除条件。

而第七十一章第五节那三个层级——严格保持函数不变、行为不可察觉、性能相当——说明了为什么给不出：那条界线是一个约定，而约定不能被定义出来，只能被选择并写明。

本书选的是第一层。选择本身是可以被反驳的，第七十一章第六节写了反驳的形式与本书接受的败绩条件。

五、两个式子之间还有第三种可能

本节处理一个常被忽略的情形，它既不是先在论也不是造成论，而它在读数上可能是最常出现的那一种。

第三种可能： P 在函数式里出现，但它的效应可以被完全归结为一个在 C 、 A 、 L 之下的分布选择。

写出来是： $R = \Phi(C, A, L, P)$ ，其中 P 的作用是从一个由 C 、 A 、 L 决定的集合里挑一个元素。

这就是“路径是选择器”那个图景（第五十六章第一节），也是第五十八章第二条让步所对应的状态。

它在形式上属于哪一侧？

属于先在论。因为那个被挑的集合是由 C 、 A 、 L 决定的，而“被知道的东西有哪些可能”这个问题的答案不依赖路径。

而它在直觉上常被当成造成论——毕竟路径确实改变了实际得到的东西。

这一处混淆是本案里最实际的一个陷阱，而且它是本书自己最容易掉进去的那一个。第五十八章第二条因此写得很硬：若读数落在这里，本书承认判决未成，不得把降级后的主张继续包装成“部分胜利”。

把第三种可能明写出来，是翻译工作的一部分：一个只给出两种可能的翻译，会迫使所有读数落进其中一种，而真实的读数很可能落在中间。

六、“不可消去”不等于“不可预测”

一个容易混淆的地方，值得在本编就拆掉，因为它会影响条款二的读法。

混淆是：把“ P 不可消去”读成“结果不可预测”。

两者不是一回事，而且它们的关系是反的。

“ P 不可消去”说的是：要写出结果是什么，函数式里必须有 P 这一项。

“不可预测”说的是：即使知道全部自变量的取值，也算不出结果。

一个函数可以有很多自变量而完全可预测——只要给定所有自变量，输出就定了。**P** 进入函数式，与函数不可算，是两件事。

这个区分有三处用处。

用处一：对相对主义那一记：第七十九章第三节论证路径进入规定不蕴含任意性，其技术形式就在这里——一个多了一个自变量的函数，仍然是一个函数。

用处二：对条款二的读法：条款二问的是 **P** 的效应能否被 **C**、**A**、**L** 的量预测。注意这里的“预测”是指用不含 **P** 的东西去预测。若能，**P** 可以被消去；若不能，**P** 不可消去——但这不妨碍“给定 **P** 之后结果完全确定”。

两句话可以同时为真：给定路径，结果确定；不给定路径，结果不确定。而先在论要的恰恰是第二句为假。

用处三：对一个可能的误用：有人可能用“训练是确定性的”来反驳本书——既然给定种子结果就定了，哪来的构成？

这个反驳落在本节的区分上：确定性说的是给定全部自变量（含 **P**）结果唯一；本案问的是 **P** 是否属于那批自变量。一个确定性的过程完全可以有不可消去的路径项，而这正是本书所主张的图景。

把这三处合起来，本节可以压成一句：

本书主张的不是世界不可算，是算的时候必须把走法写进去。

七、两个式子在首跑上的实际位置

本编写的是翻译，不是读数。但既然本书已经跑过一次，把首跑放回这两个式子上，可以检验翻译是否真的可用。

首跑测的是哪一个含义？含义——量上的消去，即条款一。

它测出了什么？表征通道上，可达集的直径在四个规模上不向零衰减；行为通道上，它单调下降但在最大规模上仍是噪声基线的两倍以上。两通道不一致，判未能分辨。

把这个结果放回两个式子：

- 它没有证实 $R = \Phi(C, A, L)$ 。
- 它没有证实 $R = \Phi(C, A, L, P)$ 。
- 它也没有落进第五节那个“第三种可能”——那需要条款二的读数，而条款二未跑。

三个位置一个也没落。

这件事对翻译的检验意义是什么？

正面的：翻译产生了一个可以什么都测不出来的结构。这听起来不像优点，其实是一个永远能落进某个位置的翻译，说明那些位置之间没有真正的分界（第六十四章第三节那条论证的翻译版本）。

负面的，而且要写足：翻译产生的结构，其可判性依赖于测量的质量，而首跑证明了测量的质量受制于一批翻译阶段没有预见的东西——噪声基线的定义、探针配比、间隔的选取。

于是本节给出一条对第五编自身的评价：

翻译做对了忠实性，做对了可测性，而在“可测”这个词的实际含金量上，它高估了自己。

第四十七章第三条那五条要求里，第二条只要求“落在一个量上，且那个量有明确的构造方式”。首跑说明这条要求太松——一个有明确构造方式的量，仍然可以因为构造里某个部件写错而不可用。

这一条应当被补进第四十七章那五条要求的第二条：量的构造方式不仅要明确，它的每一个部件都要可被单独检查。附二第二节那条“报告分母”的规定，就是这句话的最小执行形式。

八、翻译到此完成

本编的翻译到这一章完成。产出是：

- 一个对象：可达集。
- 两个函数式，以及它们之间的第三种可能。
- 一个待判的问题：P 能不能被消去，在三种含义的哪一种上。
- 一个必须事先定义、而本书只能以排除条件给出的词：实质不等价。

下一章写这次翻译可能被攻破的三个地方。

第五十章 三处翻译陷阱

翻译中偷渡的任何一点，都会使判决失效。本章写四处，每一处都会使整套论证变成循环。

前三处按危险程度排，第四处是首跑之后才浮出来的。

一、陷阱一：不能用性能代替结果

陷阱的样子。把 R 取成基准测试分数——在若干任务上各跑一遍，把分数向量当作结果。

这个做法顺手到几乎不需要理由：分数是现成的，可比的，有大量工具支持，而且所有人都在用。

它为什么会自动出某个结论。

分数是判准 L 在结果上的投影，而 L 是本案里被固定住的那一项。

用 L 的投影当结果，等于事先规定：凡是 L 看不出来的差别都不算差别。

而先在论要论证的恰恰是“差别只在标号上，在实质上不存在”。于是这个取法把结论塞进了度量。

后果是可预测的：在训练分布上，不同种子的模型分数高度接近——这本来就是它们被训练出来的目的。于是“不同种子的模型分数接近”会被误读为路径无关，条款一以一种看上去很干净的方式判负，而判负的原因不是路径差异消失了，是度量把它压掉了。

这一处陷阱在本书里出现了五次，每次的对象不同，值得列出来，因为它说明这不是一个孤立的技术要求：

- 第五十五章第一条：本书自己的结果距离不得用任务分数。
- 第七十二章：缩放律是关于损失的规律，而损失是判准的投影，因此它对本案不构成证据。
- 第七十三章第五节：那条种子间双峰的读数落在下游任务表现上，因此只能作旁证。
- 第八十三章第一节：现行评估测的是结果在判准上的投影，因此看不见结构差异。
- 第九章第四节：可重复性这个程序本身就是被设计来排除路径效应的。

五次是同一条：一个被设计来压平差异的量，不能用来测量差异。

二、陷阱二：不能事后定义“实质不等价”

陷阱的样子。先看读数，再决定什么算实质差别。

这个陷阱不像第一个那样有一个明确的技术动作，它是一种时间顺序上的错误，因此更难被发现——做的人常常不知道自己在做。

它为什么会自动出某个结论。

第四十九章第四节已经写过：任何两个独立训练的模型都有无数种差别，也有无数种相同。想找差别，取一个足够细的指标；想找相同，取一个足够粗的指标。两种都能做到，而且都不需要说谎。

于是若定义在读数之后做出，结论完全由指标选择决定。

本书的处理，以及它的实际执行情况。

处理是预注册：距离的完整定义、探针集的全部条目、判负条件，全部在接触任何读数之前冻结并公开摘要值（第五十九章、第六十章）。

执行情况是：这一条被遵守了，而且它真的挡住了一样东西。

首跑的两个通道给出相反方向的读数。若定义可以事后调整，最自然的做法是把表征通道说成主要的、行为通道说成次要的，然后报告一个方向。而第4条第三款在执行前就写着“两通道结论不一致则判未能分辨”，于是本书什么也没说（第六十四章）。

但这一条也有它没能挡住的：第五十九章第六节那句话——预注册保护的是“事后不许改判据”，它不保护“事前把判据写错”。首跑的噪声基线就是事前写错的一例。这一处陷阱被挡住了，另一处没有。

三、陷阱三：不能把工程缺陷读成本体论

陷阱的样子。看到一批关于“不同种子给出不同结果”的报告，直接把它们当作造成论的证据。

这是本书这一侧最容易掉进去的陷阱，而且它比前两处更难察觉，因为掉进去的人得到的是对自己有利的结论。

它为什么不成立。

第五十二章第二节写过：迄今为止机器学习中所报告的绝大多数路径依赖，都是先在论的自家话。非凸优化的局部极小当然依赖初始点，但目标函数由C与A给定，极小点集合在训练开始之前就已确定。

那些报告说的是“路径差异存在”。而本案要判的是“路径差异是否随资源消失”。前者不蕴含后者，而且前者与先在论完全相容。

因此第七十四章那批材料——欠规定性、多种子基准、次序效应——在本书里只能作为理由，不能作为读数。那一章第八节把这一点写死。

这一处陷阱还有一个更细的版本，值得单独点出。

工程文献里的路径依赖报告，其因变量几乎全是性能或可靠性指标。于是它们同时踩中陷阱一与陷阱三：既用了判准的投影，又把差异的存在当成了差异的不可消除。

本书对这类材料的正确用法只有一个：把它们当作“这类效应不是虚构的”的说明，以及当作设计实验的理由。第六十六章第四节那条探索性读数的处理方式，就是这个用法的标准形态——它把形式三从一个想法变成一个值得花钱去跑的实验，仅此而已。

四、第四处：不能把装置的限制读成对象的性质

上面三处是论文阶段就识别出来的。首跑之后浮出第四处，它比前三处更隐蔽，因为它不发生在设计阶段，发生在读数阶段。

陷阱的样子。把一个由装置或判据造成的现象，读成被研究对象的性质。

首跑提供了一个干净的实例。

归一化后的比值在最大规模处从 40.4 掉到 13.4。若只看这一列，自然的读法是“路径差异在大模型上急剧衰减”——一个关于对象的结论。

而实际情况是：分子只从 0.441 降到 0.411，分母从 0.0109 跳到 0.0306。那次坍缩主要是分母造成的，而分母是判据的一部分，不是对象的性质（第六十五章）。

第二个实例在同一跑里。

分组比值在最大规模上四组全线下降，其中中文那一组掉到 1.37，接近噪声。而那一组的基线在同一处从 0.045 跳到 0.121——同样是分母（第六十三章第六节）。

为什么这一处比前三处隐蔽？

因为前三处发生在设计阶段，一个认真的人在动手之前有机会发现；而这一处发生在数据已经出来之后，那时人已经在看一条曲线，而曲线看起来像是在说对象的事。

本书的处理办法，是一条很便宜的程序规定：

报告分母。凡使用任何归一化，把分子、分母、以及比值三者分别列出。

这一条不增加任何计算成本，却能把一整类隐形错误变成可见的。第六十五章第七节把它作为一条超出本案的建议提出，本章把它补进翻译陷阱的清单，因为它的根在翻译阶段——一个量若是复合的，它的成分必须可被拆开检查，否则它就不是一个合格的翻译产物。

这一处陷阱也有它对两侧的对称性：第八十章第七节指出，表征收敛那一线的读数同样很少报告“同一路径内的正常波动有多大”，因而同样面临“上升是否只是度量的产物”这一问。

五、四处陷阱的共同形状

把四处并排：

陷阱	错在哪一步	谁容易掉进去
用性能代替结果	度量选错	两侧都会，先在论受益
事后定义实质不等价	时间顺序错	两侧都会，结论由指标
把工程缺陷读成本体论	推论跨了一步	造成论一侧，本书受益
把装置的限制读成对象的性质	读数阶段归因错	两侧都会，且事后才显

四处的共同点是：它们都不需要任何人说谎。

每一处都可以由一个诚实、认真、方法上无可指摘的研究者踩中。陷阱一是行业惯例；陷阱二是人正常工作的方式；陷阱三是一个看起来只差半步的推论。

这解释了为什么本书用了这么多篇幅在程序上——预注册、冻结、双通道、败绩条件、六条不主张。若这四处陷阱只有不诚实的人会踩，那么呼吁诚实就够了；而既然诚实的人也会踩，就只能靠事先写死的程序。

最后补一句对本书不利的：本章列了四处，不等于只有四处。第四十八章第二节那三处约定、第七十一章那条变换群的界线、第八十章那三个自由参数，各自都是翻译在别处可能被攻破的地方。四处是本书能想到的，不是全部。

第五十一章 判一个实例不等于判全称

一、翻译之后剩下的那个问题

前四章把命题翻成了可测形式。即使翻译完全成功、即使三条条款全部给出干净的读数，还剩一个问题：

判决的是一个实例，而原命题是全称的。

本书判的是“以这份语料为材料、这个架构族为装置、这套损失与评估为判断的训练过程”。原命题说的是“任何知识形成过程”。

两者之间有一段距离，而本章的全部内容就是把这段距离量出来，并说明本书用什么方式跨过它——以及跨到哪里为止。

二、两种可能的论证结构

从一个实例走向一个一般结论，有两条路。

路一·类比结构：A 有性质 P，B 与 A 相似，所以 B 大概也有 P。

若本书走这条路，它会这样说：模型训练与人类学习相似，模型训练中路径进入结果，所以人类学习中路径也进入结果。

这条路本书不走，理由有三条。

其一，它的强度取决于相似性，而模型与人在相似性上的争论可以无限进行，永远得不出结论。

其二，它会把本书拖进一场关于心智的辩论，而本书在第四十五章明确设限不参与。

其三，也是最实际的：这条路太容易被截断。对手只需要说“模型与人不相似”，整条论证就停了。

路二·反例结构：存在一个 X，它落在全称命题 Q 的范围内，而 Q 在 X 上不成立；因此 Q 不成立。

这是本书走的路。

三、反例结构怎么用在本案上

先在论在其最一般的形态上主张的是：

任何以材料为输入、以判准为约束的知识形成过程，其结果由材料与判准唯一决定，路径不进入规定。

这是一个全称命题。

削弱它不需要类比，只需要一个实例；而那个实例长什么样，第七十七章第二节已经写明，本章不重复其表述，只引其要点：材料与判准都被固定，只有走法不同，而结果的规定跟着不同。

大模型训练若给出这样的实例，那么被否证的不是“人类知识也这样”，而是那条全称命题所依赖的普遍性。

这条论证有一个关键的前置条件，第四十四章第八节写过，这里再确认一次：

那个实例必须真的落在全称命题的范围内。

范围是“以材料为输入、以判准为约束的知识形成过程”。大模型训练是不是？材料是语料，判准是损失与评估，产物具有知识主张的形式（可以被评价为对或错，可以与世界上的事对照，可以在对照失败时被修改）。

三条都满足，它就在范围内。它不需要“像”任何别的东西。

这也是第四十二章为什么排除实验演化的理由：生物性状不具有知识主张的形式，因此它不在那条命题的范围内，把它的结论搬过来就需要类比。

四、普遍性破了之后会怎样

这是本章分量最重的一节，因为它说明本书能取得的最大收获是什么。

普遍性一旦破了，先在论就必须为它想主张的每一个领域单独举证——而这正是它两千年来从未做过的事。

两千年来，先在论不需要为“数学知识”和“化学知识”分别举证，因为它主张的是一条关于知识形成的一般原则。那条原则是默认的、不被追问的、构成了“发现”这个词的日常含义的一部分。

一条一般原则被一个实例破掉之后，它的每一次应用都变成一次需要独立辩护的主张。

这是一个巨大的地位变化，而它不要求模型与人相似。

用第七十七章第三节那三条边界来写清这个收获：

- 它不证明人类知识是被造成的。
- 它确实取消了“知识必然由材料唯一决定”这一原则的先天地地位，把它从公理降为待证的经验假设。
- 它确实为造成论提供了此前从未有过的东西：一个可重跑的实例。

第二条是本书的主要收获，而且它即使在最弱的读法下也是真实的（第四十五章第六节）。

五、反例结构自己的三处弱点

反例结构比类比结构硬，但它不是没有弱点。三处，逐条写明。

弱点一：对手可以修改全称命题。

面对一个反例，最自然的应对是给命题加条件——“任何由理解者进行的知识形成过程……”。

这一步对手可以走，而且走了对本书部分有利（第四十五章第五节论证过：加条件等于把那条原则改小，而本书想要的正是让它变小）。

但它也部分不利：加了条件之后，对手可以说本书的结论与人类知识无关。本书对此的回答只有第四节那三条边界，而三条都不足以让对手满意。这是一笔未结的账，第四十五章第五节已经记下。

弱点二：反例必须真的是反例。

若读数最终落在第四十九章第五节那个“第三种可能”上——路径只是选择器——那么它不构成反例，因为那个图景与先在论完全相容。第五十八章第二条那条让步就是为这种情形写的。

弱点三：一个实例不给出另一条全称命题。

这一条是本章开头就说过的，但它值得再说一次，因为它是本书结论之弱的根源：

本书能拿到的最好结果，是让一条原则失去先天地位；本书拿不到的是另一条原则。

一个只能否定而不能建立的论证，其结论必然是有限的。本书接受这个限制，并且认为它是反例结构的代价而不是缺陷——建立一条关于知识形成的新普遍原则，需要的正是第十一章那条教训所警告的那种做法。

六、反例结构在别处的先例

本书用反例结构，不是一个新发明。把先例点出来，有两个用处：一是说明这个做法有前例可循，二是从前例里看出它通常能走多远。

先例的一般形状是：一条被当作普遍必然的原则，被一个具体的构造推翻，而推翻它的构造并不主张自己是新的普遍原则。

这类事在数学与形式科学里最常见——一条被认为对一切情形成立的断言，被一个构造出来的对象证伪，而那个对象往往很特殊、甚至很“人工”，它不代表典型情形，它只需要落在断言的范围内。

这个形状有两个特征，对本书都适用。

特征一：反例可以很特殊，只要它在范围内。

有人可能反驳说，大模型训练是一个非常特殊的过程，不典型，因此不足以推翻一条关于知识形成的一般原则。

按反例结构，“不典型”不是反驳。一个反例的功能不是代表典型情形，而是落在范围内并且不满足那条断言。第四十四章第八节那句“它自己就是一个实例”说的正是这件事。

特征二：反例推翻的是普遍性，不建立替代品。

这与第五节弱点三是同一件事。构造出一个反例的人，通常不会因此得到一条新的普遍定理；他得到的是一条被限制了范围的旧定理，以及一批需要重新逐案检查的推论。

本书能得到的正是这个：先在论不被推翻，它被限制；而它此前的每一次应用都要重新检查。

先例也显示了这条路的两处限度。

限度一：对手可以接受限制然后继续。一条被加了条件的原则，在它的新范围内照常使用。这与第五节弱点一是同一件事。

限度二：反例的说服力取决于范围的判定，而范围的判定可能有争议。在形式科学里，“这个对象是否满足定理的前提”通常有明确答案；在本案里，“大模型训练是否落在那条原则的范围内”取决于“产物是否具有知识主张的形式”，而那是一条本书自己划的线（第四十二章第六节）。

两处限度合起来说明：本书用的是一个成熟的论证形式，而这个形式在本案上的效力，比它在形式科学里的效力弱——弱在范围判定不是自明的。

这一节因此以一句对本书不利的话结束：反例结构给了本书一条硬的路，但那条路的入口（范围判定）仍然是软的。

七、若翻译最终被判为失败

最后写一个本编必须考虑、而前面六节都没处理的情形：翻译本身被判为不忠实。

这不是读数判负，也不是条款判负。它是一个更靠前的失败：有人指出，本书所翻译出来的命题，与原命题的分歧点不是同一处。

这件事怎样才算发生？

按第四十七章第三条那五条要求，翻译失败有三种可被指认的形态：

形态一·忠实性被攻破：有人指出两方的主张代入本书的形式后取的是同值，或者取值相反但那个相反与原分歧无关。

形态二·中立性被攻破：有人指出可达集这个对象或本书的距离构造，本身已经偏向某一方。第四十八章第四节那个“把可达集定义成极小点集合”的误读，若本书真的踩中了，就属于这一形态。

形态三·范围诚实被攻破：有人指出本书所翻译的那个过程，并不落在原命题的范围内——具体说，“产物具有知识主张的形式”这条线站不住。

三种形态里，本书认为第三种最可能发生，理由在第四十二章第六节写过：那条线是本书自己划的，不是公认的，而本书拒绝实验演化的外推与本书自己的合法性靠的是同一条线。

若翻译被判为失败，本书交出什么？

这一条不在第五十八章那四条败绩条件之内，因此必须在这里单独写死：

若翻译被判为不忠实，本书的全部读数作废，而不是被重新解释。

“作废”与“重新解释”的区别是要害。一个失败的翻译所产生的读数，不能被搬到另一个翻译下继续使用——因为那些读数的每一个部件（距离的定义、探针的选择、判负的条件）都是按这个翻译定的。

本书接受这条，并且认为它是本编存在的理由：把翻译单独写成一编、把它可能被攻破的地方逐处点名，正是为了让这种失败可以被指认，而不是让它以“读数还是有参考价值”的形式含糊地存活下去。

八、这一编到此结束

第五编交出的东西：

一套翻译要求（五条），以及翻译不是降格这一澄清。

一个对象：可达集，连同它的三处约定与三种误读。

分歧的最终形式：P 能不能被消去，在三种含义的哪一种上；以及两者之间那个最容易被混淆的第三种可能。

三处翻译陷阱，以及它们的共同形状——三处都不需要任何人说谎。

一个论证结构：反例式而非类比式，以及它自己的三处弱点。

到这里，第四编那台装置与第六编那三条条款之间的缝合完成。装置能做什么写在第四编，问题被翻成什么形式写在本编，怎么判写在第六编。

第六编第五十二章那个承重区分，正是从本编第四十九章第二节那三种“消去”的含义长出来的。下一编开始浇柱子。

第六编 三条款

本编是全书的承重部分。

第五十二章立柱子：计算性路径依赖与构成性路径依赖的承重区分。拆不干净，后面全部作废。

第五十三章写案例的天花板——为什么此前一切造成论的实证工作都只做到第一种；缺的不是材料，是极限，而极限需要可重跑与可缩放，历史一样也给不出。

第五十四至五十七章把那三对判别特征兑现成三条可执行的条款，各带一个量、各带判负条件。第五十五章另立四条硬规定，其中第四条是首跑之后补上的。

第五十八章写死四条败绩条件，并处理一个结构性弱点：判负条件是本书写的，而判它有没有被触发的也是本书。第五十九章写那套预注册方法学，以及它挡不住的那一类错误。

本编的每一处读数都与它的判负条件写在同一页。

一、僵局不是证据不够，是同一个词被两边各用各的

到这一编为止，书里已经把两侧的现役武器都摆在台面上了。先在论有表征收敛、有彩票假说、有线性模式连通；造成论有欠规定性、有多种子基准、有次序与课程效应。一个读到这里的人很容易生出一个印象：材料已经够多了，剩下的只是掂量哪一堆更重。

这个印象是错的，而且是本案两千年判不下来的近因之一。

把双方的材料并排放一次就看得出来。先在论拿得出路径依赖的证据——它从不否认不同种子训练出的模型不一样，它只是说这种不一样会随着规模消失。造成论也拿得出路径无关的证据——它从不否认所有模型都学会了主谓一致，它只是说那不是全部。两侧不是在同一个命题上取了相反的值，两侧是在两个不同的命题上各取了一个值。

原因在于“路径依赖”这个词。它在先在论嘴里指的是求解过程的有限性；在造成论嘴里指的是结果的存在条件。这两件事都会在实验里表现为“换一条路，结果不一样”，而且在中间规模上表现得几乎一模一样。于是双方各自用自己的意思去读对方的数据，各自读出自己要的结论，谁也没有说谎，谁也没有说服谁。

一个词承担两个互不相容的所指而不被察觉，是哲学悬案最常见的病灶。处理办法只有一个：把词拆开，拆到两个所指各有各的判别特征，且这些特征在同一个实验里给出可以相互排除的读数。

本章做的就是这件拆分。这是全书的承重柱：第五十三章到第五十七章的三条条款，全部是这一次拆分的操作化；第八编对手的每一件旗舰，也都只有放回这个区分里才知道它究竟赢下了哪一半。拆不干净，后面全部作废。

二、定义一：计算性路径依赖

定义（计算性路径依赖）：路径差异造成的结果差异，其原因在于求解过程的有限性——有限步数、有限算力、有限数据、非凸景观中的局部停留。

它有三个判别特征，三条都要给足，缺一条就不算。

特征一，差异随资源增加而系统性衰减。这不是一句修辞，是一条可以画成曲线的经验后果。给定同一套材料、同一台装置、同一个判准，把资源逐级加上去，不同路径之间的结果距离应当逐级变小，并且在外推上趋于零，或

趋于纯测量噪声的水平。它可以衰减得慢，可以衰减得不均匀，可以在某一段先升后降——但方向必须是那个方向，且极限必须是那个极限。

特征二，存在一个与路径无关的描述。这一条比第一条更根本，也更常被漏掉。计算性的意思是：那个“正确答案”本来就被材料、装置与判准共同规定好了，不同的路径不过是对同一个东西取了不同精度的近似。因此必须存在这样一个描述，它只以材料、装置、判准为自变量，不提路径，而每一条路径的结果都可以被归结为该描述下的一个近似或一个成员。写不出这个描述而仍然坚持差异是计算性的，等于把计算性当成了信念而不是命题。第五十六章的条款二做的就是向对方索要这个描述。

特征三，差异在消去已知对称性之后缩小。两个结果之间的距离里，往往有一部分是纯标号的：神经元换个排号、整层乘一个正数、内部坐标系转一个角度。这些不是实质差别。真正的计算性差异，在把这些对称性消去之后会变小；若消不掉，说明剩下的那部分不属于标号。这一条对本书极其重要，因为它是我们主动给自己设的障碍：不允许靠标号差异赢。

举一个干净的例子。两个人各用一种算法算圆周率的小数位，一个用级数，一个用迭代公式。跑同样的时间，两人手上的数字串不一样。这个差异确实由路径造成，确实可测，也确实可以做出漂亮的图。但它是计算性的，三条特征全中：多给时间，两串数字会越来越像；存在一个不提算法的描述——圆周率本身——两串都是它的近似；而且这里根本没有标号自由度可言。没有人会说这两个人算出了“不同的圆周率”。

这个例子平庸得近乎无趣，而它正是要害所在：迄今为止机器学习里报告过的绝大多数路径依赖，在结构上都是这个例子。非凸优化的局部极小当然依赖初始点和下降轨迹；但损失函数是由数据与架构给定的，极小点的集合在第一步梯度落下之前就已经被完全确定。训练走到了哪一个，是路径的事；有哪些可以走到，是先在的事。

所以要讲得更硬一些：计算性路径依赖是先论的自家话，而不是造成论的战利品。把它当证据捧出来，是这场辩论里最常见、也最便宜的胜利。本书第一件要做的事就是把这条捷径堵死——不是出于风度，是出于自利：靠它赢下来的判决，对手一夜之间就能收回去。

三、定义二：构成性路径依赖

定义（构成性路径依赖）：路径差异造成的结果差异，其原因在于结果的存在条件包含路径本身。

判别特征同样是三条，逐条与上面相反。

特征一，差异不随资源增加而衰减为零。加规模、加算力、加数据，路径间距离趋于一个正的常数。注意这里要求的是极限而不是趋势：一个衰减到正常数的量，与一个衰减到零的量，在中间规模上几乎无法用肉眼分辨。第五十四章的条款一就是把这条差别变成一个可拟合的量。

特征二，不存在只由材料、装置、判准构成的描述能把不同路径的结果统一归结。索要地址而索要不到。这一条是条款二。

特征三，某些结果只有某些路径到得了。在最严格的意义上说，可达集不是满的：固定材料、装置与判准，把所有路径跑遍，也有一些结果落在集合之外——不是因为算力不够，而是因为从那条路走过去，那里没有那个东西。这一条是条款三。

三条特征的强度是递增的，不是并列的，这一点第五十八章会写清楚。

再举一个同样平庸的日常例子作锚。两个厨房各养一罐老面引子，起手的面粉与水是同一批，室温与喂养的频率都对齐，只有第一次静置时厨房里飘进去的东西不同。养一个月，两罐引子里的菌群不一样，发出来的面也不是一个味道。养十年，还是不一样——并且不会因为多养十年而互相靠近。这里不存在一个“正确的引子”，使得两罐都是它的近似；也没有哪一罐只是“还没养到”。两罐引子不是同一个东西的两个近似，是两个东西。

这个例子和圆周率那个例子放在一起，本章要的那条界线就现出来了：

计算性路径依赖说的是“你还没走到”；构成性路径依赖说的是“从这条路走过去，那里没有那个东西”。

这句话是全书反复回到的那一句。它看起来像修辞，其实每一半都对应着一组可以写死的判负条件，本编余下七章的工作就是把这两半逐条兑现。

四、日常例子能帮我们认出区分，不能帮我们判案

上一节的老面引子有一个危险：它太顺手了。顺手的类比会诱人越过一道本书不许越的门槛。

把那两罐引子当成构成性路径依赖的证据，需要满足什么？需要证明它们不会收敛——也就是把这个厨房重开一千次，把“资源”（这里是时间与喂养量）加上一两个数量级，看差异是否趋于正常数。但这件事做不到。厨房不能重跑，菌群的“规模”没有一个可以逐级加上去的自变量，而且更要紧的是，没有人能在两罐引子之间定义一个可辩护的距离，使得“差异不衰减”这句话有确定的含义。

所以那两罐引子只能当作辨认工具：它让人看清两种路径依赖在直觉上的不同形状。一旦要求它判案，它立刻退化成一个故事。

这不是老面引子的缺陷，是案例这种证据形式本身的天花板。它同样罩住了库恩的范式、皮克林的冲撞、强纲领的全部个案研究——那些工作在展示历史路径如何塑造了结果这件事上做得极为出色，但它们没有一件能排除“换一条路最终也会走到那里，只是更慢、更绕”。它们缺的从来不是材料，是极限；而极限需要可重跑与可缩放两样东西，历史一样也给不出。第五十三章专门处理这件事，那一章是本书对造成论自己这一侧最不留情面的一章。

因此本章要立的纪律很简单，写在这里，全书适用：

类比用于辨认，读数用于判决。本书不允许任何一个日常例子、历史案例或思想实验出现在判决位置上。

五、这个区分为什么是可判的

拆词容易，拆完之后两边仍然各说各话，才是常态。本章之所以不是又一次概念辨析，是因为这两个定义的判别特征全部落在可测的量上，而且这些量在同一个实验里指向相互排斥的方向。

把三对特征并排列出来：

	计算性	构成性	落成的条款
资源加上去	差异衰减到零或噪声水平	差异趋于正常数	条款一（第五十四章）
不提路径的统一描述	存在	不存在	条款二（第五十六章）
可达集	满的	不满	条款三（第五十七章）

三条都通过，构成性路径依赖成立。任何一条判负，本书作出相应让步，让步的具体内容在第五十八章逐条写明——那一章也把四条败绩条件写死，写死的时间在任何读数产生之前。

这里要提前说破一处风险，因为它足够重，不该藏到第九编去。第一行那个量依赖于“差异”怎么度量，而度量是本书的自由参数。取一种度量差异衰减，取另一种不衰减，这件事完全可能发生。若真如此，那么本章立的区分本身就会在经验上不可判，全书的判据随之作废。第八十章正面处理这一记反击，处理的办法不是辩解，是把自由参数逐处点名并在预注册中冻结。这里先记一笔：本书的判据有一个可以杀死它的方式，而我们知道那个方式是什么。

六、首跑把这根柱子顶到了哪里

本书的纪律是不利读数与有利读数同等篇幅，所以在这根柱子刚立起来的地方，就要把已经跑出来的东西摆出来，而不是等到第七编去摆。

第七编报告的首跑，测的正是表格第一行。材料是 PolyPythias 的公开检查点，四个规模点（14M、31M、70M、160M），每个规模五个只在路径上不同的运行，探针集在执行之前冻结。

表征通道的读数：路径间距离在 14M 到 160M 上依次是 0.352、0.445、0.441、0.411，先升后持平，没有向零衰减的迹象。这个读数是在线性中心核对齐度量下得到的，而该度量对神经元置换、正交变换与各向同性缩放不变——也就是说，上一节特征三要求的对称性消去已经做过了，这些差异不是标号差异。作为对照，同一条路径内相邻一千步的两个检查点之间，同一个量在最大规模上只有 0.031。

行为通道的读数：路径间距离依次是 0.263、0.221、0.171、0.116，单调下降。归一化之后，从基线的 6.45 倍降到 2.37 倍。

按预注册第四条写死的规则，条款一通过的条件是归一化量不趋向 1 且无向 1 衰减的单调趋势——表征通道满足，行为通道不满足；条款一判负的条件是归一化量单调下降且在最大规模不显著区别于 1——行为通道满足前半条，不满足后半条。两通道结论不一致，按第四条第三款判未能分辨。

这就是这根柱子目前的受力状态：它立住了，但还没有被读数压实。有一件事必须说清楚——如果只报表征通道，这一跑看上去是条款一的一次漂亮通过；如果只报行为通道，这一跑看上去是一次清楚的败绩。两种写法都能成文，两种都是作弊。第六十四章专章论证为什么“未能分辨”本身是一个结论，而不是一次没有结论。

还要补一句本跑暴露出来的方法论缺陷，因为它直接影响上面这几个数字该怎么读。作噪声基线用的“同一路径内相邻检查点”，在 14M、31M、70M 上稳定在 0.0134、0.0129、0.0109，到 160M 跳到 0.0306，接近三倍。归一化量在最大规模处从 40.4 掉到 13.4，主要不是分子变了，是分母变了。这意味着这条基线测到的是训练在该规模该时刻的推进速率，而不是一把跨规模恒定的尺子。后果是明确的：本跑的归一化曲线不能作为规模趋势的证据，只有各规模内部“路径间远大于路径内”这一条比较仍然成立。第六十五章专章写这件事，并据此修订第十三章的冻结项清单。

七、这根柱子撑起来的是什么

收束一句，把这一章在全书里的位置钉死。

拆开“路径依赖”这个词，本身不产生任何新的经验内容。它产生的是判决的可能性：在拆开之前，两侧的全部材料都是相容的，谁也驳不倒谁，争论可以再持续两千年而不损失任何一方的融贯性；拆开之后，两侧对同一批可测量的量给出了相反的预言，而相反的预言是可以被读数分开的。

这正是本书那一句脊梁在这一章里的具体形状。缺的从来不是论据——论据双方都堆成了山。缺的是一个使论据开始互相排斥的位置，以及一台能把过程重跑到那个位置上的装置。装置在第四编已经交代，位置就在本章这三行表格里。

接下来的五章把三行表格变成三条可执行的条款，第五十八章写死败绩条件，第五十九章写死冻结的方法学。到那时，这道题将第一次具备被判错的资格——而一道题能被判错，是它能被判对的全部前提。

第五十三章 案例的天花板：为什么此前的造成论只做到第一种

一、先把话说公道

造成论在二十世纪并不是没有实证工作。恰恰相反，它拥有的经验材料在数量与细致程度上都远超对手。库恩之后的六十年里，科学史与科学社会学把一桩又一桩知识的形成过程拆到了螺丝钉的层面：谁在什么时候做了什么实验、用了谁的仪器、引了谁的话、在哪一次会议上被谁说服、哪一份数据被丢掉又为什么被丢掉。这是一批极为出色的工作，它们做对的事至少有三件。

第一件，它们证明了过程不是透明的。在此之前，通行的图景是：自然界有一个事实，研究者用方法把它取出来，中间那段过程只是传输通道，通道的形状不影响被传输的东西。这一批案例研究把通道剖开了，里面全是结构——仪器的可用范围、共同体的裁定习惯、资源的分配、争论的收束方式。通道有形状，而且形状千差万别，这一点此后没有人能再否认。

第二件，它们证明了结果的确随过程而变。皮克林对夸克模型形成过程的追踪、对高能物理共同体如何在两条互不相容的解释之间收束的重建，不是印象式的叙述，是有档案、有实验记录、有当事人访谈的重建。强纲领的个案研究同样如此。这些工作反复给出同一种形状：换一批人、换一套仪器、换一个时间点，落下来的结论会不同。

第三件，它们把“社会因素”从贬义词里救了出来。在此之前，说一个结论受到社会因素影响，等于说它是错的。这一批工作的贡献是把“如何形成”与“是

否为真”拆开，让人可以一边承认某个结论是在特定共同体条件下形成的，一边继续认为它是对的。这是一个真正的概念进步。

所以下面要说的话，不是对这批工作的否定。它们做的每一件事都做成了。问题在别处：它们做成的那件事，不是本案需要的那件事。

二、把这批案例放进第五十二章的三对特征里

上一章给出了三对判别特征。现在拿它们去量这批案例，逐条看。

第一对：资源加上去，差异衰减到零，还是趋于正常数？

这一栏，案例研究一格也填不上。不是填错了，是填不了——因为没有“资源加上去”这个动作可做。一段历史只发生了一次；没有更多的算力可以加给它，没有更长的时间可以补给它，没有第二次可以拿来对照。案例研究能给出的最强陈述是“在实际发生的这一次里，结果依赖于过程”，而这句话与“再多给些时间它们也会走到一起”完全相容。

第二对：存在不提路径的统一描述吗？

这一栏可以填，但填出来的东西没有判别力。任何一个历史案例，事后都可以被写成“它们其实都在逼近同一件事，只是绕了远路”，也都可以被写成“它们抵达了不同的东西”。两种写法都能自洽地把全部史料安置进去，因为史料本身不含有能把两种写法分开的项。这正是第七章讲过的观察等价在历史材料上的表现。

第三对：可达集是不是满的？

这一栏最难填，也最能说明问题。要说“某个结果只有某条路径到得了”，必须先证明别的路径到不了；而要证明别的路径到不了，必须能把别的路径真的跑一遍。历史学家能做的只有反事实推测——如果当年李比希那一派赢了会怎样。反事实推测在科学史里是一种有价值的思维练习，但它不产生读数。没有人能把十九世纪的发酵之争重开一千次。

三栏的结果是：一栏填不了，一栏填了但没判别力，一栏只能靠推测。这就是案例这种证据形式的全部战绩。

三、三例解剖

抽象的判断不如具体地解剖三次。选这三个案例的理由只有一个：原始记载扎实，不必依赖二手评述。

例一微积分的两套记法。牛顿的流数与莱布尼茨的微分，是两条几乎完全独立的路径，起点不同、动机不同、记法不同，随后又引发了一场持续几十年的优先权争执。在当时的当事人看来，这显然是两件不同的东西。而今天的

共识是：它们是同一个数学内容的两套记法，其中一套（莱布尼茨的）因为形式上更顺手而胜出。

这是一个教科书式的计算性案例，而且三条特征全中：差异在后续的发展中衰减到了记法层面；存在一个不提路径的统一描述——微积分本身——两套记法都是它的表达；剩下的差别是纯粹的标号。用第五十二章的话说：两位当事人没有算出不同的微积分。

值得注意的是，当时没有任何人能判定这一点。要到一百年后，在两套记法都被翻译成第三套语言之后，“它们是同一个东西”这句话才有了确定的含义。判定需要的东西，在事件发生的时候不在场。

例二：发酵之争。十九世纪中叶，巴斯德主张发酵是活细胞的生命活动，李比希主张它是一种化学分解过程，可以不涉及活的有机体。两条路径的起点、仪器、判准都不同，争论持续了数十年，语气之激烈远超学术分歧的常态。后来毕希纳用无细胞提取液做出了发酵，把两边各自对了一半这件事摆到了台面上。

这个案例好在它看起来像构成性的：两派抵达的不是同一个结论，而是两个互不相容的结论。但它判不了案，原因很直接——存在第三种解释，而且这第三种解释在事后被证明更接近实情：两派都没走完，各自握住了同一件事的一部分。“抵达了不同的东西”与“都还没走到”，在这个案例上无法分开。而分不开，正是全案僵在那里的形式。

例三：孟德尔与三重再发现。孟德尔 1865 年的工作在当时几乎无人理会，三十五年后由三位彼此独立的研究者在几乎同一时间各自重新做出。这个案例是先在论最喜欢引的那一类：结果在那里等着，第一条路径走到了但没被接住，另外三条路径后来各自又走到了同一处。

放进三对特征里：差异随时间（可视为资源的一种粗糙代理）衰减；存在不提路径的统一描述；标号差别可消。三条都指向计算性。

但这里要补一句对造成论公道的话：三位再发现者所“再发现”的，是否真的是孟德尔写下的那个东西，这件事本身在史学上是有争议的——有研究指出，1900 年的框架与 1865 年的框架并不完全重合，“再发现”这个词本身带有事后整理的痕迹。而这一争议同样判不了，因为判它需要的正是“把 1900 年那几条路径各自重跑一遍，看看它们到底到了哪里”，而这做不到。

三个案例，三种不同的表面形状，落到同一个结局：它们都无法把两种路径依赖分开。

四、天花板的准确位置

现在可以把话说准了。案例研究的天花板不在于案例做得不够好，不在于史料不够多，也不在于研究者不够聪明。天花板在这句话上：

一段只发生过一次的过程，不含有区分“你还没走到”与“那里没有那个东西”所需要的信息。

这不是一个经验命题，是一个关于证据形式的命题。它对做得好的案例和做得差的案例一视同仁。再给科学史一百年，再出一百部像《建构夸克》那样扎实的著作，这条天花板不会高一寸——因为提高它需要的不是更多的历史，而是同一段历史的第二次。

由此也就解释了一个长期令人困惑的现象：社会建构论提供了汗牛充栋的精彩案例，却始终没能把实在论逼到墙角；而实在论一侧也从未能反过来证明那些案例中的路径差异终将消失。双方都做了大量诚实的工作，双方都没有赢，原因不在任何一方，在于双方共用的那种证据形式本身不含判别力。

这里必须防住一个误读。说案例不能判案，不等于说案例没有价值。上一章立过纪律：类比用于辨认，读数用于判决。案例研究属于辨认——没有这批工作，我们根本不会知道“路径可能进入结果”这个念头值得认真对待，也不会知道它在真实的科学活动里长什么样子。它们是这桩案子的起诉书，写得极好；它们只是不能同时充当判决书。

五、由此得到本书为什么必须换现场

把缺的那一样单独拎出来说：案例缺的是极限。

而极限不是一个可以靠努力补上的东西，它有两个硬件前提：

其一，可重跑。必须能把同一套材料、同一台装置、同一个判准之下的过程，从头跑不止一次，而且每一次只让路径变、别的都不变。没有这一条，“路径造成的差异”根本无法与“别的东西造成的差异”分开。

其二，可缩放。必须存在一个可以逐级加上去的资源变量，使得“差异是否随资源衰减”这句话有确定的含义。没有这一条，衰减与不衰减之间就没有区别，第五十二章那三对特征的第一对就是空的。

历史一样也给不出。物理实验能给第一条，给不了第二条中“资源”与知识形成的对应关系。人类学的田野工作两条都给不了。心理学的学习实验能给第一条，但它的对象是个体能力而不是知识主张本身。

因此本书换现场。不是因为大模型更重要，不是因为它更时髦，而是因为它是目前唯一一个同时给出这两条硬件前提、而且对象恰好是知识主张的过程。第四编已经逐条核过这件事，也逐条说明了为什么不是量子测量、不是

实验演化、不是早期人工生命。这里只补一句它的代价：这个现场自己也是被造出来的——它不是自然界提供的实验室，是工程界提供的实验室，而工程界提供它的时候想的完全是别的事。这个自指问题在第四十六章已经出过一次场，第八十章还会再出一次。

接下来的五章，就是把“可重跑”与“可缩放”这两样兑换成三条可执行的条款。先从最弱也最容易首跑的一条开始。

第五十四章 条款一·规模消解检验与不可消解度 κ

一、要判的是什么

先在论从不否认不同路径会得到不同结果。它对这件事有一个标准解释，而且这个解释在工程界几乎是常识：资源不足。

数据还不够多，步数还不够长，模型还不够大，优化还没收敛到该去的地方。在这个解释里，路径差异是暂时的，是尚未被填平的坑；只要资源继续加上，坑会被填平，不同路径终将落到同一处。

这个解释有一个不可回避的经验后果，而正是这个后果使它成为可判的：差异必须随资源增加而衰减。

不是“可以衰减”，是“必须衰减”。如果加资源不让差异变小，那么“资源不足”这个解释就失去了它的解释对象。它可以衰减得慢，可以在某一段先升后降，可以在不同的量上以不同速率衰减——但方向必须是那个方向，极限必须是零或纯噪声水平。

条款一就是去量这个衰减。它是三条条款里最弱的一条，也是唯一一条可以在现成的公开材料上首跑、不需要训练任何新模型的一条。

二、路径散度 $\Delta(N)$ 与它的三种误读

定义。固定语料 C 、架构族 A 、判准 L ，固定模型规模 N 。取 m 个只在路径上不同的运行——换随机种子、换数据呈现次序、或两者都换——得到 m 个结果 $R_1 \dots R_m$ 。定义规模 N 处的路径散度：

$$\Delta(N) = E[d(R_i, R_j)] \text{ , 对所有 } i \neq j \text{ 取平均}$$

其中 d 是结果距离，它的构造规范是下一章的全部内容，也是本条款最容易被做坏的地方。

先在论预测 $\Delta(N)$ 随 N 单调衰减并趋于零，或趋于纯测量噪声的水平。造成论预测 $\Delta(N)$ 趋于一个正的常数。两个预言对同一个可测量的量给出了相反的值，这是第五十二章那次拆词换来的东西。

这个定义看起来简单，但在实际使用中已经被误读过三次，每一次都会让条款一变成一个别的东西。

误读一：把 Δ 当成模型之间的差异。不是。 Δ 量的是路径差异所造成的结果差异，因此那 m 个运行必须只在路径上不同。语料换了、架构换了、判准换了，量出来的东西与本条款无关。这一条听起来是废话，但公开材料里满足“只在路径上不同”的模型系列极少，这正是首跑必须挑材料的原因。

误读二：把 Δ 当成不确定性或方差。工程文献里有大量关于随机种子导致的性能方差的报告，那些量的分母是任务分数，测的是“同一个能力的实现有多稳”。 Δ 不是这个。 Δ 测的是结果本身有多不同，而不是结果在某个判准的投影上有多不同。这两件事的区别就是下一章第一条硬规定的全部内容。

误读三：把 Δ 的某一次取值当成结论。 Δ 是一个以 N 为自变量的函数，条款一判的是这个函数的极限行为，不是它在任何单一规模上的取值。一个在某规模上很大的 Δ ，与先在论完全相容；一个在某规模上很小的 Δ ，与造成论也完全相容。单点读数在本条款下没有判别力，这句话要记住，它在第六节还要用一次。

三、 κ 与有限规模序列的拟合问题

定义不可消解度：

$$\kappa = \lim_{N \rightarrow \infty} \Delta(N)$$

这是本条款要判的量。先在论主张 $\kappa = 0$ （或 κ 不可与噪声基线区分）；造成论主张 $\kappa > 0$ 。

麻烦在于 N 不能趋于无穷。实际能做的只有：在一列有限的规模点上测出 Δ ，拟合一条衰减律，外推它的渐近值。若取衰减律为

$$\Delta(N) \approx aN^{(-b)} + \kappa$$

则 κ 是拟合出来的截距，需要连同它的置信区间一起报告。

这里有三件必须事先讲明的事，每一件都会决定读数能不能被采信。

第一，拟合族的选择本身是一个自由参数。幂律加常数只是一个选择。换成指数衰减加常数、换成对数形式，拟合出来的截距会不同，有时差得很远。因此拟合族必须列入冻结清单，在看到任何读数之前确定，并且给出模型选择准则——而不是事后挑一个截距最好看的。这一条写在第五十九章的冻结项里。

第二，规模点的数量决定了外推有没有意义。拟合一条三参数曲线，至少需要四个点才不欠定，而四个点拟合三参数等于零自由度，区间无从估计。要让 κ 的置信区间有意义，规模点的数量必须明显多于参数个数，而且跨度要大到足以让 $N^{(-b)}$ 这一项在区间内显著变化。

第三，“多少个点才够”这个问题，本书没有一般性的答案。诚实的说法是：不知道。能确定的只有下界——四个点不够，而这正是首跑的处境。

四、趋势不是极限

这一节是本章的心脏。

先在论今天手上最硬的经验材料，形式上正是 $\Delta(N)$ 递减：一批工作报告了不同架构、不同模态、不同训练数据的模型，其内部表征之间的相似度随规模与性能提升而系统性上升。相似度上升，等价于距离下降。这在形式上就是条款一所要求的衰减方向。

所以必须把话讲清楚：这批材料给出的是趋势，不是极限。而条款一要求的恰恰是极限。

两者的区别不是修辞上的。设想两个量，一个从 0.5 衰减到 0，另一个从 0.5 衰减到 0.3。在中间规模上，它们的曲线可以几乎重合，肉眼、图示、乃至“显著递减”的统计检验，都无法把它们分开。把它们分开需要的不是更强的信念，也不是更多的直觉，而是两样很具体的东西：足够长的规模跨度，以及在该跨度上拟合出的渐近值的置信区间。

这就是条款一存在的全部理由：它把“看起来在收敛”与“收敛到零”分开。

由此也可以把本书对先在论那件旗舰武器的态度说准。本书不主张那批表征收敛工作有误；恰恰相反，本书认为它们是这场辩论里做得最扎实的经验工作之一，第八编第六十八章会正面处理它赢的条件。本书主张的只有一句：它们迄今给出的是趋势，条款一要求它们给出极限。这是一个可以被满足的要求——只要有人在足够大的规模跨度上做出拟合并报告区间，条款一就会立刻给出判决，而判决有可能是本书判负。

反过来，这个要求对本书同样有效，而且更狠。造成论若只报告“某规模上路径差异很大”，那不过是同一种错误的镜像：它给出的也只是趋势，甚至连趋势都不是，只是单点。单点读数在本条款下没有判别力——这句话在上一节说过，现在要用它来约束自己。

五、判据与判负条件

条款一的判据，在任何读数产生之前写死如下：

通过： κ 的置信下界显著大于噪声基线。判负： κ 的置信上界不显著区别于噪声基线。既不通过也不判负：拟合不能把 κ 与噪声基线分开，或所用规模点不足以支持外推——此时结论写“未能分辨”。

三条并列，第三条不是敷衍，是必须被允许出现的结果。第六十四章会专章论证这一点。

若条款一判负，本书的让步在第五十八章写死：放弃核心命题，承认在这一现场先在论成立，并承认由此可推出一条更一般的结论——至少在“以固定语料为材料的知识形成”这一类过程中，路径不进入结果的规定。这是一条真正的败绩条件，不是修辞上的谦虚。

六、首跑在这条条款上实际跑出了什么

条款一已经跑过一次。全部细节在第七编，这里只交代它与本章判据的对应关系。

材料是一组公开的多种子检查点，四个规模点，每个规模五个只在路径上不同的运行，探针集在执行之前冻结。两个通道各给出一列读数。

表征通道：路径间距离在四个规模点上依次为 0.352、0.445、0.441、0.411。先升后基本持平，没有向零衰减的迹象。作为对照，同一条训练轨迹内相邻检查点之间的同一个量，在最大规模上是 0.031。

行为通道：路径间距离依次为 0.263、0.221、0.171、0.116，单调下降。归一化之后，由基线的 6.45 倍降到 2.37 倍。

按本章第五节的判据：表征通道满足通过方向（不向零衰减），行为通道满足判负方向的前半条（单调下降），但不满足后半条——它在最大规模上仍是基线的两倍以上，并未落到不可区分的程度。两通道结论不一致，按预注册的第三款判未能分辨。

关于这次首跑，本章必须写明三件事。

其一，本跑没有报告 κ ，本书也不报告 κ 。四个规模点不支持任何外推，拟合出来的截距没有意义，区间更没有意义。按第三节的标准，这次首跑连“不能做拟合”这道门槛都没过。本章全章不出现 κ 的任何数值，这不是疏漏，是纪律。

其二，它恰好落在本章第四节所警告的那个位置上。行为通道单调下降，正是“看起来在收敛”的典型形状；若换一个立场的人拿着同一张表，完全可以写成“路径差异正在随规模消失”。他不会说谎，他只是把趋势当成了极限。而本书事先写死的判据不允许自己这样做——这一条纪律在首跑里第一次真

的挡住了一样东西，挡住的是本书自己想要的结论的反面，也挡住了本书自己。

其三，若只报一个通道，这一跑可以被写成任何结论。只报表征通道，它是条款一的一次漂亮通过；只报行为通道，它是一次清楚的败绩。两种写法都能成文，两种都是作弊。为什么“未能分辨”本身是一个结论而不是一次没有结论，由第六十四章专章处理。

下一章处理结果距离 d ——上面每一个数字都依赖于它，而它有四种做坏的方式，其中一种是首跑之后才看清的。

第五十五章 条款一的三条硬规定，与首跑之后补上的第四条

条款一全部压在一个量上：结果距离 d 。上一章的每一个数字都是 d 的产物，换一个 d ，全部数字都会变，甚至结论都可能反转。

d 是本书最大的一处自由参数。处理自由参数的办法不是假装它不存在，而是把它可能被滥用的方式——点名，然后事先堵上。本章堵四条。前三条在首跑的预注册里就写下了：两条防止本书赢得太脏，一条防止本书输得冤枉。第四条是首跑之后补上的，它的来处是一次真实的险情。

一、不得用任务分数

做坏的样子。最顺手的 d 是用基准分数：在若干任务上各跑一遍，把分数向量的差当作结果差异。这个做法有工具、有先例、有现成的数据，几乎不需要额外工作。

为什么这样做会自动出某个结论。因为基准分数是判准 L 在结果上的投影，而 L 是本案里被固定住的那一项。用 L 的投影当结果，等于事先规定“凡是 L 看不出来的差别都不算差别”；而先在论要论证的恰恰是“差别只在标号上，在实质上不存在”。这等于把待判的命题塞进了度量里。

后果是可预测的：在训练分布上，不同种子的模型分数高度接近——这本来就是它们被训练出来的目的。用分数做 d ， $\Delta(N)$ 会天然地小，而且会随规模变得更小，因为规模越大模型越接近判准的上限。条款一会以一种看上去很干净的方式判负，而判负的原因不是路径差异消失了，是度量把它压掉了。

本书的堵法。任务分数不进入 d 。它只能作为附属读数报告，用来回答“这些模型在常规意义上是否可比”这个前提性的问题。附属读数与判决读数分开摆放，不合并计算。

堵法的代价。代价是本书放弃了与既有工程文献最容易对接的那个接口。大量关于种子方差的报告都是以分数为单位的，本书不能直接引用它们作为条款一的读数，只能引用它们作为动机。这个代价是值得付的，但要写明。

二、必须消去已知对称性

做坏的样子。直接比较两个模型的内部状态——逐个参数比，或者逐个神经元比。这样量出来的距离必然很大，而且会大得很稳定。

为什么这样做会自动出某个结论。因为神经网络有一组已知的对称性：同一层内的神经元可以任意置换，某些结构下整层可以乘一个正数再在下一层除回来，某些表示可以整体旋转。经过这些变换的两个网络，计算的是同一个函数，只是内部编号不同。编号不同不是实质差别。

如果不消去这些对称性，条款一会以一种极其廉价的方式通过：任意两个独立训练的网络，编号必然不同，距离必然很大，而且这个距离不会随规模衰减——因为它压根不是由路径造成的，是由编号的任意性造成的。

这是本书最不愿意赢的赢法。它会让整条论证变成一个度量伪影，而且是一个一眼就能被对手识破的伪影。第八编第七十一章会说明，先在论在这一点上的工作做得相当彻底，“消去置换之后两个解其实在同一个盆地”正是他们的强读数之一。

本书的堵法。d 必须在消去已知对称性之后计算。具体做法有两类：一类是显式对齐，先求一个最优置换把两个网络的内部单元配对，再算距离；另一类是采用对这些对称性本身就不变的相似度量，从构造上避开对齐这一步。

首跑采用的是第二类。它使用的表征相似度量对神经元置换、正交变换与各向同性缩放三者都不变，因此上一章那四个表征通道的数字——

0.352、0.445、0.441、0.411——不是标号差异。这一点必须写在正文里，因为它是那组读数能不能被采信的前提。这里也顺带记一条工程教训：既然度量本身已经具有这些不变性，就不应当再加一层显式对齐；多加的那一层不会让结果更干净，只会引入新的自由参数。

堵法的代价。代价是“已知对称性”这个清单本身是开放的。今天知道的对称性被消去了，明天有人发现一类新的对称性，本书的读数就要重算，而且很可能变小。本书接受这个风险，并把它明确写成一条：若有人指出一类此前未被消去的对称性，且消去之后条款一的读数落入噪声水平，条款一判负。这是本书为自己写下的一条额外败绩条件，不在第五十八章那四条之内。

三、必须包含分布外行为

前两条防的是赢得太脏，这一条防的是输得冤枉。

做坏的样子。只在训练分布上测量结果差异。这同样顺手——训练分布上的数据现成，模型行为稳定，噪声小。

为什么这样做会自动出某个结论。因为训练分布正是路径差异被压平的地方。关于欠规定性的那批文献最重要的发现就是这个形状：同一套训练规格、仅随机种子不同的模型，在训练分布上表现相同，而在分布外行为上系统地不同。差异不是不存在，是躲在判准看不见的地方。

如果 d 只在训练分布上测量，条款一会假判负：读数很小、衰减很快、结论干净利落地倒向先在论，而这个结论不是关于世界的，是关于测量位置的。

本书的堵法。 d 是一个组合量：消去对称性之后的内部表征距离，加上在预先指定的一组分布外探针上的行为距离。探针集合必须在看到任何读数之前冻结。

堵法的代价，以及本书最脆弱的一处。探针集是本书全部自由参数中最脆弱的一个，本章现在就正面承认，不留到第八十章去。

理由在首跑里有直接的读数。首跑把探针分了组，分布内一组、分布外若干组，分组读数如下：分布内一组在四个规模点上是

0.184、0.174、0.141、0.105；两组分布外探针中，归纳类在四个规模点上是 0.459、0.344、0.316、0.146，中文类是 0.496、0.312、0.193、0.166。

这张表说了两件事，两件都要写，而且要同等分量地写。

第一件对本书有利：种子差异在分布外始终大于分布内。在最小规模上，中文类探针的读数是分布内的约 2.7 倍。这与欠规定性文献的核心发现一致，也直接证明了第三条硬规定的必要性——若只测分布内，这一列差异根本不会出现。

第二件对本书不利：这个差距随规模收窄。到最大规模上，分布外与分布内的比值已经明显下降。这是先在论方向的读数，本书不予淡化。

两件都成立，而且它们共同指向同一个结论：条款一的读数对分布内与分布外探针的配比高度敏感。换一个配比，数字会变，趋势的陡缓会变，某些情形下结论本身会变。

还有一处必须写进正文而不是脚注的事实：首跑所用的中文类探针由本实验自行构造，不是第三方公开基准。自造探针的风险是显然的——构造者知道自己想看到什么。首跑在构造时把探针冻结并公开了哈希，这能防住事后修

改，但防不住事前的无意识偏好。下一跑必须改用第三方基准，这一条已列入第七编第六十六章的清单。

四、第四条：两通道必须分别报告，不得合成

前三条是预注册时就写下的。第四条是首跑之后补上的，它的来处是一次真实的险情。

做坏的样子。结果距离由两部分构成——消去对称性之后的表征距离，加上分布外探针上的行为距离。最自然的下一步是把它们合成一个数：各取一半权重，加起来，得到一个单一的结果距离，然后用它做全部判断。首跑的预注册就是这样定的，权重冻结为各一半。

为什么这样做会自动出某个结论。因为合成的权重没有任何理由。一半对一半不是从原理推出来的，它是一个默认值。而这个默认值会在两个通道给出不同方向时，悄悄地替作者做出裁决——它把“哪个通道更能代表结果”这个本案最核心的问题，交给了一个随手取的数字。

更麻烦的是这种裁决完全不可见。合成之后只剩一个数，读者看到的是一条曲线，而那条曲线是两条方向相反的曲线按某个比例混出来的。改一下比例，结论可以反转，而文本里没有任何地方提示这件事。

首跑正好落在这种情形上：表征通道不衰减，行为通道单调下降。若按冻结的权重合成，会得到一条有方向的曲线，而那个方向是权重给的，不是数据给的。

本书的堵法。两个通道必须分别报告、分别对照各自的判负条件、分别出结论。两者不一致时，结论是“未能分辨”，不是加权折衷。合成距离即使在预注册中被定义过，也不进入判决。

堵法的代价。代价有两条，都要写明。

其一，判据变复杂了。一条条款现在有两个读数口，因此有四种可能的组合状态，而不是两种。这使判决不那么干净。

其二，它提高了“未能分辨”出现的概率——两个通道同时同向的概率，总是低于一个合成量落在某一侧的概率。也就是说，这条规定让本书更不容易赢，也更不容易输。本书接受这个代价，理由在第六十四章。

还要写明一处不足。这条规定回答了“不许合成”，但没有回答“哪个通道更能代表结果”。那个问题本书答不了，第六十三章末尾把它原样提出来，第九编第七十七章处理它的哲学形态。一条硬规定能做的只是不让这个问题被一个默认权重悄悄绕过去。

由此得到本章的结语，它同时也是条款一的一处限制：

在噪声基线与探针配比这两处未定之前，条款一的任何单次读数都不足以判案。

首跑正是一次这样的单次读数。它的价值不在于它判了什么——它什么也没判——而在于它把这两处未定暴露了出来。第七编写的就是这件事。

第五十六章 条款二·语料可归约性与可归约份额 ρ

一、“路径只是选择器”——这记反击的完整形式

假设条款一通过了：路径差异不随规模衰减， κ 是一个正数。

这对先在论构成致命打击吗？不。它还有一记极硬的反击，而且这一记比条款一要处理的那一记硬得多。它的完整形式是这样的：

差异不消失，不等于路径进入了规定。那些不同的结果，可能全都落在一个由材料、装置、判准事先确定的集合里。损失景观的全部局部极小，在第一步梯度落下之前就已经由数据与架构完全决定；训练走到哪一个，是路径的事，但有哪些可以走到，仍然是先有的。

这一记的力量在于它完全承认了条款一的读数，却把读数的意义拿走了。路径被降格为一个选择器——它在一份先定的清单上挑了一项，而清单不是它写的。选择器不是构成者。在这个图景里，先在论毫发无伤，而且它甚至可以大方地接受 $\kappa > 0$ ：当然会有一个正的常数，因为清单上有不止一项。

这一记反击在哲学上的完整形态由第九编第七十五章处理，那是本书要接的最硬的一记。这里处理它的经验形态。

条款二的做法很简单，简单到近乎不客气：

请把那个先在的集合写出来。

二、可归约性的定义

说结果 R 对语料可归约，意思是：存在一个只以 C 、 A 、 L 为自变量的描述 Φ ，使得 R 可以被写成 Φ 的一个成员或一个近似。

这里的关键限定是“只以 C 、 A 、 L 为自变量”。 Φ 里不许出现路径。一旦 Φ 的表述中需要提到“从哪里出发”“按什么次序走”，那它就不是先在的描述，而是把路径偷渡进了规定——而这正是造成论的主张。

这个要求听起来抽象，但在本现场它有三种可操作的具体形式。三种形式各自可判，各自有判负条件，不必同时满足：任何一种成立，条款二判负。

三、形式一·置换对齐与盆地连通

这是三种形式里最成熟的一种，也是先在论的强读数，必须写足。

若不同路径得到的两个解，在消去神经元置换这一对称性之后，可以被一条损失不升高的路径连起来，那么它们就属于同一个盆地。同一个盆地里的两个点，可以被“该盆地的极小点集合”这一描述统一归结，而这个集合确实只由数据与架构决定。此时路径的作用确实就是选择器。

这一线工作已经积累了相当扎实的证据：不同种子训练出的解，在适当的对齐之后往往表现得像同一个盆地里的两个点。本书对此的态度与对表征收敛的态度一致——不质疑这些实验，只问它的极限行为。

条款二对形式一的要求：在条款一测出正读数的那些规模上，逐对检查对齐后的连通性，并报告连通率随规模的变化。

判负条件：若连通率随规模上升并趋于一，条款二判负。

这条判负条件要求的东西对本书极不利，而这正是它值得写的原因。若对手在一个足够大的规模跨度上把连通率推到接近一，本书在这一现场输掉，而且输得干净。

需要说清一处边界。连通率高不等于两个解相同——一条低损失路径把两点连起来，说明它们在损失景观上属于同一片区域，不说明它们在行为上等价。第八编第七十一章会处理这条边界：标号差异与实质差异的界线到底划在哪里，是本案在工程层面上的最终形式。本章在此只记一句：本书接受“同盆地”作为可归约的充分证据，但不接受“低损失路径存在”自动等同于“行为等价”。

四、形式二·统计量可预测性与 ρ

若结果之间的差异可以由语料的统计量预测—— n 元分布、主题分布、子集覆盖、某类内容在语料中的出现位置与频次——那么差异虽然真实存在，却仍然是语料的函数。此时 Φ 就是那个回归函数，路径仍然只是选择器。

操作方式：用语料统计量对路径间结果差异做回归，报告可解释方差。定义可归约份额：

ρ = 路径间结果差异中，可由 C 、 A 、 L 的量预测的方差份额

判据：

ρ 显著接近 1，条款二判负——差异是语料的函数，先在论成立。 $1 - \rho$ 有稳定的正剩余，且不随规模上升，条款二通过。那个剩余就是路径不可消去的经验形态。

为什么要给出 ρ ，而不是只给出“通过／不通过”。因为本书预期真实的读数落在中间，而且中间偏向对手那一侧。绝大部分差异很可能确实可归约——这符合一个常识：这些模型确实在学同一批世界内容，它们之间相像的地方远多于不像的地方。争的从来不是主体，是那个剩余。

判决不需要 ρ 小，只需要 $1 - \rho$ 不趋于零。这句话要写在前面，它有两个作用：防止事后把一个小剩余描述成胜利，也防止把一个大主体描述成失败。两种事后描述在这一领域都发生过。

五、形式三·可交换性检验

这是本书认为最锋利的一种形式，而且此前未被这样使用过。

论证如下。若路径只是选择器，那么次序就是路径变量的最纯形式——先学 **a** 再学 **b** 与先学 **b** 再学 **a**，材料完全相同，是同一个集合，只是呈现顺序不同。既然“材料决定结果”，那么在充分训练之后，两次训练应当收敛到可交换的结果。

反过来说：

若存在某类内容，其次序反转所造成的差异不随训练时长与规模衰减，那么“材料决定结果”这句话就在字面上被证伪了——因为两次训练的材料是同一个集合。

这一记的锋利之处在于它不需要讨论“什么算实质差异”这种容易陷进去的问题。它只需要一个反例：同一堆材料，两种顺序，结果不同且差异不消失。

实验规格。这一条不能只写到“可判断”为止，必须写到别人照着就能跑，否则它就只是一个漂亮的想法。规格如下：

其一，反转什么。构造成对的语料次序：同一份语料切成若干段，两个版本只在段的先后次序上不同，词元总数、重复次数、混合比例全部逐位对齐。次序反转必须是完整反转或预先指定的置换，不允许在执行中调整。

其二，控制什么。这一处是首跑裁过的地方，必须写死：组内共享条件要对齐。若比较“只换次序”与“只换初始化”两组的效应，则两组的对内条件必须同构——不能一组共享初始化而另一组共享次序，否则三组的对内相似度本来就不在同一条件下，任何比较都被混淆。

其三，跑多久算充分。事先指定一个收敛判据，而不是事后看图。建议采用：验证损失在预定窗口内变化低于预定阈值，且该判据对两个版本同时适用；窗口与阈值列入冻结项。

其四，测什么。仍用第五十五章规定的组合距离——消去对称性之后的表征距离，加上分布外探针上的行为距离。不得改用分数。

判负条件：次序反转造成的差异随训练时长与规模衰减至噪声水平，条款二形式三判负。

六、为什么本章不给出条款二的读数

条款二未跑。本章不报告 ρ ，也不报告连通率。

但有一条探索性读数与形式三直接相关，必须在这里摆出来，同时必须连同它的全部弱点一起摆。

首跑所用的那组公开检查点，另有两组在单一规模上的消融：一组固定权重初始化、只换数据次序，一组固定数据次序、只换初始化。这恰好是形式三所需要的材料，顺手测了。读数如下：两者都换的行为距离是 0.116，只换数据次序是 **0.138**，只换初始化是 0.118，同一轨迹内相邻检查点的基线是 0.049。

值得记下的一点是：只换数据次序所造成的行为差异，不小于两者都换，并且是基线的 **2.8** 倍。材料是同一个集合，判准相同，架构相同，权重初始化相同——只有呈现顺序不同。这是“材料决定结果”这句话在行为层面上第一次被直接顶了一下。

现在写它的弱点，而且要写足。

其一，样本量是 **3** 对。三对样本不支持任何统计推断，标准差也几乎没有意义。

其二，三组的对内共享条件不齐。只换次序那一组的三个模型共享同一个权重初始化；只换初始化那一组共享同一个数据次序；而两者都换那一组两样都不共享。三组的对内相似度本来就不在同一条件下，因此三组之间的任何比较——包括表征通道上那个看起来很强的超加性——都被这一处混淆污染。超加性不能当结论，它的正确位置是下一跑的预注册项。这正是上一节实验规格第二条的来处：这条规格是从首跑的教训里长出来的。

其三，它只是顶了一下，仅此而已。不得把这个 0.138 写成“材料决定结果已被证伪”。证伪那句话需要的是形式三的完整实验：次序反转对、控制对齐、收敛判据、跨规模。以上一件都没有。

这三条弱点写完，那条读数还剩下什么？剩下一件：它把形式三从一个漂亮的想法，变成了一个值得花钱去跑的实验。这是探索性读数在本书中被允许扮演的唯一角色。

下一章处理最强、也最贵的一条。

第五十七章 条款三·可达集不足与资源标定的不可达

一、最强形式

条款一判差异是否存在，条款二判剩下的差异能否被统一描述归结。条款三判最强的一件事：

是否存在某个结果，它在某条路径上可达，而在任何不改变材料、装置、判准的替代路径上不可达。

若存在，那么“材料与装置唯一决定结果”这句话不仅在量上被削弱，而是在集合意义上被否定。前两条条款说的是“结果有一个分布，路径影响分布”；条款三说的是“某些结果根本不在某条路的射程之内”。

用第五十二章那句话：前两条判的是“你还没走到”有多大成分，条款三直接去找“那里没有那个东西”的实例。

这是本书所能提出的最重的一条，也是最难跑的一条。第五编第四十八章定义过可达集 $\text{Reach}(C, A, L)$ ——固定材料、装置、判准时，一切路径所能到达的结果集合。条款三问的是这个集合是不是“满的”：它是否等于所有路径各自可达集的并，还是说不同路径的可达集之间存在互不覆盖的部分。

二、“不可达”为什么不等于“没跑出来”

这是条款三全部的困难，几乎所有想做这件事的人都在这里栽。

做不到与做不成是两回事。任何一次失败都可以被解释掉：算力不够、超参没调好、数据切得不巧、运气不好、还没到那个规模。这些解释里没有一条是无理取闹，每一条在工程实践中都真实发生过。于是“我们试了，它出不来”这句话在证据上等于零。

更糟的是，绝对意义的不可达不可证。要证明“在任何预算下都出不来”，必须穷尽所有预算，而预算没有上界。一个不可证的陈述不能进入判决。

所以条款三如果要成立，必须先把“不可达”从一个绝对陈述改造成一个有判负条件的相对陈述。本书采用的办法是资源标定。

三、资源标定的不可达

定义。给定预算 B （步数、数据量、超参搜索规模三项分别标定），若结果性质 Q 在路径族 P_1 中以高于 q 的比例出现，而在路径族 P_2 中，在十倍于 B 的预算下出现比例低于 q' ，则称 Q 在 P_2 下相对于 B 不可达。

四个参数—— B 、 q 、 q' 、以及那个十倍——全部必须在执行之前冻结并公开。它们不是可以事后调的旋钮，调了就等于没有判据。

这个定义有三个性质值得逐条讲明。

第一，它不是绝对不可达。它是一个带标定的陈述，标定写在结论里：不是“ Q 不出来”，而是“在十倍 B 的预算下， Q 在 P_2 中出现比例低于 q' ”。这句话的信息量比绝对陈述小，但它的好处是它是真的可以被说出口的。

第二，它可以被更大的预算推翻，而这正是它成为科学陈述的条件。任何人只要在 P_2 上用更大的预算做出了 Q ，条款三就被判负。本书明确接受这一判负条件，写在这里，不设任何附加条件、不留任何解释余地：做出来就算，本书认输。

第三，十倍这个数字是约定的，不是推导出来的。它没有理论依据，它只是一个足够大到让“资源不足”这个解释显得勉强、又足够小到真的跑得起的数量级。把它写明为约定，比给它编一个理由诚实。若有人认为十倍不够，可以提出百倍版本——那是一个更强的条款，本书乐于接受，只是本书跑不起。

四、性质 Q 不能随便取

条款三的另一处脆弱在 Q 的选取上，而且这一处比标定更容易被做坏。

取得太粗，路径族之间不会有差别。比如“模型能不能做加法”——在任何路径下都能，这个 Q 没有判别力。

取得太细，差别毫无意义。比如“某个特定神经元的取值落在某区间内”——任何两次运行都不同，但这个不同是编号层面的，第五十五章第二条硬规定已经把它排除了。

Q 必须落在中间：足够结构化，以至于它的有无是一件确定的事；又足够实质，以至于它的有无不能被对称性消去。

本书列出三类候选，按可跑性排序。

候选一—算法性内部结构的出现。有一类被反复确认的现象：模型在训练中途形成可识别的内部机制——用于复制与类比的回路、用于某类算术的周期性

表示——而这些机制的出现常常是相变式的，在某一时刻突然完成，此前几乎不存在，此后稳定存在。

关键问题是：这些机制的出现是必然的，还是路径依赖的？

若在同语料、同规模下，某一机制在一部分种子中出现、在另一部分中始终不出现，而两者的总体性能相当，那就是条款三所要的读数：同样的材料，同样的判准，得到了结构上不同的知识。

这一候选排在第一位有两个理由。其一，机制的有无是可检测的，且检测方法已有成熟工具；其二，它不需要新训练——多种子公开检查点系列已经提供了足够的材料，把检测跑一遍即可。

需要把它的操作化写清楚。“总体性能相当”要事先定义为一个区间而不是事后判断；“机制出现”要事先定义检测阈值与检测层的范围；“始终不出现”要事先定义观察窗口——是在整条训练轨迹上都没有，还是只在末点没有。三项全部列入冻结清单。

候选二：次序造成的不可达。接上一章形式三。若某个能力只在特定课程次序下出现，而在反转次序下即使延长十倍训练也不出现，这是条款三的直接实例，而且是形式最干净的一个——材料完全相同，连“材料不一样”这个辩护都用不上。它的代价是必须新训练成对的次序反转模型。

候选三：语境内临时形成的程序。模型在推理时可以在语境中形成一个训练时并不存在的、针对当前任务的临时程序。这是最诱人的猎场，理由显而易见：那个程序不在语料里，也不在权重的任何固定位置上。

但它同时是最危险的猎场。反方会说：这只是被激活的既有能力的组合，能力在权重里，语境只是触发器。本书接不住这一记——这不是修辞上的谦虚，第九编第七十八章会把接不住的位置精确写出来。

因此本书不把候选三当作主判据，只列第三顺位，并附加一条严格得近乎自缚的要求：它必须配上“该组合在权重中不存在对应结构”的证据，才被计入条款三。在这条证据拿出来之前，候选三在本书中只有启发意义，没有判决意义。

五、一个必须挡住的误用：把工程失败当作不可达

条款三最容易被滥用的方式，不是把它做坏，是把它用便宜了。

工程实践中每天都在产生这样的陈述：这个架构学不会那个任务；这种训练方式出不来那种能力；换了这个次序之后模型就崩了。这类陈述在数量上取之不尽，而且每一条都有实验支持。若条款三可以用它们来满足，那么条款三明天就能宣布通过。

这正是本书要堵死的。上面那类陈述与条款三所要求的东西，差着三道门槛。

第一道，它们通常不是在同一份材料上做的。“这个架构学不会”往往意味着换了架构，而架构是本案里被固定住的那一项。改了A再说不可达，说的不是路径。

第二道，它们几乎从不带预算标定。说“出不来”的人很少同时说清在多大预算下出不来，更不会给出十倍预算的检验。没有标定的“出不来”，正是第二节所说的那种在证据上等于零的陈述。

第三道，它们的性质Q通常取得太粗。“学不会这个任务”里的“任务”，是判准层面的描述，而判准是本案里被固定住的第三项。用判准上的失败来论证结构上的不可达，等于绕回第五十五章第一条硬规定所禁止的那件事——用判准的投影当结果。

因此本书对条款三加一条使用限制，写在这里：

任何一条关于不可达的主张，若不能同时给出：固定的材料与装置、标定的预算、以及一个不落在判准投影上的性质Q，就不计入条款三。

这条限制会挡掉工程界现有的绝大多数“做不到”的报告。这是有意的。条款三是本书三条里最强的一条，它要求的证据也必须最贵；一条可以用现成材料廉价满足的最强条款，不会是最强的，只会是最松的。

六、条款三的地位与代价

三条条款里，只有条款三需要新的大规模训练，因而最贵。

本书的立场是清楚的：条款一与条款二可以在现有公开材料上首跑，条款三作为第二阶段。若条款一或条款二判负，条款三不必跑——因为前两条已经判了案，第三条只是在已判的案子上加码。

还有一句必须写在本章末尾，而且要写得明白，不留任何让人误读的余地：

条款三是本书开出的支票，不是本书交出的读数。

本章全章没有一个数字，这不是疏漏，是事实的如实呈现。条款三未跑，因此它在本书中的全部内容就是一份规格：量怎么定义、参数怎么标定、Q怎么选、判负条件是什么、谁可以用什么方式推翻它。

一本书里出现一张未兑现的支票，是可以接受的，前提是它被标明为支票。把支票当现金花，是这一领域最容易犯、也最难被发现的错误——第五十九章会把防住这个错误的方法学写下来。而在那之前，下一章先把三条条款并排放一次，把本书的死法写死。

第五十八章 阶梯关系与四条写死的败绩条件

一、阶梯的形状

三条条款不是并列的三个论点。把它们并排放，会看出一条从弱到强的阶梯，而这条阶梯恰好对应先在论的三道退守防线。

条款	先在论的防线	造成论要拿到的 读数	判负条件
一-规模消解	差异只是资源不足	κ 的置信下界高于噪声基线	κ 的置信上界不异于噪声基线
二-语料可归约	差异落在先定的解集内	$1 - \rho$ 稳定为正，不随规模降	$\rho - 1$ ，或对齐后连通率 -1
三-可达集不足	换条路也能到，只是没到	存在标定预算下的不可达	他人以十倍预算在替代路径族上做出 Q

三道防线是层层后撤的。第一道最靠前，也最容易守——它只需要指出资源还不够，而资源永远还不够。守不住第一道，退到第二道：差异存在，但清单是我写的。守不住第二道，退到第三道：清单不是我写的，但你没有证明有哪一项是我够不着的。

理解这条阶梯的关键是：每后撤一道，先在论保住的东西就少一些，而它仍然是先在论。这不是修辞上的让步，是命题内容的实际收缩。因此本书也必须对称地写出自己在每一道上被挡住时要交出什么。

三条都通过，构成性路径依赖成立。任何一条被判负，本书作出相应让步。让步不是姿态，是把核心命题改写成一个更弱的命题，并承认改写发生过。

二、四条败绩条件

下面四条在任何读数产生之前写死，不留后路。

第一条。若条款一判负——即路径散度在消去对称性之后随规模衰减到噪声水平——本书放弃核心命题，承认在大模型这一现场先在论成立。并且承认由此可以推出一条更一般的结论：至少在“以固定语料为材料的知识形成”这一类过程中，路径不进入结果的规定。

这一条是最重的。它不只是本书输掉一场，它还要求本书把输掉的后果推广出去，交给对手一条比他原本主张的更清楚的结论。这是故意的：一条不会带来真实损失的败绩条件不是败绩条件。

第二条。若条款一通过而条款二判负——即剩余差异可由语料统计量解释，或对齐后的盆地连通率趋于——本书将核心命题降级为一条弱得多的主张：路径影响到达解集中的哪一个成员，但不影响解集本身。

并且必须同时承认：这个降级后的主张对本案不构成判决。“路径是选择器”与先在论完全相容，甚至是先在论的标准图景之一。若读数落在这里，本书承认判决未成，不得把降级后的主张继续包装成“部分胜利”。

第三条。若条款一、二通过而条款三判负——即有人在替代路径族上以十倍预算做出了Q——本书保留“路径进入规定”这一主张，但放弃“存在只有某条路径才到得了的结果”这一更强形式。

这一条的边界要划清：条款三判负不推翻前两条的读数。它推翻的是本书曾经想要的最强形式。这是三条里唯一一条可以只损失一部分的败绩。

第四条。若三条均通过——本书主张：在这一现场，“被知道的东西完全由材料与装置先行决定”这句话是假的。

它的哲学后果由第十编处理，而且第十编会同时写出倒向另一侧时本书承认什么。这一点在第八十六章有专章，此处不展开。

三、写死的时间问题

败绩条件的全部价值，取决于它写下来的时间。

事后写下的败绩条件不是败绩条件，是对已知读数的追认。任何人在看过数据之后，都可以构造出一组自己恰好没有触发的条件，并且完全真诚地相信自己本来就会那样写。这种事不需要任何恶意就会发生，它是人正常工作的方式。

因此条款的判负条件必须在读数之前公开，而且必须有办法证明它确实之前。本书采用的办法是预注册加哈希：判据、量的定义、探针集、判负条件全部冻结成文件，公开其摘要值，然后才执行。第五十九章写这套方法学的细节，第六十章把首跑的预注册全文与冻结值摆出来。

这套办法能证明的事情很有限，但很确定：它能证明文件在执行之前就是那个样子。它不能证明文件写得对——这是下一节要面对的难堪。

四、谁来宣布判负

上面四条有一个共同的结构性弱点，不指出来这一章就不算写完：判负条件是本书写的，而判它有没有被触发的，也是本书。

这不是一个可以靠决心解决的问题。一个作者在自己的命题被逼到墙角时，总能找到理由说那面墙不算数——数据有问题、条件不完全对应、对手的实现有瑕疵。这些理由有时甚至是对的，而正因为它们有时是对的，它们永远可用。

本书的处理办法是把四条败绩条件尽量写成外部可核的形式，让“有没有被触发”这件事不取决于本书的判断。逐条看它们做到了多少。

第三条做得最好。它的触发条件是“他人以十倍预算在替代路径族上做出Q”。这件事完全发生在本书之外：做出来就是做出来了，本书无权评定。Q的清单、预算的标定、比例阈值都在预注册里冻结并公开，触发与否是一个第三方可以独立核对的事实。

第一条做得次好。触发条件是“路径散度在消去对称性之后随规模衰减到噪声水平”。它依赖于两样本书自己定的东西——“消去对称性”的清单和“噪声水平”的定义。第五十五章为前者写了一条额外的败绩条件（若有人指出一类未被消去的对称性且消去后读数落入噪声，条款一判负），这把清单的开放性交给了外部。后者则被首跑证明是一个真实的弱点：噪声水平的定义本身可能写错，第六十五章处理。

第二条做得最差。触发条件里有“ ρ 显著接近 1”和“连通率趋于 1”，两个“接近”与“趋于”都需要一个阈值，而阈值本书还没有定死。这是本编留下的一处欠账，必须写明：在条款二真正开跑之前，它的判负阈值必须先冻结，否则这一条在实践中不可能被触发。

一条永远不会被触发的败绩条件，比没有败绩条件更坏——它提供了严谨的外观而不承担严谨的代价。

第四条不是败绩条件，它是三条都通过时本书主张什么。把它列在同一张表里是为了对称，但它的性质不同：前三条是本书交出什么，第四条是本书取得什么。

由此得到一条一般性的要求，本书对自己执行，也建议任何采用这套做法的人执行：

判负条件的质量，不看它写得多严厉，看它有多大比例不依赖作者自己的判断。

按这个标准，本书四条里只有一条完全合格，一条基本合格，一条欠账。这个账要记在这里，而不是记在结论里。

五、首跑之后，这四条的现状

现在把账摆出来。首跑已经执行，结论是“未能分辨”。那么上面四条败绩条件，现状如何？

一条都没有被触发。

条款一既未通过也未判负：表征通道满足通过方向，行为通道满足判负方向的前半条而不满足后半条，两通道不一致。条款二未跑。条款三未跑。

这意味着一件不舒服的事，本节要正面写出来：

写死败绩条件的全部价值，要到某一条真的被触发时才兑现，而本书至今没有兑现过。

一个从未被触发的败绩条件，与一句漂亮话之间，在外观上没有区别。本书可以说自己事先写死了死法，可以出示哈希证明它写在前面，但本书不能说自己已经证明了这些死法是真的会被执行的——证明那件事的唯一方式，是某一天真的执行一次。

这句话必须留在书里，包括在将来的增订版里。如果某一天某条条款判负而本书照章让步，那时这一节要改写成“第 N 次兑现”；如果本书始终只在未触发的区间里活动，那么这一节将一直是本书的一处未付账款。

还要防住一个记账上的错误，本节末尾写死：

不许把“未能分辨”记在四条败绩条件中的任何一条名下。

“未能分辨”不是败绩条件，它是判读规则的产物——是预注册里那条“两通道结论不一致则判未能分辨”的规则在首跑中的第一次生效。它是第五条，与前四条性质不同：前四条说的是“若读数如此，本书交出什么”；第五条说的是“若读数如此，本书什么也不说”。

把“未能分辨”记成一次败绩，会给人一种本书已经承受过代价的错觉；把它记成一次通过，则是作弊。它两样都不是。它是本书迄今唯一一次真正被自己的规则管住——管住的不是结论，是说法。

这件事的分量不小，值得在第七编单独用一章来论证。下一章先把使它成为可能的方法学写完。

第五十九章 预注册方法学：冻结什么、何时冻结、怎样防作弊

整桩两千年的悬案，就是被“倾向于支持”这种措辞维持下来的。

这句话不是感慨。两侧都拥有大量真实的材料，两侧都从材料中读出了倾向，而倾向从不与倾向正面冲突——它们可以在同一批数据上共存几十年。要让这桩案子走出这个循环，需要的不是更多材料，是一套使说法受约束的制度。本章写这套制度。

一、冻结什么

冻结清单共五项。它们的共同特征是：每一项都是一个可以在看到读数之后被调整、并且调整之后读数会改变的选择。

其一，结果距离 d 的完整定义。包括对齐算法（或所用度量的不变性说明）、表征相似度度量、层的选取规则、分布外探针集合的全部条目。探针必须逐条列出，不能只说“若干条分布外探针”。

其二，噪声基线的定义。用什么作为“同一条路径内的正常波动”，怎么测，取多少对。

其三，衰减律的拟合族与模型选择准则，以及 κ 的置信区间算法。拟合族是一个极强的自由参数，第五十四章第三节已经说明它会直接改变外推出来的截距。

其四，条款二的语料统计量清单与回归设定。哪些统计量进入回归、以什么形式进入、可解释方差怎么算。

其五，条款三的性质 Q 清单、检测方法、比例阈值 q 与 q' 、预算 B 。包括“总体性能相当”的区间定义与“始终不出现”的观察窗口。

五项之外还有一条总则：凡是执行中发现需要修改的，只能作为下一跑的新冻结项，不能追溯修改本跑。本跑的读数按原定义报告，哪怕原定义已被证明有问题——这一点在下面第四节会有一个真实的例子。

二、何时冻结，以及怎样证明冻结在先

冻结的时间点是：在接触任何读数之前。

“任何读数”包括预跑、试跑、调试时顺手看到的中间结果。这条线要划得比直觉严格，因为污染不需要作弊就会发生：一次调试中扫到的数字，足以让人在后续的选择中无意识地偏向某一侧。

证明冻结在先的办法是公开摘要值。把冻结文件与探针集各自算出摘要值，连同预注册文本一起公开，然后执行。首跑采用了这个办法：探针集共 112 条，摘要值的前十六位是 `e3b9d8a2795ccee`，在执行之前冻结，此后未改。第六十章会把首跑的预注册全文连同这个值一起摆出来。

这套办法能证明的事情非常有限，必须说清它的边界：

它能证明的：文件在执行之前就是那个样子；探针没有在看到读数之后被增删。

它不能证明的：文件写得对；探针选得好；判据本身没有系统性偏向。

边界的后半截不是无关紧要的技术细节。它是本章第四节的全部内容。

三、三条防作弊纪律

其一，先写判负再看数据。四条败绩条件在首跑之前公开，位置在第五十八章。这条纪律防的是事后构造一组自己恰好没有触发的条件。

其二，报告不利读数，且与有利读数同等篇幅。任何一条被判负、或任何一个通道给出不利方向的读数，都必须与通过的部分同等分量地写出，不得降格为脚注、附录或“另有待论”。

这一条在首跑中经受了一次实测。表征通道给出的是通过方向的读数，行为通道给出的是判负方向的读数。若只报前者，这一跑看上去是一次漂亮的通过；若只报后者，它是一次清楚的败绩。两种写法都能成文，两种都是作弊。本书两个通道并排写，篇幅相当，从第六十二章与第六十三章各一章可以看出这条纪律在版面上的落实。

其三，不以趋势代极限。若拟合不能把 κ 与噪声基线分开，或规模点不足以支持外推，结论写“未能分辨”，不写“倾向于支持”。

第三条最重要，也最容易被规避——因为“倾向于支持”这句话从来不是谎言，它通常是对图形的准确描述。它的问题在于它把一个未完成的判决说成了一个已完成的方向。本书对它的处理是取消这个措辞本身：在本书中，条款的结论只有三种取值——通过、判负、未能分辨。没有第四种。

四、还有一处：清单的完备性本身不可冻结

上面五项冻结的是“每一项里写了什么”。它没有冻结、也无法冻结的是：这张清单是不是齐的。

首跑给了一个例子。预注册里冻结了距离的定义、层的选取、探针的条目、噪声基线的定义，唯独没有规定“两个通道的读数在合成之后是否可以用于判决”——因为写的时候默认了合成是一个技术细节。执行之后才发现，那个默认的权重足以替作者做出裁决。这一条后来补进了第五十五章，成为第四条硬规定，但它是被读数逼出来的，不是被清单想出来的。

这件事没有一般的解法。一份冻结清单的完备性，只能由执行来检验；而执行一次只能检验一次。能做的只有两件：

其一，每跑完一次，把“本跑发现清单里缺了什么”作为一个独立的产出项记录下来，与读数同等分量。本编的第六十五章与第五十五章第四节就是这样产生的。

其二，承认由此推出的一条限制——单次预注册跑不构成判决，无论执行得多干净。判决需要一个序列，其中至少有一次的清单已经经受过前一次执行的修订。

五、首跑对冻结项清单的一处修订

这一节是本章最有价值的部分，因为它记录的是这套制度的一次失效。

首跑的冻结项第二条——噪声基线——写的是“同一训练轨迹内相邻检查点之间的距离”。这个选择在预注册时的理由是它偏保守：同一轨迹内相邻两步的差异应当远小于不同路径之间的差异，用它作分母，得到的比值会偏小，不利于本书。理由本身没有错。

执行之后暴露出一件预注册没有预见的事：这条基线跨规模不可比。

在三个较小的规模上，这个基线稳定在 0.0134、0.0129、0.0109；到最大规模跳到 0.0306，接近三倍。而归一化后的比值在最大规模处从 40.4 掉到 13.4——主要不是分子变了，是分母变了：分子只从 0.441 降到 0.411。

原因不难理解，只是此前没有想到：同一轨迹内相邻检查点之间的距离，测到的是训练在该规模、该时刻的推进速率，而这个速率本身随规模变化。它不是一把跨规模恒定的尺子，它是一把自己会伸缩的尺子。

后果是明确的：首跑的归一化曲线不能作为规模趋势的证据。各规模内部“路径间远大于路径内”这一条比较仍然有效，但跨规模的那条趋势线作废。

修法（下一跑必须执行）：噪声基线改用同种子、同数据次序、仅由数值非确定性造成的重训；或改用同一轨迹内多对等距检查点的距离分布的下界估计。二者都不依赖训练的瞬时推进速率。

按本章第一节的总则，这个修订不追溯。首跑的读数仍按原定义报告，同时在正文中标明该定义的缺陷。第六十五章专章处理这件事的执行层细节，包括完整的数字与下一跑的改法。

六、这套制度挡不住的那一类错误

由上一节可以直接得到本章的结语，它同时是本编留给全书的最实在的一件东西：

预注册保护的是“事后不许改判据”，它不保护“事前把判据写错”。

这两类错误的性质完全不同。第一类是意志问题，制度可以挡；第二类是知识问题，制度挡不住——在执行之前，没有人知道那条基线会跨规模伸缩，包括写下它的人。冻结把一个错误的定义同样牢固地冻在了里面，而且冻得越牢，它在整跑中造成的偏差就越一致。

这不是取消预注册的理由。相反，正因为有预注册，这个错误才被发现得如此清楚：定义被写死了，执行时才能看出它在不同规模上给出了互不相称的值；若定义是随手取的、每个规模各调一次，这个问题会被平滑掉，永远不会浮出来。冻结的价值之一，恰恰是把自己的错误暴露成一个可见的形状。

但它确实意味着一件事：单次预注册跑不构成判决，无论它执行得多干净。判决需要的是若干次跑，其中至少有一次的判据已经经受过前一次跑的修订。首跑是这个序列的第一项，它的产物不是读数，是一份修订清单。

第七编写的就是这件事的全部细节——预注册全文、材料、两个通道的读数、为什么“未能分辨”是一个结论、那处方法论缺陷的执行层记录，以及一条不能当结论的探索性读数。

第七编 首跑

本编报告一次真实执行过的实验，而它的结论是“未能分辨”。

一个“未能分辨”的结论，最容易被怀疑的地方不是数据，是判据——人们会合理地怀疑判据是不是被调整过。回答这种怀疑的唯一办法是把判据原样摆出来，连同它被冻结的证据一起摆。因此第六十章不作概述，直接给出预注册的全部内容。

第六十一章交代材料与实现，包括三处与预注册的偏离与四个踩过的坑。第六十二、六十三章是并排的两章：一章对本书有利，一章对本书不利，长度相当。第六十四章用整章论证为什么“未能分辨”是一个结论而不是一次弃权。

第六十五章记录首跑把自己的判据证伪的那一条，第六十六章给出六条修订清单与一条不能当结论的探索性读数。

本编交出的不是判决，是一次真实执行、一份修订清单，以及一次纪律的实测。

一、为什么把全文摆出来

这一编报告的是一次真实执行过的实验，而这次实验的结论是“未能分辨”。

一个“未能分辨”的结论，最容易被怀疑的地方不是数据，是判据——人们会合理地怀疑，判据是不是被调整过，使得那个不舒服的结果得以被说成“未能分辨”而不是“判负”。

回答这种怀疑的唯一办法是把判据原样摆出来，连同它被冻结的证据一起摆。因此本章不作概述，直接给出预注册的全部内容，逐节附上它在执行之后显出的问题。这一编里有一节（第六十五章）专门讲这些问题中最重的一个，而那个问题恰恰出在预注册自己身上。

预注册文件的开头写着一句：本文件写定之后不再修改；任何修改都将以追加“偏离记录”的方式写在末尾。这一条被遵守了。下面的每一小节都对应原文件的一节。

二、材料（原文件第 1 节）

模型族选定为一组公开的多种子检查点：四个规模

（14M、31M、70M、160M），每个规模五个种子，取最终检查点。同语料、同架构、同判准、同超参，仅随机种子不同——种子同时决定权重初始化与数据呈现次序。

噪声基线材料：每个规模取一号种子的倒数第二个公开检查点，与其最终检查点构成“同一路径内相邻检查点”对。

执行后的评注：材料这一节没有出问题，它是整份预注册里最稳的一节。选这组材料的理由在第四编已经论证过——它是目前唯一同时满足可重跑、可干预、可消融、可观测四条性质，且对象恰好是知识主张的公开材料。真正出问题的是拿它当尺子的那一节。

三、探针集（原文件第 2 节）

分两组，共 112 条，执行前写入文件并计入摘要值，执行后不再增删。

A 组，分布内，**64** 条：取自一个公开的英文百科语料的测试划分，按返回顺序取前 64 条字符长度不小于 200 的段落，各截断为 128 个词元。

B 组，分布外，**48** 条，本实验构造，生成规则公开，各 16 条：- B1 归纳型：随机词元串重复三遍。- B2 模算术型：模 17 的加法等式串。- B3 中文型：中文段落（所用语料中中文占比极低）。

执行后的评注：这一节包含本跑最脆弱的一处自由参数，预注册自己也这样写了。B3 由本实验构造而非第三方基准，这件事在第五十五章已经正面写过，这里再记一次，因为第六十三章的分组读数全部压在这一节上。

四、距离（原文件第 3 节）

层选取：相对深度 25%、50%、75%、100% 处的隐藏状态，按总层数向上取整，使不同规模之间可比。

表征距离：线性中心核对齐，取 1 减去相似度，四层平均。选它的理由写在预注册里：它对神经元置换、正交变换与各向同性缩放不变，因而已经消去了条款一要求消去的对称性，无需额外做置换对齐。这一条后来在执行中被确认是对的，也顺带避免了一个常见的多余步骤。

行为距离：各探针末位置的下一词元分布之间的对称散度，以 2 为底，取值落在 0 到 1 之间，在探针上平均。

合成距离：两通道各取一半权重合成，权重冻结。同时要求两通道分别单独报告。

执行后的评注，这一条必须写明：预注册定义了一个合成距离，但第 4 节的判据实际上是写在两个通道上的，且专门为“两通道结论不一致”留了一款。执行之后，两通道确实不一致——而这正是本跑最有信息量的一件事。本书因此不报告合成读数：把两个方向相反的读数按权重加起来，得到的单一数字会把不一致抹平，而不一致本身才是这次首跑真正交出来的东西。这是一处需要说明的取舍，说明写在这里，不藏在附录。

五、量与判据（原文件第 4 节）

路径散度取五个种子共十对的平均距离。噪声基线取一号种子相邻两个检查点之间的距离。归一化路径散度定义为二者之比——使用比值而非绝对距离，是为了消去度量的整体尺度自由度。

判据三款，原样抄录：

条款一通过：归一化路径散度在可及规模上不趋向 1，即路径间差异始终显著大于同一路径内相邻检查点差异，且无向 1 衰减的单调趋势。条款一判负：归一化路径散度单调下降，且在最大规模处不显著区别于 1。未能分辨：表征通道与行为通道结论不一致；或归一化路径散度无稳定趋势。

执行后的评注：第三款是这份预注册最有价值的一条，而写它的时候并没有觉得它有多重要——它看起来像一条例行的兜底条款。执行之后它成了决定

本跑结论的那一条。第六十四章专章论证为什么它给出的是一个结论而不是一次逃避。

六、事先写明的局限（原文件第 5 节）

预注册在执行前写明了三条局限。

其一，规模点仅四个、种子仅五个，远不足以做外推。本跑不报告不可消解度的外推值，只报告归一化路径散度在该区间内的实测行为。这一条被严格遵守：本编全编不出现该量的任何数值。

其二，噪声基线用相邻检查点代替同种子重训，这是一个偏保守的代理。原文的理由是：相邻检查点之间的差异包含了训练仍在推进所造成的真实变化，因而基线偏大、比值偏小；若比值仍显著大于 1，这个偏差不利于本书而本书仍通过；若比值接近 1，则不能据此判负，须另做同种子重训基线。

这一条的推理是对的，结论是错的。它正确地预见了一条基线会偏保守，却没有预见到它跨规模不可比。第六十五章专章处理。

其三，**B3** 中文探针为最脆弱处。这一条被后来的分组读数坐实了。

七、执行前修订与冻结（原文件第 6 节）

预注册留有一节“执行前修订”，记录在任何模型被下载之前所做的改动。实际发生了一处：

原定的词元位置规则是固定位置采样，但这会使短探针——B1 的归纳串与 B3 的中文段——因长度不足而被整体跳过，导致分布外通道失效。改为按相对位置采样，并要求探针长度不低于 16，否则丢弃。

此处修订写定于任何模型被下载之前，因此不构成读数污染。把它记在预注册文件里而不是事后说明里，是这套制度的正常用法：修订不可耻，追溯修订才可耻。

探针集冻结后计算摘要值，前十六位为 **e3b9d8a2795ccee**。A 组 64 条、B1 至 B3 各 16 条，合计 112 条。这个值与全部脚本、原始读数文件一并公开，任何人都可以重建探针集并核对摘要值是否一致。

八、预注册里没写的四样东西

前面逐节评注的是“写了什么”。这一节记“该写而没写”，因为后者在执行之后显得更重要。

其一，合成权重的理由。文件定义了两通道各半的合成，但没有写为什么是各半，也没有写这个合成在两通道不一致时该不该用。第 4 条第三款实际上

隐含了“不该用”，但没有明写。首跑执行之后补进了第五十五章第四条硬规定。

其二，“显著”的阈值。判据里出现了“显著大于”“不显著区别于”，而文件没有给出显著性的判定方式——用什么检验、什么水平、如何处理十对样本之间的非独立性（同一个种子出现在四对里）。首跑因此只能作定性判断。下一跑必须先把这一项定死。

其三，逐对读数的保留方式。文件只要求报告均值与标准差，没有要求保留每一对的距离。结果是最大规模上那个异常大的标准差（0.206）无法进一步分析——它可能来自若干个离群对，也可能是整体离散，本跑分不开。这是一个零成本就能避免的损失。

其四，分组基线的处理方式。文件规定了按探针组分别记录路径间距离，却没有规定各组基线如何使用。执行之后各组基线被记录了下来，而逐组相除得到的那张表（第六十三章第五节）是本跑最不利的一份读数——它是在预注册没有预见的地方冒出来的。

四条合起来说明一件事，第五十九章第四节已经把它写成了制度层的结论，这里给出它在本跑的具体形状：一份冻结清单的完备性只能由执行来检验，而一次执行只检验一次。

九、这份文件能证明什么，不能证明什么

能证明：判据在执行之前就是这个样子；探针没有在看到读数之后被增删；三款判决规则中那条决定了本跑结论的，写在读数之前。

不能证明：判据写得对。

第五十九章已经把这句话作为一编的结语写过一次，这里要用具体的形式再说一次，因为它在本编有一个真实的实例。这份预注册在第5节里用了一整段论证为什么噪声基线的选择偏保守、因而安全；论证本身严密，逻辑没有错，前提也没有错——它只是漏了一件在执行之前无人想到的事。冻结把这个漏洞同样牢固地冻了进去。

这不是对预注册的否定。恰恰相反：正因为这条基线被写死并在四个规模上统一使用，它跨规模伸缩的毛病才显形；若它是每个规模随手取的，这毛病会被平滑掉，永远浮不出来。

下一章交代材料与实现的全部细节。

一、二十四个检查点

首跑一共用了二十四个公开检查点：四个规模，每个规模五个种子的最终检查点，共二十个；加上每个规模一号种子的倒数第二个检查点，共四个，作噪声基线。

把这个数字单列一节，是因为它决定了本跑能说什么、不能说什么。

四个规模点。14M、31M、70M、160M。跨度约一个数量级多一点。第五十四章说过，拟合一条三参数衰减律至少需要四个点才不欠定，而四个点拟合三参数等于零自由度，置信区间无从估计。因此这四个点能支持的最强陈述是“在这个区间内它长什么样”，不能支持任何关于区间之外的陈述。

五个种子。每规模十对。十对样本可以给出一个均值和一个标准差，但这个标准差本身的不确定度相当大，尤其是在最大规模上——那里表征通道的标准差达到了均值的一半 (0.411 ± 0.206)。这件事在第六十二章要单独处理。

为什么不到 410M 及以上。预注册没有限定上限，实际只跑到 160M，原因是磁盘与算力：单核处理器、3GB 内存、每跑完一个模型必须立刻清掉缓存才能腾出空间放下一个。410M 及以上需要更大的机器。

这是本跑最重的一处局限，必须写在最前面而不是最后面：四个规模点无法支持任何外推。后面所有读数都要在这个前提下读。

二、探针集的实际构成

112 条，执行前冻结，摘要值前十六位 e3b9d8a2795ccee。

A 组，64 条，分布内。取自公开英文百科语料的测试划分，按返回顺序取前 64 条不短于 200 字符的段落，各截断为 128 词元。“按返回顺序”这一条是有意的——不做任何挑选，避免构造者在挑选中夹带偏好。

B1，16 条，归纳型。一串随机词元重复三遍。这类探针检测的是模型能否利用前文中已出现过的模式来预测后续，是一类有成熟文献的分布外行为。

B2，16 条，模算术型。模 17 的加法等式串。这类内容在通用语料中极少以这种密集形式出现。

B3，16 条，中文型。中文段落。所用训练语料中中文占比极低，因此这一组是四组里“分布外”程度最高的。

必须写明的一件事：B1、B2、B3 三组全部由本实验构造，生成规则公开，但不是第三方基准。前两类的构造方式在文献中有先例，第三类没有。自造探

针的风险不在于会不会被事后修改——摘要值挡住了这一点——而在于构造时的无意识偏好：构造者知道自己想看到什么。这个风险挡不住，只能写明，并列入下一跑的必改项。

三、距离怎么算

层选取。四个相对深度：25%、50%、75%、100%，按各模型总层数向上取整。用相对深度而不是绝对层号，是为了让不同规模之间可比——不同规模的模型层数不同，取绝对层号会让“第6层”在小模型里是深层、在大模型里是浅层。

采样位置。每条探针按其实际长度取八个相对位置的词元，去重后使用；长度不足16词元的探针丢弃。这条规则是预注册第6节那处执行前修订的产物。

表征距离。在上述位置上取隐藏状态，用线性中心核对齐计算相似度，取1减去它作为距离，四层平均。

这里要把一件在第五十五章已经讲过的事在执行层面再确认一次：这个度量对神经元置换、正交变换与各向同性缩放不变。因此本跑没有另做置换对齐，也不应该另做——度量本身已经具备这些不变性，再加一层显式对齐不会让结果更干净，只会引入一个新的自由参数。这是首跑踩过一次然后绕开的坑，记在这里供复现者参考。

这件事的分量在判读上很重：它意味着第六十二章那一列读数不是标号差异。

行为距离。各探针末位置的下一词元分布之间的对称散度，以2为底，因此取值落在0与1之间。在112条探针上平均，同时按A、B1、B2、B3分组记录。

合成距离。预注册定义了两通道各半的合成，但本书不报告它，理由写在第六十章第四节：合成会把两个方向相反的读数抹平，而不一致本身是本跑最有信息量的东西。

四、实现中的三件事

这一节记的是工程细节。把它写进书里，是因为复现者会遇到同样的三件事，而第三件曾经把一次计算变成了一堆无效值。

其一，磁盘。二十四个检查点不能同时留在盘上。流程是下载一个、抽取一次、立刻清掉缓存、再下一个。这意味着任何一次抽取出错都要重新下载，而不是重新计算。

其二，速度。单核前向，最大规模上一个模型需要数分钟。整跑的时间主要花在下载与前向上，分析本身几乎不占时间。

其三，数值下溢。对称散度在遇到零概率项时会产生“零乘以负无穷”的形式，直接计算会得到无效值并污染整条均值。必须显式地把零概率项按零处理。这一处修复写进了偏离记录：它是实现层的数值修复，不改变距离的定义，因此不构成对冻结项的追溯修改。这条界线要划清楚——修一个会让公式算不出数的实现缺陷，与改一个会让结论变化的定义，是两件事。

五、与预注册的三处偏离

按预注册开头那句话的要求，全部偏离逐条列出，不合并、不淡化。

偏离一：规模只到 **160M**。预注册未限定上限，实际因磁盘与算力止步于 160M。这是本跑最重的局限。

偏离二：对称散度的数值修复。见上一节。实现修复，不改定义。

偏离三：附加了一组预注册之外的探索性测量。明确标记为探索性，不计入条款一的判决，内容见第六十六章。

三条之外无其他偏离。原始读数文件、四个脚本、探针集与预注册文本全部公开，任何人可以按第七编附录的清单重跑。

六、一件没有做、但当时应该做的事

首跑在开跑之前没有做一件很便宜的检查：在同一个模型上把整条流程空跑一遍。

具体是指：取同一个检查点，与它自己配对，走完全部计算——抽取、距离、分组、平均。正确的结果应当是每一格都是零。这道检查能一次性验证采样位置规则、分组归属、平均方式与数值处理有没有实现错误，成本是一个模型的一次前向。

首跑没做这一步，理由是流程看起来足够简单。结果是那处数值下溢的问题直到正式计算中途才暴露出来，代价是一次返工。若事先空跑过，它会在第一分钟就显形。

把这件事写进书里，是因为它属于第六十章第八节那一类——该写而没写的清单项，而且是其中最便宜的一项。下一跑的预注册要加一条：任何距离的实现，必须先通过自配对返零检验，再接触多模型数据。

七、复现到什么程度

把复现的边界说清楚，比笼统地说“可复现”更有用。

完全可复现的部分。探针集可以由生成脚本重建，重建后的摘要值应当仍为 e3b9d8a2795ccee——若不是，说明脚本或依赖的版本变了，此后续一切读数都不可比。这是复现者要做的第一步，也是唯一一步有确定通过标准的检验。

模型是公开检查点，按名称与版本号取用，不存在私有材料。距离的计算是确定性的：给定同一批隐藏状态与同一批输出分布，两次计算应当给出相同的数，差别只在浮点末位。

可复现但有代价的部分。前向计算需要把二十四个检查点逐个取下来跑一遍。在本跑的条件下一—单核、3GB 内存——整跑以小时计，且必须逐个清理缓存。换更大的机器会快很多，但计算本身不会变。

不可完全复现的部分，必须写明。若有人在不同硬件、不同数值精度、不同批次划分下重跑，得到的隐藏状态会有末位差异，进而使距离在小数第三位上有出入。这不影响本编的任何结论——本编所用的差别都在小数第一、二位上——但它意味着“逐位相同”不是复现的标准。复现的标准应当是：同一张表的每一格落在同一量级上，且四个规模的相对关系不变。

无法复现的部分。若那组公开检查点将来被撤下或替换，本跑不可复现。这不是假想的风险，公开模型的可得性会随时间变化。本书能做的只有把所用的名称、版本号与摘要值全部写明，使将来的人至少能判断手上的材料是不是同一批。

一处对复现者的提醒。所用的相似度度量对神经元置换、正交变换与各向同性缩放不变。不要在它之前再加一层显式的置换对齐——那不会让结果更干净，只会引入一个新的自由参数，并使读数与本跑不可比。这一条写在这里，是因为它是一个很自然会犯的错误：在文献里，“先对齐再比较”是常规操作。

八、这一章的作用

本章没有一个结论，它只是交代了尺子是怎么做的。之所以要用整整一章交代，是因为接下来两章的全部内容就是这把尺子量出来的数，而这两章会给出方向相反的读数。

方向相反的两列数字摆在一起时，第一反应总是去怀疑其中一列测错了。本章的作用是提前把“哪一列可能测错”这个问题的材料给足：两个通道用的是同一批模型、同一批探针、同一套采样位置，区别只在量的是内部状态还是输出分布。它们不是两次实验，是同一次实验的两个读数口。

下一章先看表征通道。

一、读数

四个规模上，十对只换种子的运行之间的表征距离：

规模	路径间距离（均值 ± 标准差）	同轨迹相邻检查点基线	比值
14M	0.352 ± 0.087	0.0134	26.3
31M	0.445 ± 0.148	0.0129	34.5
70M	0.441 ± 0.117	0.0109	40.4
160M	0.411 ± 0.206	0.0306	13.4

按第五十四章第五节的判据，这一列属于条款一通过的方向。

二、这一列说了什么

第一，它不向零衰减。从14M到31M上升，此后基本持平：0.445、0.441、0.411。最后两个规模上有小幅下降，但下降的幅度远小于标准差，把它读成趋势是不诚实的。

先在论对路径差异的标准解释是资源不足，其经验后果是差异必须随资源增加而衰减。在这一列上，这个后果没有出现。规模增加了十倍，差异没有动。

第二，它不是标号差异。这一点比第一点更要紧，因为如果它是标号差异，第一点就毫无价值——编号的任意性当然不会随规模衰减。

所用的表征相似度量对神经元置换、正交变换与各向同性缩放不变。也就是说，第五十五章第二条硬规定所要求的对称性消去，在度量的构造中已经完成了。两个只有种子不同的模型，把它们的内部单元怎么重排、整体怎么旋转、怎么等比缩放，这个距离都不变。它量到的0.41，是在这些自由度全部被抹掉之后剩下来的东西。

第三，对照很悬殊。在最大规模上，两个只有种子不同的模型之间的距离是0.411；而同一个模型在训练轨迹上相邻一千步的两个快照之间，距离是0.031。前者是后者的十三倍。

这个对照的意义要说准确：它不是说两个模型“差得很远”——0.41在一个上界为1的量上是什么概念，没有先验的答案。它说的是路径间的差异远大于

同一路径内的正常波动。而后者正是我们能拿到的、关于“这个量的噪声水平是多少”的最直接的估计。

三、这一列不能说什么

本书的纪律是不利读数与有利读数同等篇幅。本节写的是这一列自己的弱点，而且要写在下一章那列不利读数之前，不能等到被对手指出。

其一，标准差很大，而且在最大规模上失控。14M 上是 0.087，160M 上是 0.206——几乎是均值的一半。十对样本上的这种离散度意味着：在 160M 这个点上，“均值是 0.411”这句话本身的不确定度相当可观。四个点里最靠右的那一个，恰恰是最不稳的那一个。

其二，比值那一列不能读成趋势。26.3、34.5、40.4、13.4——看起来像先升后崩。但这个下降主要不是分子变的，是分母变的：分子只从 0.441 降到 0.411，分母却从 0.0109 跳到 0.0306。这是首跑暴露出的方法论缺陷，第六十五章专章处理。在那一章之前，本书只使用这张表的前两列，不使用第三列作跨规模比较。

其三，“不衰减”不等于“永不衰减”。四个规模点，跨度一个数量级多一点。完全可能在更大规模上它开始下降。这一列排除不了这件事，也不打算排除——第五十四章第四节的整节内容就是在说，趋势不是极限，而这条纪律对本书自己同样有效。一列在有限区间内持平的数，与一列最终衰减到零的数，在这个区间内长得一模一样。

其四，它只是表征。表征距离量的是模型内部状态的差异。第九编第七十七章要处理的那一记反击正是冲着这里来的：内部表征不同，不等于知识不同；也许两个模型只是用不同的内部坐标记录了同一批内容，而“不同的坐标”恰恰应当被算作标号。

对这一记，本章只回答半句，剩下半句留给第七十七章：所用度量已经消去了三类已知的坐标自由度——置换、正交、缩放。因此这一记反击若要成立，必须指出一类此前未被消去的对称性。这不是一个空头要求，它是可以被满足的；而一旦被满足，按第五十五章第二节末尾写下的那条额外败绩条件，条款一判负。

四、0.41 到底大不大：一个本书答不了的问题

上面反复用到 0.41 这个数，现在必须回答一个不能绕的问题：**0.41** 在一个上界为 **1** 的量上，算大还是算小？

诚实的回答是：本书不知道，而且这不是本书的疏忽，是这类的固有处境。

这个距离由“1减去相似度”构成，它的两端有明确含义——0表示在该度量下完全一致，1表示完全无关。但中间的取值没有一把外部的尺子。0.41不像“差了41个百分点”那样可以直接解释，它只是一个落在区间中段的数。

这正是预注册里要用比值而不是绝对距离的原因：绝对距离的整体尺度是度量的自由度，换一个相似度定义，全部数字会同比例地变，而比值不会。用同一路径内的相邻检查点作分母，等于说：“我们不知道0.41有多大，但我们知道同一条路上走一千步只变0.03。”这句话是有信息量的，而“0.41很大”这句话没有。

麻烦在于，这个分母在最大规模上失控了——第三节第二点已经指出，第六十五章专章处理。分母一旦不可靠，“0.41有多大”这个问题就重新变成无解。

因此本章只能停在一个受限的陈述上，而这个陈述要原样写出来，不做任何加强：

在每一个规模内部，路径间的表征距离都远大于同一路径内相邻检查点的距离；跨规模的比较，本跑给不出。

这个陈述比“表征差异不随规模衰减”弱。后者用的是绝对读数那一列（0.352、0.445、0.441、0.411），它不经过分母，因此仍然成立。两句话的强度不同、依据不同，不要混用。

五、标准差在最大规模上膨胀，这件事本身要单独处理

四个规模上的标准差：0.087、0.148、0.117、0.206。

最后一个数字几乎是均值的一半。在十对样本上出现这种离散度，至少有三种可能的解释，而本跑无法在它们之间做出区分。

解释一：十对样本不够。十对来自五个种子，而这十对并不独立——同一个种子出现在四对里。有效样本量比十小，标准差本身的不确定度因此相当大。

解释二：大模型之间的差异本来就更参差。有可能在较大规模上，不同路径的分化方式变多了：某些种子对之间很接近，某些很远。若如此，这个膨胀本身就是一条支持本书的读数——它意味着路径差异不仅没消失，还变得更结构化了。

解释三：度量在大模型上不稳。相似度的估计依赖于采样的位置数与表示的维度，两者在不同规模上并不同比例变化。这可能引入规模相关的估计噪声。

本书不在这三者之间选。三种解释都能容纳这个数字，而区分它们需要的东西本跑没有：更多种子、逐对读数的分布、以及在同一规模上对度量本身做的标定。

写下这一节的理由是：解释二对本书有利，而在没有材料区分三者的情况下选用它，正是第六十四章要批评的那类做法。把一个不确定的数字解释成对自己有利的证据，与把它略去不报，是同一种错误的两个方向。

这一处也进下一跑清单：报告逐对距离的完整分布，而不只是均值与标准差。这件事不增加任何计算成本，本跑没有做，是设计时的疏忽。

六、四层平均掩盖了一样东西

表征距离是在四个相对深度上各算一次，然后取平均。这个做法本身没有错——它使不同规模的模型可比，这正是用相对深度而非绝对层号的理由。

但平均掩盖了一样可能很重要的东西：深度剖面。

两个模型之间的差异在浅层大还是深层大，是一个有实质含义的问题。若差异主要在浅层，一种自然的解读是它来自输入端的表面编码，随着深度推进被逐渐消化掉——那更像标号。若差异在深层同样大甚至更大，解读就完全不同：越靠近输出的地方分歧越深，意味着两个模型对同一批内容组织出了不同的高层结构。

这两种情形在本跑的读数里长得一模一样，因为它们被平均成了同一个数。

本跑没有保留逐层读数，这是设计时的疏忽而不是取舍——保留它不增加任何计算成本，只是当初没有想到要用。这一条与第六十章第八节所列的“逐对读数未保留”属于同一类损失：为了报告一个简洁的量，把生成它的那批更丰富的数扔掉了。

因此下一跑清单里要加一条：报告逐层读数，而不只是四层平均。同时，深度剖面本身应当被写成一个独立的观察项——它有可能给第九编第七十七章那一记反击（“这只是表征的形成，不是知识的形成”）提供正面材料，也有可能给它提供弹药。两种都有价值，而本跑一种也没给出。

这一节的存在本身说明了一件事：首跑真正的产出不是那四个数字，是它让人看清了应该记录什么。

七、为什么不在这里宣布胜利

如果本书只报这一章，它会是一份很好看的材料：路径差异在消去三类对称性之后仍然存在，且在一个数量级的规模跨度上不衰减，是同轨迹噪声的十几倍到四十倍。这足以写成一篇有说服力的文章。

本书不这样做，理由有三个层次。

最表层的理由：下一章的读数方向相反，而预注册要求两个通道同等篇幅。

中间一层的理由：这一列本身有上一节那四处弱点，其中第二处足以让第三列作废。一份材料如果只在挑出来的那一列上成立，它的成立就不是关于对象的，是关于挑选的。

最深一层的理由，也是本书真正在意的那一条：只报一个通道不是省略，是构造结论。同一次实验里有两个读数口，它们给出了不同的方向；选一个报出来，等于让读者相信实验给出了一个方向。这比数据造假更难被发现，因为每一个数字都是真的。

第六十四章会把这件事讲完。在那之前，先看另一列。

第六十三章 读数（二）：行为通道——单调下降

一、读数

同一批模型，同一批探针，同一套采样位置。量的不再是内部状态，而是输出分布。

规模	路径间距离（均值 ± 标准差）	同轨迹相邻检查点基线	比值
14M	0.263 ± 0.067	0.0407	6.45
31M	0.221 ± 0.030	0.0398	5.57
70M	0.171 ± 0.010	0.0307	5.56
160M	0.116 ± 0.008	0.0487	2.37

这一列是先在论方向的读数。它必须与上一章同等分量地写出，这是预注册的第二条防作弊纪律。

二、这一列说了什么

第一，它单调下降，而且降得干净。0.263、0.221、0.171、0.116。四个点、三段下降，没有一段反向。规模增加了十倍多，路径造成的行为差异降到了不足原来的一半。

第二，标准差随规模收缩。0.067、0.030、0.010、0.008。这与上一章那列形成了刺眼的对照——那里标准差在最大规模上膨胀到 0.206，这里收缩到 0.008。越大的模型，它们在行为上越一致，而且这种一致性本身也越稳定。

第三，这正是先在论所预测的形状。资源不足的解释要求差异随资源衰减，这一列给出的就是衰减。如果只看这一列，条款一的前半条判负条件已经满足了。

这三句话本书照写，不加任何缓冲。

三、但它没有满足判负条件的后半条

第五十四章第五节写死的判负条件有两半：单调下降，且在最大规模处不显著区别于基线。

前半条满足了。后半条没有。

在最大规模上，路径间行为距离是 0.116，同轨迹相邻检查点基线是 0.0487，比值 2.37。它降了很多，但它没有降到噪声里去——仍然是基线的两倍以上。

这个区别不是技术性的挑剔。“衰减”与“衰减到零”的分别，正是第五十四章第四节整节在讲的那件事，而那一节讲的时候用的是针对先在论的语气。现在轮到它被用在本书自己身上：本书不能因为这一列在下降就判自己输，正如先在论不能因为它在下降就宣布自己赢。两边受同一条纪律约束。

所以这一列的准确读法是：它向着判负的方向走了很长一段，但在本跑所及的最大规模上还没有走到。它是否会在更大规模上走完，这四个点答不了。

四、分组读数：一个对本书有利的事实和一个对本书不利的事实

行为通道按探针组分开记录。四组在四个规模上的读数：

规模	A（分布内）	B1（归纳）	B2（模算术）	B3（中文）
14M	0.184	0.459	0.146	0.496
31M	0.174	0.344	0.200	0.312
70M	0.141	0.316	0.123	0.193
160M	0.105	0.146	0.077	0.166

两件事同时成立，都要写。

有利的一件：种子差异在分布外显著大于分布内。在最小规模上，B1 是 A 的约 2.5 倍，B3 是 A 的约 2.7 倍。这与关于欠规定性的那批文献的核心发现完

全一致——同一套训练规格下的不同种子，在训练分布上表现相同，在分布外行为上系统地不同。

这条读数直接证明了第五十五章第三条硬规定的必要性：若 **d** 只在分布内测量，整条差异会被压掉。看 A 那一列就知道：它从 0.184 降到 0.105，降幅比总均值更平缓，但绝对值一直很小。只测 A，本跑会得到一份干净、无趣、且倾向于判负的读数。

不利的一件：这个差距随规模收窄。B1 从 A 的 2.5 倍降到 1.4 倍，B3 从 2.7 倍降到 1.6 倍。也就是说，分布外这个“路径差异的藏身之处”，正在随规模变浅。

本书不淡化这件事，也不给它加任何解释性的缓冲。它是一条实打实的不利读数。

还有一件要写明：B2 那一列不单调，14M 到 31M 之间反而上升（0.146 到 0.200）。一列本该随规模衰减的量在中间反弹，最可能的解释是这一组探针的构造带来的噪声——模算术串的内容在不同随机构造下差别很大，而每组只有 16 条。这是样本量不足的迹象，不是发现。记下来，不据此说任何事。

五、分组基线：一处更难看的读数

上一节只用了分组的路径间距离。四组各自还有自己的噪声基线，而那一列比主表更难看。

各组的路径间距离除以各组自己的基线：

规模	A (分布内)	B1 (归纳)	B2 (模算术)	B3 (中文)
14M	5.16	8.08	9.24	7.12
31M	5.10	5.54	5.02	7.77
70M	5.95	6.76	4.27	4.30
160M	3.66	2.39	1.75	1.37

（由上一节的路径间距离与各组基线逐格相除得到，两列均为首跑的原始读数。）

这张表要逐条读，不许跳过任何一格。

第一，四组在最大规模上全线坍塌。前三个规模上，四组的比值大多在 4 到 9 之间，没有明显的规模趋势；到 160M，四格同时掉到 3.66、2.39、1.75、1.37。

第二，最脆弱的那一格恰好在本书最看重的那一组上。B3 中文组的比值从 14M 的 7.12 掉到 160M 的 1.37。**1.37** 已经接近噪声。若条款一的判负条件只在这一组上执行，它会满足——单调下降，且在最大规模处已经很难与基线区分。

这一格是首跑里对本书最不利的一个数字。它写在这里，位置与其他读数相同，字号与其他读数相同。

第三，**B2** 那一格是 **1.75**，同样接近噪声。

所以行为通道的处境比主表所显示的更不利：主表的比值在最大规模上是 2.37，那是四组平均的结果；拆开看，有两组已经落到 2 以下。

六、但这张表本身也被下一章那件事污染了

写完上面三条，必须立刻接一句，否则这一节会变成一次挑选性的悲观。

B3 那一格的基线，在最大规模上是 0.121。而它在三个较小规模上分别是 0.070、0.040、0.045。基线自己在最大规模上翻了两三倍。

也就是说，B3 比值从 4.30 掉到 1.37 这一段，分母的贡献远大于分子的贡献——分子只从 0.193 降到 0.166，分母却从 0.045 跳到 0.121。

这与第六十五章要处理的那件事是同一回事，而且这里给出的是它最极端的一个实例：噪声基线不仅跨规模不可比，它在不同探针组之间的不可比程度还不一样。

于是这张表的准确读法只能是：

在最大规模上，四组的比值全部下降，其中两组已接近噪声；但这次下降中有多少来自路径差异真的变小、有多少来自分母失控，本跑分不开。

“分不开”三个字要照写。既不能用它来解释掉那个 1.37——那是回避不利读数；也不能拿着 1.37 直接判负——那是把一个被污染的量当作判据。

这两条纪律的方向是相反的，而它们同时有效。一份读数既不利于本书、又不可靠，处理它的正确方式是两件事都写出来，然后把它列进下一跑必须重做的清单——而不是从中挑一件来用。

七、行为距离只看了一个词元

这一节写这个通道在构造上的一处窄化，它比上面两节的任何一条都更根本，而且对两个方向都不利。

行为距离的定义是：取每条探针末位置的下一词元分布，算两个模型之间的散度，在 112 条探针上平均。

也就是说，一条 128 个词元的探针，只有一个位置被用来测行为——最后那个。前面 127 个词元的作用仅仅是提供语境。

这个选择有它的理由：末位置的预测依赖于全部前文，因此是信息量最大的单点；而且它的定义干净，没有位置权重的自由度。表征通道则不同，它在八个位置上采样。

但代价要说清楚。

其一，它把“行为”窄化成了“一步预测”。模型之间的行为差异可以体现在很多地方：长程一致性、多步生成中的分歧累积、对同一提示的不同延续方式。这些全部不在本跑的测量范围内。本跑测到的“行为差异随规模下降”，严格地说只是“单步下一词元分布的差异随规模下降”。

其二，单步预测恰好是最容易被训练压平的那一层。所有模型都在同一个目标上被优化，而那个目标就是单步预测。用它来测差异，等于在模型被最用力地对齐过的那个位置上找分歧。这一点对本书不利的方向和有利的方向同时存在：不利的是，这个位置上的差异本来就该小；有利的是，即便在这个最被压平的位置上，最大规模的路径间差异仍是基线的两倍以上。

其三，散度的取值范围造成的错觉。所用的散度以 2 为底，取值落在 0 到 1 之间。0.116 看起来是一个很小的数，但这个量在分布几乎相同的两个模型之间会非常接近 0——同轨迹基线 0.049 就是这个量级。判断 **0.116** 大不大，只能靠与基线比，不能靠它离 1 有多远。这与第六十二章第四节对表征通道说过的是同一个问题。

下一跑应当在单步之外加测至少一种多步行为，并保留逐探针的读数而不只是组均值。这两条都写进第六十六章的清单。

八、这一列把什么问题逼到了台前

把两章并排看，局面是这样的：同一次实验的两个读数口，给出了方向相反的答案。

内部表征上，路径差异不衰减；输出行为上，路径差异单调衰减。两个通道用的是同一批模型、同一批探针、同一套位置，区别只在量的是什么。

这不是矛盾，它在技术上完全可能——两个模型可以用相当不同的内部组织，产生相当接近的输出。这件事本身甚至是一个值得单独研究的现象。但对本案来说，它把一个此前一直藏在背后的问题顶到了台前：

“结果”究竟指什么？是模型内部所形成的东西，还是它表现出来的行为？

条款一判的是“路径差异是否随规模衰减”。如果“结果”指内部组织，答案是否；如果指输出行为，答案是接近于是。两个答案都由同一次实验给出。

这个问题不是本跑造成的，它一直在那里，只是此前没有材料把它逼出来。第九编第七十七章处理它的哲学形态——“这只是表征的形成，不是知识的形成”。而在判决层面，预注册第三款事先就为这种情况写好了处理方式。

下一章讲那条处理方式为什么是一个结论。

第六十四章 “未能分辨”是一个结论

一、本跑判了什么

按预注册第4条：

- 条款一通过的条件——归一化路径散度不趋向1、无向1衰减的单调趋势：表征通道满足，行为通道不满足。
- 条款一判负的条件——单调下降且在最大规模处不显著区别于1：行为通道满足前半条，不满足后半条。
- 第三款：两通道结论不一致，判“未能分辨”。

本跑的结论是“未能分辨”。不是“倾向于支持”，不是“初步证据表明”，不是“总体而言偏向”。这条纪律在执行之前写死，现在照办。

二、两种作弊，每一种都由真实的数字构成

先把可以作弊的两条路摆出来，因为不摆出来就看不出这条纪律挡住了什么。

写法一：只报表征通道。那么本跑的叙述是这样的：在消去神经元置换、正交变换与各向同性缩放之后，只因随机种子不同的模型，其内部表征距离在一个数量级的规模跨度上不衰减，稳定在0.41至0.45之间，是同一训练轨迹内相邻检查点距离的十几倍到四十倍。条款一在表征层面通过。

这段话里的每一个数字都是真的，每一句陈述都经得起复核。它是一次漂亮的通过。

写法二：只报行为通道。那么叙述是这样的：种子造成的行为差异随规模单调下降，从0.263降到0.116，降幅超过一半，标准差同步收缩；分布外探针

上的差异同样随规模收窄。路径差异正在随资源增加而消失，条款一判负，先在论在这一现场取胜。

这段话里的每一个数字也都是真的。它是一次清楚的败绩。

两种写法都能成文，两种都是作弊。而且第二种更隐蔽——因为它得出的是不利于作者的结论，读者会本能地认为一个愿意报告自己输了的作者是诚实的。

作弊之所以成立，不在数字，在于同一次实验里有两个读数口，而叙述只用了一个。这类作弊不留痕迹：所有数字可复核，所有陈述可验证，被略去的那一列从未在文本中出现过，读者甚至不知道它存在。

防住它的办法只有一个：在看到任何读数之前，就规定两个通道必须同等篇幅地报告，并规定两者不一致时的处理方式。这正是预注册第3节末尾与第4条第三款所做的事。

三、为什么“未能分辨”是结论而不是弃权

有一种自然的反应是：两通道打架，说明这次实验没做成，结论栏应该空着。

这个反应错在哪里，要分三层说。

第一层：它是一个有信息量的判决。“未能分辨”不是“什么都没测到”。本跑测到的东西相当具体：在这个规模区间、这套探针、这个度量之下，内部组织的路径差异不衰减，而输出行为的路径差异衰减但未衰减到噪声。这三件事都是事实，都可被复核，都排除了若干种可能——它排除了“路径差异在两个通道上都消失”，也排除了“路径差异在两个通道上都稳定”。它没有排除的，恰恰是本案最关键的那一支。

第二层：它把一个此前没人问的问题逼了出来。上一章末尾那个问题——“结果”指内部组织还是指输出行为——在两个通道给出同向读数时根本不会出现。一次给出一致读数的实验会让人心安理得地绕过它。本跑的不一致使它无法再被绕过：在本案里，你必须先说清楚你把什么算作结果，才能谈路径是否进入了结果。

这是本跑交出来的最重的一件东西，而它是“未能分辨”这个判决的副产品。若本跑按写法一或写法二成文，这个问题会被一并埋掉。

第三层，也是最要紧的一层：允许“未能分辨”存在，是判据有约束力的前提。一套只有“通过”和“判负”两个取值的判据，等于强迫每一次实验都给出方向。而实验并不总有方向。强迫它给出方向的结果不是获得更多信息，是

获得一个由作者的偏好填充的方向——因为当数据不指向任何一边时，填进去的只能是别的东西。

一个永远能给出结论的判据，其实是一个不受数据约束的判据。

四、这条纪律在本跑里挡住的是什么

值得把这件事说得具体些。

本书的立场是造成论一侧。表征通道的读数支持本书，行为通道的读数不支持。按人之常情，这里会发生的事情是：把表征通道写在前面、写得详细，把行为通道写在后面、写得简略，然后在总结里写一句“综合来看，路径差异在表征层面稳健存在，在行为层面虽有衰减但仍显著高于噪声，总体倾向于支持条款一”。

这句总结里没有一个字是假的。它甚至比只报一个通道更诚实——它两个通道都提到了。但它做的事情和作弊是一样的：它用“倾向于”把一次未完成的判决说成了一个已完成的方向。

第五十九章说过，整桩两千年的悬案就是被这种措辞维持下来的。“倾向于支持”从来不是谎言，它通常是对图形的准确描述。它的问题是它让一个判决在未完成的状况下被计入账目，而一旦计入，后续的工作就会建立在它之上，再没有人回去查那笔账是怎么记的。

本书对它的处理是取消这个措辞本身。在本书中，条款的结论只有三种取值：通过、判负、未能分辨。没有第四种，也不接受任何形式的加权折衷。

这也是本书为什么不报告预注册里定义过的那个合成距离。合成会把两个方向相反的读数按权重加起来，得到一个单一的数——而那个数会以一种看起来很客观的方式，完成上面那句“总体倾向于”所做的事。权重是 0.5 比 0.5，这个选择本身没有任何理由，它只是一个默认值；用它算出来的数，承载不起判决。

五、为什么“未能分辨”在学术文献里很少见

一个附带的观察，值得单独一节，因为它解释了这条纪律为什么必须写死而不能靠自觉。

在已发表的文献里，明确以“未能分辨”作为结论的工作极少。这不是因为实验很少给出不明确的读数——恰恰相反，不明确是常态。少见的原因在别处，而且是结构性的。

第一，不明确的结果难以发表。一份“我们做了这个实验，它没有给出方向”的报告，在任何评审制度下都处于劣势。它不推进任何一方，不产生可引

用的结论，读起来像一次失败。于是这类结果大量地留在抽屉里，而留在抽屉里的那一批，恰恰是最能约束人们下结论的那一批。

第二，不明确的结果几乎总能被加工成明确的。这一点比第一点更要命。一份两通道打架的读数，只要换一个叙述重心、加一个加权、或者干脆把其中一个通道降格成“附加分析”，就能变成一份有方向的结果。加工过程不需要伪造任何数据，只需要在写作时做一系列看起来合理的取舍。

第三，加工的动机不必是不诚实。大多数情况下，作者真心认为自己在“抓住主要方面”。而在两个通道都真实存在的情况下，“哪个是主要方面”本身没有客观答案——除非事先就规定好。

这三条合起来，构成一个稳定的机制：不明确的读数系统性地从文献中消失，或者以明确的形态进入文献。结果是整个领域看起来比实际情况更有方向感。

本案两千年悬而未决，与这个机制不是无关的。第五十三章说过，双方都堆了大量材料却谁也没能把对方逼到墙角。一个可能的原因是：那些最有约束力的材料——两边读数打架的那些——在进入文献之前就已经被加工成了一边的证据。

本书对此的处理是把它变成一条制度而不是一种态度：预注册第4条第三款在执行之前就规定了两通道不一致时的处理方式，因此在读数出来的那一刻，“要不要加权”“哪个是主要方面”这些问题已经没有被问的余地了。

这条纪律的代价是真实的：本编因此交不出一个方向。但代价的另一面是，本编交出的那份“未能分辨”，是一份没有被加工过的读数——而在这个案子上，没有被加工过的读数很可能比又一个方向更稀缺。

六、这个判决是暂时的，暂时性也要写明

最后一件事：“未能分辨”是对本跑的判决，不是对条款一的判决。

条款一仍然是一条可判的条款。本跑判不了它，原因是具体而可修的三条：规模点只有四个，噪声基线跨规模不可比（下一章），探针集由本实验构造。三条都改掉之后，同一条判据可以再跑一次，那一次可能给出通过，也可能给出判负。

因此本编的结论不是“这件事判不了”，而是：

第一次跑没有判出来，而它明确地告诉了我们下一次要改什么。

第六十五、六十六两章就是这份“要改什么”的清单——一章讲判据本身的缺陷，一章讲一条不能当结论但值得去跑的线索。

一、缺陷

预注册的冻结项第二条规定：噪声基线取“同一训练轨迹内相邻检查点之间的距离”。归一化路径散度定义为路径间距离除以这个基线。

执行之后，基线的实测值如下：

规模	表征通道基线	行为通道基线
14M	0.0134	0.0407
31M	0.0129	0.0398
70M	0.0109	0.0307
160M	0.0306	0.0487

三个较小的规模上，表征基线稳定在 0.011 到 0.013 之间；到最大规模跳到 0.0306，接近三倍。行为基线同样在最大规模上反弹。

这个跳变直接决定了比值那一列的形状：

规模	路径间距离	基线	比值
14M	0.352	0.0134	26.3
31M	0.445	0.0129	34.5
70M	0.441	0.0109	40.4
160M	0.411	0.0306	13.4

比值在最大规模上从 40.4 掉到 13.4，看起来像一次剧烈的坍缩。

但把分子单独拎出来看：0.352、0.445、0.441、0.411。分子几乎没动。

比值那一列的坍缩，主要不是分子变了，是分母变了。

二、原因

原因不难理解，难的是在执行之前想到。

“同一训练轨迹内相邻检查点之间的距离”测的是什么？是模型在相邻两个快照之间变了多少。而模型在相邻两步之间变多少，取决于训练在那个时刻推进得有多快。

于是这条基线实际上是一个训练推进速率的代理，而推进速率本身随规模、随训练进度而变。不同规模的模型在同一个名义步数上，处在各自训练过程

的不同阶段：有的已经趋于平缓，有的还在活跃变化。用它当分母，等于用一把自己会伸缩的尺子去量四根长度差不多的棍子，然后报告棍子在变短。

预注册第5节对这条基线做过一段论证，论证说它偏保守：相邻检查点之间的差异包含了训练仍在推进所造成的真实变化，因而基线偏大、比值偏小，不利于本书；若比值仍显著大于1，这个偏差不影响结论。

这段论证是对的，而且它的结论在单个规模内也确实成立。它漏掉的是跨规模那一层：偏大多少，每个规模不一样。一个在各规模上偏大程度不同的分母，不能用来做跨规模比较。

三、缺陷的第二层：间隔本身也是一个自由参数

上面讲的是基线随规模伸缩。还有一层，预注册同样没有写到：“相邻检查点”这个说法里的“相邻”，是一个自由参数。

本跑取的是相隔一千步的两个公开快照。一千步不是从原理推出来的，它只是那组公开检查点在末段的发布间隔。

若取相隔一百步的两个快照，基线会更小，全部比值会更大；若取相隔一万步的，基线会更大，比值会更小。而这个量不是线性缩放的——训练推进在不同阶段的速率不同，间隔与距离之间的关系本身就是曲的。

于是这条基线实际上带着两个都没有被论证过的选择：用推进量当噪声，以及用一千步当推进量的单位。第一个选择在预注册里有一段论证（论证是对的，只是漏了跨规模那一层）；第二个选择连论证都没有，它是材料给的，不是设计给的。

这一层比第一层更难察觉，因为它不会产生任何可见的异常——四个规模用同一个间隔，表面上完全一致。它只在一处露了马脚：如果比值的分母是一个依赖于任意间隔的量，那么“比值是40.4还是13.4”这类陈述就没有绝对意义，只有相对意义。而本书此前用这些数字时，语气偶尔偏向了绝对。第六十二章第三节与本章第四节已经把使用范围收紧，这里把根因写明。

推论：第五节那两条修法之所以正确，不只是因为它们避开了推进速率，还因为它们都不依赖一个任意的间隔——同种子重训的差异没有“间隔”这个参数，而多对等距检查点的分布下界把间隔从一个点变成了一个分布。

四、后果

后果要写得精确，既不夸大也不缩小。

作废的部分：本跑的归一化曲线不能作为规模趋势的证据。表征通道的26.3 / 34.5 / 40.4 / 13.4 这一列，不得读成“路径差异先增强后急剧衰减”。行为

通道的 $6.45 / 5.57 / 5.56 / 2.37$ 同样不得单独作为衰减的证据——它的最后一段下降里，有一部分来自分母的反弹。

仍然有效的部分：各规模内部的比较仍然成立。在每一个规模上，路径间距离都远大于同轨迹内的相邻检查点距离——最小的一处也有 2.37 倍，最大的一处有 40 倍。这一条不受分母跨规模不可比的影响，因为它是在同一个规模内做的比较，分子分母来自同一个模型的同一段训练。

不受影响的部分：第六十二章与第六十三章那两张表的前两列——路径间距离本身，与它的标准差。这些是绝对读数，不经过分母。第六十三章关于行为通道单调下降的结论，用的正是绝对读数（0.263、0.221、0.171、0.116），因此那个结论不因本章而动摇。

这一条要特别写明，因为它对本书不利：本章的缺陷削弱的主要是比值那一列，而比值那一列在最大规模上恰好是对本书不利的（**13.4** 相对于 **40.4** 的坍缩）。换句话说，承认这个缺陷，对本书是有利的。正因为如此，本节必须把“仍然有效的部分”和“不受影响的部分”列清楚，以免这份承认变成一次挑选性的作废——只废掉对自己不利的那一列，留下有利的那些。上面三段就是为了防这一手。

五、修法

下一跑必须换基线。两条路，各有代价。

修法一：同种子、同数据次序、仅由数值非确定性造成的重训。用完全相同的种子和次序再训练一次，两次之间的差异只来自硬件与并行计算带来的数值不确定性。这是“同一条路径走两遍”最严格的实现，因此也是最正确的噪声基线。

代价：需要真的重新训练，而且要在每个规模上都训练一次。这是本跑跑不起的东西，也是它当初选择代理的原因。

修法二：同一轨迹内多对等距检查点的距离分布的下界估计。不只取相邻一对，而是在整条轨迹上取多对间隔相同的检查点，得到一个距离的分布，取其下界作为基线。

代价：它仍然带着训练推进速率的痕迹，只是通过取分布下界削弱了这个痕迹。它比现在这条好，但不如修法一干净。

本书的建议是：下一跑用修法一，至少在最小的两个规模上做，用来标定修法二在那些规模上的偏差，再把修法二外推到大规模。这是一个折衷，它的正当性取决于标定是否稳定，而这件事本身需要读数来回答。写在这里作为下一跑的预注册项，不作为结论。

六、修订冻结项清单

按第五十九章第一节的总则，执行中发现的问题只能作为下一跑的新冻结项，不能追溯修改本跑。因此：

- 本跑的读数按原定义报告，比值那一列照登，同时在正文中标明其不可用于跨规模比较。第六十二章第三节与第六十三章已经这样做了。
- 冻结项第二条的新版本写入下一跑的预注册：噪声基线改用同种子重训，或同轨迹多对等距检查点的分布下界；两种之中选哪一种、以及若选折衷方案其标定如何做，必须在执行前定死。

此外，条款一的判据表述也要相应修订。现行判据是写在归一化量上的——“不趋向 1”“不显著区别于 1”。既然分母被证明不可靠，下一跑的判据要么改写到绝对量加独立标定的噪声水平上，要么等基线换好之后再用比值。这一条同样写入下一跑的预注册项。

七、一条超出本书的警告

这个缺陷不是本书独有的。用“同一条轨迹上相邻两个快照之间的差异”来标定噪声，是一个相当自然的做法，而且在比较模型之间差异的工作里并不罕见——它便宜、直观、不需要额外训练。

本章的发现因此有一个超出本案的推论，值得单独写一句：

任何用训练轨迹内部的变化量作噪声基线、并在多个规模上做比较的研究，都应当先检查这个基线本身是否随规模变动。

检查的办法很简单：把基线单独画出来看。如果它在不同规模上相差几倍，那么由它归一化出来的任何跨规模趋势都不可采信，无论那个趋势看起来多干净。

首跑之所以发现了这件事，纯粹因为预注册要求把基线作为一个独立的读数报告出来，而不是只报归一化后的比值。若当初只记录了比值，这个问题会完全隐形——四个比值看起来会是一条有趣的曲线，而且是一条可以讲出故事的曲线。

这一点值得推荐给任何做类似工作的人：把分母单独报出来。这几乎不增加成本，却能把一整类隐形错误变成可见的。

八、这件事的一般意义

这一章记录的是一次制度的失效，而失效的方式值得单独说一句。

预注册保护的是“事后不许改判据”，它不保护“事前把判据写错”。前者是意志问题，制度可以挡住；后者是知识问题，制度挡不住——在执行之前，没有人知道那条基线会跨规模伸缩，包括写下它并为它做过一段正确论证的人。

但这一章同时也是对预注册的一次辩护，而且是比任何正面论证都有力的辩护：正因为这条基线被写死并在四个规模上统一使用，它的毛病才显形。假如基线是每个规模随手取的、按当时的手感调的，四个规模各自都会得到一个“看起来正常”的比值，这个问题会被平滑掉，永远浮不出来，而由它造成的偏差会静静地进入结论。

冻结的价值不只是防作弊。它还把自己的错误固定成一个可以被看见的形状。

由此得到本编对下一跑的第一条要求，也是最优先的一条：换基线。第六十六章给出剩下的清单，以及一条不能当结论、但值得花钱去跑的线索。

第六十六章 一条探索性读数，与下一跑的清单

一、这条读数是怎来的

首跑所用的那组公开检查点，除了“换种子”的主系列之外，在最大规模上另有两组消融：一组固定权重初始化、只换数据次序；一组固定数据次序、只换权重初始化。

这恰好是第五十六章形式三——可交换性检验——所需要的材料的一个粗糙版本。模型已经下载在盘上，测一次几乎不增加成本，于是顺手测了。

它是预注册之外的附加测量，在偏离记录里被明确标记为探索性，不计入条款一的判决。本章把它摆出来，连同它的全部弱点。

二、读数

最大规模（160M）上，四种条件下的距离：

干预	对数	表征距离	行为距离
两者都换	10	0.411 ± 0.206	0.116 ± 0.008
只换数据次序	3	0.101 ± 0.027	0.138 ± 0.011
只换权重初始化	3	0.096 ± 0.022	0.118 ± 0.006
基线（相邻检查	1	0.031	0.049

点)

两件事值得记下来。

其一，只换数据次序所造成的行为差异是 **0.138**，不小于两者都换的 **0.116**，是基线 **0.049** 的 **2.8** 倍。

把这个条件说清楚：材料是同一个集合，判准相同，架构相同，权重初始化相同——只有呈现顺序不同。

如果“材料决定结果”这句话在字面上成立，那么同一个集合以不同顺序呈现，在充分训练之后应当收敛到可交换的结果。这一读数不是这样。这是那句话在行为层面上第一次被直接顶了一下。

其二，表征通道呈现强超加性。单换任一项各约 0.10，两项同换 0.41，远大于两者相加。这提示路径变量之间存在交互，不能按独立因素分解。

三、它的三处弱点

现在写弱点，而且要写足——本章的大部分篇幅在这里。

弱点一：样本量是 **3** 对。

三对样本不支持任何统计推断。表上那个标准差是三个数的标准差，它本身的不确定度极大。0.138 与 0.116 之间的差别，在这个样本量下不具备可辩护的显著性。把它写成“大于”已经是本书在语气上所能允许的极限，写成“显著大于”就是越界。

弱点二，也是最重的一处：三组的对内共享条件不齐。

- “只换数据次序”那一组的三个模型，共享同一个权重初始化。
- “只换权重初始化”那一组，共享同一个数据次序。
- “两者都换”那一组，两样都不共享。

三组的对内相似度本来就不在同一条条件下。前两组各自被一项共享条件“拉近”，第三组没有。因此三组之间的任何比较——包括上一节那个看起来很强的超加性——都被这一处混淆污染。

超加性不能当结论。它可以完全是这个共享结构的产物，而不是路径变量交互的产物。它的正确位置是下一跑的预注册项：设计一组对内条件严格对齐的消融，再看超加性是否还在。

这正是第五十六章第五节那条实验规格的来处。那条规格里写着“组内共享条件要对齐，否则三组的对内相似度本来就不在同一条件下”——那句话不是从原理推出来的，是从这次读数裁的跟头里长出来的。

弱点三：它只是顶了一下。

不得把这个 0.138 写成“材料决定结果已被证伪”。证伪那句话需要的是形式三的完整实验：成对的次序反转、严格对齐的控制、事先指定的收敛判据、跨规模的重复。以上一件都没有。本跑用的是现成的消融材料，它们当初被制作出来的目的不是回答这个问题。

四、那么它还剩下什么

三条弱点写完，这条读数还剩下什么？

剩下一件，而且只剩这一件：它把形式三从一个漂亮的想法，变成了一个值得花钱去跑的实验。

在这条读数之前，可交换性检验是一个纸面上的设计——论证很锋利，但没有任何迹象表明它会给出非平凡的结果。完全可能的情况是：真的去做次序反转实验，跑完发现差异微乎其微，整条设计作废。

这条读数改变了这个判断。它表明，在一个虽然粗糙但方向正确的近似实现里，次序单独造成的行为差异并不小，甚至不比“次序加初始化一起换”更小。这不构成证据，但它构成理由——去做那个昂贵实验的理由。

这是探索性读数在本书中被允许扮演的唯一角色：它可以决定下一笔钱花在哪里，不可以进入任何一条判决。

五、下一跑清单

把本编所有章节里散落的“下一跑必须改什么”收在一处，按优先级排列。

第一，换基线。本跑暴露出的第一优先项。改用同种子、同次序、仅数值非确定性的重训，或同一轨迹内多对等距检查点的分布下界。理由与两种修法的代价见第六十五章。在此之前，任何跨规模的归一化读数都不可采信。

第二，补规模点。至少加到 410M，若条件允许加到 1B 及以上。四个点不足以拟合，更不足以外推。只有在规模跨度显著扩大之后，才谈得上给出不可消解度及其置信区间——而在那之前，本书不报告这个量的任何数值。

第三，换分布外探针。现有的分布外探针由本实验构造，其中中文一组尤其脆弱，不是第三方公开基准。下一跑必须改用第三方基准，或至少并行报告自造探针与第三方基准两套读数。这一条的理由在第五十五章第三节已经写

过：探针配比是本书最脆弱的自由参数，而分组读数证明结论对它高度敏感。

第四，把次序可交换性做成正式实验。按第五十六章第五节的规格：成对次序反转、组内共享条件严格对齐、事先指定收敛判据、不得改用分数作距离。需要自训练，是这份清单上最贵的一项。

第五，判据表述随基线一并修订。现行判据写在归一化量上，而分母已被证明不可靠。下一跑的判据要么改写到绝对量加独立标定的噪声水平上，要么等基线换好之后再用品值。二选一，执行前定死。

第六，在前两条完成之前，不报告不可消解度。这一条是纪律，不是建议。首跑没有报告它，下一跑在第一、二条完成之前也不应报告。

六、这份清单要花多少钱

清单列完，必须交代它的代价，否则它只是一份愿望。六条的成本相差很大，按量级排三档。

近乎免费的三条。保留逐对读数、保留逐层读数、并行报告自造探针与第三方基准——这三条不增加任何前向计算，只是把已经算出来的东西记下来，或换一批现成的探针文本。它们之所以在首跑里没做，原因是设计疏忽而不是资源不足。下一跑没有任何理由不做。

中等代价的两条。补规模点与换基线中的第二种修法，都只需要更大的机器，不需要重新训练：前者是把更大的公开检查点取下来跑前向，后者是在已有轨迹上多取几对快照。它们的代价是存储与算力，在本跑那种单核、3GB 的条件下做不了，在一台常规的工作站上做得了。这一档的瓶颈是设备，不是方法。

昂贵的两条。换基线的第一种修法（同种子重训）与正式的次序可交换性实验，都必须从头训练模型。前者要在每个规模上各重训一次，后者要成对地训练次序反转的模型，且组内共享条件必须严格对齐。这一档的代价是数量级上的跳跃：它不再是“借用别人已经训好的东西”，而是“自己训”。

这个分档有一个直接的推论，它也是本编给出的最实际的一条建议：

下一跑应当先把前两档全部做完，再决定第三档做不做。

理由是：前两档做完之后，本跑的两条局限里已经解决了两条（规模点、探针），第三条（基线）也至少被改善到可用。在那个状态下重跑一次条款一，很可能就能给出通过或判负——而不是又一次“未能分辨”。只有当那一跑仍然判不出来，或者判出了通过而需要继续往条款二推进时，第三档的花费才有正当理由。

把昂贵的实验押后，不是保守，是顺序问题。条款三是本书开出的支票，而在条款一还没兑现之前就去兑第三张支票，即使成功也无人采信——因为那时人们会正确地指出：第一条都没判出来。

七、这一编交出了什么

第七编到此结束。把它交出来的东西盘一次，不多说也不少说。

它没有交出判决。条款一的结论是“未能分辨”，四条败绩条件一条都没有被触发。

它交出了一次真实执行。二十四个公开检查点、112 条冻结探针、两个通道、全部脚本与原始读数公开。任何人可以重跑并核对摘要值。

它交出了一份修订清单。上一节六条，其中第一条是首跑自己把自己的判据证伪的产物。

它交出了一条线索。本章那条探索性读数，不能当结论，但足以决定下一笔投入的方向。

最后，它交出了一次纪律的实测。预注册的第三条防作弊规则——不以趋势代极限——在本跑中第一次真的挡住了一样东西。它挡住的不是对手，是本书自己：表征通道给了本书想要的读数，行为通道没给，而规则不允许本书把这两件事加权成一句“总体倾向于支持”。

这件事的分量，要到本书的某一条条款真的被判负、而本书照章让步的那一天，才能完全兑现。在那之前，本编只能记下它第一次生效的样子。

第八编 对手

本编去接对手的武器，因此它有一条独有的纪律，写在最前面：

不许把对手写弱。每一件武器都必须按它最强的形式复述，用它自己的术语、它自己的读数、它自己的作者所声称的范围。

这不是风度，是自利：靠打稻草人赢下来的判决，第二天就会被收回去；而本书的全部价值在于它可能判错，要让判错成为可能，对手必须被放在它能赢的位置上。

四件在役武器分属四个层面：表征收敛（表征层）、彩票假说与模式连通（解的结构层）、缩放律（判准层）、相变与涌现（动力学层）。每一章末尾都有同一个接口：这件武器若成立，本书的哪一条条款判负。

本编还有一处不对称必须先讲明：对手不需要赢，只需要不输。先在论是默认立场，举证责任在本书。

第六十七章 先在论今天有实证武器，而且很硬

一、这一编为什么必须存在

第三编用二十六章处理了哲学史上的先在论。那一编做完之后，有一种容易产生的错觉：对手已经被交代完了。

这个错觉必须打掉。哲学史上的先在论是叙事——它用论证、类比、直觉来支撑“被知道的东西先于知道它的过程而存在”。今天的先在论不是这样。它有实验、有可复现的代码、有公开的模型、有在多个架构与多个规模上重复过的读数。它在形式上与本书的判据是同一类东西：它也给出可测的量，它也做外推，它也承担被证伪的风险。

这才是本案真正的对手。任何绕开它而宣称造成论已经获胜的论证，都不值得认真对待。

二、四件在役武器

本编处理四件，它们分属四个不同的层面，因此不能互相替代，也不能一起打发。

武器一表征收敛（表征层）。主张不同架构、不同模态、不同训练数据的模型，其内部表征之间的相似度随规模与性能提升而系统性上升。若这条趋势外推到完全对齐，路径被完全消去。第六十八章处理。

武器二彩票假说与模式连通（解的结构层）。主张解在训练之前就被材料与架构确定，训练只是把它找出来；不同种子之间的差别在消去对称性之后只是标号。第七十章与第七十一章各处理一半。

武器三缩放律（判准层）。主张结果可由材料、架构与算力预测，路径不进入这个预测。第七十二章处理，并将给出一个意外的结论：这件武器其实不落在本案的现场上。

武器四相变与涌现（动力学层）。主张某些结构的出现是被规模决定的必然事件。第七十三章处理，并将发现这件武器在最近几年里长出了一个对先在论不利的分支。

第七十四章处理的不是对手的武器，而是本书这一侧的材料——但它同样属于本编，因为那批材料是被对手一侧的研究者做出来并按对手的方式解读的。

三、本编的纪律：不许把对手写弱

这条纪律单独立在这里，并适用于本编每一章：

每一件武器都必须按它最强的形式复述，用它自己的术语、它自己的读数、它自己的作者所声称的范围。

任何一处把对手的主张简化、稀释或漫画化，都算作弊。

这条纪律不是风度，是自利。理由有三条：

其一，靠打稻草人赢下来的判决，第二天就会被收回去。一个被削弱过的对手一旦被还原，整条论证链会当场崩塌，而崩塌的时候连其中真实的部分也一起丢掉。

其二，本书的全部价值在于它可能判错。一本不可能判错的书没有判决力。要让判错成为可能，对手必须被放在它能赢的位置上。

其三，也是最要紧的一条：本编是本书唯一可能输掉的地方。前七编都是本书自己建判据、自己跑实验、自己写败绩条件——那些地方本书不可能输，因为没有别人在场。真正的对抗发生在这一编。把对抗写软，等于取消了全书的对抗性。

由此还引出一条具体的禁令，写在这里：本编不得引用首跑的读数来削弱任何一件对手的武器。首跑的结论是“未能分辨”，而一次未能分辨的读数不能用来反对任何主张。首跑在本编的位置是背景，不是论据。

四、一个必须先讲明的不对称

对手与本书的处境不对称，而这个不对称对本书不利。

先在论是默认立场。“被知道的东西本来就在那里，我们只是找到了它”——这句话不需要论证就能被大多数人接受，它是日常语言里“发现”这个词的默认含义，也是科学实践的默认自我理解。造成论则必须论证。

由此得到举证责任的分配：

对手不需要赢，只需要不输。本书不能靠指出对手的证据不足来取胜；本书必须自己拿出正面的读数。

这一条在实践中意味着什么，值得说清楚。它意味着本编每一章最后那个“它赢则本书如何判负”的接口，是单向的——对手的武器成立则本书判负，而对手的武器不成立并不等于本书通过。本书的通过条件写在第六编的三条条款上，与本编无关。

本编能做的只有两件事：把对手的取胜条件写清楚，以及把本书的让步写清楚。它不能替本书赢。

这与第五十一章讲过的那件事是同一件：判一个实例不等于判全称。那里说的是范围，这里说的是责任。

五、本编不处理的两件事

为免误会，把两件看起来该在本编、其实不在的事交代掉。

其一，先在论的哲学形态的反击。“极小点集合本来就在那里”“这只是表征的形成不是知识的形成”“这是在给相对主义开门”——这三记都是针对本书主张的反击，而不是先在论自己的实证武器。它们在第九编处理，那一编里还有一记本书接不住的。本编只处理可以被实验判定的东西。

其二，本书自己的材料。欠规定性、多种子基准、次序效应这一批，通常被算作造成论这一侧的材料。它们放在第七十四章，位置在本编之内——理由是那批材料是由对手一侧的研究者做出来、并按对手的方式解读的，因此它们首先是“对手怎么看这件事”的证据，其次才是本书的材料。这个安排本身有争议，本书接受这个争议。

六、本编的证据标准

最后立一条本编专用的证据标准，它比全书其余各编更严。

本编涉及的每一件对手武器，其主张必须落到原文，不得转引二手评述。

这条标准在第三编已经立过一次——那里的对象是哲学家，要求读原文定位。本编把它延伸到实验文献，理由更实际：一件武器在二手评述里往往被讲成它的最强版本或最弱版本，而这两者都不是它自己的版本。

具体执行为三条：

其一，主张按原文的表述复述，包括原作者对自己范围的限定。

其二，原作者自己报告的负面结果与反例，必须与正面结果一并写出。本编有三处这样的材料，它们分别出现在第六十八、七十、七十一章——三处全部是对手一方自己报告的，不是本书挖出来的。

其三，凡本书未能核到原文的线索，一律不写进正文。本编在写作过程中确有一条这样的线索被查实后采用，也有若干条因核不到而弃置；弃置的不留痕迹，采用的注明出处。

这条标准会让本编读起来比其余各编慢一些、碎一些。这是值得的：本编是全书唯一可能输掉的地方，输给一个被准确复述的对手，比赢过一个被简化的对手更有价值。

七、本编的读法

八章之间有一条贯穿的线，在这里先点出来，各章只作回指：

标号差异与实质差异的界线，等于所允许的变换群。

两个结果”只是标号不同”这句话，永远是相对于某一组被认为无关紧要的变换而言的。允许的变换越多，越多的差异被划进标号；允许的变换越少，越多的差异被算作实质。而允许哪些变换，不是一个自然事实，是一个约定——它恰恰是本案在工程层面上的最终形式。

第七十一章是这条线的主场。其余各章只在与它相撞的地方引一句，不重复论证。

每章的结尾都有同一个接口：这件武器若成立，本书的哪一条条款判负，让步到什么程度。让步的内容一律以第五十八章那四条为准，本编不另立新的让步。

第六十八章 旗舰一·表征收敛与柏拉图表征假说

一、假说的主张

2024 年，Huh、Cheung、Wang 与 Isola 在一篇题为《柏拉图表征假说》的论文中提出：人工智能模型——尤其是深度网络——的表征正在趋同（ICML 2024，arXiv:2405.07987）。

他们的论证分三步。第一步是综述：在文献里，不同网络表征数据的方式随时间、跨多个领域而变得越来越一致。第二步是新的测量：随着视觉模型与语言模型变大，它们衡量数据点之间距离的方式越来越相像——这一步是跨模态的，比较的是两类完全不同的模型。第三步是命名：他们把这个趋同的去向假设为一个共享的关于实在的统计模型，并借柏拉图的理念说给它取名。

取名本身就说明作者们清楚自己站在哪一侧。这不是一个中立的技术术语，它是对本案的一次表态：模型们正在向同一个关于世界的表征收敛，就像影子在向同一个理念靠拢。

二、这件武器的分量

必须承认它的分量。

它不是修辞，是测量。它给出的是一族可复现的对齐度读数，覆盖多个模型族、多个规模、多个模态，任何人都可以用公开模型重做。

它正面击中本案的要害。本书第六编的三条条款里，条款一问的就是路径差异是否随规模衰减。表征对齐度随规模上升，在形式上就是路径差异随规模下降。这不是一件擦边的材料，它是冲着同一个量来的。

它的方向比本书所需要的更强。本书的条款一只要求处理“同语料同架构、仅路径不同”的模型之间的差异。而这件武器谈的是换了语料、换了架构、甚至换了模态的模型之间仍在趋同。若连这样的差异都会随规模消失，那么仅由路径造成的差异当然更会消失。

三、取胜条件

把它的取胜条件写成一句可判的话：

表征对齐度的极限是完全对齐，而不是某个正的不一致水平。

若这一条被稳固确立，本书第五编所定义的可达集在规模极限下收缩为一个点，路径被完全消去，先在论在经验上取胜。

这一条不是本书替对手拟的，它是从假说自身的主张直接读出来的：假说说的是模型在向同一个共享表征收敛，“同一个”这三个字要求的就是极限而非趋势。

四、这件武器的三处自我限定

这三处全部出自原文，不是本书的加工。逐条列出，并逐条说明它们不构成什么。

其一，它被作者标明为一篇立场论文。标题的前缀是“Position”。作者们在提出主张的同时，声明这是一份立场陈述而非终局的实证报告。

必须写明：这一点不构成反驳。本书不得用文体来削弱主张——立场论文可以是对的，而且这一篇的经验部分是实打实的新测量。指出它的文体，只有一个正当用途：说明它自己把自己定位在什么位置上，而这与它主张的真值无关。

其二，作者自己讨论了局限与反例。原文在结尾处讨论了这些趋势的局限，并给出了对自身分析的反例。一篇在自己的结论旁边列出反例的论文，比一篇不列的更值得认真对待，而不是更不值得。

其三，它的核心陈述是关于趋势的。原文报告的是对齐度随规模与性能提升而系统性上升，并由此假设一个收敛的去向。“上升”与“收敛到完全对齐”之间的距离，就是本书第六十九章要处理的全部内容。

第三条不是对这篇工作的批评。任何关于极限的主张，在有限的规模窗口内都只能以趋势的形式呈现——这是处境，不是缺陷。本书对它的要求，与本书对自己的要求完全一样：给出极限，而不只是方向。

五、对齐度是怎么测的，以及这件事为什么要紧

在进入本章最要紧的区分之前，先处理一个技术前提，因为它决定了这件武器量到的是什麼。

“两个模型的表征有多像”这句话，本身不是一个可直接观测的量。要把它变成数，必须先选一个东西：一个衡量相似的核。常见的做法是不直接比较表征本身，而是比较它们在一批数据点上诱导出的距离结构——甲模型认为哪两个点接近，乙模型是否也这样认为。

这个做法有一个重要的好处，也正是它被广泛采用的原因：它绕开了两个模型的内部坐标不可直接对应的问题。视觉模型与语言模型的内部维度既不同数量也不同含义，逐维比较没有意义；而“哪些点彼此接近”这种关系结构，是可以跨模型比较的。

但它同时带来一个后果，必须写明：

任何一个对齐度，都只看见那个核所能看见的差异。

两个模型若在“哪些点接近”上高度一致，而在别的方面不同——比如它们把同一批点组织成不同的层级、或者在近邻关系相同的前提下对边缘情形作出不同的处理——这些差异不会出现在对齐度里。

这不是对这件武器的指控。任何度量都只看见它能看见的，本书自己的表征距离同样如此，第七十一章会把这件事说成一条对两侧都适用的原则。这里只需要记下一个结论：

“表征在趋同”这句话，严格说应当读作“在某个特定的相似性核下，表征的某一类结构在趋同”。这个限定不削弱它的分量，但它决定了它能被外推到多远。

六、选择压力：一个值得反问的地方

原文在提出趋同之后，讨论了几种可能的选择压力——为什么模型会被推向同一个表征。本书对其中一类压力有一个反问，这个反问对本案有直接后果。

那一类压力大致是这样的：当一个模型被要求同时做好越来越多的任务时，能够同时满足所有这些要求的表征就越来越少；在任务足够多的极限下，可行的表征收缩为一个。

这条论证是有力的，而且它有一个漂亮的直觉支持：约束越多，解越少。

本书的反问是：在这条论证里，被增加的是什么？

答案是判准。任务变多，意味着 L 变大、变严。而本案的设定是固定 C 、 A 、 L ，问在固定之后路径是否仍进入结果。

于是这条选择压力所论证的，严格地说是：

当判准被加强到某个极限时，可达集收缩为一点。

这句话本书不与之争，而且认为它很可能是对的。但它与本案的争点擦肩而过——本案问的不是“判准足够严时结果是否唯一”，而是“判准给定时结果是否唯一”。

把这两件事分开，有一个可检验的后果：若趋同主要由判准的加强驱动，那么在判准固定的条件下，趋同应当显著变慢甚至停止。这是一条可以设计实验去检验的预言，而且它对两侧都有风险——若在判准严格固定的条件下趋同仍然照常，本书这一节的反问就落空了。

这一节的分寸要把握住：本书不是在说原文混淆了这两件事。原文讨论的是一个更一般的现象，不必受本案设定的约束。本书只是在指出，把那条选择压力当作本案的证据来用时，需要先过这一道。

七、一个本书必须自己讲清的区分

这一节是本章最有价值的部分，因为它决定了这件武器打到本书身上有多重。

跨模态趋同与同模态跨种子趋同，不是同一件事。

跨模态趋同说的是：一个视觉模型与一个语言模型，训练材料完全不同、架构完全不同、判准也不同，但它们衡量数据点之间距离的方式在变得相像。

同模态跨种子趋同说的是：两个模型，语料相同、架构相同、判准相同，只有随机种子不同，它们的表征在变得相像。

用本书第五编的记号：前者换的是 C 与 A ，后者换的只有 P 。

这两件事的分量为什么不同？

先在论需要的是后者。本案要判的是“固定 C 、 A 、 L 之后，结果是否仍由路径决定”；只有同模态跨种子的那一支，才落在这个问题上。

而跨模态那一支，在本书的框架里其实说的是另一件事：它说的是不同的材料与装置可以逼近同一批世界内容。这一点本书完全不争，而且本书的核心

命题与它相容——一本讲路径进入结果的书，并不需要主张不同的材料会通向不同的世界。

于是要把话说准：

跨模态趋同是一件更醒目的事实，却是一件与本案关系更远的事实。

这个判断对本书有利，因此要立刻补上它的反面，否则这一节就是一次挑选。

反面：跨模态趋同在本案中并非全无量。它给出了一个一般性的理由——若连材料与架构都换掉之后表征都在趋同，那么“仅换路径”这个更弱的扰动更不可能产生持久的分化。这是一个从更强推更弱的论证，而它是有效的。

本书能回的只有一句，而且这一句必须诚实：从更强推更弱的论证，其强度取决于那个更强的主张是否成立于极限。若跨模态对齐度收敛到一个正的不一致水平而非零，这条推论就不成立。而那又回到了第六十九章的问题。

八、与条款一的对接

它若成立——即表征对齐度的极限是完全对齐——本书条款一判负。

按第五十八章第一条让步，一字不改，此处不重述其内容。只强调一点：那一条是四条败绩条件里最重的一条，它不止要本书放弃核心命题，还要本书把输掉的后果推广出去。

这是四条败绩条件里最重的一条。本书在此重申它，不加任何限定。

它若只成立于趋势而不成立于极限，本书不因此取得任何东西。这一点由第六十七章第四节那个不对称决定：对手的武器不成立并不等于本书通过。本书的通过条件在第六编，与本章无关。

下一章处理趋势与极限的分界，它是本章与第七十二章共用的底座。

第六十九章 趋势不是极限

一、问题的形状

设有两个量，都随规模单调下降。一个的极限是零，另一个的极限是 0.3。

在任何有限的规模窗口内，它们可以长得几乎一样。两条曲线都在降，都降得越来越慢，都能被同一族函数拟合得很好，都能通过“显著递减”的检验。画在同一张图上，肉眼分不开；分别画在两张图上，更分不开。

而这两个量说的是完全相反的两件事。前者说路径差异终将消失，后者说它不会。

这就是本案在经验层面上的真实形状。它不是“证据不够多”，是“证据的形状不含区分”。第五十三章讲过案例研究缺的是极限，那是历史材料的处境；本章讲的是同一件事在实验材料上的处境。

二、区分它们需要什么

四样东西，缺一样都做不成。

其一，足够长的规模跨度。两条曲线在窗口内的重合程度，随窗口变长而下降。多长算够，没有一般答案，但有一个可操作的判据：窗口右端的量值，必须与所要区分的那个正常数处在可比的量级上。若怀疑极限是 0.3，而窗口右端的读数还在 0.4，那么窗口内的全部信息几乎都来自尚未衰减的那一部分，外推是空的。

其二，事先冻结的拟合族。幂律加常数、指数加常数、对数形式，各自给出不同的截距，有时差得很远。拟合族必须在看到读数之前定下来并公开，否则外推出来的截距只是一次挑选。

其三，截距的置信区间，而不只是截距。一个点估计的截距说明不了任何事。要判的是区间是否包含零。这要求规模点的数量明显多于拟合参数的个数。

其四，事先声明的外推范围。从若干个规模点外推到无穷，是一件本身需要辩护的事。至少要写明：外推到多大规模仍被认为有效，以及超出该范围之后结论作废。

三、这条要求对两侧同样有效

上面四条是本书对表征收敛那一线工作的要求。现在把它们反过来对准本书自己。

第七编的首跑，四个规模点，跨度约一个数量级多一点。按第一条，窗口远远不够；按第三条，四个点拟合三参数等于零自由度，区间无从估计。因此首跑没有报告不可消解度，也没有做任何外推。

更要紧的是第七编第六十三章那一列：行为通道的路径差异单调下降。这正是“看起来在收敛”的典型形状。一个立场相反的人拿着同一张表，完全可以

写成“路径差异正在随规模消失”——而他不会说谎，他只是把趋势当成了极限。

本书事先写死的判据不允许自己这样做。这条纪律在首跑里第一次真的挡住了一样东西，而它挡住的是本书自己。

把这件事写在本章，是因为它决定了本章的语气：本书对表征收敛那一线工作提出的要求，不是一个外部的苛责，而是本书自己已经付过代价的一条纪律。若本书只对对手要求极限而对自己只给趋势，这一章就没有资格存在。

四、这个领域最有名的一次外推，两年后被推翻

上面三条说的都是原则。本节给一个这个领域自己的实例，它比任何原则都更能说明外推的脆弱。

2020 年，Kaplan 等人在跨越多个数量级的模型上拟合出损失与参数量、数据量、算力之间的幂律关系，并据此给出算力分配的处方：给定预算，绝大部分投入模型规模，少部分投入数据量。这条处方被当作操作手册使用了将近两年，一批当时最大的模型是按它规划的。

2022 年，Hoffmann 等人在固定算力下重新做了一次更仔细的扫描，得到了不同的最优分配——参数量与词元数应当大致等比例增长。按新分配训练出的模型，在同等算力下胜过了按旧处方训练的更大的模型。

拟合的框架活了下来，常数是错的。

两次扫描的分歧不来自数据造假，也不来自数学错误，而来自实验设计的选择——尤其是学习率安排在扫描中是否随每一次运行的预算而调整。一个看起来属于技术细节的选择，改变了外推出来的处方。

后续还有一层：有人对第二代结果做了复现尝试，在大体确认其指数的同时，指出了原文损失拟合表中的报告错误。这说明即便是这个领域最受重视的一条拟合，其细节也仍在被核查。

这件事对本章的意义有两层。

第一层是警示：这个领域已经有过一次教训——在数个数量级的数据上拟合出来的幂律，其外推结论在更仔细的扫描下被推翻。而本书首跑所用的规模跨度，比那两次扫描都小得多。任何人拿着一个比那更短的窗口去外推，都应当先把这件事放在眼前。

第二层是对称的：这件事同样限制对手。表征对齐度的外推，与损失的外推，在方法上是同一类操作，因而承担同一类风险。一条趋势线被更仔细的扫描推翻，这在本领域不是假想的可能性，而是已经发生过的事。

五、三种不解决问题的补救

最后排除三种常见的、看起来像在加强外推、其实不解决问题的做法。

其一，加更多的规模点，但不扩大跨度。在原有窗口内加密采样，能让拟合优度变好，能让区间变窄，但它不提供关于窗口之外的任何新信息。区分零与正常数所需要的信息，全部在窗口的右端。

其二，提高显著性。“递减是显著的”这句话在两种情形下都成立，因为两条曲线在窗口内都在递减。显著性检验回答的是“有没有在降”，而本案问的是“降到哪里”。这是两个问题，前者的答案再确定也不回答后者。

其三，换一个更好看的拟合。在同一批点上换一族函数，往往能把拟合优度提高一点，同时把截距改变很多。若拟合族不是事先冻结的，这一步就是在挑选结论。第五十九章第一节把它列为冻结项第三条，正是为此。

三条之外还有一条不是补救而是诚实的做法：承认本窗口无法区分，并说明需要多长的窗口才能。这句话没有判决力，但它是可以被兑现的——它给出的是一个具体的条件，而不是一个态度。

六、一个可执行的对照设计

抽象的要求不如给出一个别人能照着做的设计。本节给出一个，它同时适用于表征收敛那一线与本书自己。

目标：把“对齐度趋于完全对齐”与“对齐度趋于某个正的不一致水平”分开。

步骤一先确定要区分的那个正常数的量级。这一步是设计的前提，却常被跳过。若不先说明“我们要把零与多大的常数分开”，就无法判断需要多长的窗口。合理的做法是取当前最大规模上的读数的某个分数作为待区分的候选值，并把这个选择写进预注册。

步骤二选规模点，使窗口右端进入该量级。由步骤一决定。若做不到，诚实的结论是“本设计无法区分”，而不是硬做一个外推。

步骤三冻结拟合族与模型选择准则。并预先声明：若两个拟合族给出的截距区间不重叠，结论作废，写“未能分辨”。

步骤四报告分母。若使用任何归一化，把分母单独报出来，并检查它是否随规模变动。这一条是首跑用代价换来的——详见第六十五章。

步骤五两侧都报。表征通道与行为通道，或任何两个读数口，必须分别报告，不得合成。理由见第五十五章第四条硬规定。

五步之中，只有第一步是新的。其余四步在第六编都已写过，本章把它们组装成一个针对对手主张的检验。

七、一个反问：本书凭什么要求极限

在开出邀请之前，先接一个针对本章的反问，因为它是对本章最有力的质疑。

反问是：极限是测不到的。任何实验都在有限的规模上做，要求对手给出极限，等于要求他做一件原则上做不到的事；而一个原则上做不到的要求，不是一条判据，是一堵墙。

这个反问必须被认真对待，因为它说对了一半：极限确实测不到。

回答是：本章要求的从来不是直接测量极限，而是拟合出渐近值并给出它的置信区间。这是一件标准的、每天都在做的事——第四节那两代缩放律做的正是它，而且第二代的参数化形式里明明白白地含有一个不可约的常数项，即损失的非零下界。一个领域能够在自己的损失曲线上拟合渐近值并讨论它是不是零，就没有理由说在另一个量上做同样的事是不可能的。

因此本章的要求可以重述为一句更谦逊的话：不要求测到极限，只要求把外推做成外推的样子——冻结拟合族、报告区间、声明有效范围。

这个重述同时把要求变得更硬了：它不再可以用“极限测不到”来推掉。

八、由此给对手开出的邀请

本章以一个邀请结束，它是本编所能提供的最实质的东西。

本书愿意接受的判负形式是：任何人在一个足以让窗口右端进入待区分量级的规模跨度上，用事先冻结的拟合族，报告出对齐度的渐近值，且其置信区间包含完全对齐。

这不是一个苛刻的要求。它要求的每一样都是标准做法，只是很少被一起做。它也不是一个本书料定对方做不到的要求——恰恰相反，本书认为它在未来几年内是可做的，而且若有人去做，它极有可能在本书之前就把条款一判掉。

本书对这个结果没有任何保留：若它发生，第五十八章第一条自动生效。

最后要说明本章为什么不单独对接某一条条款。它不是一件武器，也不是一条判据，它是一副尺子——第六十八章的表征收敛与第七十二章的缩放律，都要放到这副尺子上才知道量到了什么。下一章回到武器本身。

第七十章 旗舰二·彩票假说

一、原始主张

2019 年，Frankle 与 Carbin 提出彩票假说：一个随机初始化的稠密神经网络中，包含着稀疏的子网络；若把这个子网络单独取出来、保留它在原网络中的初始权重、再单独训练，它能在相当的步数内训练到与原网络相当的性能。

他们把这个子网络叫作“中奖彩票”。找它的办法是迭代式的量级剪枝：训练、剪掉权重最小的一部分、把剩下的权重重置回初始值、再训练，反复若干轮。

主张的落点在“重置回初始值”这一步上：彩票在训练之前就在那里，训练只是把它找出来。

二、为什么这是最纯粹的先在论表述

哲学上的先在论说“被知道的东西先于过程而存在”，这句话的麻烦在于它不指认任何对象——“存在于哪里”这个问题，先在论传统上回答不了，本书第九编第七十六章正是要向它索取一个地址。

彩票假说给出了地址。

它把“先在”落到了一个可指认、可取出、可单独训练的对象上：一组初始权重的子集。不是一个抽象的解集，不是一个“逻辑上可能的结果空间”，而是一批具体的数，存在于一台具体的机器上，在训练的第一步梯度落下之前就已经写好了。

这是先在论在工程上能够做到的最强形式。本书认为，如果先在论在这个现场要赢，最有可能是从这里赢。

三、它在规模上失效

现在写这件武器自身的历史，而这段历史是由彩票假说一方自己写下的。

原始形式在小型视觉任务上可靠地工作，在更深、更大的网络上则不然：迭代式量级剪枝在那些网络上找不到中奖彩票——把子网络重置回初始权重之后，它训练不到原有的性能；换句话说，初始权重本身是无关紧要的，随机重新初始化同一个子网络，结果没有差别。

这一点由若干独立的工作报告（Liu et al. 2018；Gale et al. 2019），也由 Frankle 与 Carbin 自己报告。为了在较深的网络上找到中奖彩票，他们不得不对每个网络的学习率安排做专门的改动——降低学习率，或加一段预热。

必须写明：这是 LTH 一方自己报告的结果，不是本书的发现。本书在这里只是复述。

四、修复方式是回绕

2019 至 2020 年，Frankle、Dziugaite、Roy 与 Carbin 给出了修复（arXiv:1903.01611，后并入 ICML 2020 的《线性模式连通与彩票假说》）。

修复的核心是一个叫作回绕的操作：不把子网络重置回初始化，而是重置回训练早期的某一点。

他们引入了一个分析工具：一个网络对随机梯度下降的噪声是否稳定——即从同一点出发、只因数据次序不同的两次训练，是否会落到同一片区域。结论是：在中奖彩票于初始化处不稳定的情形中，它们会在训练早期变得稳定，并在那之后变得可匹配。把子网络回绕到那一点，就能在大规模网络上产生可以单独训练到全精度的稀疏子网络。

按原文的表述，修复后的主张不再是“中奖彩票在初始化时就在那里”，而是“子网络在训练早期的某一点之后是稳定且可匹配的”。

这一节的复述必须是中性的。不得写成“他们不得不退让”这类带情绪的说法。回绕是一个技术上合理、经验上成功的修正，它使一个原本在规模上失效的假说重新工作起来。这是科学工作的正常样子。

五、修复所用的工具，本身量的就是次序

在进入本章的承重处之前，先看一眼回绕所依赖的那件工具，因为它的构造对本案有独立的意义。

回绕不是随便挑一个早期时点。挑哪一点，由一个叫作不稳定性分析的工具决定。它的做法是：从训练轨迹上的某一点出发，让两个副本沿着不同的数据次序各自训练到底，然后看两个终点之间是否存在损失障碍——若不存在，就说该网络在那一点对随机梯度下降的噪声是稳定的。

一个网络在初始化处往往不稳定；训练一小段之后变得稳定。回绕就回到变得稳定的那一点。

现在看这件工具量的是什么：

给定一个出发点，仅改变数据呈现的次序，两次训练会不会落到同一片区域。

这几乎就是本书第五十六章形式三——可交换性检验——的雏形。材料相同，架构相同，判准相同，只有次序不同；问的是结果是否可交换。

这件事值得单独说一句，因为它的来历很特别：这个工具不是造成论一侧为了论证路径重要而设计的，它是先在论最纯粹的那件武器为了修复自己而设计的。设计者的目的是找出“从哪一点之后次序不再要紧”，而这个目的本身预设了：在那一点之前，次序是要紧的。

本书从中取的不是一个结论，是一个方法上的承认：次序造成的分化，是一个被双方共同承认为真实、并且可测的量。争的从来不是它存不存在，而是它随规模的走向。

六、这次修复在本案里意味着什么

现在到本章的承重处。

修复后的主张有一个本书极为关心的结构：它把“先在性生效的时点”从第 0 步挪到了第 k 步。

原始主张里，那个时点是零——一切都在训练之前定好。修复后的主张里，那个时点是训练早期的某一点，而这一点被实验确定为不是零。

于是问题来了：

在第 0 步与第 k 步之间发生的事情，是什么？

它不是材料——材料在那段时间里只被用掉了一小部分。它不是架构——架构在整个过程中不变。它不是判准——判准从未改变。

它是路径。

这一段是初始权重与数据次序共同决定的一段具体的行走。而按修复后的主张，正是走完这一段之后，解才变得确定、稳定、可匹配。走完之前，它不确定。

由此得到一个此前没有被这样提出过的量：

先在性生效的时点 k 。

这个量是可测的。它由稳定性分析本身定义——从同一点出发的两次训练何时开始落到同一片区域，这正是原文所用的判据。它可以在不同规模上分别测出来，画成一条曲线。

这是本书能从这件武器里取得的最大收获：先在论最纯粹的工程表述，在它自己的修复史中交出了一个把“先在”与“路径”分开的可测边界。

七、对手的最佳回答，以及本书接不接得住

现在写对手对上一节的最佳回答。不写，本章就是一次伏击。

对手可以这样说：第 0 步到第 k 步之间那一小段，仍然是由材料、架构、判准加上一段确定性的优化动力学所决定的。给定初始化的分布与数据次序的分布，那一段的行为在统计意义上是被规定好的。因此“先在”只是从第 0 步挪到了第 k 步，本体论上什么也没有变：解仍然是由 C、A、L 所决定的东西，只不过它的确定需要先跑一小段而已。

这个回答是有力的。它与第五十二章所定义的计算性路径依赖完全一致：你还没走到——走一小段就到了。本书不能靠修辞把它挡回去。

本书唯一能做的回应是把问题量化：

k 是否随规模增大而趋于零？

若 **k** 随规模趋于零，对手赢：先在的边界在极限上回到了第 0 步，那一小段只是有限资源下的暂态，属于计算性路径依赖。

若 **k** 随规模稳定为正，或者更强地，若 **k** 随规模增大，那么情况就反过来了：“先在”的边界本身是路径的函数，而且这个函数不向零收缩。在这种情形下，“解由材料与架构决定”这句话即使在极限上也必须附带一个非零的前置行走，而那个行走不属于材料与架构。

这是一条新的、可执行的检验，它不在本书第六编的三条条款之内，也不在首跑的预注册之内。它的正确位置是下一跑的预注册候选，已列入第六十六章那份清单的增订。

必须同时写明这条检验的两个弱点。其一，**k** 的定义依赖于稳定性判据，而稳定性判据本身有阈值，阈值是自由参数——这与第五十五章第三条所说的探针配比是同一类问题。其二，本书至今没有跑过它，因此它是一张支票，不是一份读数；按第五十七章末尾那句话的标准，它必须被标明为支票。

八、这件武器为什么被拆成两章

在进入对接之前，说明一下本编的一处安排，因为它关系到读者怎么把两章接起来。

彩票假说与线性模式连通，在文献上是同一条线，甚至在同一篇论文里——上面第四节那篇修复工作的标题就把两者并列。修复所用的稳定性判据，正是用“两个终点之间有没有损失障碍”来定义的，而那就是线性模式连通。

本书把它拆成两章，理由是它们打在本案的两个不同位置上。

本章打的是时间轴：先在性在什么时候生效？原始形式说第 0 步，修复后的形式说第 **k** 步，而 **k** 不是零。

下一章打的是空间轴：两个终点之间的差别算不算实质？答案取决于允许多大的变换群。

两者共用同一批实验，却各自通向不同的条款——本章通向条款二关于解集的部分，下一章通向条款二形式一关于可归约性的部分。把它们合成一章会让两条论证互相遮蔽，因此分开。

九、与条款二的对接

它若在原始形式上成立——即中奖彩票确实在初始化时就在那里，且这一点在大规模上也站得住——本书条款二判负。

理由：彩票假说的原始形式直接给出了条款二所索要的那个地址。解集不但先定，而且可以被具体指认为初始权重的一个子集。路径的全部作用就是把它找出来，即选择器。

按第五十八章第二条，本书的让步是：把核心命题降级为“路径影响到达解集中的哪一个成员，但不影响解集本身”，并承认这个降级后的主张对本案不构成判决——它与先在论完全相容。

它若只在回绕形式上成立，则本案落到第七节那个量化问题上，而那个问题目前无人回答。本书不因此取得任何东西，也不因此判负；这正是第六十七章所说的那种单向局面。

下一章处理这件武器的另一半——不同种子之间的差别究竟是不是标号。

第七十一章 线性模式连通与置换对齐：标号与实质的边界

一、置换不变性，以及它为什么必须被消去

神经网络有一组已知的对称性。同一层内的神经元可以任意重新编号——只要下一层的连接跟着换——网络计算的仍是同一个函数。某些结构下整层可以乘一个正数再在下一层除回来。某些表示可以整体旋转。

这些都是编号，不是内容。

第五十五章第二条硬规定已经写过本书为什么必须消去它们：不消去，条款一会因为纯粹的编号差异而假通过，而那是本书最不愿意赢的赢法。这里不重复那条论证，只接着往下问一个那里没问的问题：

已知对称性的清单，是谁定的？

二、猜想与证据

2021年，Entezari、Sedghi、Saukh 与 Neyshabur 提出一个猜想

(arXiv:2110.06296, ICLR 2022)：大多数随机梯度下降找到的解，都属于这样一个集合——其中的元素可以被适当地置换，使得它们之间的线性插值路径上不存在损失的障碍。用这一线工作的术语说，它们在消去置换之后是线性模式连通的。

线性模式连通这个概念本身来自 Frankle、Dziugaite、Roy 与 Carbin 2020 年那篇工作（即上一章那篇），最初用于同一初始化出发的网络；Entezari 等人把猜想推广到不同初始化训练出的网络。

2022 至 2023 年，Ainsworth、Hayase 与 Srinivasa 给出了强有力的经验支持（《Git Re-Basin》，arXiv:2209.04836，ICLR 2023）。他们提出三种匹配算法，把一个模型的单元置换到与参考模型对齐的位置上，由此得到一组功能上等价、却落在参考模型附近一个近似凸的盆地里的权重。他们在多个架构与数据集上展示了这一现象，其中包括在独立训练的残差网络之间实现零障碍线性模式连通。

这是先在论的强读数，必须写足。

若这条线成立，结论是直接的：不同种子训练出的解，在消去置换之后属于同一个盆地；而同一个盆地的极小点集合，是由数据与架构完全决定的。于是不同种子之间的差别就只是标号差别，而标号差别按定义不是实质差别。条款二形式一判负，本书降级。

本书不质疑这批实验。它们做得扎实，可复现，而且作者们自己在进一步的工作中不断加强它。

三、三处反面材料，全部出自这条线自己的文献

其一，**Git Re-Basin** 原文自己报告了一个反例。在提出单盆地现象的同一篇论文里，作者们讨论了线性模式连通假说的不足，并给出了一个针对单盆地理论的反例。一篇在自己的主张旁边放一个反例的论文，值得被更认真地对待，而不是更少。

其二，线性模式连通并非总是成立。Juneja 等人（2022）报告，即使在微调的情形下，线性模式连通也不总是成立。这不是一个边缘结果：微调的两个模型共享了大量的训练历史，若连它们之间都可能存在障碍，那么“消去置换之后就在同一个盆地”这句话就不是一条普遍规律，而是一个在某些条件下成立的经验现象。

其三，零障碍常常需要一道额外的手续。Jordan、Sedghi、Saukh、Entezari 与 Neyshabur 提出了 REPAIR（ICLR 2023）：在对齐之后的插值过程中，中间点的激活统计会发生系统性的偏移，需要重新标定才能把损失障碍消掉。

第三条最值得细看，因为它把问题从“是不是同一个盆地”推到了另一个地方。

四、本章的承重论证

把上一节第三条的含义展开。

要把两个独立训练的解连起来，实际需要的机器是：一次置换匹配，再加一次激活重标定。前者是把编号对上，后者是把中间点的统计分布修回来。

于是要问：这两道手续，是在揭示两个解本来就在同一个盆地，还是在制造这个事实？

这个问题不是一个诡辩。它有一个精确的形式，而这个形式正是本编的那条贯穿线：

标号差异与实质差异的界线，等于所允许的变换群。

若只允许置换，某些解之间有障碍；若允许置换加激活重标定，障碍消失。允许的变换越多，越多的差异被划进“标号”；允许的变换越少，越多的差异被算作“实质”。

而允许哪些变换，不是一个自然事实。置换之所以被公认为无关紧要，是因为它严格保持函数不变——换编号之后，网络对每一个输入的输出逐位相同。这是一个硬标准。但激活重标定不满足这个标准：它改变的是插值路径上那些中间模型的行为，而那些中间模型并不是原来的两个解中的任何一个。

于是这条线在自己的技术细节里给出了本案最锋利的一处形式：

对齐所需要的机器越多，“它们只是标号不同”这句话就越弱。

这句话可以被操作化。给定一组被允许的变换，定义“标号”为该群的轨道，定义“实质差异”为轨道之间的距离。争论的实质不是两个模型像不像，而是那个群该有多大。

本书对这个问题的立场是：群的边界应当由“严格保持函数不变”来划定。置换、正交变换、各向同性缩放在合适的架构条件下满足这个标准，因此本书的读数消去了它们；而任何改变了被比较对象行为的手续，不得计入标号。

这是一个可以被反驳的立场，而不是一个定义。反驳的方式是指出：某些不严格保持函数不变的变换，其造成的行为差异在任何实际判准下都无法被察觉，因此把它们排除在标号之外是过于严苛的。这个反驳有力量，本书接受它是一个开放问题。

五、变换群的三个层级

上一节说争论的实质是“那个群该有多大”。本节把可能的答案排成三层，因为混用这三层是这类讨论里最常见的混乱来源。

第一层：严格保持函数不变。变换之后，网络对每一个输入的输出逐位相同。神经元置换在任何架构下都满足；正交变换与各向同性缩放在合适的架构条件下满足。这一层是硬的：满足它的差异，没有任何人会主张是实质差异。

第二层保持行为在任何实际判准下不可察觉。变换之后网络的输出并非逐位相同，但差别小到在任何实际使用中测不出来。这一层比第一层大得多，而且它的边界是模糊的——“任何实际判准”是一个开放的集合，今天测不出来不等于明天测不出来。

第三层保持性能相当。变换之后网络在既定基准上的分数相当。这一层最大，也最没有资格算作标号——它正是第五十五章第一条硬规定所禁止的那个等同。两个分数相同的模型可以在分布外差得很远，第七编第六十三章的分组读数就是实测。

争论全部发生在第二层。

第一层没有争议，第三层不应被采纳。而第二层里住着本章前面讲的那道额外手续：激活重标定改变的是插值路径上中间模型的行为，因此它不在第一层；它之所以被接受，理由是那种改变被认为无关紧要——这正是第二层的论证形式。

把三层排出来之后，几件事变得清楚：

其一，“消去对称性”这个说法本身是歧义的。说自己消去了对称性，必须说明消到第几层。本书消到第一层，并在第六十二章写明了所用度量的不变性。任何一份不说明层级的对齐结果，都无法与另一份比较。

其二，第二层的扩张是单向的。每当有人提出一类新的“无关紧要的变换”并被接受，界线就向“标号”一侧移动一格，而且很难移回来——因为要移回来，必须证明那类变换造成的差异在某处是要紧的，而这需要找出一个能测出它的判准。

其三，本案的最终形式因此可以写成一句话：

争的不是两个模型像不像，而是第二层该延伸到哪里。

本书的立场在上一节已经写明——界线应划在第一层，凡改变了被比较对象行为的手续不得计入标号。这个立场偏保守，它使本书的读数偏大，因此它对本书有利；正因为它对本书有利，下一节必须把它的代价写足。

六、这对本书同样不利的一面

上一节的论证有一个对称的后果，本节必须写足。

既然界线随变换群移动，那么本书自己的读数也只是某一个特定群下的读数。

第六十二章报告的表征距离，用的度量对置换、正交变换与各向同性缩放三者不变。这意味着本书消去的是这三类。若有人指出第四类——一类此前未被消去、而仍应算作标号的变换群——本书的读数会变小，可能变小很多。

这正是第五十五章第二节末尾那条额外败绩条件所承诺的东西，现在把它落到具体形式上：

若有人指出一类此前未被消去的对称性，且消去之后条款一的读数落入噪声水平，条款一判负。

这一条不在第五十八章那四条之内，它是本书为自己写下的第五条败绩条件，理由就在本章。

还要补一句更不利的：本书没有能力证明自己所用的那三类已经穷尽了标号。没有人能证明这件事，因为“标号的全体”不是一个可以从原理上界定的集合，它只能被一条一条地发现。于是本书的读数在原则上永远处在可被削减的状态。这不是本书的缺陷，是这类论证的固有处境——但它必须被写出来，而不是被读者自己发现。

七、与条款二形式一的对接

它若成立——即在条款一测出正读数的那些规模上，对齐后的连通率随规模上升并趋于——本书条款二形式一判负。

按第五十八章第二条，本书将核心命题降级为“路径影响到达解集中的哪一个成员，但不影响解集本身”，并承认判决未成。

本书对这条检验的具体要求，写在这里供人执行：报告连通率随规模的变化，而不只是在单一规模上报告若干成功案例；写明所用的对齐机器（只置换，还是置换加重标定），因为按第四节，这两者对应着不同大小的变换群，因而是两个不同的主张；若使用了重标定，同时报告未使用时的障碍高度。

三条要求都不苛刻，而第三条尤其关键——它让读者自己看见那道额外手续究竟承担了多少。

下一章处理一件被广泛当作先在论证据、而其实落在本案之外的东西。

第七十二章 缩放律：它支持哪一侧，以及它默认了什么

一、先讲明本章不做什么

本章不是对缩放律的反驳。

缩放律是成立的。它是这个领域里最可靠的经验规律之一，在多个数量级上被反复验证，被用作真实的工程规划工具。本书不挑战它的经验内容，一个字也不挑战。

本章要做的只有一件事：指出它的证据落点。一条正确的经验规律，未必对每一个问题都构成证据；它构成证据的范围，由它所测量的那个量决定。

这一区分必须在章首讲明，否则整章会被读成一次外行的质疑。

二、缩放律的两代形式

第一代：Kaplan 等人（2020）在跨越多个数量级的模型上报告，交叉熵测试损失与非嵌入参数量、数据集规模、训练算力之间存在干净的幂律关系。他们据此给出了算力分配的处方：给定算力预算，绝大部分应当投入模型规模，少部分投入数据量。

第二代：Hoffmann 等人（2022）在固定算力下重新做了一次更仔细的扫描（四百余个模型），得到不同的最优分配——模型规模与训练词元数应当大致等比例增长，经验法则是每个参数约二十个词元。按这个分配训练出的模型，在同等算力下胜过了按第一代处方训练的更大的模型。

两代之间的差别值得记一笔：第一代的常数是错的，框架活了下来。这本身是一个健康的科学过程，也提醒了一件与本案相关的事——幂律的指数不是普适常数，它依赖于训练协议、架构与数据分布。

三、它被当作先在论证据的通常读法

在公共讨论里，缩放律常被这样使用：

结果可以由材料、架构与算力预测，因此路径不进入结果。

这个读法有它的道理。缩放律确实给出了一个只以 C 、 A 与算力为自变量的函数，而且它预测得相当准。按第五十六章的说法，这看起来正是先在论所需要的那个描述 Φ ——一个不提路径、却能定出结果的描述。

若这个读法成立，条款二当场判负。

四、这个读法的隐含前提

但它有一个前提，而这个前提通常不被明说：

“结果”被等同于损失，或等同于基准分数。

缩放律预测的是交叉熵损失。第二代的参数化形式甚至明确写成“两个随规模衰减的项，加上一个不可约的常数”——那个常数是自然语言本身的熵，是损失能降到的下界。

也就是说，缩放律是一条关于判准投影的规律。它说的是：不同的模型，在损失这一个标量上的取值，可以由材料、架构与算力预测。

而第五十五章第一条硬规定写的正是：不得用任务分数作结果距离。

那一条的理由在这里原样适用：损失是判准 L 在结果上的投影，而 L 是本案里被固定住的那一项。用 L 的投影当结果，等于事先规定“凡是 L 看不出来的差别都不算差别”。而先在论要论证的恰恰是“差别只在标号上，在实质上不存在”——用判准的投影去论证它，是把结论塞进了度量。

五、为什么这个等同是争点，而不是前提

把上一节的话说得更准确些。

两个模型的损失相同，不蕴含它们是同一个模型。损失是一个标量，模型是一个函数。一个标量相同的两个函数，可以在无数个地方不同——只要那些不同发生在损失的测量分布上出现概率极低的地方。

而第七编第六十三章的分组读数，正好给出了这件事的一个实测形态：种子差异在训练分布上被压得很平，在分布外探针上大得多。分布内正是损失被测量的地方。

于是局面很清楚：

缩放律测的是那个被压平的方向。它在那个方向上的精确预测，
与另一个方向上的分化，可以同时成立。

两个损失相同而结构不同的模型，缩放律看不见。这不是缩放律的缺陷——它从来没有声称要看见这个。这是使用者的越界。

六、缩放律实际支持的是什么

本节把本书愿意承认的东西一次写足，不留余地。

本书完全承认：在判准投影上，结果具有高度的可预测性；这种可预测性由材料、架构与算力决定，与路径无关；这一点在多个数量级上被验证，且是工程实践的可靠基础。

本书不与之争的还有一件：第二代形式中那个不可约的常数，说明这个领域已经习惯于用“随规模衰减的项加上一个非零渐近值”这样的拟合族来描述自己的量，并且承认那个渐近值可以不是零。

这一点顺带回答了一种可能的质疑：本书第五十四章要求把不可消解度作为一个可能为正的渐近值拟合出来，是不是一个异想天开的要求？不是。对手在自己的损失曲线上用的正是同一个拟合族，而且承认渐近值非零。本书只是要求在另一个量上做同样的事。

本书唯一主张的是：以上全部与本案的争点不接触。争点是两个损失相同的模型是否持有结构相同的知识，而缩放律对这个问题一言未发。

七、一处比上面更要紧的事：指数依赖于协议

上面几节处理的是“缩放律测的是判准投影”。本节处理一件更靠近本案核心的事，它出自缩放律自身的历史。

第二节提到，两代缩放律的分歧不是数学错误，而是实验设计的差异——其中最关键的一项是学习率安排在扫描中如何处理。第一代在整个扫描中沿用了一套锚定在最大运行上的安排；第二代对每一次运行分别调整。换了这一项，最优分配的指数就变了。

由此得到一个不常被说出口的结论：

缩放律的指数不是普适常数。它依赖于训练协议、架构与数据分布。

这件事对第三节那个通常读法的打击，比前面几节都重。

那个读法说：结果可由材料、架构与算力预测，因此路径不进入。现在看：做出这个预测的那条规律，其参数本身依赖于协议。而协议是什么？学习率怎么降、预热多长、批量多大、数据怎么排——这些正是本书所说的路径的一部分。

于是那句话的完整形式应当写成：

给定协议，结果可由材料、架构与算力预测。

加上“给定协议”这四个字之后，这条论证对本案的效力就变了性质。它不再说“路径不进入结果”，它说的是“在路径的某些方面被固定之后，结果可由其余三项预测”。这是一个弱得多、也诚实得多的陈述，而且它与本书的核心命题并不冲突——本书从不主张固定了一切之后结果还会乱跳。

必须立刻补上对这一节的限制，否则它会被用过头。

其一，协议依赖不等于路径进入了结果的规定。对手可以完全合理地说：协议是可以被最优化掉的，存在一个“最好的协议”，而它同样由C与A决定；两代扫描的分歧正是因为第一代没有把协议调到位，第二代调到位了。这个回答有力，而且从科学史上看它似乎正在应验——后续工作确实是朝着“更仔细地调协议”的方向收敛的。

其二，随机种子不在协议里。协议是可调的，种子不是——把种子“调好”这句话没有意义。因此本节的观察不直接支持条款一，它支持的只是一件更弱的事：“只由C、A、算力决定”这句话在字面上不成立，至少要补一个自变量。

其三，本节完全建立在文献的方法学记录上，本书没有做过任何相关的测量。它是一条论证，不是一份读数。

八、用可达集的语言重述一遍

把前面几节的结论翻译成第五编的记号，会更清楚。

可达集 $\text{Reach}(C, A, L)$ 是固定材料、装置与判准时，一切路径所能到达的结果的集合。缩放律说的是什么？

它说的是：这个集合在损失这一根轴上的投影，其位置可由 C 、 A 与算力预测。更准确些，它预测的是这个投影的下端——在给定资源下能达到的最好损失。

它没有说这个集合有多大。它没有说集合里的成员在别的方向上分布得多开。它甚至没有说集合是不是一个点——一个集合在某根轴上的投影收缩成一点，完全不蕴含这个集合本身收缩成一点。

这就是本章全部论证的几何形式。一条把投影预测得很准的规律，对集合本身的形状一言未发；而本案问的恰恰是集合的形状。

由此也可以说清本章与第六十八章的关系。表征收敛那件武器是冲着集合本身来的——它主张模型的表征在趋同，那是对集合形状的主张，因此它落在本案的现场上，是真正对手。缩放律不是。两者常被一起引用来支持同一个立场，但它们的证据落点差着一层。

九、这一章对接的是什么

本章不对接三条条款中的任何一条。它对接的是第五十五章第一条硬规定：不得用任务分数作结果距离。

那一条在第六编是作为一条自我约束提出的——本书不许用分数，免得把结论塞进度量。本章是它在文献层面上的正面论证：当别人用分数做这件事时，得出的结论同样不能进入本案。

一条自我约束若只约束自己，那是洁癖；若它同时使一整类外部论证失效，那它就是一条判据。本章把第五十五章第一条从前者变成了后者。

最后留一处交接。两个损失相同的人是否持有结构不同的知识，这个问题在本编只能被提出，不能被回答。它的后果——如果答案是肯定的，教育、评估与人才选拔该怎么办——由第十编第八十三章处理。

下一章回到动力学层，处理一件近年来长出了两个相反分支的材料。

一、现象清单

有一批现象，形状相同：某个能力或某个内部结构，在训练过程中或沿着规模轴，不是逐渐出现的，而是在某一点突然完成的。

grokking (Power 等, 2022)：模型在小型算术任务上先是完全过拟合——训练集全对，验证集接近随机——然后在继续训练很久之后，验证性能突然跃升到接近完美。

机制性进展度量 (Nanda、Chan、Lieberum、Smith、Steinhardt, ICLR 2023)：对上述现象的逆向分析表明，模型在那段看似停滞的时期里，内部正在逐步形成一套可识别的周期性表示，而外在性能的跃升对应于这套机制完成并接管的时刻。

归纳回路的形成 (Olsson 等, 2022)：在语言模型的训练过程中，某类用于复制与类比的注意力结构会在某一段突然形成，并伴随着一次可观察的损失曲线偏折。

能力涌现 (Wei 等, 2022)：某些下游能力在小模型上几乎不存在，在超过某个规模之后出现。

四者的共同形状是：离散的、有时刻的、事后可识别的结构出现。

二、读法一·先在论

先在论对这批现象有一个自然的读法，而且是有力的读法：

相变是同一个必然结构被达到的时刻。那套周期性表示、那个归纳回路，是由任务结构与数据分布唯一决定的；它是这个问题的正确解法，任何足够大、训练得足够久的模型迟早都会找到它。早晚由资源决定，而“找到什么”由材料决定。

这个读法有一条很强的经验支持：同一类任务上，不同的模型往往形成看起来相同的机制。模算术任务上的周期性表示、语言模型中的归纳回路，都被在多个模型上反复识别出来。若机制是路径决定的，为什么大家找到的是同一个？

在本书第五十二章的框架里，这是一个典型的计算性路径依赖的图景：不同的路径以不同的速度到达同一个地方。

三、读法二·造成论

造成论的读法是：

相变的发生与否，以及形成哪一套机制，依赖于路径。看起来“大家都找到了同一个”，可能是因为看的粒度太粗——被识别为“同一个归纳回路”的东西，在细处可以是不同的实现；也可能是因为观察者只报告了成功的那些运行。

这两条备择解释值得各补一句，因为它们决定了读法二能不能被认真对待。

关于粒度：机制识别是在一个描述层上做的。说两个模型都形成了“用于复制的注意力结构”，是在一个相当粗的层上说的；在更细的层上——它由哪几个头承担、在第几层、与哪些通路耦合——两个模型完全可以不同。而“同一个机制”这句话的分量，取决于它是在哪一层上成立的。这与第七十一章的变换群是同一个问题的另一副面孔：粗的描述层相当于一个大的变换群，它把更多的差异划进了标号。

关于报告：机制识别的文献通常从一个已经表现出目标能力的模型出发，去找它是怎么做到的。这个工作方式极有价值，但它天然不采样失败的那些运行。于是“大家都找到了同一个”这句话，在证据上可能只覆盖了找到了的那些。

这两条都不是指控，它们是备择解释；而备择解释要变成主张，需要一个判据。

四、一个把两种读法分开的判据

判据的形状在第五十七章已经写过，这里把它与本章的现象对上。

在同语料、同规模下，某一机制在一部分种子中出现、在另一部分中始终不出现，而两者的总体性能相当。

若这件事发生，那就是条款三候选一所要的读数：同样的材料，同样的判准，得到了结构上不同的知识。

若不发生——即机制在所有种子上都出现，只是时刻不同——那么读法一成立，本书在这个候选上判负。

这个判据的好处是它不需要争论“什么算实质差异”。它只需要一个二值事实：有，还是没有。

而近年来出现的一批工作，把这个判据从纸面上推到了可触及的位置。

五、一条把判据推近的结果，与它为什么还不能直接用

Zhao、Qin、Alvarez-Melis、Kakade 与 Saphra 的《涌现能力的随机缩放》

(arXiv:2502.17356) 报告了这样一件事：某些能力在固定规模上的表现，在不同随机种子之间呈双峰分布——同一个规模上的不同模型，要么可靠地解出某个任务，要么完全失败，而不是分布在中间；成功的概率随规模上升。

他们由此提出：所谓的“突破”不是某个规模阈值被跨过，而是训练结果的概率分布在连续变化。他们的图示中，同样的数据、同样的超参数，不同的随机种子给出的缩放趋势有的是突变式的，有的是线性的。用他们的话说，在这些规模上，“涌现”是一个随机的性质。

这批结果对本案的分量很重，值得逐条说清它给了什么、又不能给什么。

它给了什么。它给出了本书第四节那个判据所要找的形状：不是连续分化，而是双峰——要么有，要么没有。一个连续分布的种子间差异，可以被读成“大家都在同一条路上，只是走得远近不同”；一个双峰分布不容易这样读。它同时坐实了一件本书需要的事实：在固定的 **C**、**A**、**L** 之下，结果的分化不是量的分化，而可能是类的分化。

它不能直接用作条款三的读数，理由有二。

其一，它测的是下游任务表现，即判准的投影。按第五十五章第一条硬规定与第七十二章的论证，落在判准投影上的读数不得充当结果距离。条款三候选一要的是“机制出现与否”，而不是“任务做得对不对”。这两者高度相关，但不是同一件事——一个模型可能形成了机制却在该任务的格式上失手，也可能靠别的途径把题做对。

其二，它的作者是把这件事当作缩放律的修正提出的，而不是当作本案的证据。他们的结论指向的是“外推下游指标时必须预测成功的概率，而不只是成功者的表现”。这是一个方法学结论，不是一个本体论结论。本书若把它直接搬来用，就是在替他们下一个他们没有下的结论。

因此本书的用法是：把它列为条款三候选一的一条强旁证，并把它作为设计正式实验的直接依据。正式实验必须把观测量从任务表现换成机制检测，其余设计——同语料、同规模、多种子、性能相当性的事先定义——照第五十七章的规格。

顺带记一笔：这批工作的作者之一，也是本书首跑所用那套多种子检查点的作者之一。同一批人既造了材料，又在材料上看出了分化的形状。这一点在第七十四章还会再出现一次。

六、度量伪影这一侧的反击

处理完上面那一条，必须立刻处理它的对头，而且这个对头对本书同样不利。

Schaeffer、Miranda 与 Koyejo (NeurIPS 2023, arXiv:2304.15004) 提出：所谓涌现能力可能是一种假象，主要由研究者选择的度量所造成——非线性或不连续的度量会把平滑变化的逐词元错误率变形为突兀的跃升；换用线性或连续的度量，同一批模型输出呈现的是平滑、连续、可预测的变化。

这一记针对的是第一节那批现象的突然性。若突然性是度量造的，那么“相变”这个说法本身就要重估。

必须写明：这一记同时削弱本书在第四节提出的判据，而不只是削弱对手。

理由是直接的。第四节的判据依赖于一个二值判断——机制“出现”还是“不出现”。而机制检测本身也要有阈值：相似度超过多少算形成，某个结构的强度超过多少算存在。阈值就是非线性。若“某些种子始终不出现”这个观察是检测阈值造成的，那么本书的判据与被它批评的那批“涌现”报告犯的是同一个错误。

本书不得只用这一记去打对手。它落在本书自己头上的那一半，必须与落在对手头上的那一半同等分量地写出——这正是第五十九章第二条防作弊纪律的要求。

本书对它的正面回应只有一条，而且是设计上的：条款三候选一的机制检测，必须报告检测量本身的分布，而不只是报告阈值判断后的有无。若双峰在连续量上就已经出现，那么阈值只是在给一个本来就分开的分布画界；若连续量是单峰的，那么“有无”就是阈值造出来的，判据作废。这一条写入第五十七章那份规格的修订。

七、本章不下结论的理由

本章没有判决，这是有意的。

两种读法目前都活着。读法一有“不同模型形成相同机制”的反复观察支持；读法二有种子间双峰分布的新结果支持；而两者共同的地基——相变的突然性是不是真的——又被度量伪影那一记动摇。

三样东西互相牵制，而把它们分开所需要的实验尚未被执行。在这种状态下写出任何一个方向的结论，都属于第六十四章所定义的那种“用倾向于代替判决”的做法。

本章能交出的只有一件：一个把两种读法分开的判据，以及它必须满足的两个条件——观测量不得落在判准投影上，检测量的分布必须与阈值判断一并报告。

这件东西的位置在条款三候选一。而条款三，按第五十七章末尾那句话，是本书开出的支票，不是本书交出的读数。

第七十四章 欠规定性与多种子基准：被当作工程缺陷的那批材料

一、欠规定性

2020 至 2022 年间，D'Amour 与一个大型合作团队发表了一篇题为《欠规定性给现代机器学习的可信度带来的挑战》的长文（arXiv:2011.03395；JMLR 2022，第 23 卷第 226 篇）。

他们的定义是精确的：一条机器学习流水线是欠规定的，如果它能返回许多在训练域上留出性能同样强、但彼此不同的预测器。

所谓流水线，指的是训练与验证的全套程序——数据、架构、初始化方案、损失函数、验证方式。欠规定性的意思是：这一整套程序没有把解定死；它定下来的只是“在留出集上表现好”这一条，而满足这一条的模型有很多个，它们之间可以差得很远。

而它们差在哪里？作者们的核心发现是：这些被按训练域表现视为等价的预测器，在部署域中的行为可能非常不同。他们在计算机视觉、医学影像、自然语言处理、基于电子健康记录的临床风险预测、医学基因组学等多个领域各给出了实例。

作者们把这件事当作可信度问题提出。结论指向的是实践：应当在流水线中显式地考虑欠规定性，在模型被批准使用之前更严格地规定需求并做压力测试。

这是一个工程视角，而且是一个负责任的工程视角。

换一个视角读，它是什么？

同一套 **C**、**A**、**L** 不唯一地决定 **R**。

这正是第五编所说的、路径不可消去的直接证据形态。而且它的形状恰好对上第五十五章第三条硬规定：差异不是不存在，它在训练分布上被压平，在分布外显形。

二、多种子基准

2021 至 2022

年，Sellam、Yadlowsky、Tenney、Wei、Saphra、D'Amour、Linzen、Basting s、Turc、Eisenstein、Das 与 Pavlick 发布了

MultiBERTs (arXiv:2106.16163, ICLR 2022)：二十五个 **BERT-Base** 检查点，超参数与原始模型相似，只在随机权重初始化与训练数据的打乱方式上不同；另附五条训练轨迹上的一百四十个中间检查点。

他们提出这套资源的理由，在摘要里写得很清楚：用单个检查点做的实验，其结论只适用于那个具体的产物，未必适用于产生它的那套程序；而已有工作表明，重跑预训练可能导致实质不同的性能。为了让研究者能对程序而不只是对产物下判断，他们同时给出了一套统计推断方法。

这同样是一个方法学视角。它要解决的问题是：“我们报告的改进，会不会只是种子运气？”

换一个视角读：它是一份关于“同一套程序的多次执行会落到多远”的系统测量。种子间的下游差异在某些任务上大到足以淹没所谓的模型改进——这句话作为方法学警告很刺耳，作为本案的读数则直截了当。

值得记一笔：这两篇工作有共同作者。欠规定性那篇的作者之一，也是 MultiBERTs 的作者之一。这不是巧合——同一批人，在同一段时间里，从两个方向测到了同一件事。

三、本书所用的那份材料

本书首跑所用的，是这条线上更晚也更完整的一份：**PolyPythias** (van der Wal、Lesci、Müller-

Eberstein、Saphra、Schoelkopf、Zuidema、Biderman, ICLR 2025, arXiv:2503.09543)。

它在既有的模型系列之上新增了四十五次预训练：五个模型规模、每个规模九个新种子，连同原有的种子共十个，产生约七千个新的检查点，全部公开。种子同时决定参数初始化与数据次序。作者们用它研究三件事：下游性能、习得的语言学表征、训练阶段的出现。

这是目前公开可得的、最适合本案的材料：同语料、同架构、同判准、多规模、多路径，且带完整的中途状态。第四编第四十四章逐条核过它满足本案所需的四条性质。

四、一件必须正面写明的事

PolyPythias 的作者自己的结论是：除若干例外之外，语言模型的训练在不同规模与不同初始条件之间大体稳定。

原文的表述是清楚的：他们的分析总体上显示出高度一致的训练动力学，跨模型规模与跨初始条件皆然；在此之上，新增的种子使他们得以识别出离群的训练轨迹并刻画其特征，并据此讨论预测训练稳定性的可能。

也就是说：

本书是在逆着原作者的结论重读他们的材料。

这件事必须写在正文最显眼处，不能藏在脚注里，也不能靠措辞含混过去。任何读到本书第七编那些读数的人，都应当同时知道：提供这批材料的人，看完同一批材料之后写下的是“大体稳定”。

五、凭什么可以这样重读

这一节必须回答上一节提出的问题，否则本书对这批材料的全部使用都站不住。

答案只有一个可辩护的形式：两方问的不是同一个问题。

原作者问的是流水线的可靠性。他们的问题形如：种子差异是否大到会影响正常使用？在这个问题下，“大体稳定”是一个精确而正确的回答——训练动力学一致，性能分布集中，离群者可识别且稀少。对一个要把这套流水线当工具用的人来说，这正是他需要知道的。

本书问的是极限行为。本书的问题形如：种子差异是否趋于零？在这个问题下，“大体稳定”不构成回答，因为一个稳定地保持在某个正水平上的量，与一个趋于零的量，都可以被称为“大体稳定”。

于是关键的一句是：

“大体稳定”与“不趋于零”可以同时为真。

这两句话不矛盾，因为它们量的是不同的东西。前者量的是分散程度相对于使用容忍度的大小，后者量的是分散程度随资源增加的走向。一个分散程度小到不影响使用、却稳定不向零收缩的量，同时满足两者。

这个辩护有一个代价，要写明。它意味着本书不能从原作者的结论中获得任何支持——本书用的是他们的数据，不是他们的判断。若有人指出“这批材料的作者并不认为它支持你的主张”，本书的回答只能是：“他们没有被问到这个问题。”这是一个诚实的回答，但它比引用一个支持性的结论要弱得多。本书接受这个弱势。

还有一条必须写死的禁令：不得把原作者的结论写成“他们没看出来”。他们看出来的和本书要看的不是同一回事，这是问题之别，不是眼力之别。事实上，本书第七编那处最要命的方法论缺陷——噪声基线跨规模不可比——正是本书自己没看出来、靠执行才暴露出来的。在这件事上本书没有任何资格居高临下。

本节就是本书欠这批作者的那个交代。

六、离群轨迹这一条只能作旁证

PolyPythias 的一项产出是识别出了离群的训练轨迹，并在较大规模上观察到某些种子的训练轨迹呈现出与其余不同的走向。

这对本案显然有吸引力：若某些种子走上了结构上不同的道路，那看起来就是条款三候选一所要的东西。

但它只能作旁证，理由与第七十三章第五节完全相同：这些刻画建立在性能与训练阶段的统计描述上，即判准投影的一侧；而条款三候选一要的是机制的有无。把离群轨迹直接当作“结构不同的知识”，是替原作者下一个他们没有下的结论，也违反第五十五章第一条硬规定。

正确的用法与第七十三章一致：它指示了一个值得去做正式实验的方向，仅此而已。

七、次序与课程效应，以及它通向哪里

这条线上还有一支，本书要用它把本编接回第六编。

数据呈现的次序、课程的安排、重复的策略对最终模型的影响，已有大量报告。工程上的处理方式是“调好它”；本书关心的是另一件事——它到底能不能被调没。

这正是条款二形式三：若路径只是选择器，那么“先学 a 再学 b”与“先学 b 再学 a”在充分训练之后应当收敛到可交换的结果，因为两次训练的材料是同一个集合。

第七编第六十六章报告过一条探索性读数：在最大规模上，只换数据次序所造成的行为差异，不小于两者都换。那条读数只有三对样本，且三组的对内共享条件不齐，因此不能当结论——它的全部作用是把这条检验从“值得一想”变成“值得一跑”。

这批材料在本章的位置由此确定：它们不是本书的读数，是本书的理由。

八、三批材料的共同结构，以及它本身是一条读数

把本章前面三批材料并排看，会发现一个重复出现的形状，而这个形状本身值得记下来。

欠规定性：作者问的是可信度——这些模型部署之后会不会出问题。多种子基准：作者问的是推断的稳健性——我们报告的改进会不会只是种子运气。多种子预训练材料：作者问的是流水线的稳定性——训练过程可不可靠。

三次都是同一个结构：造材料的人问的是“这会不会给我添麻烦”，而本书问的是“这会不会消失”。

三次也都得到了同一类回答：麻烦是真的、可测的、值得警惕的；而它是否随资源增加而消失，无人问及，因此也无人回答。

这个重复不是巧合，它有一个可以说清的来源：

一个领域的工程关切，会系统性地决定哪些问题被问。

在一个以“把东西做好用”为主要目标的领域里，种子差异是一个需要被压下去的麻烦。压下去的办法是取多个种子求平均、是做压力测试、是改进流水线。这些办法全都不要求知道差异的极限行为——它们只要求差异小到不碍事。于是“差异会不会趋于零”这个问题从来没有被提上日程，不是因为它难，而是因为没有人需要它的答案。

本书需要它的答案，因为本书问的是另一类问题。

这件事有两个后果，都要写明。

后果一，对本编的：本书能从这批材料里取得的，只有数据，不是结论。这一点第五节已经说过，这里给出它的普遍形式——凡是被当作工程缺陷提出的材料，其原作者的结论都不会站在本书这一侧，因为他们问的问题不通向那里。

后果二，对第十编的：如果本案最终倒向造成论，那么上面这个“关切决定问题”的机制本身就要被重新看待。它不再只是一个关于学术社群的社会学观察，而成为一个方法论的警告：判准的设定不仅决定了什么算好的结果，还决定了什么问题会被提出来。这条线在第十编第八十四章会被重新拾起，在那里它关系到人工智能研究自身的目标设定。

本节在此打住。它是一条观察，不是一份读数；按本书的规矩，它不进入任何判决。

九、与条款一、条款二的对接

本章处理的不是对手的武器，因此没有“它若成立则本书判负”的接口。它的对接是反向的。

与条款一：欠规定性与多种子基准提供的是“差异存在”的证据，而条款一判的是“差异是否随规模衰减”。前者不蕴含后者。这一点必须写明，否则本书会犯自己在第五十二章批评过的那个错误——把计算性路径依赖的材料当作造成论的战利品。这批材料全部是在有限规模上取得的，它们与“差异随规模消失”完全相容。

与条款二形式三：次序效应这一支直接通向可交换性检验，规格见第五十六章第五节。

与条款三候选一：离群轨迹这一支只作旁证，理由见第六节。

本编到此结束。八章处理了四件在役武器与一批被误读的材料，没有判掉任何一条条款，也没有被判掉任何一条。这个结果是预料之中的：按第六十七章第四节那个不对称，本编本来就不能替本书赢，它只能把对手放在它能赢的位置上，并写清本书在每一处输掉时要交出什么。

下一编处理最后一批东西——那些本书接得住的反击，以及那一记接不住的。

第九编 反击与边界

本编处理五记反击，并写明本书接得住哪几记、接不住哪一记。

第一记最重——极小点集合本来就在那里。它不需要任何经验读数，能毫发无伤地接受本书的全部读数，且不依赖任何具体证据。第七十五、七十六两章处理它，办法不是驳倒，是向它要一个地址，把它从形而上学请到一个能拿数据说话的位置上。

第二记攻击的不是本书的论证，是本书的现场；第四记攻击的是本书的后果；第五记是方法论上最危险的一记，而本编在那里对第七编作了一处主动下修。

第七十八章是本书唯一一章在承认自己接不住。它的写法与其余各章相反：反击——为什么接不住——做了哪些补救——补救为什么不够。

末章列本书不主张的六件事。每一条都在拒绝一个比本书实际主张更强、也更好用的版本。

一、这一记的形式

把它按最强的形式复述一遍。

训练不过是在一个由语料与架构共同确定的损失景观上做下降。那个景观——它的全部局部极小、全部鞍点、全部盆地——在第一步训练之前就已经被完全确定了。路径决定你落进哪一个坑，但坑早就在那儿挖好了。

因此，一切路径依赖都只是“选择了哪一个先在者”，而不是“造成了一个新东西”。凸优化里路径依赖为零，非凸里不为零——但目标函数在两种情况下同样先在。造成论把非凸性误当成了本体论。

（以上两段是这一记的原样复述，按第六十七章第三节那条纪律，不作简化、不作稀释。）

这是本书所知对核心命题最强的一击。

它强在三处：

其一，它不需要任何经验读数。前一编那四件武器都要靠实验，因而都可以被实验推翻。这一记不靠实验。它只需要一个数学事实，而那个事实为真——给定数据与架构，损失函数确实在训练之前就完全确定了。

其二，它可以毫发无伤地接受本书的全部读数。假设条款一通过、 κ 是一个正数，这一记照样成立：当然有一个正的常数，因为坑不止一个。第七编那些数字对它构不成任何威胁。

其三，它是先在论的最后阵地。第八编那四件武器里的任何一件被推翻，这一记都还在。它不依赖表征收敛、不依赖彩票假说、不依赖模式连通，甚至不依赖任何一篇具体的论文。

一个不靠实验、能容纳对手全部读数、且不依赖任何具体证据的论证，在辩论中是极难对付的东西。本章与下一章用两章来对付它。

二、回答的第一步：承认它为真，并指出它证明得太多

第一步不是反驳，是承认。那个数学事实为真，本书不与之争一个字。

但要接着问：这个论证的适用范围有多大？

同样的论证可以毫无阻碍地应用到任何一个物理过程上。给定初始条件与动力学，演化的全部可能轨迹”早就在那儿”。于是：

- 寒武纪之后的一切生命形态也都先在。
- 人类历史的一切走向也都先在。
- 每一部尚未被写出的小说，在它被写出之前也都先在。
- 每一件尚未被制造的器物，在它被制造之前也都先在。

这个版本的先在论把整个宇宙判成一本早已写好的书。

它可能是对的。本书不主张决定论为假，这件事本书没有立场，也不需要立场。

但它有一个代价，而这个代价足以使它退出本案：

它不再是关于知识的主张，而是关于决定论的主张。

而且它付出的代价是取消了“造成”这个概念在任何地方的适用性——包括在制造、艺术、立法、生育这些没有任何人会否认其为造成的地方。

一个使“造成”一词在宇宙中无处可指的论证，不是赢了这场争论，是解散了这场争论。

这里要补一句，因为它关系到本章的分寸：指出一个论证证明得太多，不等于证明它错了。一个证明得太多的论证仍然可能为真，只是它不再能用来区分本案的两方——而不能做区分的东西不能用来判案。这与下一章第三节将要用到的那个判据是同一条原则。

三、这一记不是新的，新的是它第一次可以被请下来

这一记在哲学上有很长的家谱，值得点一句，因为家谱决定了它为什么这么难缠。

它的一般形式是：给定初始条件与演化律，后来的一切都被确定，因此没有任何东西是真正被造成的。这个论证在近代以决定论的形式出现过，在更早以“一切可能者已在”的形式出现过。它在每一次出现时都有同一个特点——它不能被经验触及，因此既不能被经验推翻，也不能被经验支持。

正因为如此，它在两千年里一直是先在论的保险。无论经验层面发生什么，这一记都还在。

本案的新处不在于这一记变弱了，而在于它第一次有了一个可以被指认的载体。

在自然界里，“那个先定的结构在哪里”这个问题没有答案可查——没有人能把宇宙的初始条件与演化律取出来看一眼。而在大模型训练里，那个被说成

先定的东西有一个名字、有一个定义、有一段可以打印出来的代码：损失函数由数据与架构确定，而数据和架构都是人写下的、可以逐位检查的对象。

于是一个此前只能在原则上讨论的问题，变成了一个可以动手查的问题：

把那个先定的集合写出来。

这就是下一章要做的事。能做这件事，是换现场换来的。第四编论证过为什么是大模型而不是量子测量或实验演化，那里给的理由是可重跑与可缩放；这里可以补上第三个理由——在这个现场，先在论所主张的那个先在者，是一个可以被要求出示的对象。

四、这一记与计算性路径依赖是同一件事

把这一记放回第五十二章的框架，它的位置立刻清楚了。

它说的是：路径造成的结果差异，其原因在于求解过程在一个先定的景观上的有限行走。不同的路径落进不同的坑，而坑是先定的。

这正是计算性路径依赖的定义——“你还没走到”的一个变体，准确地说是“你走到了另一个已经存在的地方”。

第五十二章第二节写过一句话，现在要兑现它：迄今为止机器学习中所报告的绝大多数路径依赖，都是先在论的自家话。这一记就是那句话的哲学形态。本书从一开始就没有打算靠“路径差异存在”来赢，正是因为这一记在那里等着。

由此也可以说清本编与第六编的关系：第六编的三条条款，整个就是为对付这一记而设计的。

- 条款一问：这些坑之间的差别会不会随资源消失？
- 条款二问：这些坑能不能被一个不提路径的描述写出来？
- 条款三问：有没有哪个坑是从某条路走过去根本到不了的？

三条都是在向这一记索要它所承诺的那个“先定的集合”的具体形态。

五、这一记的可辩护形态

经过上面两步，这一记被压缩了。压缩后的形态是这样的：

结果的规定可由 **C**、**A**、**L** 写出，路径只是选择器。

这句话与它的原始形态有两处不同。

第一，它放弃了“在数学上必然为真”的地位。原始形态说的是一个数学事实——损失函数由数据与架构确定。压缩后的形态说的是一个关于描述的主

张：那个先定的集合可以被写出来。这不是一个数学事实，是一个待证的经验命题。

第二，它变成了可测的。一旦要求把集合写出来，就有了检验：写出来的描述能不能覆盖实际到达的结果。这就是条款二。

这一步转换是本书全部工作的目的。不是赢下这一击——本书赢不下它，它在自己的地盘上是安全的——而是把它逼成一个可以拿数据说话的命题。

一个只在形而上学层面成立的论证，无法被任何实验触及，因此也无法被任何实验支持。先在论若停在原始形态上，它就同时失去了被判负的可能与被判赢的可能。把它请下来，对它是公平的，对本案是必需的。

下一章做那件索要工作：向它要一个地址。

六、为什么这一记排在本编第一

最后说明本编的排序，因为排序本身是一个判断。

本编五记，按本书认为的分量从重到轻排：极小点集合先在（本章）、表征不是知识（第七十七章）、临时程序只是激活（第七十八章）、给相对主义开门（第七十九章）、度量的产物（第八十章）。

这个排序有一处可能引起异议：第七十八章那一记是本书接不住的，为什么不排第一？

理由是接不住与分量大是两件事。

第七十八章那一记接不住，但它的射程很窄——它只打到条款三的第三个候选，而本书已经把那个候选降为第三顺位并附加了一条几乎过不去的门槛。一记打在一个本书已经主动放弃的位置上，即使接不住，也不改变判决。

本章这一记射程最宽：它不需要实验、能容纳本书的全部读数、且不依赖任何具体证据。它若成立于原始形态，本书的全部工作都是在一个已经输掉的问题上做技术改进。

而第八十章那一记排在最后，理由也要说明：它是方法论上最危险的一记，但它攻击的是本书的执行而不是本书的立场；一个执行上的缺陷可以靠更好的执行修复，而修复方案本书已经写在第六十六章那份清单里。危险与致命是两回事。

排序不是评分，它只说明本书认为该把最多的篇幅花在哪里。读者若不同意这个排序，各章是独立的，可以按别的次序读。

一、问题

“极小点集合本来就在那里。”

本章只问一句：

在哪里？以什么方式？

这不是一个刁难。任何一个主张某物先在的立场，都应当能够指出那个物在何处。第七十章讲过，彩票假说之所以是先论最纯粹的工程表述，正是因为它给出了地址——一组初始权重的子集。那是一个可以被指认、取出、单独训练的对象。

而“极小点集合”这个说法给出的不是地址，是一个名字。本章逐一检查它可能的四个地址。

四个地址不是本书替对手拟的，它们是这个主张在逻辑上可能的落点：那个集合要么由材料决定，要么由目标函数决定，要么由装置决定，要么什么也不需要——因为它只是“一切可能”的一部分。

二、地址一：它在语料里

第一个回答是：那个集合由语料决定。不同的语料给出不同的损失景观，因而给出不同的极小点集合；路径在其中选一个，但选择的范围是语料划定的。

这个回答是三个里最实在的一个，因为它把先在的载体落在了一个具体的、可测量的对象上。

它的后果是可检验的。若集合由语料决定，那么不同路径所到达的结果之间的差异，应当可以由语料的量写出来—— n 元分布、主题分布、子集覆盖、某类内容在语料中的出现位置与频次。

这正是条款二形式二所测的东西：可归约份额 ρ ，即路径间结果差异中可由 C 、 A 、 L 的量预测的方差份额。

判据照抄第五十六章： ρ 显著接近 1，这个地址成立，条款二判负； $1 - \rho$ 有稳定的正剩余且不随规模上升，这个地址落空——有一部分结果的规定不是语料的函数。

要把话说公道：本书预期 ρ 的主体部分会很大。这些模型确实在学同一批世界内容，它们之间相像的地方远多于不像的地方。争的从来不是主体，是那

个剩余。第五十六章第四节已经写死了这个分寸：判决不需要 ρ 小，只需要 $1 - \rho$ 不趋于零。

这个地址的现状：条款二未跑，因此本书对它没有任何读数。这是一张支票。

三、地址二：它在损失景观里

第二个回答是：那个集合由损失函数本身决定——“景观”这个对象是先有的，与谁来走它无关。

这是最常被默认的一个回答，也是最少被检查的一个。本节要指出一个被普遍忽略的事实。

在实际的训练系统中，损失景观不是一个独立于路径的对象。

分两层说。

第一层，较弱但已足够：在有限的训练中，被实际触及的只是景观中一条测度为零的带。说“全部极小点都先在”，与说“训练走过的那一小段区域先在”，在数学上都为真，但在经验上说的是两件事。前者关于一个从未被访问、也不可能被访问的集合；后者关于一段被实际走过的路。一个从未被任何路径访问的极小点，与它不存在，在本案中无法区分。

第二层，更硬：现代训练里被下降的那个函数，在训练过程中本身就在变。

数据次序改变每一步梯度所对应的那个批损失；批次构成改变它；学习率调度假改变有效的下降动力学；而在多数实际流水线中被使用的数据重复策略、筛选策略、课程安排，直接改变了在不同阶段被优化的那个目标。

严格地说，被下降的不是一个函数，而是一族随路径变化的函数。

若如此，“景观先在”这句话就不再是一个数学事实，而是一个理想化假设——而且是一个在实际系统中已知为假的假设。

这一节必须补上它的限制，否则它会被用过头：

限制一：可以把上面那一族函数看作某个更大的、固定的函数在不同参数下的切片，从而把先在性恢复到那个更大的对象上。这个回退是合法的，但它把问题推到了地址三——那个更大的对象越来越像“一切可能”。

限制二：本书没有测量过这一族函数的变动幅度。第二层论证是从训练流程的构造得出的，不是从读数得出的。按本书的规矩，它是一条论证，不是一份证据。

限制三：这一层与第七十二章第七节那个观察是同一件事的两副面孔——那里说的是缩放律的指数依赖于协议，这里说的是被下降的函数依赖于协议。同一处事实，两处使用，不得计作两条独立证据。

四、地址三：它在“可能性空间”里

第三个回答是常被用作最后退守的一个：那个集合存在于所有可能权重配置的集合之中。

所有可能的权重配置当然“存在”，正如所有可能的小说都存在于所有字符串的集合中。

这个回答不能被驳倒，因为它什么也没说。

拿这一种“在”去撑“知识是被发现的”，会得到一个谁也不愿意要的推论：托尔斯泰发现了《战争与和平》——理由是那部书一直躺在所有可能的字符串里面。

要把这个判断说得精确，需要一条一般原则，它在第七十五章第二节已经用过一次，这里正式立出来：

一个概念若对一切事物同样适用，它就不能用来区分任何两件事；而不能做区分的概念不能用来判案。

这个意义上的先在是免费的——不需要任何条件就能获得，也因此是无内容的——它不把任何一件事与任何另一件事区分开。在这个意义上，被造成的东西和被发现的東西同样先在，于是两千年的争论在这个地址上自动消失。

有人可能会说，这不正说明争论本身是虚假的吗？不。它说明的是：这个地址无法承载争论，而不是争论无法成立。前两个地址是能承载的——它们给出了可区分的后果。一个立场若只能退到第三个地址上才安全，它的安全是以放弃全部内容为代价买来的。

五、地址四：它在架构里

上面三个是这个主张最常被给出的地址。还有第四个，它比地址二更硬，也比地址三有内容得多，却更少被明说，因此放在最后单独处理。

第四个回答是：那个集合由架构决定。一个网络结构划定了它能表示的函数族；再加上优化算法的归纳偏置，可达的解就被限制在一个由结构决定的范围内。语料决定这个范围里哪一块被偏好，而范围本身是架构给的。

这个回答比前三个都强，理由有二。

其一，它落在一个完全可指认的对象上——架构是一份可以逐行读的代码，比“景观”具体得多，也比“可能性空间”窄得多。

其二，它与大量经验相符：不同架构确实有不同的能力边界，这在文献里是常识，也是架构研究本身的前提。

它的后果同样是可检验的，而且检验的设计并不复杂：若先在性落在架构上，那么固定架构、只换路径所造成的结果差异，应当可由架构本身所划定的那个范围来解释——具体地说，不同路径所到达的结果应当落在同一个由架构决定的子空间里，而它们之间的差异应当随着这个子空间被填满而减小。

在本书的记号里，这意味着可达集 $Reach(C,A,L)$ 的形状主要由 A 决定，而路径只在其内部移动。条款一与条款二都能测到这件事的后果：若差异随规模衰减，说明子空间被填满；若可归约份额接近 1，说明差异可由 C 与 A 的量写出。

因此这个地址不需要新的条款，它落在已有的两条上。这一点值得写明——一个更强的对手形态没有要求本书新增判据，说明第六编那三条条款的覆盖面比它看起来更宽。

但这个地址有一个它自己必须面对的问题，而且这个问题正是第七十章那一整章：若先在性落在架构上，那么彩票假说的原始形式就应当成立——中奖彩票由架构与初始化给定，在训练之前就在那里。而那一形式在规模上失效，修复的办法是把时点挪到训练开始之后。

于是这个地址被迫接受一个限定：架构划定范围，但范围内哪一块变得可达，取决于一小段路径。而“一小段”有多长、它是否随规模趋于零，正是第七十章第七节那个尚无人回答的量化问题。

六、四个地址查完之后

把四次检查并排：

地址	性质	本案中的处理
在语料里	可检验	条款二形式二，未跑
在损失景观里	在实际系统中是理想化假设	本章第三节，论证而非
在架构里	可检验，且最强	条款一与条款二，未跑 见第七十章
在可能性空间里	免费，因而无内容	不能判案，退出

结论不是“先在论被驳倒了”。结论是：

先在论的可辩护形态，只剩下第一个与第四个地址；而这两个都是可测的。

这正是第七十五章第四节所说的那次压缩的完成。第二个地址若被坚持，它需要先回答“被下降的到底是不是一个固定的函数”，而那个问题本身是经验的；第三个地址被自己的空洞挡在门外；第四个地址站得住，但它必须接受第七十章那个尚未回答的时点问题。

由此得到本书对这一记的最终态度：本书没有赢下它，也不声称赢下它。本书做的是把它请到一个能拿数据说话的位置上。它在那个位置上完全可能赢——条款二判负，本书按第五十八章第二条让步，把核心命题降级，并承认判决未成。

一个能赢的对手，才值得被这样对待。下一章处理另一记，那一记攻击的不是本书的论证，是本书的现场。

第七十七章 第二记·这只是表征的形成，不是知识的形成

一、这一记的形式

就算全部三条条款都通过，被判的也只是模型内部表征的形成，而不是知识的形成。表征是一种工程对象；知识要求真、要求辩护、要求与世界的接触。把前者的路径依赖推广到后者，是范畴混淆。

这一记不攻击本书的判据，它攻击本书的现场。它说：你那套实验做得再干净，做的也是别的题。

这一击的力量必须被承认到底。

本书不主张模型拥有知识。本书不主张模型是认识主体。本书不主张模型理解它所处理的任何东西。第四编第四十五章已经写明，本书不使用“理解”“意识”“智能”这三个词，并说明了为什么不使用它们论证反而更强。

若本书的核心命题被读成“因为模型的表征是被造成的，所以人类知识是被造成的”，那它就是一个糟糕的类比论证，本书与之划清界限，而且划得很清楚。

二、本书的论证结构不是类比

回答从一个结构上的区分开始，这个区分是本章全部内容的支点。

类比论证的形状是：A 有性质 P，B 与 A 相似，所以 B 大概也有 P。这种论证的强度取决于相似性，而模型与人在相似性上的争论可以无限进行下去，永远得不出结论。

反例结构的形状完全不同。

先在论在其最一般的形态上主张的是：

任何以材料为输入、以判准为约束的知识形成过程，其结果由材料与判准唯一决定，路径不进入规定。

这是一个全称命题。

要削弱一个全称命题，不需要类比，只需要一个实例——一个材料固定、判准固定、只有路径不同而结果的规定不同的过程。

大模型训练若给出这样的实例，被否证的不是“人类知识也这样”，而是先在论所依赖的那条一般原则的普遍性。

这个区别在效果上有多大，值得说清楚：

普遍性一旦破了，先在论就必须为它想主张的每一个领域单独举证——而这正是它两千年来从未做过的事。

两千年来，先在论从不需要为“数学知识”和“化学知识”分别举证，因为它主张的是一条关于知识形成的一般原则。一条一般原则被一个实例破掉之后，它的每一次应用都变成一次需要独立辩护的主张。这是一个巨大的地位变化，而它不要求模型与人相似。

三、这个回答的边界，逐条画出

上一节的论证有力，正因为有力，它的边界必须画得比它本身更清楚。三条，一条也不含糊。

其一，它不证明人类知识是被造成的。一个实例破掉一条全称命题，不等于给出了另一条全称命题。本书从未主张、也不会主张“人类知识也是这样形成的”。任何把本书读成这个主张的人，读的是另一本书。

其二，它确实取消了那条原则的先天地地位。“知识必然由材料唯一决定”这句话，此前是作为一条不需要论证的前提在使用的——它是“发现”这个词的默认含义的一部分。一个反例把它从公理降为待证的经验假设。这个降级是真实的，而且是本书所能取得的最大的东西。

其三，它确实为造成论提供了此前从未有过的一样东西：一个可重跑的实例。第五十三章讲过案例的天花板——历史案例无法排除“换条路也会走到那里”。一个可重跑、可缩放的实例没有这个缺陷。这是本书换现场的全部理由，也是换现场唯一的收获。

三条之外还有一条要补，因为它对本书不利：这三条全部以三条条款通过为前提。条款一在首跑中未能分辨，条款二三未跑。因此本章的全部内容目前是一个条件句的后件，而前件尚未成立。

四、“知识需要与世界接触”这一条

这一记里还有一个分支，它值得单独处理，因为它看起来对本书不利，细看之下方向是反的。

反方说：知识与表征不同，知识要求与世界的接触——要求那个表征是关于某物的，并且在某种意义上对得上。

本书同意这一条。而且本书认为它是这一记里最有内容的部分。

但要接着问：接触是怎么发生的？

接触是通过路径发生的。

一个认识者与世界的接触，不是一次无形式的对接。它有具体的形式：在什么条件下接触、按什么次序接触、用什么工具接触、先遇到哪一类情形后遇到哪一类。这些正是路径。

于是：

一个把接触算进知识条件的立场，很难同时主张接触的具体方式不进入结果的规定。

把接触写进知识的定义，等于把一段具体的历程写进知识的定义；而那段历程的形式，恰恰是本案所争的东西。

这一步推论要小心，它有一个明显的反驳，必须写出来：接触的方式可以影响你得到什么，而不影响那个东西本身是什么。两个人从不同角度看同一座山，得到的图像不同，山是同一座。反方可以说，知识是关于山的，不是关于图像的。

本书对这个反驳的回应只有半句：那要看“知识”指的是山还是图像。若指山，则知识不在认识者这一边，本案讨论的东西就不叫知识；若指图像，则路径已经进入了。这个二分本身是本案在认识论层面的形式，而本书没有能力在这里判它——这需要一篇专门的文章，本编只作标记。

五、这一记的一个更强版本：那里的判准不会变

上面处理的是这一记的标准形式。它还有一个更强的版本，而这个版本比标准形式难对付得多，本书必须正面写。

更强的版本是这样的：你的现场与知识形成的差别，不在于模型懂不懂，而在于那里的判准不会变。

在本书的实验里， L 是被固定住的——损失函数写好了就不再多动，评测方式定好了就不再改。而在真实的知识形成中，判准本身在变：什么算一个好的解释、什么算充分的证据、什么算一个问题被解决了，这些在科学史上一直在改。库恩那一批工作最扎实的部分恰恰是这个。

于是反方说：你判的是“判准固定时路径是否进入结果”，而真实的知识形成里判准从不固定。你的实例因此不是那条全称命题的反例——它是那条命题在一个特殊条件下的实例，而那个条件恰好是真实情形中不成立的。

这一击有力量，而且它的力量正好落在本书最得意的地方：本章第二节那个反例结构，其全部效力来自“材料固定、判准固定、只有路径不同”。若这三个固定中有一个在真实情形中不成立，反例的身份就被质疑了。

本书的回答分三步，三步都不完整。

第一步：反例的身份不取决于条件是否常见。一条全称命题说的是“任何以材料为输入、以判准为约束的过程”。这句话里没有“判准会变”这个条件。一个判准固定的过程，仍然是那句话所覆盖的一个过程。若它构成反例，那条全称命题就破了——即使判准固定的情形在现实中罕见。

第二步：判准可变只会使情况更不利于先在论，不会更有利。若在判准固定时路径都已经进入规定，那么在判准本身也随路径变化时，结果对路径的依赖只会更强，不会更弱。反方若要用“真实情形里判准会变”来救先在论，他需要论证的是一件很奇怪的事：判准的流动性恰好抵消了路径的效应。这个论证本书没有见过，而且不容易想象它怎么做。

第三步，也是不完整的那一步：上面两步都没有回答一个更深的可能——判准可变的过程，也许根本不是同一类过程。若 L 会变，那么“固定 C 、 A 、 L 之后结果是否唯一”这个问句在那里就无从提起，本书的整套翻译（第五编）也就无从应用。这不是说先在论赢了，而是说本案在那里需要另一套判据。

本书不能排除这个可能。它与第七十八章那一记不同——那一记本书接不住是因为缺一条界线；这一记本书接得住一半，而另一半需要的是一套本书没有的判据。

因此本章把它标记为：一个部分有效的限制。它不推翻反例结构，但它把反例结构的适用范围限制在“判准固定”这一类过程上。而这个限制是真实的，应当写进第八十一章第二条的边界里。

六、这一记在本书里的位置

最后说清这一记的位置，因为它与下一章那一记的位置不同。

这一记是有效的，但它不改变判决。它正确地指出本书的现场是模型而不是人；本书接受这个指认，并且从一开始就把论证结构建成反例式而不是类比式，正是为了在接受它之后仍然站得住。

它改变的是本书结论的表述范围。若三条条款通过，本书能说的是：在这一现场，那条一般原则不成立。本书不能说：人类知识是被造成的。这两句话之间的距离，本书不打算用任何方式缩短。

下一章那一记不同。那一记本书接不住。

第七十八章 第三记·语境内的临时程序只是激活——本书接不住的那一记

一、先说明这一章为什么单独存在

本书在这一章里没有赢，也不打算装作赢了。

一本论辩的书通常这样处理接不住的反击：略过、降格为脚注、或者用一句“这超出了本书的范围”打发掉。本书不这样做，理由与第五十八章那四条败绩条件是同一个——一本不承认自己哪里薄的书，它说自己哪里厚也不可信。

因此本章的写法与本编其余各章相反。其余各章的结构是“反击—回答”；本章的结构是“反击—为什么接不住—本书做了什么补救—补救为什么不够”。

二、这一记的形式

先回到它攻击的对象。

第五十七章的条款三列了三类性质候选，其中候选三是：语境内临时形成的程序。模型在推理时可以在语境中形成一个训练时并不存在的、针对当前任务的临时程序。

这是最诱人的猎场，理由显而易见：那个程序不在语料里——语料里没有这道题；也不在权重的任何固定位置上——权重在推理时没有改变。它看起来是一个在推理那一刻被造出来的东西。

反击是这样的：

所谓“形成”，只是把权重里已有的能力按语境组合起来激活了一次。组合的规则本身是训练出来的；能力本身是训练出来的；语境只是触发器。因此那个临时程序仍然先在——它先在于权重之中，只是以一种被压缩的、待触发的形态。

三、为什么本书接不住

本书接不住这一记，原因不是修辞上的，是结构上的。要把它说准。

问题在于“组合”与“形成”之间没有一条本书能画出来的界线。

设有一个模型，它在权重里有能力 a、能力 b，而在某个语境中表现出了能力 c，且 c 在训练中从未被单独要求过。反方说：c 是 a 与 b 的组合，组合规则也在权重里。

本书要反驳这句话，必须能说明：c 不只是 a 与 b 的组合。而这需要回答“什么叫只是组合”。

试几种回答，逐一看它们为什么不成立。

回答一：若 c 在权重中没有对应的固定结构，则 c 不是先在的。这个回答看起来最有力，但它把举证责任放到了一个极难完成的位置上——要证明一个结构不存在于权重中。第五十七章第二节讲过绝对不可达不可证，这里是同一个困难的另一个实例：“权重里没有 c”这句话，与“我们还没找到 c 在哪里”无法区分。

回答二：若 c 的出现依赖于语境，则 c 是被语境造成的。这个回答失败得更快。依赖于触发条件的东西，不因此就不是先在的——钥匙依赖于锁孔才起作用，钥匙仍然是先做好的。

回答三：组合的数量是组合爆炸的，因此不能说每一个组合都先在。这个回答有直觉上的吸引力，但它恰好落进第七十六章第四节那个地址三里：说“所有组合都先在”，与说“所有小说都在字符串集合里”，是同一句话。而本书已经论证过那个地址是无内容的——问题在于这一次，无内容的是本书自己需要的那一侧。若“组合的先在是免费的因而无内容”，那么反方的“c 是组合”这句话也无内容；可无内容不等于假，它只是不能判案。于是这一记打成了平手，而平手在本案里等于本书拿不到读数。

三条都不成立。本书没有第四条。

四、这一记有它自己的代价，但代价不构成回答

要把话说完整：这一记不是没有代价。

若“组合的激活”可以算作先在，那么任何造成都可以被同样地重述为“某个更大空间里已有元素的组合被激活了一次”。作曲是音符组合的激活，写作是词语组合的激活，发明是零件组合的激活。第七十五章第二节那个“证明得太多”的诊断，在这里同样适用。

因此，要让这一记站得住，反方必须给出一个非平凡的界限：

哪些组合算激活，哪些组合算形成？

给不出这个界限，这一记就与“所有小说都在字符串集合里”是同一句话。

但这不是一个回答，只是一次对等的索取。

本书向反方要一个界限，反方同样可以向本书要一个界限——而本书上一节已经承认，本书给不出。双方都欠着同一笔账。在一个双方都欠账的位置上，谁也拿不到判决。

这就是为什么本书把这一处标记为尚未解决的争点，而不是标记为“本书的回答有待展开”。两者的差别不是措辞：前者承认没有回答，后者暗示回答存在只是没写。

五、本书实际做了什么补救

承认接不住之后，本书在工序上做了三件事。三件都是减法，没有一件解决了问题。

其一，把候选三降为第三顺位。条款三三类性质候选中，候选一（算法性内部结构的出现）排第一，候选二（次序造成的不可达）排第二，候选三排最后。排序的依据在第五十七章写着是可跑性，而这里要补一个更实在的依据：候选三是唯一一个本书在哲学上守不住的。

其二，给它附加了一条额外的证据要求。候选三必须配上“该组合在权重中不存在对应结构”的证据，才被计入条款三。

这条要求是本书为自己设的障碍，而且是一道几乎过不去的障碍——上一节回答一已经说明，证明一个结构不存在极其困难。本书明知如此仍然设它，理由是：一个守不住的候选，若不设一道几乎过不去的门槛，就会变成本书的软肋。

其三，在条款三未跑之前，候选三在本书中只有启发意义，没有判决意义。这一条写在第五十七章第四节，本章重申。

六、补救为什么不够

三件补救加起来，做到的只有一件事：它们使本书不会因为这一记而输掉。

它们没有做到的是：使本书能够在这个方向上赢。

这个区别要说清楚。把候选三降级、加门槛、限制其判决意义，等于本书主动把这条路封了。封路之后，反方那一记打在空处——它攻击的是一个本书已经不再倚重的候选。从防守上说，这是有效的。

但条款三本来就是本书三条条款里最强的一条，而候选三本来是它最诱人的一个实例。封掉它之后，条款三只剩候选一与候选二，而这两条都需要新的实验，其中候选二还需要大规模新训练。

所以补救的实质是：本书用放弃一条进攻路线的代价，换来了不在这条路线上被反击。这是一笔亏本的交易，本书接受它，因为没有更好的选择。

七、这个争点不是模型特有的

在写“怎样才算解决”之前，先指出一件对本章的处境有帮助、但对本书的论证没有帮助的事。

同一个争点在人身上有一个同构的版本。

一个人解决了一个他此前从未遇到过的问题。问：他是形成了一套新的做法，还是组合了他已有的若干种做法？

这个问题在关于创造的讨论里已经存在了很久，而且从来没有被判掉。一方说：所谓创造，无非是已有元素的新组合；元素是学来的，组合的能力也是学来的。另一方说：若一切都是组合，那么“新”这个词就没有指称了，而我们明明能区分一次真正的突破与一次熟练的拼装。

两方所用的论证，与本章第三节、第四节所写的两方论证，形状完全相同。

这件事有两个作用，一个对本书有利，一个对本书不利，两个都要写。

对本书有利的那个：它说明本书接不住这一记，不是因为本书的现场特别弱，也不是因为本书的判据不够好。这是一个更一般的困难，它在任何一个讨论“新东西如何出现”的地方都会出现。一本在这里承认接不住的书，与一个在这里含混过去的传统，前者更诚实。

对本书不利的那个，而且更重：既然这个争点在人身上也没有被判掉，那么本书原本指望从这个方向上取得的东西——一个可重跑、可缩放的现场所带来的判别力——在这里失效了。换现场没有帮到本书。

第五十三章论证过换现场的理由是可重跑与可缩放；第七十五章又补了三个理由——在这个现场，先在者是可以被要求出示的对象。而这一记正好绕开了三个理由中的每一个：它不需要重跑（组合与形成的区别不随重跑次数改变），不需要缩放（它在任何规模上都同样成立），也不需要出示地址（权重就在那里，只是不知道该往里面找什么）。

一记同时绕开本书换现场的全部三个理由——这是本章那句“接不住”的完整分量。

八、这一处需要什么才能被解决

最后写清这一处将来可能怎么被解决，因为一个只说“接不住”而不说“怎样才算解决”的承认，是廉价的。

要让这一记被判掉，需要的是一个非平凡的、可操作的激活与形成的界限。它至少要满足三条：

其一，它不能以“在不在权重里”为唯一判据。因为那个判据落在一个不可证的否定命题上。

其二，它必须对两侧同样适用。一个只判得出“这是激活”而判不出“这是形成”的界限，不是界限，是一个立场的重述。

其三，它必须给出一个可测的量。按本书全书的标准，一个不带量与判负条件的界限，不能进入判决。

本书没有这样的界限，也不知道它长什么样。这是本书留给后来者的一个具体的问题，而不是一句谦辞。

有一点可以说：这个问题的形式与第七十一章第五节那个“变换群的三个层级”高度相似——那里问的是哪些变换算标号，这里问的是哪些组合算激活。两者都是在问一条约定的边界该划在哪里。若那一处的框架能被推广到这一处，也许是一条路。本书只能提示到这里，提示不是解决。

第七十九章 第四记·这是在给相对主义开门

一、这一记的形式

若知识的规定依赖于路径，那么不同路径得到的不同知识之间就无从比较优劣。科学的客观性瓦解，真理成了社会协商的结果。

这一记与前三记的性质不同。前三记攻击的是本书的论证或现场，这一记攻击的是本书的后果——它不说本书错了，它说本书若对了会很糟。

因此它很容易被当作不值一驳的东西打发掉：一个主张的后果不受欢迎，不是它为假的理由。这个回答在形式逻辑上无懈可击，但用它来打发这一记是不够的，理由有二。

其一，这一记通常不是作为逻辑论证提出的，而是作为一个担忧。担忧提得有没有道理，与它是不是有效推论，是两件事。

其二，更要紧的是：这一记里确实含有一个有效的部分，只是它被混在无效的部分里。拆开它，是本章的主要工作。

二、拆开：两个命题被合并了

这一记把两句话合并成了一句：

命题甲：路径进入结果的规定。命题乙：任何结果都同样好，或者无法比较优劣。

由甲推乙，需要一个隐含的中间步骤：唯一性是可比较性的前提。只有当存在唯一正确的终点时，不同的结果才能按“离终点多远”来排序；没有唯一终点，就没有排序。

本章的全部内容就是拆掉这个中间步骤，再加上一句反过来的记账。

三、路径进入规定，不蕴含任意性

第一步要说明的是：造成论从未主张任何路径都能造出任何结果。

这一点在本书里不是一句表态，它是结构性的。

第六编三条条款的全部设计，都建立在“约束极强”这个前提下：同样的语料、同样的架构、同样的判准，路径能造成的差异是有限的、可测的、多数可归约的。争的只是那个不可归约的剩余是否为正。

把它写成一个量上的对照，最清楚不过：

	相对主义的世界	本书所争的世界
可达集	几乎不受约束	极窄
可归约份额 ρ	接近 0	预期接近 1
所争的对象	全部	那个剩余

第五十六章第四节写过一句话，现在它有了新的用处：判决不需要 ρ 小，只需要 $1 - \rho$ 不趋于零。这句话本来是为了防止事后把小剩余说成胜利；反过来看，它也说明本书所主张的世界与“怎么说都行”的世界相距极远——本书连 ρ 很大都愿意事先承认。

一个剩余为正的世界，不是一个任意的世界。它是一个绝大部分被决定、而有一小部分由走法决定的世界。这两者之间的差别，不是程度的差别，是种类的差别。

四、可比较性不需要唯一性

第二步拆掉那个中间步骤本身。

两条路径得到的两个结果之间，可以有严格的比较标准：

- 预测力：哪一个在更多情形下给出正确的预期。
- 可干预性：哪一个支持更多有效的干预。
- 可承受的反例范围：哪一个在遇到反例时需要修改得更少。

这些标准的存在，不要求二者最终收敛为同一个东西。

一个现成的例子来自演化。两个不同谱系各自演化出的飞行方案——不同的骨骼结构、不同的翼面、不同的代谢支持——可以在具体的环境下被严格比较优劣：哪一个更省能量、哪一个在哪一种气流下更稳、哪一个受伤后恢复得更快。这些比较是实打实的，可以量化，可以判出高下。而它们并不是同一个解，也不在收敛到同一个解。

把“没有唯一终点”读成“没有高下”，是把本体论主张与评价主张混为一谈。

这两类主张的自变量不同：本体论主张问的是“有几个”，评价主张问的是“在某个标准下哪个好”。后者不需要前者回答“只有一个”才能运作。

这里要防住一个过度的推论，否则本节会被用得太满。可比较不等于全序可比——两个结果可以在某些标准上各有胜负，而没有一个总分能把它们排成一列。这是真的，而且在实践中常见。但它同样不支持相对主义：局部可比也是可比，而相对主义主张的是不可比。

五、反过来记一笔账

前两节是防守。本节是本章唯一的一次进攻，而且是一笔从未被记过的账。

先在论也有它的代价，只是从不被要求举证。

若结果由材料唯一决定，那么推论是：一切路径上的努力，在原则上都是有可无的。

- 教学次序的精心安排，只影响学得快慢。
- 科研训练中先做什么后做什么，只影响成熟早晚。
- 技艺传承里师傅让徒弟先练哪一样，只影响出师迟早。
- 一门学科的入门书该从哪里讲起，原则上无关紧要。

这个推论与我们在教育、科研训练、技艺传承中所观察到的一切经验都不符合。几乎没有一个真正教过东西的人会同意“次序只影响快慢”。

但因为它是先在论的推论而不是造成论的推论，从来没有人要求它举证。

这是一种不对称的记账：造成论的每一个奇怪后果都被拿出来质问，先在论的奇怪后果被当作背景噪声。第六十七章第四节讲过举证责任的不对称，那里说的是证据，这里说的是后果——两处不对称的方向是一致的，因为它们出自同一件事：先在论是默认立场。

本书的条款二形式三——次序可交换性——正是把这笔账第一次摆上台面。它问的就是那句从未被举证过的话：同一堆材料，换个顺序，最后真的一样吗？

要写明的是：这一节不构成对先在论的反驳。一个立场的推论与日常经验不符，可能说明立场错了，也可能说明日常经验里混入了别的因素——教学次序影响的可能确实只是效率，而效率在实践中重要得足以让人误以为它改变了结果。本节主张的只有一件事：这笔账应该被记，而且应该由声称“次序不要紧”的那一方来结。

六、“科学的客观性瓦解”这半句

这一记的后半句单独值得一答，因为它比前半句更常被说出口。

客观性在实践中意味着什么？它意味着一个主张能不能被别人独立地检验、能不能在不同的人手里给出一致的结果、能不能在遇到不利证据时被修改。

这三样，没有一样要求“结果唯一”。

可检验要求的是主张有确定的后果；一致性要求的是检验程序可被复现；可修改要求的是存在能推翻它的事实。一个由不止一条路径形成、彼此结构不同的知识体系，仍然可以对每一条都提出这三项要求，而且要求得同样严。

本书自己就是一个例子——第五十九章那套预注册方法学，全部是为客观性服务的：冻结判据、公开哈希、报告不利读数、不以趋势代极限。一本主张路径进入结果的书，在方法上比多数不这样主张的工作更严，这件事本身说明两者不是一回事。

要补的限制是：本节说的是客观性的操作含义。若有人把客观性定义为“独立于一切认识过程的唯一真相”，那么本书确实与那个定义冲突。但那个定义本身就是待判的那一条，用它来反驳本书是循环的。

七、“相对主义”这个词要先拆开

在给这一记定位之前，先拆一下这个词本身，因为它在讨论中承担了至少三个不同的意思，而本书只与其中一个有关。

含义一判断相对主义：同一个主张在不同的人那里可以同时为真和为假。本书与它无关，而且本书的每一条判据都预设了它为假——一个既通过又判负的条款是没有意义的。

含义二·真理相对主义：不存在与认识者无关的事实。本书与它也无关。路径进入结果的规定，说的是结果依赖于走法，不是说事实依赖于走法。两个不同的结果可以都是关于同一个世界的，并且都可以出错。

含义三·形成相对主义：同一套材料与判准，可以形成不止一个结构不同的结果。

本书主张的只有第三种，而且只是它的一个受限版本——受限在“那个剩余是否为正”这一点上。

三种含义之间没有蕴含关系。第三种成立，第一、二种不因此成立；这一点在第四节已经用演化的例子说明过：两个不同的解可以都在同一个世界里、可以被同一套标准评价、可以分出高下。

把三种含义混在一起使用，是这一记之所以听起来吓人的主要原因。拆开之后它的威力少了大半，剩下的那一部分——第三种含义确实会给某些实践带来麻烦——是真的，并且由第十编处理。

八、这一记的正确位置

最后给这一记一个位置。

它不是一个可以被判掉的反击，因为它不落在任何一条条款上——没有哪个读数能证明“这不会导致相对主义”。它属于另一类东西：关于后果的争论。

本书对这类争论的处理办法是把它们集中到第十编去。那一编分两侧写：若判决倒向造成论，科学史的说明模式、教育与评估、人工智能研究自身的目标、归属与权利各要改什么；若倒向先在论，本书承认什么，以及为什么那可能是更重要的结果。

本章在这里能做的，只是把这一记从“因此你错了”降格为“因此要小心”。降格之后它仍然有效，而且值得认真对待——一个在后果上需要小心的结论，与一个在后果上不需要小心的结论，在实践中确实不一样。

下一章回到判据本身，处理方法论上最危险的一记。

第八十章 第五记·不可消解度可能只是度量的产物

一、这一记的形式

条款一的全部重量压在结果距离 d 上。而表征相似度的度量并不中立：不同度量对不同类型的变换敏感程度不同，同一批模型在

不同度量下可以得到不同的相似度排序。于是有一个致命的可能——那个不可消解度的正负，是 **d** 的自由参数，不是世界的性质。

度量取得足够细，任何两个不同的实现都必然不同，它自动为正；取得足够粗，一切差异都被抹平，它自动为零。既然如此，条款一测的就不是路径是否进入规定，而是实验者选了多细的尺子。

这是方法论上最危险的一记，比第七十五章那一记更难缠。

难缠在哪里，要说准：第七十五章那一记可以被逼成可测命题——把它请到地址上，它就落进条款二。这一记不能。它攻击的正是“可测”本身。若它成立，第六编不是被推翻，是从一开始就是循环论证：本书先选了一把能看见差异的尺子，然后报告说看见了差异。

本章用三步回答，然后用两节写这三步没能挡住的部分——而那两节里有一节是首跑给出的实测。

二、回答的第一步：这个量从来不是绝对距离，而是比值

第五十九章把噪声基线列为冻结项第二条，理由当时只写了一句“它是归一化的分母”。现在把它的分量说足：它不是一个技术细节，它是条款一之所以能成立的结构。

噪声基线的定义应当是：同一条路径、同一批数据、同一个种子，仅因硬件数值非确定性而重跑所产生的距离分布。

这条基线与路径间的距离用的是同一把尺子。

于是条款一真正要判的，不是“路径间距离是否大于零”，而是

路径间距离 ÷ 同路径重跑距离

这个比值随规模的行为。

尺子整体变细或变粗，分子分母同时变，比值不动。

度量的尺度自由度在这里被消掉了。这一步不是补丁，它是设计。而且它有一个额外的后果，本书据此提出一条对文献的要求：

任何不给出噪声基线的路径依赖读数，本书都不认为构成证据。

这一条同时约束造成论那一侧的材料。第七十四章那批欠规定性与多种子的读数，绝大多数没有做这种归一化，因此它们在本书里只能作为理由，不能作为读数——这一点第七十四章第八节已经写过，本章给出它的方法论根源。

三、回答的第二步：要求两条独立通道一致

尺度自由度被比值消掉了，但形状自由度没有。

不同的度量对不同的变换敏感性不同，这不是尺度问题——把一把尺子整体放大缩小，改变不了它在哪些方向上敏感、在哪些方向上迟钝。

对此本书的处置是设两条通道：

- 表征通道：消去对称性之后的表征距离。它依赖度量选择。
- 行为通道：冻结的分布外探针上输出分布的差异。它不依赖任何表征相似度量——它直接观察模型的输出，可以被任何人以完全不同的方式复核。

条款一要求两条通道给出一致结论才算通过。若一条判正而另一条判负，结论写“未能分辨”。

这条纪律在第五十五章被写成第四条硬规定，在第六十四章被论证为一个结论而非弃权。它在本章的位置是：它是对形状自由度的唯一有效约束。两把在不同方向上敏感的尺子同时指向同一个方向，比一把尺子指得再准都更可信。

四、回答的第三步：承认残余，并指明它在哪里

比值消掉了尺度，双通道约束了形状，仍有一个自由参数没有被消掉：

分布外探针集合的选择。

探针选得偏，行为距离就偏。而行为通道本来是用来独立约束表征通道的，它自己带一个自由参数，就削弱了这个约束。

本书不能从内部解决这一点。没有一个原则能告诉人“正确的探针集”是什么——探针的选择本身就预设了要看哪一类行为。

能做的只有程序上的限制：探针在碰到任何读数之前就写定并公开，而且尽量从与本案无关的现成公开基准里取，不为这次实验另造一套。

还要认下一条：假如有人换一套同样事先写定的探针，跑出相反的读数，那么该下的结论是这条判据还不够稳，而不是哪一方赢了。

五、首跑证明这一记在本书身上是有效的

上面三步是本书在开跑之前写下的回答。现在把首跑的实际情况摆出来，而实际情况对本书不利。

第一步没有被兑现。第二节说噪声基线应当是“同种子、同数据次序、仅数值非确定性的重训”。首跑用的不是这个，用的是同一轨迹内相邻检查点这个代理。理由是算力——重训跑不起。

代理的后果在第六十五章有完整记录：它测到的是训练在该规模该时刻的推进速率，跨规模不可比。在三个较小规模上它稳定在 0.011 到 0.013 之间，到最大规模跳到 0.031。归一化后的比值在最大规模处从 40.4 掉到 13.4，主要不是分子变了，是分母变了。

于是本章第二节那个漂亮的结构——“尺度自由度被比值消掉”——在首跑里没有生效。分母不是一把恒定的尺子，它自己在变。

更要紧的是第六十五章第三节那一层：“相邻”这个说法里的间隔本身也是自由参数。首跑取的是一千步，而一千步是那组公开检查点的发布间隔，不是设计给的。取一百步基线更小，取一万步基线更大。

结论必须写得直白：这一记攻击的是“比值能消掉度量自由度”这个回答；而首跑表明，在实际执行中，比值引入了一个新的自由度——分母的定义——而且这个新自由度当初没有被识别为自由度。

第三步的承认也比原先写的更重。第四节说探针“应尽量取自既有公开基准”。首跑的分布外探针全部由本实验构造，其中中文那一组连构造方式的先例都没有。而第六十三章第五节的分组读数显示，四组探针在最大规模上的比值分别是 3.66、2.39、1.75、1.37——结论对探针配比高度敏感，敏感到换一个配比就可能改变判决方向。

只有第二步经受住了。两条通道确实独立，确实一个判正一个判负，确实按规则判了“未能分辨”。这一步是三步里唯一在首跑中真正起了作用的。

六、这一记最狠的形态：连“未能分辨”也可能是度量的产物

上一节说第二步经受住了。本节要收回一部分，因为这一记还有一个更狠的形态，而首跑正好落在它上面。

更狠的形态是这样的：两条通道给出相反的读数，本书把它读作“世界上有两件事，而它们不一致”。但还有一个同样融贯的解释——两把尺子在不同方向上敏感，所以它们量到了不同的东西，而世界上可能只有一件事。

表征通道用的是一个对内部结构敏感的度量；行为通道看的是输出分布在一批探针上的差异。一个对结构敏感、一个对输出敏感。两个模型若在结构上不同而在输出上接近，前者报告大距离、后者报告小距离，这完全可能只是两把尺子的分工，而不是两个通道的分歧。

若是这样，那么第六十四章整章论证的那个“未能分辨”，其地位就要重估：它不是“两个读数口给出了相反的答案”，而是“两把不同的尺子量了不同的东西，然后被拿来比较”。

本书对这一形态的回答只有一条，而且它不完整。

两条通道确实量的是不同的东西——这一点本书从不否认，第五十五章第四条硬规定正是建立在此之上：不得合成，因为合成会把两件不同的东西混成一个数。

但从“量的是不同的东西”推不出“它们之间的比较无意义”。条款一问的是极限行为，而极限行为是每条通道各自可以回答的：表征距离随规模趋于什么，行为距离随规模趋于什么。两条各自的答案不一致，说的就是“在结构这一侧路径差异不消失，在输出这一侧它在消失”。这仍然是一个关于世界的陈述，而不是关于尺子的陈述。

不完整在哪里：上面这个回答要成立，两条通道各自的极限行为必须是可靠测到的。而按第五节，首跑的归一化在两条通道上都受分母失控的影响，行为通道还额外受探针配比的影响（第六十三章第五节那张分组比值表，四组在最大规模上分别是 3.66、2.39、1.75、1.37）。在这两处未定之前，“两条通道的极限行为不一致”这句话本身就不牢。

于是本节的结论是一句本书不愿意但必须写的话：

首跑那个“未能分辨”，目前无法与“两把尺子量了不同的东西”区分开。

它仍然是执行前写死的规则所给出的结论，这一点没有变；它作为纪律的意义（第六十四章）也没有变。变的是它作为读数的分量——它比第七编所呈现的更弱。

这一节是本书对第七编的一处下修，写在这里而不是写在第七编，是因为它只有在这一记的逼问下才显形。

七、这一记对两侧同等有效

最后一点必须说明，否则本章会显得是一次单方面的自我攻击。

表征收敛那一线的读数，同样建立在表征相似度量之上。

第六十八章第五节已经写过：任何一个对齐度都只看见它所用的那个核能看见的差异；“表征在趋同”这句话，严格说应当读作“在某个特定的相似性核下，表征的某一类结构在趋同”。

而那一线工作同样面临“相似度上升是否只是度量的产物”这一质问，并且它同样没有普遍采用噪声基线归一化——很少有人报告“同一路径内的正常波动

有多大”，因而也很少有人能说清所观察到的对齐度上升相对于什么而言是显著的。

因此这不是一记单方面的攻击，而是对双方的共同约束。

本书的态度是接受这个约束，并主张：谁先把比值、基线与双通道一致性做齐，谁的读数才进入判决。

这句话对本书自己最不利——因为按第五节，本书自己至今只做齐了三样里的一样。写在这里，是因为本书没有资格用一条自己尚未达到的标准去要求别人，除非同时承认自己也没达到。

第六十六章那份下一跑清单的第一条是“换基线”，它的正当性全部在本章。

第八十一章 本书不主张的六件事

为了不让后续讨论在稻草人上消耗，把边界一次写清。六件，逐件说明它是什么、为什么本书不主张它、以及有人若把它按在本书头上，本书的回答是什么。

一、本书不主张大模型拥有知识、理解或认识主体性

全部论证只用到四条工程性质：可重跑、可干预、可消融、可观测。第四编第四十五章逐条说明了为什么不使用“理解”“意识”“智能”这三个词，而且说明了不使用它们论证反而更强——一个不需要模型懂什么的论证，不会因为模型不懂而倒。

任何以“模型不懂”为由的反驳都打在空处，因为本书从未主张它懂。

这一条与第七十七章的关系要说清：那一章处理的是“表征不是知识”这一记，本条是它的前置声明。承认模型没有知识，与本书的论证完全相容——理由见那一章第二节反例结构。

二、本书不主张人类知识与模型训练是同一类过程

本书的论证是反例结构而不是类比结构。

一个实例破掉一条全称命题，不等于给出了另一条全称命题。本书能说的是：那条一般原则的普遍性破了，先在论从此必须为它想主张的每一个领域单独举证。本书不能说：人类知识也是这样形成的。

这两句话之间的距离，本书不打算用任何方式缩短。完整的论证与边界在第七十七章第二、三节。

三、本书不主张数学是发明而非发现

数学的情形有它自己的特殊困难：形式系统内部的必然性、独立发现的高度趋同、以及“证明”这一判准与其他领域判准的性质差异。本书的三条条款无法直接移植到数学上，需要另行设计。

此处只指出一点，它是一个方向而不是一个主张：如果条款三在语言模型上通过，那么“必然性”本身作为一种可能被路径塑造的性质，将成为一个可研究的问题，而不再是一个不言自明的前提。

这是一个很弱的陈述，本书有意把它写得这么弱。

四、本书不主张已经完成判决，也不主张首跑判出了任何东西

这一条在本书里比在任何一份前置材料里都更需要写明，因为本书有读数，而有读数的书最容易被读成有结论的书。

首跑的结论是“未能分辨”。按第五十八章第五节，它不记在四条败绩条件中的任何一条名下——它不是一次败绩，也不是一次通过，更不是一次部分胜利。

尤其不主张的是：表征通道那一列（不向零衰减）构成对条款一的支持。它只是两个读数口中的一个；另一个方向相反；而按执行前写死的规则，两者不一致时本书什么也不说。第六十四章用整章论证了为什么这不是弃权。

条款二与条款三未跑。第五十七章末尾那句话对它们都适用：它们是本书开出的支票，不是本书交出的读数。

五、本书不主张路径依赖是好事

这一条是六件里最容易被忽略的一件，因此要写得明白。

本书论证路径可能进入结果的规定，不等于本书认为这是一件值得高兴的事，也不等于本书站在“多样性优于收敛”这类价值立场上。

若判决倒向造成论，它的后果里有相当一部分是坏消息：

- 两个在任何既有判准下同分的人，可能持有结构不同的知识——这对一切依赖分数的选拔与认证都是麻烦，不是解放。
- 结果对训练路径的敏感，意味着不可复现性是结构性的而非工程性的，某些今天被当作“待改进”的问题可能根本改不掉。
- 科学史上的一些结论将失去“迟早会被发现”这层保险。

这些后果由第十编逐条处理，并且第十编同时写另一侧——若倒向先在论，本书承认什么，以及为什么那可能是更重要的结果。

本书在价值上没有立场，在判据上才有立场。一本因为喜欢某个结论而去论证它的书，它的判据是不可信的。

六、本书不主张先在论是愚蠢的立场

恰恰相反。

本书认为先在论是当前经验证据的合理综合。第八编花了八章复述它的四件在役武器，而那一编的第一条纪律就是不许把对手写弱。那四件武器里，有三件的负面材料是对手一方自己报告的——一个会自己报告反例的阵营，不是一个愚蠢的阵营。

而且，先在论拥有本书接不下来的一记。第七十八章整章写的就是那一记，以及本书为什么接不住、做了哪些补救、补救为什么不够。

判决若真的到来，它应当来自数据，而不是来自任何一方的修辞胜利。

附一 为什么是六条，而第六条是新加的

前置材料里这份清单只有五条。第五条（路径依赖不是好事）是写本书时新加的，理由值得记一笔，因为它与首跑有关。

在只有判据而没有读数的时候，“本书不主张路径依赖是好事”这句话没有用武之地——一本什么也没测到的书，谈不上偏爱任何结论。有了读数之后情况变了：首跑的表征通道给出了本书想要的方向，而行为通道没有。在那一刻，“希望某个结论成立”这件事第一次成为一个实际的风险，而不是一个抽象的告诫。

第六十四章写过，若按人之常情，那里会发生的事情是把有利的一列写详细、把不利的一列写简略，然后用一句“总体倾向于支持”收尾。挡住这件事的是执行前写死的规则；而规则之所以能被写死，前提是写规则的人当时还不知道读数会长什么样。

一旦读数出来了，规则只能挡住这一次，挡不住下一次——下一跑的预注册是在已经知道首跑结果的情况下写的。防住这一点的办法，只有把“本书在价值上没有立场”这句话明写出来，并且把倒向造成论的坏消息与倒向先在论的好消息同等地列出来（第十编）。

因此第六条不是一句谦辞，它是一条针对下一跑的防护。

附二 与之对照：本书主张的那一件事

六条都是否定。为免读者读完六条之后不知道本书到底主张什么，把正面的那一句写在这里，只写一句：

在大规模语言模型的训练中，存在构成性路径依赖——即存在结果层面的差异，它由路径单独引起，并且不随规模、算力与数据量的增加而衰减为零；因而不存在只以语料、架构与判准为自变量的函数能够唯一地决定所到达的结果。

这就是第五十二章第三节那条核心命题，一字未改。

关于它，本书能说的只有：它是可判的，它的判负条件写在第五十八章，而它至今未被判决。

把这句话与上面六条并排，本书的全部位置就清楚了：一条正面主张，六条不主张，四条败绩条件，两条补充的败绩条件，一次未能分辨的首跑，两条未跑的条款。这就是全部库存，没有别的。

附三 六条边界的共同形状

把六条并排，会看出它们有同一个形状：每一条都在拒绝一个比本书实际主张更强、也更好用的版本。

更强的版本总是更好用的——“模型也有知识”“人类知识也是被造成的”“数学是发明”“首跑支持了造成论”“多样性是好事”“先在论是过时的”——这六句话每一句都比本书实际主张的那句更响亮、更容易传播、也更容易被反驳掉。

本书拒绝它们，不是出于谨慎的美德，而是因为一个具体的利害：

一本书能被推翻的方式，应当是它自己写下的那几种，而不是别人替它想象的那几种。

第五十八章为条款写下了四条败绩条件，第五十五章与第七十一章各补了一条。本章做的是同一件事的另一半：把那些本书没有主张、因而无法被用来推翻本书的东西，一次清点干净。

第九编到此结束。下一编处理后果——两侧的后果，以及一条比两侧都长的观察。

第十编 后果与更长的观察

判决尚未做出，而本编把两个方向的后果都推演一遍。这件事本身需要一句辩护：它防止研究者在读数出来之后才决定自己在乎什么。

第八十二至八十五章写若判决倒向造成论，科学史的说明模式、教育与评估、人工智能研究自身的目标、归属与权利各要改什么，并给出各自可立刻执行的检验与它们的困难。

第八十六章写另一侧，篇幅不比那一侧少——若倒向先在论，本书承认什么，以及为什么那时被建立的东西比本书想建立的更重要。

第八十七章推出一条比本案更一般的观察：有一类问题，其不可判性来源于过程不可重跑；对这类问题，进展不来自更强的论证，而来自出现一个可重跑该过程的人工系统。而本书自身也在这条观察之内。

一、为什么后果要在判决之前写

判决尚未做出。本编却要把两个方向的后果都推演一遍，这件事本身需要一句辩护。

辩护是这样的：它防止研究者在读数出来之后才决定自己在乎什么。

一个人若在看到数据之前就写下“若倒向这一侧我承认什么、若倒向那一侧我承认什么”，那么数据出来时他没有多少操作空间。若他等到数据出来之后再去看后果，他会不自觉地把后果往对自己有利的方向安排——不是因为不诚实，而是因为在那个时刻，后果与结论已经缠在一起了。

这与第五十八章写死败绩条件是同一条纪律的两个部分：那里写的是“若判负本书交出什么”，这里写的是“若判成本书主张什么、若判负世界会得到什么”。两者都必须写在读数之前。

首跑之后，这条纪律的必要性反而更强了——因为现在本书已经有一次读数，而那次读数的两个通道给了相反的方向。在这种处境下写后果，比在完全没有读数时更需要防备自己。

本编第八十六章写另一侧，且篇幅不比这一侧少。

二、科学史不再是“逼近加噪音”

先在论下的科学史有一个标准的说明模式，它如此通行以至于常常不被察觉：

科学史 = 逐步逼近真相的过程 + 可以略去的人事噪音。

第四章第三节已经把这个模式的内容写过一遍，本节不重复，只取它的落点：在这个模式里，说明力全在主线上，而谁读过哪本书、哪台仪器先做出来、钱往哪个方向给，都被划到主线之外——它们可以进传记，不进“为什么得到了这个结论”。

若路径进入规定，这些东西就不再是花边，而是规定的一部分。

这个转变的分量要说准，它不是“历史变得更重要”这样一句含糊的话。它的精确形式是：

说明一个结论为什么是这样而不是那样，必须包含它是从哪条路上来的；不包含这一项的说明是不完整的，而不只是不详细。

“不完整”与“不详细”的区别在于：不详细的说明可以补充细节而结构不变；不完整的说明缺的是一个自变量。

三、反事实科学史从消遣变成方法

由上一节直接得到一条具体的研究纲领。

反事实的科学史——“如果十九世纪的化学先有了光谱学再有了原子量，周期表会是什么样”——在现行模式下是一种消遣。它被当作消遣，不是因为它无趣，而是因为它无法被回答：历史只发生了一次，任何答案都只能是推测。

第五十三章已经写过这件事的一般形式：一段只发生过一次的过程，不含有区分“你还没走到”与“那里没有那个东西”所需要的信息。

但若本案倒向造成论，反事实科学史的地位就变了两次。

第一次变化：它从消遣变成必需。若路径进入规定，那么“如果走另一条路会怎样”就不是一个闲问题——它正是“这条路造成了什么”的另一种问法。不回答它，就等于不知道实际发生的那条路贡献了什么。

第二次变化，更实在：它获得了一个可操作的近似形式。

本书的三条条款，本质上就是在做缩尺的反事实实验——固定材料、固定判准、只换走法，跑很多次，看到达的地方是否同一处。这套做法在原理上可以被移植到一个以科学史材料为语料的缩尺系统上：把某一段时期的文献、数据、仪器记录作为材料，把当时的接受标准作为判准，然后改变呈现的次序，跑若干次。

必须立刻写明这条纲领的三重限制，否则它就成了了一句漂亮话。

限制一：它测的不是历史，是一个模型在历史材料上的行为。这与第七十七章那一记是同一件事——本书的现场是模型，不是人，更不是共同体。任何从这类实验得出的结论，都只能是关于“以这批材料为输入、这套判准为约束的过程”的结论。

限制二：判准在真实科学史中不固定。第七十七章第五节那一记在这里原样复现，而且更重：科学史上最有趣的变化，恰恰常常是判准本身的变化。一个把判准钉死的缩尺实验，测不到那一层。

限制三：材料的选取本身携带了历史判断。把哪些文献算作“当时的材料”，这个选择是由后来的人做的，而后来的人已经知道结局。这与第五十五章第三条讲的探针选择是同一类自由参数，且更难控制。

三条限制加起来，得到一个诚实的结论：反事实科学史可以从消遣变成方法，但它变成的是一种受限的方法，而不是一台时间机器。它能回答的

是“在这批材料与这套判准下，走法能造成多大的分化”，不能回答”周期表本来会是什么样”。

四、一个反事实问题该怎么被提出

上一节说反事实科学史可以变成受限的方法。本节把”受限”写成格式，因为一条纲领若不给格式，它就只能被当作口号。

一个可被处理的反事实问题，必须指定四样东西。少一样，它就退回消遣。

其一，材料。哪些文献、数据、仪器记录算作输入，以及它们的边界在哪里。这一项最容易被含糊过去，而它是全部自由参数中最大的一个——“当时的材料”这个说法本身就是由后来的人划定的。诚实的做法是把纳入与排除的规则写出来并冻结，而不是声称自己取的是”全部”。

其二，判准。在那个时期，什么算一个被接受的结论。这一项必须被钉成一个可执行的判断规则，否则整个实验没有L。而钉死它的代价，正是第七十七章第五节那一记——真实历史里判准是在变的，钉死它就测不到那一层。这个代价要写在结论旁边，不能只写在方法里。

其三，要改的路径变量是哪一个。次序？某份材料出现的早晚？某类工具可得的时点？一次只改一个，其余固定。这是本书第五十六章形式三那条规格在历史材料上的翻版，而它在这里比在模型上更难做到——历史材料的各项彼此牵连，很难只动一样。

其四，被观察的结果量。不得是”得到的结论对不对”——那是判准的投影，第五十五章第一条禁止。可用的是结构性的量：得到的表述能覆盖哪些现象、在哪些方向上迁移得动、遇到反例时需要改动多少。这三样与第八十三章第四节那一栏所要测的东西是同一批。

四样齐备，一个反事实问题才从”如果当年……会怎样”变成一个有输入、有控制、有观测的设问。

四样之中，第一样与第二样本书认为目前都做不干净。这不是说这条纲领不该做，而是说它的第一批产出只能是方法学的，不会是历史学的——先做出一套大家肯接受的材料纳入规则与判准钉法，再谈结论。一条需要先花几年建规范的纲领，本书照样把它列出来，因为它是这一栏唯一具体的东西。

五、一条可以现在就开始的具体工作

上面那条纲领需要缩尺系统，成本不低。但它有一个便宜得多的前置工作，可以立刻开始，而且不依赖本案的判决。

把科学史上的多重发现案例，按”路径差异”重新编目。

多重发现在现行的说明模式里被当作先在论的证据：几个人独立地走到了同一处，说明那一处本来就在。第二编第八章处理过这个论证，指出它的归类是事后做出的——把两件被后来判定为“同一个发现”的事归为一类，这个判定本身用的是后来的判准。

重新编目的做法是：对每一组多重发现，逐项记录当时两方的差别——他们各自能做什么预测、各自认为什么算证据、各自的版本在后来被保留了多少、被丢弃了多少。

这项工作的做法、产出与它对两侧的杀伤力，第八章第五、六节已经写足，本节不重复。这里只补一句它在本编的位置：它是本书所列的三项可执行工作里，唯一一项完全属于科学史的——不需要算力，不需要模型，只需要档案与耐心。

本书特别指出这一项，是因为它是本编所有后果推演中唯一一项不需要等判决、不需要新设备、且对两侧同等可能不利的工作。

六、这一栏的现状

本章全部内容以三条条款通过为前提。而条款一在首跑中未能分辨，条款二三未跑。

因此本章说的每一件事都是条件句的后件。按第八十一章第四条，本书不主张已经完成判决；本章的任何一句都不得被引用为“科学史应当这样改”的理由。

它能被引用为的只有一件：如果判决这样落，那么要改的是这些，而不是别的。

下一章处理一栏影响更直接、也更容易被立刻误用的后果。

第八十三章 若倒向造成论·教育与评估

一、现行评估测的是什么

先在论下的教育有一个理所当然的做法：把结果当作评估对象。学生是否掌握了那个本来就在那里的东西——掌握了多少，掌握得多牢，能不能在新题上用出来。

这个做法的合理性完全依赖于一个前提：存在一个“那个东西”，而所有学会了的人学到的是同一个。

若判决倒向造成论，这个前提就要加一个限定。学生所到达的东西的规定本身依赖于他走过的路径，于是：

两个分数相同的学生，可能持有结构上不同的知识。

而现行评估在设计上看不见这一差别。

看不见的原因不是技术不够好，是结构性的：它测的是结果在判准上的投影。

这正是第五十五章第一条硬规定所禁止的那个量。那一条说：不得用任务分数作结果距离，因为分数是判准的投影，用它当结果等于事先规定“凡是判准看不出来的差别都不算差别”。第七十二章把同一条论证用在了缩放律上。本章是它在教育上的第三次出现。

三处是同一件事：一个被设计来压平差异的量，不能用来测量差异。考试正是被设计来压平差异的——它要让同等掌握的人得同等分数，这是它的目的，不是它的缺陷。

二、一条可立刻执行的检验

这一栏与前一章不同：它有一条不需要等判决、也不需要缩尺系统就能做的检验。

做法是与条款一同构的：

- 同一门课程，同一批材料，同一套判准。
- 把学生随机分组，各组的学习次序不同——先讲哪一块后讲哪一块，先做哪类练习后做哪类。
- 测什么：不是总分，而是分布外迁移上的系统差异。即在事先冻结的、与教学内容不重合的一批迁移任务上，看不同次序组的表现是否出现系统的、可复现的差别。

这条设计的每一步都照搬第六编：不得用总分（第五十五章第一条）；迁移任务必须事先冻结（第五十五章第三条）；必须有噪声基线（第八十章第二节）；不得把两类观测合成一个数（第五十五章第四条）。

本书认为这是一条被长期空着的经验战线。教育研究里关于“次序”的工作不少，但它们几乎全部以总分或学习效率为因变量——问的是哪种次序学得更快更好，而不是哪种次序学到的是不同的东西。这与第七十四章第八节那个观察是同一个形状：一个领域的实践关切，决定了哪些问题被提出来。教育实践关心的是效果，于是“次序会不会造成结构不同的知识”这个问题没有被提上日程。

三、“两个同分的人”这句话的三种读法

这句话是本章最容易被传播、也最容易被读歪的一句，因此先把三种读法分开，写明本书指的是哪一种。

读法一最弱：两个同分的人，掌握程度其实不同，只是考试没测准。

这是一个测量精度问题。它完全在先存论之内——存在一个“那个东西”，两人掌握得不一樣多，而考试分辨率不够。改进的办法是出更好的题。本书说的不是这一种。

读法二中等：两个同分的人，掌握的内容不同——甲会这几块，乙会那几块，加起来分一样。

这也在先存论之内：那个东西有若干部分，两人各掌握了一部分。它对应的是一份内容清单上的不同勾选。改进的办法是报告分项成绩而不是总分。本书说的也不是这一种，虽然这一种与本书要说的容易混。

读法三本书指的那一种：两个同分的人，所掌握的东西组织方式不同——不是会的块不一样，是同样的那些块之间的连接、优先次序、触发条件不一样。于是在清单上他们勾选相同，在遇到新情形时他们的行为系统地不同。

三种读法的区别可以用一个判据分开：能不能靠加细清单来消掉。

读法一靠出更好的题消掉；读法二靠分项报告消掉；读法三消不掉——因为无论清单加得多细，它记录的仍然是“会什么”，而不是“怎么连起来的”。

这正是第五十五章第一条硬规定在教育上的形态：清单是判准的投影，而结构不在投影上。把读法三误读成读法一或二，会让人以为这件事靠改进考试就能解决，于是本章第五节那一栏就显得多余了。

必须补一句对本书不利的：读法三比前两种难测得多，而且它与前两种在实际数据里很难分开。一份显示“同分而迁移不同”的读数，完全可能是读法二造成的——两人会的块不同，而迁移任务恰好偏向其中一块。要把读法三单独逼出来，需要在分项成绩也相同的子样本上看迁移差异，而那个子样本通常很小。这是本章第二节那条检验在设计上最难的一处，比第三节那四条困难更靠里。

四、这条检验的四处困难，逐条写明

上一节读起来太顺，必须把困难写足，否则它会被当作一个已经准备好的方案。

困难一：噪声基线在人身上极难取。第八十章第二节说噪声基线应当是“同一条路径重跑”。在模型上这意味着同种子重训；在人身上，没有“同一个学生重学一遍”这回事。可用的替代是组内个体差异——同一次序组内不同学生

之间的差别——但那个量里混杂了资质、动机、既往知识，它比模型上的数值非确定性大得多，也脏得多。分母一脏，整条比值就不牢，这正是首跑裁过的地方。

困难二：材料与次序无法真正分离。在模型实验里，“同一个语料的两种次序”可以做到逐位对齐。在课堂上做不到：换了次序，讲法就会变，例子就会变，学生的提问也会变。严格的次序反转对在教育现场几乎不可能构造。

困难三：判准在教育中不固定，而且它的不固定是被追求的。好的教学会随着学生的反应调整目标。第七十七章第五节那一记在这里再次复现。

困难四：迁移任务的选择是最脆弱的自由参数。与第五十五章第三条所说的探针配比完全同类，且在教育测量里这个问题更严重——迁移任务的难度、形式、与教学内容的距离，每一项都会改变结论。

四条加起来意味着：这条检验可以做，但它的一次结果不构成判决。这与首跑的处境完全一样，理由也一样：在基线与探针两处未定之前，任何单次读数都不足以判案（第五十五章末尾）。

五、若它成立，评估要增设的那一栏

假设上一节的困难被逐步解决，且读数指向差异存在。那么评估要改的是什么呢？

不是把现行评估推翻。是增设一栏。

现行评估回答的是：到达了多高。这一栏继续有效，本书不主张它没有意义——它测的东西是真实的，只是不完整。

要增设的一栏回答的是：到达的是哪一种。

这一栏在今天的全部主流评估里都是空的。而按本案的推论，它才是路径差异唯一会显形的地方。

它具体要测什么？至少三样：

其一，迁移的形状。不是迁移得好不好，而是往哪些方向迁移得动、往哪些方向迁移不动。两个同分的人可能在完全不同的方向上卡住。

其二，失效的模式。出错时错在哪里，是同一类错还是不同类错。错误模式比正确答案携带更多关于结构的信息，这一点在诊断性评价里早有共识，只是没有被用在这个问题上。

其三，重组的代价。当已有的理解需要被修改时，需要改动多少。这一条最难测，也最接近“结构”这个词的实质。

六、这一栏最容易被误用的地方

本节是本章必须写的，因为这一栏的后果会最快地被拿去用在人身上。

误用一：把“结构不同”读成“各有各的道理”。第七十九章已经拆过：路径进入规定不蕴含任意性，可比较性不需要唯一性。两个结构不同的知识可以被严格比较——预测力、可干预性、遇到反例时的修改代价。本章第五节那三样要测的东西，恰恰是为比较服务的，不是为取消比较服务的。

误用二：把它当成反对统一考试的论据。本书不提出任何教育政策主张。统一考试所服务的功能——大规模、可复核、程序上的公平——不在本案的讨论范围内，而且那些功能的正当性不依赖于“所有人学到的是同一个东西”。指出一个工具有它看不见的东西，不等于主张废掉它。

误用三：把它当成已经成立的结论去改课程。本章全部以三条条款通过为前提，而条款一在首跑中未能分辨。按第八十一章第四条，本书不主张已经完成判决。

误用四，最隐蔽的一条：把它当成一件好消息。第八十一章第五条写过，本书不主张路径依赖是好事。若两个同分的人真的持有结构不同的知识，那么一切依赖分数的选拔与认证都会遇到一个结构性的麻烦——不是可以靠改进题目解决的麻烦。这是坏消息，而不是解放。

下一章处理一栏最直接、却最少被提的后果。

第八十四章 若倒向造成论·人工智能研究自身的目标

一、当前路线里隐含的那个目标

这一栏最直接，却最少被提。

当前的主流路线隐含着一个先在论的目标，而且是一个很少被明说出来的目标：

用更多的数据、更大的规模、更好的优化器，去逼近由数据与目标所唯一确定的那个最优模型。

“那个”两个字是关键。在这个图景里，存在一个由材料与目标决定的最佳答案，而工程的任务是尽可能接近它。

在这条路线里，路径被当作工程噪音。三件常规做法都以抹平路径为方向：

- 种子要固定，以便复现。

- 次序要打乱，以便无偏。
- 课程要设计，以便加速。

三件事都合理，而且在各自的目标下都做得很好。本章不质疑其中任何一件在工程上的正当性。

本章要指出的只有一件：这三件事共同预设了路径不进入结果。若构成性路径依赖为真，这个方向在原则上就是错的，而不只是不够好。

二、三条具体的改法

改法一：多样性要被当作资产，而不是方差。

若走法不同带来的是结构不同的东西，那么留一批走法各异的模型，它们值多少就不能只看同一把尺子上的分差——分差量的是它们在那把尺子上的远近，不是它们彼此之间的不同。

现行做法是“选最高分那一个”。在先而论下这是对的——分数高的那个更接近那个唯一的最优解，其余的是它的劣化版本。在造成论下这是在系统地丢掉信息：被丢掉的那些不是劣化版本，是别的东西。

这条改法有一个可立刻检验的后果：一族路径不同、分数相当的模型，其集合的价值应当超过其中任何单个模型的价值，而且这个超出不应随规模衰减。若集成、互补、覆盖度这类指标上的收益随规模系统地消失，这条改法就落空了。

改法二：训练路径要成为被设计的一等对象。

与数据和架构并列，而不是被当作需要消除的随机性。

这一条最直接的后果落在课程研究上：它的地位将从提速手段升为构成手段。今天的课程研究问的是“什么顺序学得快”；在造成论下要多问一个问题——“什么顺序学到的是哪一种”。

第七十章第五节记过一件相关的事：回绕所依赖的稳定性分析，其构造正是“仅改变数据次序，两次训练会不会落到同一片区域”。那个工具是先而论一方为修复自己而造的，它的存在本身说明：次序造成的分化，是一个双方都承认为真实且可测的量。争的是它随规模的走向。

改法三：评估要增设一栏。

除了测到达了多高，还要测到达的是哪一种。

这一栏在今天的全部主流基准里都是空的。而按本书的推论，它才是路径差异唯一会显形的地方——第七编第六十三章的分组读数就是实测：种子差异在训练分布上被压得很平，在分布外探针上大得多。

这一条与第八十三章第四节那一栏是同一件事在两个领域的形态。两处要测的东西也相似：迁移的形状、失效的模式、重组的代价。

三、三条改法各自的成本

上一节三条改法读起来都像好事。本节把它们各自的成本写出来，因为一条只报收益不报成本的建议，与第八十一章第五条所拒绝的那种乐观是同一类东西。

改法一的成本：保留一族模型很贵。

“多样性是资产”这句话在账面上意味着：不再只留最高分那一个，而是留一批。存储、维护、版本管理、部署时的选择逻辑，每一样都要乘以那个族的大小。而在收益尚未被证实之前，这笔支出没有依据。

更麻烦的是：这条改法与现行的一切效率压力方向相反。一个必须把成本压到最低的组织，不会因为一条尚未判决的哲学主张去保留一族模型。因此这条改法在实践中只可能以另一种形式进入——先证明那个超出的价值存在且可测，再谈保留。这也正是第四节要说的：它可以先被局部检验。

改法二的成本：路径成为设计对象，意味着搜索空间爆炸。

数据与架构已经构成了一个极大的搜索空间。把路径也提升为一等对象，等于再加一整个维度——次序、课程、配方、每一段的时长。而这个维度与前两者相互牵连，不能独立调。

这条成本有一个更深的层次：路径一旦成为设计对象，“复现”这件事的含义就要改。今天的复现意味着固定种子，而固定种子恰恰是把路径消掉。若路径是构成性的，那么复现一个结果就必须复现那条路径的全部，而那比记录一个种子难得多。一条主张路径重要的立场，必须同时承担“复现变难”这个后果，不能只享受“路径有价值”这一面。

改法三的成本：增设的那一栏没有现成的尺子。

“到达的是哪一种”要测的三样——迁移的形状、失效的模式、重组的代价——今天都没有成熟的标准化做法。而在没有标准的情况下增设一栏，最可能的结果不是看见了新东西，是每家各测各的，互相不可比。

这与第五十五章第三条所说的探针问题同源：一个自由参数很大的新指标，在被规范化之前，它的读数不足以判案。本书自己的首跑就是这句话的实例。

三条成本加起来，得到一个对本章其余部分的限制：这三条改法不是可以立刻照办的建议，它们是一条需要预付前期投入才能被检验的假设。下一节说明那笔前期投入可以有多小。

四、三条改法都可以在判决之前被局部检验

这一节是本章最有分量的一处，因为它把后果推演变成了一件可以现在就做的事。

三条改法各自有可观察的后果，而这些后果不依赖三条条款的判决：

- 多样性是否有超出分数差的价值，可以在现有模型族上直接测。
- 路径设计是否只影响速度，可以用同一份材料的不同课程安排做对照。
- “哪一种”这一栏是否测得出稳定差别，可以在现有多种子检查点上做。

三条都不需要新的大规模训练，都不需要等条款三。

而它们的反面同样有意义，这一点必须写明：

若它们全部无效——多样性没有额外价值、路径设计无非提速、“哪一种”这一栏测不出稳定差别——那本身就是对条款的一次独立的旁证式判负。

这是本书主动交出的又一条可以输掉的路。它不在第五十八章那四条败绩条件之内，因为它是旁证而不是判据；但若三条全部落空，本书的处境会显著变坏，而本书不打算在那种情形下辩解说“这些只是工程指标”。

五、一件更深的事：关切决定了哪些问题被问

第七十四章第八节记过一个观察，本章是它应当落地的地方。

那一节指出：欠规定性、多种子基准、多种子预训练这三批材料，其作者问的都是“这会不会给我添麻烦”，而本书问的是“这会不会消失”；后一个问题从未被提上日程，不是因为它难，而是因为没有人需要它的答案。

由此得到的一般形式是：

一个领域的工程关切，会系统性地决定哪些问题被提出来。

在本编之前，这只是一个关于学术社群的观察。放在这一栏里，它变成了一个方法论上的警告，而且是一个与本案直接相关的警告：

判准的设定不仅决定了什么算好的结果，还决定了什么问题会被提出来。

这句话对人工智能研究自身有一个具体的含义。若这个领域的判准长期只包含“分数高、可复现、训练稳”，那么“到达的是哪一种”这个问题就会持续地无人提问、无人资助、无人发表——不是被否定，是被漏过。

而按本章第二节的改法三，那一栏恰恰是路径差异唯一会显形的地方。于是有一个不舒服的可能性：

这个领域可能正在用一套看不见路径效应的判准，去论证路径效应不存在。

必须立刻限制这句话，否则它会变成一种廉价的怀疑论。它不是在说这个领域的研究者有偏见，也不是在说现有读数不可信。它说的是一件更具体、也更可修的事：判准的覆盖面是可以被扩充的，而扩充它不需要先接受本书的任何主张。增设“哪一种”那一栏，对先在论同样有用——若差异确实随规模消失，那一栏会是最先看到它消失的地方。

六、这一栏与本书自身的关系

最后要说一句对本书不利的话，因为不说它，本章就是在单方面地要求别人。

本书自己也是这套关切的产物。

本书所用的材料，是别人为研究训练稳定性而制作的；本书所用的度量，是这个领域为别的目的发展出来的；本书所用的机器、软件、模型，全部来自一条特定的技术路线。第七十五章第三节说过，这个现场之所以存在，是因为它被造出来了，而造它的人想的完全是别的事。

因此本章第五节那个警告，第一个落在本书自己头上：本书能提出的问题，同样被本书所能拿到的工具限定着。首跑的四个规模点、112条探针、单核算力——这些不是本书选的判准，是本书能够到的东西。

这件事没有解法，只有程序上的应对：把用了什么、为什么用它、它限制了什么，全部写出来。第七编第六十一章就是这样一份交代。

下一章处理一栏落在法律与归属上的后果。

第八十五章 若倒向造成论·归属与权利

一、一条把本案当地基的界线

专利制度里有一条很老的界线：自然规律不可专利，技术方案可专利。

理由是直白的：自然规律本来就在那里，任何人发现它都不构成创造，因此不能把它圈起来归自己；技术方案是被做出来的，做的人可以主张权利。

这条界线的全部重量，压在本案待判的那一句上：

有些东西本来就在那里，有些东西是被做出来的。

这不是一个法律上的类比，它就是同一句话。先在论与造成论之争，若有一个地方已经被写进了制度，就是这里。

本书不提出任何法律主张。本章不建议修改任何法条，不评价任何判例，也不主张现行界线划错了。本书只指出一件事：这条界线的地基就是本案，而地基未定。

二、若路径进入规定，需要重新检查的是哪一步

若判决倒向造成论，被动摇的不是整条界线，而是界线所依赖的一步推理。

那步推理是：

这是被发现的自然事实，所以它不属于任何人。

若路径进入结果的规定，这一步就需要重新检查它在哪些场合仍然成立。

要把“需要重新检查”说准，因为它很容易被读得太重。它不是说“发现也应当可专利”。它说的是这一步推理原本是一步无条件的推理——只要判定某物是被发现的，归属问题就自动解决。若路径进入规定，那么“被发现的”这个判定本身就带上了条件：在什么材料下、由什么路径、按什么判准发现的。

一个原本无条件的推理变成有条件的，其后果是程序上的：每一次使用它，都要先确认那些条件成立。这比“推翻它”弱得多，也具体得多。

三、这条界线与第七十八章那一记是同一条

本章最有价值的一处观察在这里。

第七十八章写的是本书接不住的那一记：语境内临时形成的程序，究竟是形成了新东西，还是组合了已有的能力被激活了一次。本书在那里承认，它给不出一条非平凡的界限。

现在看归属与权利这一栏：它需要的恰恰是同一条界限。

- 一项技术方案，若被认定为“已有元素的常规组合”，通常不被认为具有创造性。
- 若被认定为“非显而易见的新方案”，则可以。

“常规组合”与“非显而易见”之间的那条线，与“激活”和“形成”之间的那条线，是同一条线。

这个对应有两个方向的含义，两个都要写。

对本书有利的一面：它说明第七十八章那个困难不是本书特有的窘境。同一条界限，法律实践已经与它搏斗了很久，并且发展出了一整套操作性的判定办法——尽管那些办法在理论上从未被奠基。一个在理论上悬着、却在实践中不得不天天判的问题，说明它是真问题。

对本书不利的一面，而且更重：法律实践之所以能判，是因为它有一个本书没有的东西——一个有权作出裁断的机构，以及一套可以被接受的、无需理论奠基的惯例。法律不需要知道“形成”的本质是什么，它只需要一套能让争议停下来的程序。

本书不能这样做。本书要的是一个带量、带判负条件的判据，而不是一个能让争议停下来的程序。因此法律实践的成功，恰恰不能被借用为本书的解法。

这一点要说得更直白些：从法律那里能借到的是“这条线可以在实践中被划”这个事实，借不到的是“这条线应当划在哪里”这个答案。前者对本书是安慰，后者才是本书缺的。

四、第三种处理：不判性质，判贡献

上一节的结论是：本书与法律共用一条界限，而法律之所以能判，靠的是本书不能借用的东西。

但还有第三种处理方式，它既不需要判定“这是被发现的还是被做出来的”，也不需要一套裁断机构的权威。它值得单独写，因为它是本章唯一一处可能真正有用的地方。

做法是：不判对象的性质，判路径的贡献。

不问“这个结果是先在的还是被造成的”，而问“在得到这个结果的过程中，这条路径贡献了多少”。

这个转向的好处是它与本书的量直接对上。可归约份额测的正是这件事：路径间结果差异中，有多大一部分可由材料、架构与判准预测，有多大一部分不可。那个不可归约的剩余，就是路径的贡献。

于是一条原本二值的界线，变成了一个连续的量。

这个转向有三个后果，两好一坏。

好处一：它绕开了第七十八章那个本书接不住的困难。那一记要求区分“形成”与“激活”，而这个转向不需要区分——它只问差异中有多少不能由输入端写出来。一个被反复“激活”的组合，若它在不同路径下稳定地相同，那么它的不可归约份额就接近零；若不同路径给出稳定不同的组合，份额就为正。不需要先回答那个界限问题。

好处二：它与本书已有的判据同构，因此不需要新发明。条款二形式二就是它的现成形态。

坏处，而且很重：它把一个法律上需要是非分明的判断，换成了一个需要阈值的判断。二值界线的好处是可预期——当事人事先知道自己站在哪一边。一个连续量加一个阈值，其可预期性取决于阈值有多稳，而按第五十五章与第八十章，本书自己的量对基线与探针的选择都相当敏感。一个自己都还不稳的量，不适合拿去承担需要稳定预期的功能。

因此本节的结论要写得明白：这个转向在研究上是可行的方向，在制度上不是。本书提出它，是作为一条可以被测量的研究路线，而不是作为一个可以替代现行界线的方案。

五、三处会被立刻波及的具体场合

为免本章停留在原则层面，列三处若判决倒向造成论会被立刻波及的场合。列举不是主张，只是指出地基在哪里承重。

其一，对自然对象的权利主张。凡是依据“这是被发现的自然事实”来否定或肯定权利的场合，都要重新确认那一步推理的条件。

其二，模型产出的归属。一个模型产生的东西，其归属论证常常绕回“这是数据里已有内容的重组”或“这是新生成的内容”。这与第七十八章那条界限是同一个问题的产业版本。本书在这里没有任何主张，只指出它与本案共用地基。

其三，训练路径本身的地位。若路径进入结果的规定，那么“用什么次序、什么课程、什么配方训练”就不只是工艺，它是结果的构成部分之一。这一点与第八十四章改法二（路径成为一等对象）是同一件事在权利层面的投影。

六、为什么本书在这一栏格外克制

前面几章的后果推演都给出了可执行的检验：第八十二章给了四条格式，第八十三章给了一条课堂设计，第八十四章给了三条可局部检验的改法。这一栏没有给。

克制是有意的，理由三条。

理由一：这一栏的误用代价最高。前几栏若被误用，后果是一批做错了的研究、一批白花的钱。这一栏若被误用，后果落在具体的人身上——一份被驳回的申请、一次被改判的归属。一个地基未定的论证被拿去支撑一项具体裁断，其代价不由提出论证的人承担。

理由二：本书没有这方面的能力。本书作者不是法律工作者。上面几节所用的只是这条界线最公开、最通行的表述，而任何一个具体制度里，这条界线

都被一整套判例、例外、程序所包裹，那些东西本书不懂。一个不懂细节的人指出地基在哪里，是有用的；他接着指点房子怎么改，是有害的。

理由三，也是最要紧的一条：这一栏与本书接不住的那一记重合。第三节写过，归属判断所需要的“常规组合与非显而易见”之间的界线，与第七十八章“激活与形成”之间的界线是同一条。而本书在那一章明确承认给不出这条界限。

于是处境很清楚：本书在这一栏里唯一有分量的那句话，恰恰是“我说不出这条线该划在哪里”。一个说不出线在哪里的人，去主张现行的线划错了，是没有资格的。

本书能做的只有一件：指出那条线不是从常识里来的，它是从本案里来的；本案未判，则那条线的正当性未定。至于它在未定的情况下该不该继续用、怎么用——那是另一个领域的问题，而且很可能答案是“继续用”，因为制度需要一条线胜过需要一条正确的线。本书对此没有异议。

七、本章的限制

三条限制，与前几章同类，但这一章需要写得更硬，因为法律领域的误用代价更高。

限制一：全部以三条条款通过为前提。条款一在首跑中未能分辨，条款二三未跑。

限制二：本书的现场是模型，不是人，更不是制度。第七十七章那一记在这里原样适用：本书的论证是反例结构，它取消的是一条一般原则的先天地位，不是给出了另一条一般原则。任何把本书的结论直接搬到人类创造活动上的推理，都超出了本书的范围。

限制三：本书不主张这是好消息。第八十一章第五条在这一栏尤其适用。若“被发现的东西不属于任何人”这一步变得有条件，其后果不是更公平，而是更不确定——一条原本清晰的界线变得需要逐案判断，而逐案判断的成本由谁承担、按什么标准承担，这些都是本书不处理、也无力处理的问题。

指出一个制度的地基未定，与主张那个制度应当改变，是两件事。本书只做前者。

下一章转到另一侧，写若判决倒向先在论，本书承认什么。那一章的篇幅不比这一侧少。

一、把这一侧也写完

前四章写的是一侧。这一章写另一侧，篇幅不比那一侧少——这是第五十九章第二条防作弊纪律在本编的形态：不利读数与有利读数同等篇幅。

一本书若把自己希望的那一侧写四章、把不希望的那一侧写半页，那么它前四章的可信度也要打折。

二、若条款一判负，本书承认三件事

条款一判负的条件写在第五十四章第五节：不可消解度的置信上界不显著区别于噪声基线；具体形态是消去对称性之后的路径散度随规模衰减到噪声水平。

若如此，本书承认：

其一，在以固定材料为输入的知识形成中，路径不进入结果的规定。这是第五十八章第一条写死的让步，一字不改。

其二，表征收敛假说在其强形式上成立。即第六十八章第三节那个取胜条件被满足：对齐度的极限是完全对齐，而不是某个正的不一致水平。

其三，机器学习中所观察到的一切路径依赖都是计算性的——它是求解器的性质，而不是结果的性质。按第五十二章的定义，这意味着全部差异都属于“你还没走到”，没有一样属于“那里没有那个东西”。

三条承认里，第三条最重。它不只是本书输掉一场，它还要求本书把第五十二章那整根承重柱的实际适用范围缩到零：区分仍然成立，但世界上只有一边有实例。

三、这个承认不是小事，它的正面后果同样重大

这一节是本章的要点，而且它必须被写得像样，不能写成一次礼节性的让步。

若条款一判负，被建立起来的东西是这样的：

知识具有一种可被工程验证的稳健性——不同的路径、不同的共同体、不同的历史，只要材料与判准相同，终将达到同一处。

这是自启蒙以来科学的自我形象。它一直是一个哲学主张，靠论证、靠直觉、靠“科学毕竟有效”这样的间接理由支撑。

若条款一判负，它将第一次拥有一个在可控系统中的实验支持。

这件事的分量要说清楚。两千年来，先在论从未被实验支持过——它被大量的成功实践间接支持，但那些支持全部有第二编所说的那个毛病：产物层观察等价，成功的实践与两种解释都相容。一次在可重跑、可缩放、可干预的系统上得到的正面读数，是另一回事。它把一个默认立场变成了一个被验证的立场。

而一个被验证的默认立场，比一个未被验证的默认立场强得多——它此后可以被引用、可以被外推、可以在别的领域被当作先例。

因此这句话要原样写下来：

若读数如此，本书乐于交出这个结果，因为那时被建立的东西比本书想建立的更重要。

这不是风度。它是一个判断：一个被工程验证过的“知识稳健性”，其价值高于本书证明路径进入规定所能带来的价值。

四、本书唯一坚持的一条

在上面的承认之后，本书只坚持一件事：

这个承认必须来自不可消解度的置信区间，而不是来自趋势图上的一条向下的线。

理由是第六十九章整章的内容：一个衰减到零的量与一个衰减到正常数的量，在中间规模上几乎无法分辨；区分它们需要的是足够的跨度、冻结的拟合族、区间、以及事先声明的外推范围。

而第六十九章第三节已经写过，这条要求对本书自己同样有效，并且本书已经为它付过代价——首跑的行为通道单调下降，正是“看起来在收敛”的典型形状，而本书没有因此判自己输，也没有因此判自己赢。

同一条纪律，两侧适用。本书不会因为一条向下的线就交出这一侧的承认，正如本书没有因为一条持平的线就宣布那一侧的胜利。

五、若条款二判负，本书承认什么

条款一判负是最重的一条。还有两条较轻的，一并写完。

若条款一通过而条款二判负——剩余差异可由语料统计量解释，或对齐后的连通率随规模趋于——本书按第五十八章第二条让步：把核心命题降级为“路径影响到达解集中的哪一个成员，但不影响解集本身”。

并且承认：这个降级后的主张对本案不构成判决。它与先在论完全相容，甚至是先在论的标准图景之一。本书不得把它包装成“部分胜利”。

这一条要补一句，因为它与第七十六章直接相关：条款二判负，意味着第七十六章那四个地址里，第一个或第四个被证实了——那个先在的集合确实可以被写出来，而且写出来的描述覆盖了实际到达的结果。本书在那一章说“向它要一个地址”，若地址真的被给出，本书就该认账。

若条款一、二通过而条款三判负——有人在替代路径族上以十倍预算做出了那个性质——本书保留“路径进入规定”，放弃“存在只有某条路径才到得了的结果”这一更强形式。这一条是三条里唯一一只损失一部分的。

六、若倒向先在论，本书这套方法学仍然留下什么

本书若在判据上输掉，交出的不只是一个结论。还有一批东西不随结论一起倒，它们值得单独清点，因为这是本书在那一侧唯一还能留下的东西。

其一，比值与噪声基线这条纪律。第八十章第二节那句话——任何不给出噪声基线的路径依赖读数都不构成证据——对两侧同等有效。而按同一章第六节，今天这条纪律在两侧都没有被普遍执行：造成论那一侧的多种子材料多数没有归一化，先在论那一侧的对齐度读数同样很少报告“同一路径内的正常波动有多大”。若本书倒下，这条纪律仍应当立着。

其二，双通道不得合成。第五十五章第四条。它的价值与判决方向无关：两个读数口给出相反方向时，合成会把最有信息量的那件事抹平。这一条在首跑里是三步防护中唯一真正起了作用的一步。

其三，“未能分辨”作为一个合法结论。第六十四章。一套只有“通过”和“判负”两个取值的判据，等于强迫每次实验给出方向，而实验并不总有方向。这一条同样与判决方向无关。

其四，那份被自己证伪的冻结项。第六十五章记录的是一次制度失效——预注册保护的是“事后不许改判据”，它不保护“事前把判据写错”。这件事的价值不在本案，在任何做预注册的地方。

四样里没有一样是“造成论的方法”。它们是测量路径效应所需要的方法，而无论最终判决落在哪一侧，那个测量都要被做一次。

因此这一节的结论是：若条款一判负，本书的主张倒下，而本书的工序留下。这不是自我安慰——第五十八章第一条的让步一字不减，核心命题该放弃就放弃。它只是把两件可分的东西分开：主张可以错，工序可以对。

七、若倒向先在论，第三编那二十六章算什么

一个具体的问题，值得单独答一句。

第三编用二十六章把两千年的谱系按“缺哪台装置”重排。这个重排的组织原则，是假定那台装置真的能判。若条款一判负，那个组织原则还成立吗？

成立，而且成立得更好。

第三编做的事情不是“证明他们都缺装置所以都没判出来”，而是“指出每个人的主张在装置到手之后会变成什么可测命题”。这件工作与判决方向无关：一个被翻译成可测命题的主张，无论最后被判成立还是判不成立，翻译本身都是有效的。

事实上，若条款一判负，第三编的价值会更显眼——它会成为一份记录：这些人各自主张的东西，在第一次被真的测过之后，结果是这样。一份从未被兑现的翻译，与一份被兑现并判负的翻译，后者更有分量。

这一节的一般形式是：把命题翻成可测形式，其价值不取决于测出来是哪一边。这句话本该是显然的，但在实践中常被忘记——人们倾向于认为某个立场做的准备工作，会随那个立场一起失效。第五编与第六编同理。

八、首跑之后，这一侧的处境并没有变差

这一节是本书不愿意写、但按纪律必须写的。

有人可能会以为，首跑的表征通道不向零衰减，多少对这一侧不利。不是这样。

理由一：首跑的结论是“未能分辨”，而未能分辨对两侧同等无效。第六十四章论证过它是一个结论，但那个结论的内容是“本跑判不出来”，不是“本跑略微倾向于某一侧”。

理由二：首跑的行为通道单调下降，方向正是这一侧。它没有满足判负条件的后半条（在最大规模上仍是基线的两倍以上），但它走在那个方向上。

理由三，最重要的一条：按第八十章第五、六节，首跑的三步防护只兑现了一步——基线是代理且跨规模不可比，探针全部自造且结论对配比高度敏感；更狠的是，两通道的不一致目前无法与“两把尺子量了不同的东西”区分开。这些缺陷削弱的是本书这一侧的读数，不是对手那一侧的。

三条加起来：首跑之后，先在论的处境如果有变化，是变好而不是变坏。这句话写在这里，因为一本在自己有读数之后仍然如实报告对手处境的书，它的其余部分才值得读。

九、为什么两侧都写完之后，本书仍然不下注

写完两侧，一个自然的问题是：那么本书自己押哪一边？

本书的正面主张在第八十一章附二写着，一字未改：存在构成性路径依赖。这是本书的主张，不是本书的预测。

两者的区别是：主张是要被检验的东西，预测是对检验结果的猜测。本书提出主张，并交出检验它的判据与败绩条件；本书不对检验结果下注，理由在第八十一章第五条——一本因为喜欢某个结论而去论证它的书，它的判据不可信。

而本编两侧各写一遍，正是把这件事做实：若本书只在乎赢，这一章不会存在。

下一章处理一条比判决本身更一般的观察。

第八十七章 更长的一条：可判性本身是历史的

一、不是他们不够聪明

两千年里，这个问题不是没有被聪明人想过。想它的是柏拉图、亚里士多德、康德、黑格尔、皮亚杰、库恩、哈金——第三编用二十六章把这份名单按“缺哪台装置”重排过。

它不可判，不是因为他们不够聪明。

是因为判决它所需的干预，在他们手上没有对象可施加。

他们能做的只有两件事：

其一，整理产物。把已经形成的知识拿来比较、分类、追溯它的来历。这条路的问题在第二编第七章：产物层观察等价——两种解释对同一批产物给出相同的预期，因此产物不含分辨力。

其二，构造思想实验。“把演化的录像带倒回去重放一遍”这类设问，形式上完全正确，它问的正是本案该问的东西。但它不可执行——没有录像带，也没有重放的装置。

一条零分辨力，一条不可执行。两千年的僵局是这两条的合成。

二、一个不常被说出的推论

由上一节直接得到一个推论，它比本案本身更一般：

一个问题是不是“哲学问题”，可能不是它的本性，而是它当下的处境。

这句话听起来像是在贬低哲学，其实不是。它说的是分类的依据。

燃素、以太、生命力，都曾是在思辨中争论不休的题目。关于它们的争论有完整的论证结构、有各自的拥护者、有看起来无法调和的分歧。后来它们被仪器判了——不是被更好的论证判的，是被一台此前不存在的装置判的。

判掉它们的那些装置，在争论最激烈的时候并不存在。于是那些问题在当时确实是“哲学问题”，而在装置出现之后确实不是了。这个变化不发生在问题的内容上，发生在问题与可用手段的关系上。

本案的特殊之处在于，判它所需的不是——一台更精密的测量仪器。

更精密的测量，解决的是“看不清”的问题。本案的困难不是看不清——两千年来，没有人抱怨过材料不够清楚。本案的困难是只有一份样本：一段知识形成的历史只发生一次，而判决需要的是同一段过程的第二次、第三次、第一百次。

因此本案需要的是：

一台能把形成过程整体重跑的装置。

这种装置在自然界里不存在——自然界不提供“同一段历史再来一遍”。它只能被造出来，而造出来是很晚近的事。

三、推到一般形式

于是可以把本书的诊断推到它的一般形式：

有一类问题，其不可判性来源于“过程不可重跑”。对这类问题，进展不来自更强的论证，而来自出现一个可重跑该过程的人工系统。

这条观察本身是可检验的。

若它为真，那么随着可重跑系统在更多领域出现——演化、经济、语言变迁、社会制度的仿真——我们应当看到另一批长期悬置的“哲学问题”陆续改变类型。它们不会被解决，它们会从“靠论证争”变成“靠读数争”。

本书不试图列举它们，只把这条判据留在这里。

要写明这条观察的两处限制。

限制一：可重跑不等于可判。一个能重跑的人工系统，必须同时满足第四编第四十条那四条性质——可重跑、可干预、可消融、可观测——而且它的对象必须真的是那个问题所关心的东西。第四编逐条排除了量子测量、实验演化、早期人工生命，用的正是这一条。一个领域有了仿真，不等于那个领域的哲学问题就近了。

限制二：重跑的系统本身会带来新的不可判问题。本书自己就是例子：首跑暴露出的那两处未定——噪声基线的定义、探针配比——都不是原问题里有的，是重跑装置带来的。装置解决一层不可判，同时制造另一层。这不取消第一层的进展，但它意味着”有了装置就能判”是一句过于乐观的话。

四、还有第二种不可判：关切从未指向它

上一节说的不可判来自”过程不可重跑”。第七十四章第八节与第八十四章第四节记过另一种，它应当在这里与第一种并列。

那一种是：问题从未被提出来，不是因为它难，而是因为没有人需要它的答案。

三批多种子材料的作者，问的都是流水线可靠性；教育研究里关于次序的工作，因变量几乎全是总分或效率。在这两处，“差异会不会随资源消失”与”次序会不会造成结构不同的知识”这两个问题都没有被问——它们不是被回答错了，是被漏过了。

把两种不可判并排：

	来源	解法
第一种	过程不可重跑	出现一个可重跑的人工
第二种	关切从未指向它	判准的覆盖面被扩充

第二种比第一种便宜得多——扩充判准不需要新装置，只需要有人提出那个问题并被认为值得做。但它也更隐蔽：第一种不可判是可见的，人们知道自己判不了；第二种的不可判是不可见的，人们不知道有什么没被问。

本案同时受这两种约束。第一种由大模型的出现部分解除；第二种至今没有解除——按第八十四章第四节，这个领域的判准里”到达的是哪一种”那一栏仍然是空的。

四、这条观察的一个反例检验

第三节说这条观察本身是可检验的，但只说了正面：随着可重跑系统出现，应当看到一批问题改变类型。正面的检验太慢——要等几十年。本节给一个更快的反面检验。

反面检验是：找一个已经有了可重跑人工系统、而其哲学争论却毫无变化的领域。

若这样的领域存在且不止一个，那么”可重跑带来进展”这条观察就要被重估——它也许只是把不可判从一处挪到了另一处，而不是解除了不可判。

本书不做这项检查，因为它需要跨领域的调查，超出本书的能力。但可以先写清检查的格式，与第八十二章第四节同一个思路：

其一，那个人工系统必须真的满足四条性质（可重跑、可干预、可消融、可观测），而不只是“有仿真”。第四编逐条排除量子测量、实验演化、早期人工生命，用的正是这一条。一个不满足四条的系统，其所在领域的争论没有变化，不构成反例。

其二，那个系统的对象必须真的是争论所关心的东西。这一条与第七十七章那一记同源：一个能重跑但重跑的是别的东西的系统，不能用来判原来的争论。

其三，“毫无变化”要写成可观察的：争论的双方是否仍然只用论证而不用读数；是否出现了带量与判负条件的表述；是否有人写下过“若读数如此我方认输”。第三条最硬——一个领域若从未有人写下自己的败绩条件，那里的争论就还没有改变类型，无论它用了多少仿真。

这项检查的结果对本书两侧都有用：若找不到反例，这条观察得到支持；若反例成片，那么本书对自己所处位置的估计就过于乐观了——大模型的出现也许并没有把本案从第一类不可判里捞出来，只是把它换了个地方悬着。

而按第三节的限制二，本书已经知道这件事至少部分地发生了：首跑暴露的那两处未定——噪声基线的定义、探针配比——都是装置带来的新的不可判。区别在于它们是可修的，而原问题的不可判是不可修的——历史不能重跑。这个区别是本书认为进展确实发生了的全部理由，而它比“有了装置就能判”弱得多。

五、还有第三种：判准本身在变

前两种不可判，一种来自过程不可重跑，一种来自关切从未指向它。还有第三种，它在第七十七章第五节出现过一次，应当在这里与前两种并列，因为它是三种里本书最没有办法的一种。

第三种是：所问的那个问题，其判准本身在随过程变化。

本书的全套翻译（第五编）建立在固定 C、A、L 之上。固定了它们，才有“结果是否唯一”这个问句。若 L 自己在变——什么算一个好的解释、什么算充分的证据、什么问题被解决了，这些随着过程本身在改——那么那个问句在那里无从提起。

这不是说先在论在那里赢了。是说本案在那里需要另一套判据，而本书没有。

三种并排：

	来源	解法	本书的处境
第一种	过程不可重跑	出现可重跑的人工系统	已部分解除
第二种	关切从未指向它	判准的覆盖面被扩充	未解除，但便宜
第三种	判准本身在变	未知	无解法

第三种最难，而且难在一个具体的地方：前两种的解法都是“加一样东西”——加一台装置，或加一个问题。第三种要求的是改判据的形式本身——一套能处理“约束在变”的翻译，而本书第五编那套翻译从第一步起就预设了约束不变。

本书对第三种能做的只有两件事，都很弱：

其一，把本书的适用范围明写出来。第八十一章第二条的边界因此要补一句：本书的反例结构适用于判准固定的那一类过程。这个限制是真实的，而且它比“本书的现场是模型不是人”那条限制更靠里——后者是关于对象的，前者是关于问题结构的。

其二，指出第三种不可判可能有它自己的装置。若将来出现一种可重跑、且判准本身也被建模并可被干预的系统，那么第三种也许会落到第一种의 框架里。这是一句猜测，本书不为它提供任何理由，只把它留在这里作为一个可能的方向。

七、本书自身在这条观察之内

最后一句必须说，因为它关系到本书自己的位置。

本书所依赖的这台装置，它自己也是被造出来的——被一条特定的技术路径、特定的产业结构、特定的资助方式造出来。第八十四章第五节已经写过：本书能提出的问题，被本书所能拿到的工具限定着。

若判决倒向造成论，那么这个判决本身也在它所主张的范围之内：

它是从这条路径上得到的判决。

这不是一个自我瓦解的悖论。任何把自身包含在内的主张都要接受这一层，而接受它不等于失效——一条说“路径进入结果”的结论，若它自己也是从某条路径上来的，这与它为真并不冲突；它只是意味着这个结论自己也带着来路。

本书对此的处理不是回避，而是把它写进判据。正因为如此：

- 条款的判负条件必须事先写死（第五十八章）。

- 读数必须公开（第六十一章）。
- 预注册必须在接触数据之前完成（第五十九章、第六十章）。

一句话：

一个承认自身有来路的立场，靠程序而不是靠超然来维持可信。

这句话是本书全部方法学的根。第五十九章那套冻结与防作弊的做法，看起来像是为了对付别人的怀疑；实际上它是为了对付一个更难对付的东西——本书自己也在它所描述的那个机制之内。一个站在过程之外的观察者可以靠超然取信；本书不在外面，因此只能靠把自己的每一步都写下来。

下一章是结语。

结语

结语 美诺问题的实验回答

一、回到那个角落

回到开头那个角落。

美诺问苏格拉底：你怎么能去寻找你不知道的东西？若你已经知道它，就不必寻找；若你不知道它，你又凭什么认出它？

柏拉图的回答是：你其实早就知道，只是忘了。寻找不过是回忆。

这个回答统治了两千年。不是因为它令人信服——它从来都不十分令人信服，连柏拉图自己也是借一个神话把它说出来的。它统治了两千年，是因为没有人能够用任何观察把它和它的对手分开。

第一编写的是这个角落的形状，第二编写的是三道闸为什么关着，第三编写的是二十六个人各自缺哪一台装置。本书全部的工作，就是回答一个问题：那台装置到了没有。

二、本书给出的是条件，不是回答

本书给出的不是美诺问题的答案。本书给出的是那个答案的条件。

它可以这样陈述：

把寻找的过程本身放到台面上来，把它重跑一百次，每次只换走法不换材料，然后看到达的地方是不是同一处。

如果是同一处，柏拉图对。

如果不是同一处，而且这个“不是”不随你走得更久、更远、更有力而消失，那么被寻找的东西就不是一直在那里等着——它有一部分是在寻找中被做成的。

两千年里，这句话只能作为立场来主张。

现在它第一次可以作为读数来等待。

三、本书有一次读数，而那次读数什么也没判出来

前面那句话听起来像是一个漂亮的收尾。本节要把它按住。

本书有一次读数。

首跑执行了：二十四个公开检查点，四个规模，每规模五条只在路径上不同的运行，112 条执行前冻结的探针，两个通道。

读数是：表征距离在四个规模上不向零衰减；行为距离单调下降，但在最大规模上仍是同轨迹基线的两倍以上。两个通道结论不一致。

按执行前写死的第三款规则，判“未能分辨”。

不是“倾向于支持”。不是“初步证据表明”。不是“总体而言偏向”。第六十四章用整章论证了为什么这不是弃权而是一个结论，以及为什么只报一个通道的两种写法都能成文、两种都是作弊。

而第八十章第六节又把这个结论往下修了一层：两通道的不一致，目前无法与“两把尺子量了不同的东西”区分开。首跑的三步防护只兑现了一步。

所以要把话说到底：

本书有一次读数，而那次读数判不出任何东西，并且本书知道它为什么判不出来。

最后那半句是本书唯一敢多说的一句。第六十五章、第六十六章、第八十章第五节，逐条写明了首跑为什么判不出来——规模点不够、噪声基线跨规模不可比、探针全部自造且结论对配比高度敏感。三条都具体，三条都可修，三条都已列入下一跑的清单。

四、本书交出的全部库存

把交出的东西清点一次，不多不少。

一条正面主张：在大规模语言模型的训练中，存在构成性路径依赖。

一个承重区分：计算性路径依赖与构成性路径依赖——“你还没走到”与“从这条路走过去，那里没有那个东西”。

三条条款：规模消解检验、语料可归约性、可达集不足。

四个量：路径散度、不可消解度、可归约份额、标定不可达。

六条败绩条件：第五十八章四条，第五十五章与第七十一章各补一条。

一份预注册与它的冻结值，以及全部脚本与原始读数。

一次未能分辨的首跑。

一份修订清单：六条，其中第一条是首跑自己把自己的判据证伪的产物。

一记接不住的反击：语境内的临时程序究竟是形成还是激活，本书给不出界限，并说明了为什么这一记绕开了本书换现场的全部三个理由。

六件本书不主张的事。

这就是全部。没有别的。

五、为什么这是唯一诚实的交付方式

本书没有把这份库存写成一个结论，理由在这里说完。

一个悬置了两千年的问题，不应该被任何人用一本书宣布解决。它应该被交给一台能判它的装置，并且事先说清楚，怎样算输。

这句话里有三个部分，每一部分都对应本书的一道工序。

“交给一台装置”——对应第四编：为什么是大模型，以及为什么不是量子测量、实验演化、早期人工生命。

“能判它”——对应第五编与第六编：把形而上学命题翻成可测命题，再把可测命题变成带量、带判负条件的条款。

“事先说清楚怎样算输”——对应第七编与第九编：预注册、冻结哈希、三条防作弊纪律、六条败绩条件、以及一章专写本书接不住的那一记。

三道工序做完之后，剩下的事不归本书管。剩下的事是跑。

六、跑第二次需要什么

结语本该在这里收，但收之前要把那张清单落到实处，否则“有人按那张清单去跑第二次”就只是一句期待。

需要的不是新的哲学，也不是新的算法。第六十六章那六条里，没有一条要求任何理论突破。逐条看它们各自卡在哪里：

卡在设备上的两条：补规模点与换基线中的第二种修法，都只需要更大的机器，不需要重新训练。首跑在单核、三吉字节内存的条件下做不了，在一台常规工作站上做得了。这两条的门槛是钱，不是本事。

几乎免费的三条：保留逐对读数、保留逐层读数、并行报告自造探针与第三方基准。这三条不增加任何前向计算，首跑没做是设计疏忽。这三条的门槛是记得做。

真正贵的一条：正式的次序可交换性实验，需要从头训练成对的次序反转模型，且组内共享条件必须严格对齐。这一条的门槛是训练预算。

按第六十六章第六节的建议：先把前两档做完，再决定第三档做不做。前两档做完之后，首跑的三条局限解决了两条，第三条也至少被改善到可用。在那个状态下重跑一次条款一，很可能就能给出通过或判负，而不是又一次未能分辨。

还要说一句关于人的：这件事不需要一个哲学家，也不需要一个理论家。它需要一个愿意照着一份写死的预注册去跑、并且在读数不合自己心意时照登的人。本书全部的方法学工序——冻结、哈希、双通道、报告不利读数、不以趋势代极限——都是为了让这件事不依赖于跑它的人有多超然。

一个不需要超然的人也能做对的程序，比一个需要超然的人才能做对的程序，更可能被做第二次。

七、最后一句

本书最想说的话，第五十二章已经说过一次，这里不重复。

要说的是另一句，它是首跑之后才有资格说的：

两千年里这道题判不了，缺的不是论据；今天它仍然没被判掉，缺的也不是论据。

缺的是把装置用对——而这一次，我们至少知道用错在哪里。

第一次跑没有判出来。它交出来的不是一个方向，是一张清单：换基线、补规模点、换探针、把次序可交换性做成正式实验、判据随基线一并修订、在前两条完成之前不报告不可消解度。

六条都具体。六条都不需要新的哲学。

一个两千年的问题走到这一步，已经不再需要更聪明的人来想它了。它需要的是有人按那张清单去跑第二次。

本书到此为止。

参考书目

本书的引用纪律写在第六十七章第六节：凡未能核到原文的，一律不写进正文。本书目按同一标准编列——只收正文实际依据的文献，不收为充实篇幅而罗列的条目。

第三编所处理的二十六位思想者，其著作按通行版本引用，此处只列书名，不列具体译本与页码；正文中凡引用其主张之处，均按各自原著的核心表述复述，未转引二手评述。

一、古典与近代（第一、二、三编）

柏拉图《美诺》《斐多》《理想国》亚里士多德《形而上学》《后分析篇》奥卡姆《逻辑大全》，及唯名论与实在论之争的相关文本 培根《新工具》笛卡尔《谈谈方法》《第一哲学沉思集》维柯《新科学》休谟《人性论》《人类理解研究》康德《纯粹理性批判》黑格尔《精神现象学》《逻辑学》

二、十九至二十世纪（第三编）

马赫《感觉的分析》《力学及其发展的批判历史概论》彭加勒《科学与假设》杜恒《物理学理论的目的与结构》蒯因《经验论的两个教条》《语词和对象》波普尔《科学发现的逻辑》《猜想与反驳》皮亚杰《发生认识论原理》及守恒、可逆运算相关实验报告 维果茨基《思维与语言》及中介工具相关著述 乔姆斯基 关于普遍语法与语言习得装置的相关著作 列维-斯特劳斯 关于神话与亲属制度的结构分析著作

三、科学哲学与实践转向（第二、三编）

库恩《科学革命的结构》拉卡托斯《证伪与科学研究纲领方法论》费耶阿本德《反对方法》布鲁尔《知识和社会意象》（强纲领四原则）拉图尔 关于实验室生活与行动者网络的相关著作 哈金《表征与干预》卡特赖特《物理定律是如何撒谎的》皮克林《实践的冲撞》《建构夸克》伍德沃德《让事情发生：因果解释理论》

四、演化与重放（第三、四编）

古尔德《奇妙的生命》——伯吉斯页岩与“重放录像带” 康威·莫里斯 关于趋同演化的相关著作 长期演化实验与重放实验的相关报告

五、机器学习（第四、七、八编）

表征收敛 Huh, M., Cheung, B., Wang, T., & Isola, P. *Position: The Platonic Representation Hypothesis*. ICML 2024, PMLR 235:20617–20642. arXiv:2405.07987.

彩票假说与回绕 Frankle, J., & Carbin, M. *The Lottery Ticket Hypothesis: Finding Sparse, Trainable Neural Networks*. ICLR 2019. Frankle, J., Dziugaite, G. K., Roy, D. M., & Carbin, M. *Stabilizing the Lottery Ticket Hypothesis*. arXiv:1903.01611.

Frankle, J., Dziugaite, G. K., Roy, D. M., & Carbin, M. *Linear Mode Connectivity and the Lottery Ticket Hypothesis*. ICML 2020, PMLR 119:3259–3269. 规模失效的报告：Liu et al. 2018；Gale et al. 2019.

模式连通与置换对齐 Entezari, R., Sedghi, H., Saukh, O., & Neyshabur, B. *The Role of Permutation Invariance in Linear Mode Connectivity of Neural Networks*. ICLR 2022. arXiv:2110.06296. Ainsworth, S. K., Hayase, J., & Srinivasa, S. *Git Re-Basin: Merging Models modulo Permutation Symmetries*. ICLR 2023. arXiv:2209.04836. Jordan, K., Sedghi, H., Saukh, O., Entezari, R., & Neyshabur, B. *REPAIR: REnormalizing Permuted Activations for Interpolation Repair*. ICLR 2023. 反面材料：Juneja et al. 2022（线性模式连通并非总是成立）。

缩放律 Kaplan, J., et al. *Scaling Laws for Neural Language Models*. 2020. Hoffmann, J., et al. *Training Compute-Optimal Large Language Models*. 2022. 复现与勘误：Besiroglu et al. 2024.

相变、涌现与机制 Power, A., et al. *Grokking: Generalization Beyond Overfitting on Small Algorithmic Datasets*. 2022. Nanda, N., Chan, L., Lieberum, T., Smith, J., & Steinhardt, J. *Progress Measures for Grokking via Mechanistic Interpretability*. ICLR 2023. Olsson, C., et al. *In-context Learning and Induction Heads*. 2022. Wei, J., et al. *Emergent Abilities of Large Language Models*. TMLR 2022. Schaeffer, R., Miranda, B., & Koyejo, S. *Are Emergent Abilities of Large Language Models a Mirage?* NeurIPS 2023. arXiv:2304.15004. Zhao, R., Qin, T., Alvarez-Melis, D., Kakade, S., & Saphra, N. *Distributional Scaling Laws for Emergent Capabilities*. arXiv:2502.17356.

欠规定性与多种子材料 D'Amour, A., et al. *Underspecification Presents Challenges for Credibility in Modern Machine Learning*. JMLR 2022, 23(226):1–61. arXiv:2011.03395. Sellam, T., et al. *The MultiBERTs: BERT Reproductions for Robustness Analysis*. ICLR 2022. arXiv:2106.16163. van der Wal, O., Lesci, P., Müller-Eberstein, M., Saphra, N., Schoelkopf, H., Zuidema, W., & Biderman, S. *PolyPythias: Stability and Outliers across Fifty Language Model Pre-Training Runs*. ICLR 2025. arXiv:2503.09543. Biderman, S., et al. *Pythia: A Suite for Analyzing Large Language*

关于本书目的三点说明

其一，第五节所列的每一条，本书都核到过原文或原文摘要，并按第六十七章第六节的标准，在正文中复述其主张时不使用二手评述的转述。

其二，第一至四节所列的古典著作，本书只在第三编按“缺哪台装置”的框架处理其核心主张，不做文本学考订，也不介入其学派内部的解释争论。凡本书未能核到原文的具体论断，正文中一律未写。

其三，本书目不含首跑所用的材料与工具。那些在第六十一章与附四有完整记录：公开检查点系列的名称与版本号、探针集的摘要值、四个脚本与两份原始读数，全部与本书一并公开。它们不是参考文献，是实验器材。

附录

附一 量的定义汇总表

本书全部的量集中在这里。每一个量给出记号、名称、定义、两侧的预测，以及它的现状。

记号	名称	定义	先在论预测	造成论预测	现状
$\Delta(N)$	路径散度	规模 N 处，只在路径上不同的运行之间的结果距离期望	随 N 衰减至噪声	衰减至正常数	首跑已测，四个规模点
κ	不可消解度	$\Delta(N)$ 的极限（有限规模下由衰减律外推）	$\kappa = 0$	$\kappa > 0$	未报告
ρ	可归约份额	路径间结果差异中，可由语料、架构、判准的量预测的方差份额	$\rho - 1$	$1 - \rho$ 稳定为正	未跑
—	对齐后连通率	消去置换后，成对解之间线性模式连通的比例	-1	不趋于 1	未跑
—	标定不可达	性质 Q 在路径族 P_1 中出现率 $> q$ ，在 P_2	不存在	存在	未跑

记号	名称	定义	先在论预测	造成论预测	现状
		中十倍预 算下 $< q'$			
k	先在性生效时点	子网络对 随机梯度 噪声变得 稳定的训 练步数	随规模趋 于零	稳定为正 或增大	未跑，新 增候选

关于 k 的一条纪律，写在这里以免被漏读：本书全书不出现 k 的任何数值。首跑的四个规模点不支持外推，而第六十六章第五节规定：在换基线与补规模点两条完成之前，下一跑也不应报告它。

关于最后一行：先在性生效时点 k 不在原三条条款之内，它是第七十章第七节从彩票假说的修复史里逼出来的新检验，已列为下一跑的预注册候选。它在这里列出，是为了与其余五个量一并接受同一套纪律——没有读数就标明没有读数。

六个量之间的关系与读数顺序

六个量不是平行的，它们之间有依赖，而依赖决定了跑的顺序。

$\Delta(N) - k$ ： k 是 Δ 的极限，因此必须先有一列 Δ 才谈得上 k 。而“一列”要多长，由第六十九章第二节那四条决定——跨度必须让窗口右端进入待区分的量级。首跑只有四个点，因此有 Δ 无 k 。

$k - \rho$ ：条款二是在条款一通过之后才有意义的。若差异本来就趋于零，“剩下的差异能否被语料写出来”这个问题没有对象。因此 ρ 的测量应当排在 k 之后。

$\rho -$ 标定不可达：条款三最贵，且若前两条任一判负，它不必跑（第五十七章第六节）。

k 与前五个都正交：先在性生效时点不依赖三条条款中的任何一条，它可以独立测，而且它是六个量里唯一一个测“时间”而不测“差异”的。这也是它被单列为下一跑预注册候选的理由。

由此得到读数顺序，它与第六十六章那份清单一致：

换基线 - 补规模点 - 重测 Δ 并首次报告 k - 若通过，测 ρ 与连通率 - 若通过，才考虑标定不可达。 k 可在任一阶段并行。

最后一条纪律：任何一步未完成而报告下一步的量，都属于第五十章第二处陷阱（事后定义）的变体——它把一个尚未取得资格的读数提前计入账目。

附二 结果距离 d 的构造规范

本规范给出 d 的构造要求，并在每一条后标明首跑的实际执行与偏离。

一、六条构造要求

1. 层选取。 在每个模型上取预先指定的相对深度位置（如总层数的 25%、50%、75%、100%），不按绝对层号，以保证跨规模可比。

首跑执行： 按此执行，四个相对深度，向上取整。

2. 对称性消去。 先做神经元置换对齐（权重匹配或激活匹配），再计算表征相似度；缩放对称通过归一化消去。

首跑执行： 采用对置换、正交变换与各向同性缩放本身就不变的相似度度量，因而不另做显式对齐。并记一条工程教训：既然度量已有这些不变性，就不应再加一层对齐——那不会更干净，只会引入新的自由参数。

3. 表征距离。 在同一批冻结探针输入上取激活，计算对齐后的相似度距离，多层取平均。

首跑执行： 按此执行。并记一条改进项：本跑只保留了四层平均，未保留逐层读数，因而深度剖面不可考（第六十二章第六节）。下一跑必须保留逐层读数。

4. 行为距离。 在冻结的分布外探针集合上比较输出分布，取对称散度。

首跑执行： 取各探针末位置的下一词元分布之间的对称散度。并记一条限制：只取末位置一个词元，因而“行为”被窄化为“单步预测”（第六十三章第七节）。下一跑应在单步之外加测至少一种多步行为。

5. 合成。 d 取表征距离与行为距离的预先指定加权和，权重在接触数据前冻结。

此条作废。理由见第五十五章第四条硬规定与第六十四章第四节：合成会把两个方向相反的读数按一个无理由的权重抹平，从而替作者做出裁决，且裁决不可见。

改为：两通道分别报告、分别对照各自的判负条件、分别出结论；两者不一致时结论写“未能分辨”。

6. 噪声基线。同种子、同数据次序、仅硬件数值非确定性造成的重跑之间的 d 分布，作为零点。

此条是正确的，但首跑没有执行。

首跑实际使用：同一训练轨迹内相邻检查点之间的距离（代理，因算力所限）。

后果：该代理跨规模不可比——它测到的是训练在该规模该时刻的推进速率，而速率随规模变化。且“相邻”所含的间隔本身是一个自由参数。详见第六十五章。

下一跑必须执行：改用同种子重训，或同一轨迹内多对等距检查点距离分布的下界估计。

二、三条使用规定

规定一：报告分母。凡使用任何归一化，把分子、分母、比值三者分别列出。这一条零成本，而它能把一整类隐形错误变成可见的（第五十章第四节）。

规定二：保留逐对读数。不只报告均值与标准差。首跑未保留，因而最大规模上那个异常大的标准差无法进一步分析。

规定三：不得用任务分数。分数只能作为附属读数报告，用以回答“这些模型是否可比”这一前提性问题，不进入 d （第五十五章第一条）。

附三 预注册模板

本模板可被他人直接套用。每一节后附一句说明它防的是什么。

【一】材料

- 模型族与具体标识（名称、版本号）：
- 固定项（语料、架构、判准、超参）：
- 变动项（路径变量，逐项列出）：
- 噪声基线材料：

防的是：事后更换材料，或事后声称某一项“本来就该固定”。

【二】探针集

- 分布内组：来源、筛选规则、数量、截断长度
- 分布外组：逐类给出构造规则或第三方基准出处、数量

- 冻结方式：写入文件，计算摘要值，公开其前若干位
- 采样位置规则：

*防的是：*看到读数后增删探针。注意它防不住构造时的无意识偏好——因此分布外探针应尽量取自与本命题无关的既有公开基准。

【三】距离

- 层选取规则：
- 表征距离的度量，及其不变性说明：
- 行为距离的定义：
- 两通道是否合成：按附二第 5 条，不得合成。

*防的是：*事后换一把尺子。

【四】量与判据

- 待测量的定义：
- 噪声基线的定义：
- 归一化方式（若有）：
- 通过条件：
- 判负条件：
- 未能分辨的条件：

*防的是：*事后构造一组自己恰好没有触发的条件。第三款（未能分辨）必须写——一套只有通过判负两个取值的判据，等于强迫每次实验给出方向，而实验并不总有方向（第六十四章第三节）。

【五】事先写明的局限

逐条列出已知的局限，特别是：

- 规模点或样本量是否足以支持外推；
- 所用代理量的偏向方向；
- 最脆弱的自由参数是哪一个。

*防的是：*事后把局限说成“已经考虑过了”。

【六】执行前修订

在接触任何读数之前所做的改动，逐条追加于此，注明改动时间早于任何数据接触。

*防的是：*把事后修订混入设计。修订不可耻，追溯修订才可耻。

【七】执行后偏离记录

执行中与预注册不符之处，逐条列出，不合并、不淡化。区分两类：

- 实现修复（不改变定义，如数值下溢保护）；
- 设计偏离（改变了定义或范围，如规模上限）。

防的是：把设计偏离说成实现细节。

【八】本模板挡不住的

写在模板末尾，作为使用者的提醒：

预注册保护的是“事后不许改判据”，它不保护“事前把判据写错”。

一份冻结清单的完备性，只能由执行来检验，而一次执行只检验一次。因此：单次预注册跑不构成判决，无论它执行得多干净。

【九】一份对照：首跑按本模板的得分

把首跑的预注册按本模板逐节对照，作为使用样例。这不是一份合格样本，它是一份有明确缺项的真实样本，而这正是它的用处。

模板节	首跑是否写了	质量
一 材料	写了	合格，是全份里最稳的一节
二 探针集	写了，含摘要值	冻结合格；来源不合格（分布外探针自造，非第三方基准）
三 距离	写了	度量合格；合成一项后来作废
四 量与判据	写了三款	合格，且第三款决定了本跑结论
五 事先写明的局限	写了三条	两条准确，一条推理对而结论错（基线代理保守，却未预见跨规模不可比）
六 执行前修订	写了一处	合格
七 执行后偏离	写了三条	合格，且区分了实现修复与设计偏离
八 挡不住的	未写	缺项——这一节正是从

八节里，四节合格，三节部分合格，一节缺失。

把这张表放进模板，是因为一份从未被真的填过的模板不值得信任；而一份填过、并且在填完之后被自己的执行证伪了一项的模板，至少知道它的薄弱处在哪里。

附四 复现清单

一、模型

- 模型族：公开的多种子、多规模检查点系列（详见第六十一章）。
- 使用：四个规模（14M、31M、70M、160M），每规模五个种子，取最终检查点。
- 噪声基线：每规模一号种子的倒数第二个公开检查点与最终检查点。
- 未使用：410M 及以上（磁盘与算力所限）。
- 附加消融（探索性，不计入判决）：最大规模上的“只换数据次序”与“只换权重初始化”两组各三个。

检查点总数：24 个（主系列 20 + 基线 4），另加探索性 6 个。

二、探针集

- 总数 112 条：分布内 64 条，分布外三类各 16 条。
- 摘要值前十六位：**e3b9d8a2795ccee**
- 复现的第一步是重建探针集并核对此值。若不一致，后续一切读数不可比——这是本清单中唯一有确定通过标准的检验。

三、脚本

四个，功能如下：

1. 探针生成：重建探针集并计算摘要值。
2. 表示抽取：逐模型下载、前向、抽取隐藏状态与输出分布。
3. 条款一分析：计算表征距离、行为距离、基线与比值，按探针分组输出。
4. 消融对比分析：最大规模上三组干预的对照。

四、原始读数

两份，构成本书全部数字的唯一来源：主系列四个规模的全部读数（含分组），以及三组干预的对照读数。

本书正文中的每一个数字都可追到这两份文件。

五、硬件与环境

- 单核处理器，3 GB 内存，单精度浮点。
- 最大规模上单个模型前向约需数分钟；整跑时间主要花在下载与前向上。
- 磁盘为硬约束：每跑完一个模型必须立刻清理缓存。

六、四个已踩过的坑

1. 磁盘会爆——逐个模型下载、抽取、清理。
2. 散度会因零概率项下溢为无效值——必须显式把零概率项按零处理。这是实现修复，不改变距离定义。
3. 不要在已具不变性的度量之前再加一层对齐——多加的那一层只引入新的自由参数。
4. 开跑前做自配对返零检验——同一检查点与自身配对，走全部计算，每一格应为零。首跑未做，代价是一次返工（第六十一章第六节）。

七、复现到什么程度

- 完全可复现：探针集（有确定通过标准）、距离计算（给定同一批状态，结果确定）。
- 可复现但有代价：前向计算，需逐个取用检查点。
- 不可完全复现：不同硬件或精度下，隐藏状态有末位差异，距离在小数第三位上可能不同。复现的标准是同一量级与同一相对关系，不是逐位相同。
- 无法复现：若所用公开检查点被撤下或替换。本书能做的只有把名称、版本号与摘要值全部写明。

八、这份清单挡不住的三件事

清单写完，把它挡不住的写出来，与附三第八节同一个用意。

挡不住之一：材料消失。见第七节。若公开检查点被撤下，本跑不可复现，而这并非复现者的问题，也不是本书能预防的问题。

挡不住之二：判据错误。一份完整的复现清单能保证别人跑出同样的数字，不能保证那些数字有意义。首跑的噪声基线是可复现的——任何人按清单跑都会得到同样的 0.0306——而它跨规模不可比这件事，复现一百次也不会显形。复现性与正确性是两件事，而本清单只管前者。

挡不住之三：同一套设备的系统偏向。若所有复现者都用同一批公开模型、同一套工具、同一类探针，那么他们复现的不只是读数，也复现了那批材料所携带的偏向。第四十六章第二节列过三处错配——规模点分布、检查点间隔、种子数量——它们对每一个复现者同样生效。

因此本清单的正确用法是：用它核对“我跑的是不是同一件事”，而不是用它论证“这件事是对的”。

三件合起来给出一条对复现这个概念的限制，它与第九章第二节那条论证是同一个形状：复现所保证的，是在被认可的操作等价类内部结果稳定；而等价类的边界是被定的。本清单第七节那三档（完全可复现、有代价、不可完全复现）就是本书为这次实验划下的边界，写明它，是为了让别人能质疑这条边界本身，而不是只能在边界之内重跑。

附五 与相邻立场的分界

本书在若干立场附近，但与每一个都不同。逐条划界。

一、与社会建构论

本书不主张知识由社会协商决定，也不主张约束是软的。

本书主张约束极强，争的是约束是否唯一决定结果。第七十九章第三节给出了量上的对照：本书预期可归约份额的主体部分很大，争的只是那个剩余是否为正。

分界的技术根据在第五十三章：建构论提供了大量案例而始终无法判决，原因是案例不能区分两种路径依赖——它无法排除“换一条路径最终也会走到那里，只是更慢或更绕”。本书与它的差别不在结论，在证据形式。

二、与结构实在论

结构实在论主张被保留下来的是结构而非对象。

若条款二的对齐后连通率趋于一，结构实在论获得一个强有力的新支持。

本书把这一读数明确列为自己的判负条件之一（第五十八章第二条），而不是试图解释掉它。这是本书与它最实在的关系：它是本书可能输给的对手之一，而本书事先写明了怎样算输。

三、与工具主义

本书不主张理论只是工具。

可用性论证在第十章已被处理：可用性证明约束的实在性，不证明被造物的先在性，也不证明被造物只是工具。三件事各不相同，而把它们混为一谈是这场争论里最常见的偷换。

四、与“发现的语境／辩护的语境”之分

该切分把“一个想法怎么来的”与“它凭什么成立”分开，并主张只有后者与认识论相关。

本书认为这个切分预设了待判的那一条：它假定来路不进入规定，因而来路只与心理学或社会学相关。而这正是本案的争点。一个预设了争点的切分，不能用作判据。

五、与决定论

本书对决定论没有立场。

第七十五章第二节处理过：把“给定初始条件与动力学，一切都已确定”用作先在论的论证，会证明得太多——它同时取消“造成”这个概念在制造、艺术、立法、生育等处的适用性。一个使“造成”一词在宇宙中无处可指的论证，不是赢了这场争论，是解散了这场争论。

但这不等于决定论为假，本书不主张它为假。本书只主张它在本案上没有判别力。

六、与相对主义

第七十九章第六节拆过三种含义：判断相对主义、真理相对主义、形成相对主义。

本书只与第三种有关，而且只是它的一个受限版本——受限在“那个剩余是否为正”这一点上。前两种与本书无关，且本书的每一条判据都预设第一种为假。

七、与干预主义

本书的判据直接来自干预主义（第十三章、第四十章第七节），因此这里划的不是对立，是继承与边界。

继承的：判据必须落在“能不能动手改变它，并看着结果跟着变”上，而不是落在“哪个叙事更融贯”上。本书四条性质就是这条判据在本案上的展开。

边界一：本书因此继承了干预主义的全部前提。若有人主张存在不能被干预的因果关系，那么本书的四条清单就不是唯一可能的清单，而第四编排除三个候选的理由也相应变弱。这个依赖本书不论证，它是借来的。

边界二：哈金那条判据用的是“能用它去干预别的东西”，而本书用的是“能干预它本身的形成”。后者比前者强，而且强出来的那一截正是本案所需要的——能用电子做事，不说明电子这套描述是怎么来的。

八、与库恩式的范式论

共同点：都主张形成的条件进入结果，都反对“科学史 = 逼近加噪音”这个说明模式（第八十二章第二节）。

分界一，关于普遍性：范式论把构成装置从先验层面拉回历史层面，因而避开了普遍性自伤（第十二章第七节）。本书在这一点上与它同侧，并且认为那是造成论走出自伤的唯一途径。

分界二，关于证据形式：范式论的结论建立在案例上，因而受案例天花板所限——它无法排除“换一条路最终也会走到那里”。本书与它的全部差别，就是这一条。

分界三，关于不可通约：本书不主张不同路径得到的结果之间不可比较。第七十九章第四节给出了三条可用的比较标准——预测力、可干预性、遇到反例时的修改代价——并论证可比较性不需要唯一性。

因此本书与范式论的关系可以写成一句：本书接受它的诊断，拒绝它的证据形式，并且不接受由它常被引出的那个不可比较的推论。

九、与“模型也有知识”这一类主张

本书不主张模型拥有知识、理解或认识主体性；本书也不主张它没有。这三个问题本书不处理，理由见第四十五章。

本书唯一主张的是：模型训练的产物具有知识主张的形式——可以被评价为对或错，可以与世界上的事情对照，可以在对照失败时被修改。这条线是本书全部现场选择的承重处，而第四十二章第六节写明了它的处境：本书拒绝把实验演化外推到知识，与本书自己的合法性，靠的是同一条线。

可判性的到来

发现还是发生？

「知识是被发现的，还是被造成的」——这道题自《美诺》以来悬置两千年。本书主张它不可判有一个结构性的原因：判决所需的干预，在知识的形成过程上从来无法施加。缺的不是论据，是一台能把形成过程整体重跑的装置。

本书论证这台装置已经出现，并把待判的命题翻译成可测形式：固定语料、架构与判准，只改变训练路径，问所到达的结果是否同一处。全书交出一个承重区分、三条条款、四个量、六条写死的败绩条件、一份预注册，以及一次已执行的首跑。

首跑的结论是「未能分辨」。

本书不交出结论，只交出判据、读数与一份修订清单；并用整章写明本书接不住的那一记。

德麦国际专著第 123 号

DEMAI INTERNATIONAL PRESS

ISBN 979-8-90690-092-0

条码区（印厂置入 EAN-13）

US \$25.00