

拒绝的社会生产

——教育评价的测度外壳与外壳再分泌律

王德生

德麦国际 · SDE UNIVERSES · 今日长文 · 2026 年 7 月 18 日

摘要

现代教育评价研究共享一个从未被审视的预设：评价装置是为了测量学习而被发明的，它在当代的失灵是一种退化。本文论证这一预设历史与结构两个层面都不成立。从科举到普鲁士文官考试再到美国的标准化测验，大规模评价装置的诞生场景无一不是认知需求，全部是分配危机——需要在稀缺机会面前产生一种能被落选者接受的落选。据此，本文提出一个方向相反的判断：**评价装置的社会产品不是关于学习的信息，而是可接受的拒绝；测度不是这一产品的目的，而是它的生产条件**。测度功能是安抚功能为使拒绝可接受而分泌的准确性表象，本文称之为"测度外壳"。外壳在结构上必须看起来像测量，但不必是测量，因为它所生产的从来不是准确性而是不可争辩性。这一重新定位产生三个既有理论无法产生的推论：其一，分数与能力的脱钩不是病症而是常态，人工智能所揭穿的不是脱钩本身，而是社会曾经相信过耦合这一集体记忆；其二，任何承担稀缺分配功能的替代性评价装置，将在一到两代人的时间内分泌出同构的测度外壳——替代不是替代，是宿主更换，本文将这一机制凝缩为"外壳再分泌律"；其三，该律有一个精确的边界条件——排序型装置必然分泌外壳，阈值型装置不必，这一区分为干预给出了一个非同义反复的落点。本文以此正面对置波特（Porter）的机械客观性理论这一最强竞争解释，设计了一项能够区分两者相反预测的判决性检验，并以本文自身在同行评审中的处境完成对该理论的自反检验。

关键词：可接受的拒绝；测度外壳；外壳再分泌律；排序型与阈值型装置；教育评价；通约化

目录

- 一、一个问错了的问题
- 二、四条抵近而未合拢的脉络
- 三、可接受的拒绝、测度外壳与再分泌律
- 四、方法与它的边界
- 五、产品倒置：三个装置的诞生场景
- 六、外壳为什么不必准确，又为什么仍需一点准确
- 七、外壳再分泌律：一条会禁止事情的律

八、与最强对手的正面交锋

九、两个落点，都不在评价内部

十、结论

十一、自反：这条律适用于评价本文的装置吗

十二、参考文献

一、一个问错了的问题

（一）一个不可解释的事实

2023 年以来，随着大语言模型能够在数分钟内生成合格的课程论文，全球教育界爆发了一场关于评价合法性的持续争论。争论的形式高度一致：如果机器能够在不具备学科素养的情况下拿到分数，那么分数还能证明什么？由此衍生出的对策也高度一致——加强监考、回归纸笔、开发检测工具、重新设计题型，或者更激进地，用项目制评价、能力档案、微证书来替代标准化分数。

这些对策彼此对立，却共享同一个前提：**评价系统是一个测量装置，它现在测不准了，所以需要修理或更换**。争论的双方——保守派要修理旧仪器，改革派要更换新仪器——在“这是一个仪器问题”这一点上从未分歧。

本文认为这个前提是错的，并且它错得很彻底：它不是把答案搞错了，是把这个装置是什么搞错了。

考虑一个在现有框架中无法被消化的事实。2008 年金融危机以一种无可辩驳的方式证明，三大信用评级机构对结构化金融产品的评级不具备预测效度——被评为 AAA 的证券大规模违约。按照“测量装置失灵则被更换”的逻辑，评级机构应当在此后被边缘化。实际发生的是相反的：标普、穆迪、惠誉在危机后的十余年里营收创下历史新高，其评级被更深地写入了各国的金融监管条款。一个被公开证伪的测量装置，不但没有消亡，反而获得了更强的制度地位。

如果测量的准确性是这类装置的存在理由，这个事实就是不可解释的。如果它不是，那么我们需要问的就不是“这个装置测得准不准”，而是**“这个装置到底在生产什么，以至于它的测不准无关紧要”**。

本文的回答是：它生产的是可接受的拒绝。

（二）三种既有解释及其共同的方向错误

围绕教育评价的困境，既有研究提供了三条主要解释路径。

第一条是技术优化路径。这一路径将评价视为一个测量工程问题，其核心议程是提高信度、效度与公平性（Black & Wiliam, 1998; Stiggins, 2002）。它对当前危机的诊断是“工具跟不上时代”，处方

是更好的工具。这一路径的盲区是自明的：它无法解释为什么一个多世纪的测量技术改进，并没有使公众对评价的信任上升，反而与之同步下降。

第二条是批判再生产路径。 这一路径指出评价装置是社会不平等的再生产机制——它并非中立地测量预先存在的能力差异，而是把阶级结构的不平等转译为看似天然的分层数据（Bourdieu & Passeron, 1977; Bowles & Gintis, 1976; Au, 2009）。这一路径的解释力极强，但它有一个自身难以消化的经验困难：如果评价装置是统治结构施加于被统治者的符号暴力，那么最积极维护“分数是公平的”这一命题的，本应是既得利益者。经验上恰恰相反——最激烈反对降低标准化考试权重的，往往是中下层家庭。批判路径通常用“误识”（méconnaissance）来处理这个困难，即被统治者内化了统治者的标准而不自知。但这一处理引入了一个不可证伪的辅助假设：任何反例都可以被解释为更深的误识。

第三条是制度惯性路径。 这一路径强调旧制度在教材体系、教师培训、录取算法、社会认知上的巨大沉淀，用路径依赖与锁定来解释改革的反复失败（David, 1985; Arthur, 1994; Pierson, 2004; Mahoney & Thelen, 2010）。这一路径能够解释“改起来慢”，但它预测的是一条持续衰减的阻力曲线，而非教育改革所呈现的“启动—反弹—回到原点—再启动”的波形。更关键的是，它把评价装置的**当前功能**当作既定事实接受下来，只研究它为何难以改变，从不追问它一开始为何被建立。

三条路径的解释力各不相同，但它们共享一个方向：**它们都把“测量学习”当作评价装置的目的，把“正当化分配”当作它的效应、副产品或被劫持的结果。**技术路径要修好这个目的；批判路径揭露这个目的被权力污染；制度路径解释为什么这个目的难以被重新校准。

本文提出的判断是：**方向反了**。正当化分配不是效应，是目的；测量学习不是目的，是这个目的得以运作的条件。这不是强调重点的调整，而是因果箭头的调转，其后果贯穿本文全篇。

（三）本文的判断与结构

本文的核心判断可以先行给出：

大规模教育评价装置的社会产品，是**可接受的拒绝**——一种能够让被排除者在被排除后继续参与社会合作、而不诉诸暴力、退出或指认具体施害者的排除方式。为使拒绝可接受，装置必须分泌一层看起来像测量的表层，本文称之为**测度外壳**。外壳的产品不是准确性，而是不可争辩性；它必须借用测量的语法，因为测量的语法自带不可争辩性，但它不必真的测量任何东西。

这一判断的三个直接推论构成本文的主体：

推论一（脱钩常态）：外壳与被测对象的脱钩不是退化，是稳态。所谓“人工智能揭穿了分数与能力的脱钩”这一说法本身包含一个错误——被揭穿的**不是脱钩**（它一直存在），而是**社会曾经相信过耦合**这件事。被摧毁的是记忆，不是效度。

推论二（外壳再分泌律）：任何承担稀缺分配功能的排序型评价装置，其测度外壳都将在一到两代人的时间内与它声称测量的对象脱钩，而装置本身不会因此消亡；试图以新装置替代旧装置的努力，会使新装置在获得同一社会功能的同时分泌出同构的外壳。**替代不是替代，是宿主更换。**

推论三（排序/阈值分界）：外壳再分泌律有一个精确的边界条件。装置分泌外壳的压力，来自它必须让被拒者接受被拒；而”被拒”有两种语法。**排序型装置**（你比别人差，所以你出局）必然分泌外壳，因为它的拒绝理由是相对的、因而永远可被争辩（“凭什么是他不是我”）。**阈值型装置**（你没到线，所以你出局）不必分泌外壳，因为它的拒绝理由是绝对的、可被被拒者自己验证（“我确实不会开飞机”）。这一区分解释了一个长期被忽视的经验规律：职业资格考试的测度效度显著高于升学考试，且不随时间衰减。它同时给出了本文唯一的、非同义反复的干预落点。

本文的结构安排如下。第二节梳理文献，精确定位本判断与最接近的既有理论——波特的机械客观性——之间的分岔点。第三节提出理论框架，操作化”可接受的拒绝”“测度外壳”“外壳再分泌律”三个概念并给出命题系统。第四节说明方法。第五节是本文的论证主体：5.1 从装置的诞生场景论证产品倒置；5.2 论证外壳的分泌机制与其”不必准确”的结构原因；5.3 论证外壳再分泌律并处理其边界条件；5.4 正面对置最强竞争解释并给出判决性检验设计；5.5 从该律推出干预路径。第六节结论，含理论贡献、政策含义、局限，以及对本理论的自反检验。

二、四条抵近而未合拢的脉络

（一）通约化研究：把不可比的东西变成可比的

与本文最相关的第一条脉络，是关于通约化（commensuration）的社会学研究。埃斯佩兰和史蒂文斯（Espeland & Stevens, 1998）在一篇奠基性综述中把通约化定义为”把不同性质的属性转化为一个共同度量”的社会过程，并指出它是一种被严重低估的权力形式：通约化通过决定什么被纳入度量、什么被排除在度量之外，重塑了它所度量的世界。他们特别强调，通约化的核心效应是**信息的丢弃**——它把大量异质信息压缩为一个可排序的标量，而被丢弃的部分不会留下痕迹。

这一脉络在埃斯佩兰和绍德（Espeland & Sauder, 2007; Sauder & Espeland, 2009）对法学院排名的研究获得了最有力的经验兑现。他们发现，《美国新闻与世界报道》的法学院排名并非中立地反映法学院的质量，而是**反应性地**（reactively）改变了法学院的行为：院校为了提升排名而重组资源配置、操纵录取数据、改变奖学金策略，最终使排名所测量的对象向排名的度量标准靠拢。他们把这一机制称为”反应性”，并指出其结果是排名与它声称测量的东西之间形成一个自我实现的闭环。

这一脉络对本文极其重要，但它止步于一个关键处：它解释了通约化如何改变被测对象，没有解释**通约化为什么被社会需要**。埃斯佩兰与史蒂文斯在综述结尾承认，通约化的兴起动因是一个未解问题，他们列出了效率、可比性、问责等若干候选，但没有给出一个统一机制。本文提供的正是这个机制：通约化被需要，是因为**排序必须被排除者接受**，而排序只有在被表述为共同度量上的位置差异时才可能被接受。通约化不是权力的工具，它是拒绝的语法。

（二）波特的机械客观性：最接近的、也是最强的竞争解释

本文必须正面处理的最强竞争解释来自波特（Porter, 1995）的《相信数字》。这是与本文判断最接近的既有理论，两者的分岔点必须被精确划出，否则本文的贡献将被消解为一次换词。

波特的论证是：定量方法在现代社会的兴起，不能用“科学进步”来解释，因为在许多领域，量化取代专家判断反而降低了决策质量。真正的动因是**信任的匮乏**。他的核心经验对置极其有力：法国的国立路桥学校工程师拥有牢固的社会地位与不受挑战的专业权威，他们从不使用成本效益分析；美国陆军工程兵团处在国会、地方利益集团与公众舆论的持续质疑之中，他们发展出了世界上最精密的成本效益分析体系。波特由此提出“机械客观性”（mechanical objectivity）概念：数字提供了一种非个人的、按规则运行的、看起来不依赖任何人的判断的决策形式，它的功能不是让决策更准确，而是让决策**能够抵御质疑**。他的凝缩是：量化是弱者的策略。

波特已经说了“量化不是为了准确”。那么本文还剩下什么？

分岔点有三处，且每一处都产生相反的预测。

第一，因果方向相反。 波特的机制是**防御性的、自上而下的**：专家或官僚在被质疑的处境中，采用量化作为盾牌。承担需求的是**决策者**。本文的机制是**需求性的、自下而上的**：被拒绝者在必须接受拒绝的处境中，需要一个能让自己接受拒绝的理由。承担需求的是**被决策者**。这不是同一个机制的两种说法。它们对同一个变量给出相反的预测：波特预测**专家权威越高，外壳越薄**；本文预测**拒绝越不可逆，外壳越厚，与专家权威无关**。第 5.4 节将以此设计判决性检验。

第二，解释范围不同。 波特解释了量化为何被采用，没有解释量化在被证伪后为何不被放弃。他的框架内含一个预测：如果机械客观性的客观性外观被戳破，它的防御功能就失效，从而应被放弃。这一预测被 2008 年后信用评级机构的境遇直接证伪——外观被彻底戳破，制度地位反而上升。本文的框架能够消化这个事实：承重的从来不是客观性，是可接受性；而可接受性只要求“存在一个非人格的程序”，不要求“这个程序是对的”。

第三，理论形态不同。 波特提供的是一部历史社会学的谱系，其命题形态是“在什么条件下量化会兴起”。本文提供的是一条带边界条件的律（外壳再分泌律），其命题形态是“任何承担 X 功能的装置必然出现 Y，除非满足 Z”。律必须能被证伪，本文在 5.3 节给出了它的证伪条件与边界。

一个更大的家族。 波特不是孤例。斯科特（Scott, 1998）关于国家可读性（legibility）的论证具有同样的形态：国家为了管理而把复杂的、地方性的、只有当事人才懂的社会现实，简化为可以从中心被读取的网格——地籍、姓氏、标准度量衡、单一栽培林。斯科特与波特分享同一个因果方向：**简化是自上而下的需求，被简化者是承受方**。本文与这整个家族的分岔是同一处：本文主张，在评价这一类装置上，简化的需求首先来自**下面**——来自那个必须接受自己被简化的人。不是国家需要把他读成一个数字，是他需要被读成一个数字，才能接受那个数字对他做的事。这一分岔在 5.4 中被转化为一次判决性检验。

（三）组织社会学的脱耦：分离，而非分泌

迈耶和罗恩（Meyer & Rowan, 1977）的经典命题指出，组织采纳某些正式结构并非为了技术效率，而是为了与制度环境中的合法性标准保持一致，而这些结构可能与组织的实际运作完全脱耦

（decoupled）。布罗姆利和鲍威尔（Bromley & Powell, 2012）进一步区分了“政策—实践脱耦”与“手段—目的脱耦”，指出当代组织越来越多地只是执行规则的形式，而不再关心规则是否实现其宣称的目的。

这一脉络为”学校维持严格评价并非为了促进学习，而是为了展示公正”提供了精确的制度主义描述，本文承其洞见。但脱耦理论描述的是一种**分离关系**：两样东西本来在一起，后来分开了，或者一开始就是两张皮。本文描述的是一种**生成关系**：其中一样是另一样分泌出来的。这个差别不是修辞。脱耦理论预测：如果外部合法性压力消失，正式结构会被放弃，因为它此时纯属冗余。分泌关系预测：即使外部压力消失，只要装置仍需产生拒绝，外壳仍会被分泌——因为外壳不是给外部看的，是给**被拒者**看的。取消排名后立即出现的自发影子排序（见 5.4.3），是脱耦理论无法预测而本文可以预测的现象。

（四）文凭主义与信号理论：两个被误读的经典

科林斯（Collins, 1979/2019）的文凭社会理论论证，教育扩张并未提高社会流动性，而是制造了文凭通胀的螺旋；文凭是身份群体争夺职业垄断地位的武器。斯宾塞（Spence, 1973）的信号模型则论证，教育的价值不在于所传递的技能，而在于高能力者获取文凭的成本较低这一分离均衡条件，使文凭成为可靠信号。

这两个经典在当代讨论中被反复引用，但都被误读为”文凭的功能是筛选”。实际上科林斯的论证已经非常接近本文：他明确指出文凭的技术功能（培养生产力）在经验上几乎不成立，其真实功能是**冲突中的地位划界**。本文与科林斯的分岔在于：科林斯是冲突论的，他的世界里有争夺者与被排斥者，装置是前者压制后者的武器；本文的世界里，被排斥者**自己需要这个装置**。这不是补充科林斯，是与他相反。一个纯冲突论的世界无法解释为什么落选者游行要求的是”考试要更严格更公平”而不是”取消考试”。

斯宾塞的模型则给出了一个本文可以直接使用的技术结论：一旦获取信号的成本对所有类型的行动者都趋近于零，分离均衡崩溃，信号的信息含量归零。生成式人工智能正在做的就是这件事。斯宾塞的模型由此预测文凭应当失去价值。它没有失去。这是信号理论无法消化、而本文可以消化的事实：信号的信息含量与它的社会功能无关。

（五）拒绝的社会学：一条被忽视的线索

有一条与本文直接相关、却几乎从未被引入教育研究的线索：埃尔斯特（Elster, 1989）在《所罗门式判决》中系统研究了社会如何在**理性无法决定**的情况下做出决定——器官分配、子女监护权、征兵、稀缺住房的分派。他的核心发现是：在这些场景中，社会经常选择那些明显不是”最优”的机制（抽签、排队、先到先得、机械的资历规则），而选择它们的理由恰恰是它们**不做实质判断**。埃尔斯特指出，一个机制的价值有时正在于它切断了争辩的可能性。

埃尔斯特研究的是分配，没有研究评价；他的机制是”不判断”，本文的机制是”看起来在判断”。但他给出了本文所需的、既有文献中最硬的一块地基：**存在一整类社会装置，其功能是产生可被接受的分配结果，而不是产生正确的分配结果**。教育评价属于这一类装置，只是它选择了与抽签相反的策略——不是承认自己不判断，而是分泌一层判断的外壳。为什么？因为抽签生产的是可接受的**运气**，而现代社会需要的是可接受的**应得**。这个差别是本文 5.1.3 节的主题。

（六）缺口的精确定位

综上，既有文献在四个方向上分别抵近了本文的判断：通约化研究看到了排序如何重塑被排序者，波特看到了量化不为准确，脱耦理论看到了形式与实质的分离，埃尔斯特看到了存在一类以可接受性而非正确性为产品的装置。

但没有任何一条脉络把这四点合起来问一个问题：**如果一个装置的产品是可接受的拒绝，那么它的”测量”部分是什么？**

本文的回答——测量部分是这个产品的分泌物，即测度外壳——不能从上述任何一条脉络单独推出：通约化研究会说它是共同度量，脱耦理论会说它是仪式性外壳（这个词最接近，但它假设外壳是给外部环境看的），波特会说它是抵御质疑的盾牌，埃尔斯特会说它是切断争辩的规则。这四个说法各自解释了外壳的一个侧面，没有一个解释它为什么必须**看起来像测量**而不是像抽签、像资历、像神谕。

答案在第三节。

三、可接受的拒绝、测度外壳与再分泌律

（一）核心概念

概念一：可接受的拒绝（Acceptable Rejection）

本文将”可接受的拒绝”操作化定义为：一种排除方式，它使被排除者在被排除之后，仍然继续参与产生该排除的社会合作体系，而不采取以下三类行动之一——诉诸暴力、退出体系、指认一个具体的施害者。

这一定义有三个要件，缺一不可。

要件一：被排除者继续参与。 一次拒绝如果导致被拒者永久离场，它在社会意义上是失败的——不是对被拒者失败，是对体系失败，因为体系需要落选者继续在其中劳动、纳税、供养下一代考生。可接受的拒绝的成功标志是：被拒者第二年再来，或者他的孩子再来。赫希曼（Hirschman, 1970）关于退出、呼吁与忠诚的经典三分法为此提供了精确的坐标：可接受的拒绝所要生产的，正是在遭受损失之后仍然选择忠诚而非退出、且不诉诸呼吁的那种状态。赫希曼关心的是组织如何因缺乏反馈而衰败；本文关心的是一类装置如何专门生产这种无呼吁的忠诚——在本文的框架中，那不是衰败的症状，是产品。

要件二：不指认具体施害者。 这是最关键的要件，也是理解全部现象的钥匙。当一个人被拒绝时，他会寻找责任的落点。如果落点是一个具体的人（考官、校长、招生办主任），拒绝就转化为怨恨，怨恨积累为冲突。可接受的拒绝要求责任的落点是**非人格的**——不是任何人拒绝了你，是你的分数拒绝了你。分数的社会功能，首先是**吸收怨恨**。

要件三：可接受性由被拒者承担，不由拒绝者承担。 这是本文与所有批判理论的分岔点。拒绝者（大学、雇主、国家）需要的只是**决定**；他们不需要被拒者接受。是被拒者自己需要接受——因为不接受的

代价由他自己承担：一个认为自己被不公正地毁掉了的人，无法组织自己剩下的人生。**接受不是被灌输的，是被拒者为了继续活下去而自己生产的。**

由要件三推出一个反直觉但可检验的命题：**对”分数是公平的”这一命题的信念强度，应与被拒风险负相关，而非与既得利益正相关。**最需要相信考试公平的，是那些最可能考不好的人。这一命题在第五节将被展开，它同时是本文与批判再生产路径的判决性分岔。

概念二：测度外壳（Measurement Shell）

本文将”测度外壳”操作化定义为：为使拒绝可接受而分泌的、借用测量语法但不承担测量义务的表层结构。

外壳有三个结构特征。

特征一：借用测量的语法。 外壳必须以分数、等级、排名、指标等形式呈现，必须有命题、评分、统分的完整流程，必须能被表述为”某人在某个维度上的位置”。它必须**看起来像**一次测量。

特征二：不承担测量义务。 外壳不需要真的与它声称测量的对象保持稳定关联。它的效度可以长期为零，且这一事实可以被广泛知晓，而不影响它的运作。

特征三：产品是不可争辩性，不是准确性。 外壳所生产的是”这个结果无法被争辩”这一状态。它之所以必须借用测量的语法（特征一），正是因为测量的语法自带不可争辩性——一个数字不能被反驳，只能被重新计算；而重新计算需要挑战整套程序，其成本远高于任何个体所能承担。

特征三解释了特征一与特征二为何可以共存：如果外壳的产品是准确性，那么特征二是它的失败；如果外壳的产品是不可争辩性，那么特征二根本不是它的性质之一——准确与否与它无关。

一个必须被区分开的日常混淆。 被拒者说的是”至少高考是公平的”，不是”高考是准确的”。这两句话在既有文献中被系统性地混用，它们的差别却是整个理论的枢纽。“准确”是关于装置与世界的关系（效度问题）；“公平”是关于装置与被拒者的关系（可接受性问题）。一个装置可以完全不准确而完全公平——只要它对所有人施加同一套非人格的程序。这正是被拒者所要求的東西。他们从未要求过准确。他们要求的是”没有人在暗中动手脚”，即：**没有可指认的施害者。**

概念三：外壳分泌（Shell Secretion）

分泌关系不同于寄生关系、脱耦关系、共生关系，必须被精确区分。

- **寄生**：A 依附于 B 并消耗 B，B 先于 A 存在。若测度被安抚寄生，则测度曾独立存在过。本文否认这一点。
- **脱耦**：A 与 B 并存但不连接。若测度与安抚脱耦，则两者是并列的两张皮。本文否认这一点。
- **分泌**：B 为了自身的运作而产生出 A，A 从未独立存在过，且 A 的形态完全由 B 的功能需求决定。贝壳不是贝的寄生物，也不是与贝脱耦的另一样东西；贝壳是贝分泌出来包住自己的东西，它的形状由贝的需要决定，它从未有过自己的生活。

测度是安抚分泌出来的壳。 这句话的全部内容：教育评价装置中的测量成分，其形态、精度、覆盖面、技术演进方向，全部由”使拒绝可接受”这一功能需求决定，从未由”认识学习”这一认知需求决定。第 5.2 节将逐条兑现这个断言。

概念四：外壳再分泌律 (The Law of Shell Re-secretion)

本文的核心律，其完整表述为：

任何承担稀缺分配功能的**排序型**评价装置，其测度外壳都将在一到两代人的时间内与它声称测量的对象脱钩，而装置本身不会因此消亡。试图以新装置替代旧装置的努力，将使新装置在获得同一社会功能的同时分泌出同构的测度外壳。**阈值型**装置不受此律约束。

律的三个组成部分需要分别说明。

(a) 脱钩的必然性：不是因为人们作弊，也不是因为指标被优化目标反噬（这是坎贝尔定律 [Campbell, 1979] 与古德哈特定律的内容，本文承其洞见但主张它们只是表层机制），而是因为**外壳从一开始就不承担测量义务**。脱钩不需要机制来产生，它是默认状态；需要机制来解释的反而是耦合——为什么在某些时期外壳与被测对象保持了一定关联？答案见 5.2.4：那是外壳借用测量语法所必须支付的最低保真成本，一旦这个成本可以被更低成本地替代（如通过程序的仪式性来提供不可争辩性），保真度就会被放弃。

(b) 装置的不死性：装置不因脱钩而消亡，因为脱钩没有伤害它的产品。这是本文对信号理论、技术优化路径与制度惯性路径的共同回应：它们都预测装置会因失效而承压，只是对承压后果的判断不同。本文预测装置不承压。

(c) 再分泌：这是律的核心，也是它最锋利的地方。它的推理链是：安抚需求内生于被拒者 → 需求不因旧装置被废除而消失 → 新装置一旦承接稀缺分配功能，立即面对同一需求 → 新装置必须让被拒者接受被拒 → 因此必须提供非人格的、不可争辩的拒绝理由 → 因此必须分泌测度外壳 → 因此在一到两代人内与它声称测量的对象脱钩。

这条链的每一步都不依赖任何人的意图。 没有人策划它。设计新装置的人真诚地想要一个更好的评价方式；他们分泌外壳，是因为他们的装置一旦承接了分配功能，就必须回答”凭什么是他不是我”，而这个问题只有一种社会上可行的答案格式。

(二) 命题系统

P1 (产品命题)：大规模教育评价装置的社会产品是可接受的拒绝，不是关于学习的信息。测度是这一产品的生产条件，不是产品本身。

P2 (分泌命题)：测度功能是安抚功能为使拒绝可接受而分泌的准确性表象。其形态由可接受性的需求决定，不由认识的需求决定。外壳的产品是不可争辩性，不是准确性。

P3 (脱钩常态命题)：外壳与被测对象的脱钩是稳态而非退化。人工智能所揭穿的不是脱钩，而是社会曾相信过耦合这一集体记忆。被摧毁的是记忆，不是效度。因此，一切以”恢复分数的效度”为目

标的对策（监考、检测、回归纸笔、重设题型）都是范畴错误——它们试图修复一个从未存在过的东西。

P4（再分泌命题）：任何承接稀缺分配功能的排序型替代装置，将在一到两代人内分泌出同构的测度外壳。替代不是替代，是宿主更换。

P5（分界命题）：排序型装置必然分泌外壳；阈值型装置不必。区别在于拒绝理由的语法：排序型的拒绝理由是相对的（你比别人差），因而永远可被争辩，因而需要外壳来切断争辩；阈值型的拒绝理由是绝对的（你没到线），可被被拒者自己验证，因而不需要外壳。

P6（干预命题）：由 P4，一切在评价端的干预（改测量、换指标、建替代认证）都是同义反复——它们只更换宿主。唯一非同义反复的干预有两个落点：（i）**语法落点**：把排序型装置改造为阈值型装置；（ii）**需求落点**：降低单次拒绝的终身不可逆性，从而降低安抚需求的产生率，从而降低外壳的分泌压力。两者都不在教育评价内部。

命题之间的逻辑关系：P1 是地基；P2 说明地基如何产生上层建筑；P3 是 P1+P2 对当前危机的直接应用；P4 是 P1+P2 的时间展开，是本文的核心律；P5 是 P4 的边界条件，同时是它的可证伪面；P6 是 P4+P5 的实践推论。

（三）本框架产出而既有框架产不出的推论

一个理论的份量不在它能解释多少已知现象，而在它能否产出竞争理论产不出的推论。本文列出四条，每一条都在第五节被展开并给出经验落点。

推论一（信念的逆向分布）：对”评价是公平的”这一信念的强度，应与被拒风险**正相关**，而非与既得利益正相关。批判再生产路径预测相反（既得利益者最维护这套标准）。这是一个可以用现有调查数据直接检验的分歧。

推论二（评级机构的不死）：一个被公开证伪的排序装置，其制度地位不会下降，可能上升。技术优化路径、信号理论、制度惯性路径都预测下降或至少承压。

推论三（影子排序）：取消一个排序装置的显式度量后，若其分配功能未被取消，将立即出现自发的、由参与者自建的影子排序。脱耦理论预测取消后正式结构变为冗余而被放弃；批判路径预测取消后焦虑下降。两者都不预测影子排序的自发涌现。

推论四（阈值型装置的保真）：不承担排序功能的资格型装置（飞行执照、外科手术资格、职业焊工认证），其测度效度显著高于升学考试，且不随时间衰减。既有框架中没有任何一个预测这一分野——它们的机制（通约化、机械客观性、脱耦、路径依赖、坎贝尔定律）全部应当同等地作用于这两类装置。

推论四是本文最重的一笔，因为它把一条”什么都能解释”的犬儒判断（评价都是骗人的）转化为一条有边界、有反例、可被证伪的律。

四、方法与它的边界

（一）研究设计

本文是一项概念分析与机制建构研究，以历史谱系追溯与跨域结构同构为双重校验工具，其产出是一条带边界条件的律及其可证伪的检验设计。本文不提供一手数据。

选择这一设计的理由是：本文所挑战的不是既有理论的某个结论，而是它们共享的前提（评价装置是测量装置）。挑战前提不能靠在前提内部收集更多数据——那样收集到的一切都会被前提消化。它只能靠两件事：（i）追溯前提的历史来源，看它在装置的诞生场景中是否成立；（ii）寻找前提在其他领域中的同构失效，看它是否是一个跨域的系统性错误。本文两者都做。

（二）历史谱系追溯

第 5.1 节对三个独立起源的大规模评价装置——中华帝国晚期的科举、19 世纪普鲁士—德意志的文官考试、20 世纪美国的标准化测验——的诞生场景进行结构化追溯。追溯的目标不是叙述制度史，而是回答一个单一问题：**在每一个装置被建立的时刻，建立者试图解决的问题是“我们不知道谁有能力”，还是“我们不知道如何让落选者接受落选”？**

选择这三个案例的理由是它们的**独立性**：三者 in 文化传统、政体形式、经济结构上没有共同祖先（普鲁士考试受科举影响的说法在史学上有争议且不是本文的论据），若三者的诞生场景呈现同一结构，这一结构就不能被归因于文化传播。

追溯依据的是这三个领域中已被广泛接受的二手史学研究（Elman, 2000; Miyazaki, 1976; Lemann, 1999; Karabel, 2005），本文不提供新的档案工作。这构成本文的一个明确局限（见 6.4）。

（三）跨域结构同构

第 5.3.3 节将外壳再分泌律在五个教育之外的领域中兑现：政治学的选举、法学的正当程序、金融的信用评级、组织管理的绩效考评、医学的诊断分类。

跨域调用有被批评为“隐喻不肖”的风险，因此本文对每一次调用设定了统一的准入条件：**该领域必须存在一个承担稀缺分配或不可逆决定功能的装置，且该装置的测度效度已被独立研究证伪，且该装置未因此消亡**。只有同时满足这三条的领域才被纳入。不满足的领域被显式排除并说明理由（如“生态防火”这类常被用作类比的场景不满足第一条，因而不在于本文的地图中）。

这一准入条件的作用是使跨域地图可被证伪：如果有人能指出某个满足三条准入条件的领域，其装置在效度被证伪后确实消亡了，本文的律就受到实质挑战。

（四）与本文的自我关系

本文的对象是一类装置，而本文自身正在被这类装置评价（同行评审、期刊分级、引用计数）。这不是一个可以被回避的修辞尴尬，而是本理论必须面对的最硬的检验：**如果本理论正确，它必须能够解**

释它自己的命运。第 6.5 节承担这一检验，并预先给出本文在评审中的处境的理论预测。这一检验的纪律是：如果本文能够论证该律适用于一切装置却唯独不适用于评价本文的装置，那么该律就不是一条律，而是一个指向他人的标签，应被作废。

（五）方法局限

其一，历史追溯依赖二手研究。本文对三个装置诞生场景的解读，建立在既有史学成果之上，未做档案工作。一个持不同框架的史学家可能从同样的材料中读出不同的诞生动机。本文在 5.1 中的处理是：只使用那些在各自领域内已被广泛接受、且不由本文的框架所引导的史学结论，并在每处标注该结论的争议状态。

其二，“一到两代人”的时间尺度是估计。该数字来自三个历史案例的粗略归纳（科举从隋唐确立到明清完全形式化用了数百年，但明清八股定型后的形式化只用了约两代人；SAT 从 1926 年设立到 1980 年代应试产业成熟约两代人；中国高考从 1977 年恢复到应试体系完全成熟约一代半），不是从任何机制推导出来的。律的核心内容不依赖这个数字，但律的可证伪性依赖它——一个不给时间窗的”必然”是不可证伪的。这是本文最脆弱的一处，在 6.4 中被再次承认。

其三，阈值/排序的分界在现实中是连续谱。现实装置很少是纯粹的排序型或纯粹的阈值型（医学院录取既有分数线又有排名）。本文在 5.3.4 中给出了一个操作化的连续指标，但该指标的信度尚未被检验。

五、产品倒置：三个装置的诞生场景

本节回答一个只需要历史材料就能回答、却几乎从未被提出的问题：大规模评价装置被建立的那一刻，建立者要解决的是什么问题？

1. 科举：一个以落第者为产品的装置

科举制在隋唐之际的确立，其历史场景在史学界并无重大争议：它是皇权对付门阀士族的工具。关陇集团垄断了官职的世袭通道，皇帝需要一个能够绕过这一通道、向皇权直接输送人员的机制。这是一个纯粹的分配危机。没有任何证据表明当时存在一个”我们不知道谁有才能”的认知困境——门阀内部对谁有才能的判断相当清楚，问题是他们的判断权本身。

真正说明问题的是科举在其成熟期的运作数据。艾尔曼（Elman, 2000）对明清科举的系统研究给出了一组常被引用却极少被真正消化的数字：明清两代，通过乡试者约占应试者的百分之一到二，会试的录取比例更低；一个士人从童生到举人可能耗费三四十年，绝大多数人终身停在最低一级或根本不入级。这意味着，**这个装置在其全部运行历史中，百分之九十九以上的产出是落第者。**

按照”选拔人才”的功能定位，这是一个荒谬低效的装置——它耗费了整个社会几个世纪的智力资源，产出的绝大部分是失败。但如果把落第者本身视为产品，一切就顺了。艾尔曼指出，落第者并未离场：他们成为塾师、幕友、讼师、地方乡绅、宗族领袖，构成了帝国基层治理的实际承担者，并且**继**

续把自己的儿子送进同一个装置。他们不但没有成为体系的敌人，反而成了体系最坚定的维护者与最有效的传播者——因为他们是唯一有能力向下一代解释“为什么这是值得的”的人。

一个装置若真的以选拔为目的，落第率是它的成本。若以生产可接受的拒绝为目的，落第者就是它的产品，而落第者继续参与就是它的成功指标。明清科举的运作数据只在第二种读法下是可理解的。

2. 糊名与誊录：一项针对“施害者”而非“误差”的技术

科举史上最能说明外壳性质的，是宋代确立的糊名（弥封）与誊录制度。糊名将考生姓名籍贯密封，誊录则由专人将试卷重抄一遍再交考官评阅，以防笔迹辨认。

这两项技术在评价技术史上通常被记为“提高公正性的进步”。但需要精确地问：它们提高的是什么？

它们不提高效率。糊名不会让一份八股文更准确地反映考生的治国能力——它对测量精度的贡献为零。誊录甚至可能降低精度（抄错、书法信息丢失）。它们所消除的，是**考官偏袒的可能性**，即：**可指认的施害者**。

这是一个可以推广到整个评价技术史的观察。逐条检视升学评价技术的演进——统一命题、统一考场、统一评分细则、双盲阅卷、机读答题卡、多套试卷随机分发、成绩复核程序——每一项引入时的官方理由与社会诉求，几乎无一不是“这样能更准确地测量学生”，全部是“这样就没有人能做手脚”。技术的演进方向是**朝向不可争辩性**，不是朝向准确性。

这是本文 P2 的第一个直接经验兑现：外壳的形态由可接受性的需求塑造，不由认识的需求塑造。

3. 普鲁士文官考试：非人格性作为产品

普鲁士在 1806 年耶拿战败后的施泰因—哈登堡改革中系统建立文官考试制度，其场景同样是分配危机：贵族对官职的世袭垄断与新兴受教育市民阶层的参与要求之间的冲突，叠加战败后国家对行政效能的紧迫需求。

韦伯（Weber, 1978）对这一制度的分析给出了本文所需的关键概念。他把官僚制的核心特征概括为 *sine ira et studio*——不带怨恨与偏爱地处理事务，并把“非人格性”（Unpersönlichkeit）列为官僚制合理性的首要来源。韦伯是在赞美这一特征的行政效率，但他所描述的机制，在本文的框架下是另一件事：**非人格性的首要功能不是效率，是让被处理者无法怨恨任何人**。

一个被贵族排斥的市民之子，知道自己被谁排斥了，他的怨恨有落点，落点会积累为政治力量。一个考试不及格的市民之子，不知道被谁排斥了——排斥他的是一个程序。他的怨恨没有落点。它只能返回自身，成为“我不够格”。

这不是一个副作用。这是这个装置在 1806 年的普鲁士被建立起来所要解决的、最紧迫的那个问题。

4. 关键实验：当测度威胁到分配需求时，谁让步？

前三节论证了诞生场景，但一个批评者可以合理地反驳：诞生动机不决定后续功能，一个为分配危机而建的装置，完全可能在运行中真的发展出测量功能。这个反驳是有力的，它要求一个能够区分两者的实验。

历史提供了这个实验。卡拉贝尔（Karabel, 2005）对哈佛、耶鲁、普林斯顿录取史的研究记录了一个精确的自然实验。1920 年代，这三所大学的录取以学术考试为主。这一装置产生了一个它的设计者不想要的结果：犹太学生的比例迅速上升——因为他们在考试上表现更好。哈佛的犹太学生比例在 1920 年代初期达到百分之二十以上。

面对这一结果，这三所大学做出的选择被完整地记录在案：**它们改掉了装置**。1926 年前后，三校陆续引入”品格”（character）、“领导力”、“全面发展”（well-roundedness）等无法被标准化考核的维度，引入校友面谈、推荐信、体育特长、家庭背景问询。这套新标准的公开理由是教育理念的升级——培养完整的人，而非书呆子。其实际效果与实际目的（卡拉贝尔的档案工作在这一点上是明确的、并已被广泛接受）是把犹太学生比例压回可接受的水平。

这个实验的结构是：**测度与分配需求发生冲突。谁让步？**

答案是测度让步。而且让步的方式极其说明问题：它没有被替换成一个更准确的测度，它被替换成了一个**更模糊**的测度——因为模糊性正是分配需求所需要的。

如果测量学习是这个装置的目的，1926 年的常春藤应当欢呼——它们的测量工具正在成功地识别出最有能力的学生，只不过这些学生恰好是犹太人。它们没有欢呼。它们改掉了工具。

一次改动可以是偶然。但这个结构在评价史上反复出现：智力测验因为”测量了无法通过努力改变的东西”而被逐出升学录取；SAT 从 Scholastic **Aptitude** Test 一路更名，最终在 1990 年代彻底放弃 aptitude 一词，并在 2016 年的改革中明确宣布向高中课程内容对齐——即，向**可以通过努力提高的东西**对齐。

这一条演进线的方向，用”提高测量准确性”完全无法解释：如果目标是准确地测量学生的认知能力，从能力倾向转向课程掌握度是一次纯粹的倒退，因为后者混淆了能力与教学质量、家庭资源、备考投入。用本文的框架，它是一次必然：**外壳必须测量可归因于被拒者自身的东西，否则拒绝不可接受。**”你天生不行”是一个无法被接受的拒绝理由——它不满足要件一（被拒者会离场）也不满足要件三（他无法用它组织自己剩下的人生）。“你不够努力”则是一个完美的拒绝理由：它把责任交还给被拒者，从而完成了怨恨的吸收。

外壳向可努力性靠拢，不向准确性靠拢。这是 P2 最锋利的经验兑现，也是既有框架中没有任何一个能够产出的推论。

六、外壳为什么不必准确，又为什么仍需一点准确

1. 不可争辩性的生产

外壳的产品是不可争辩性。这需要通过机制化地说明，而不是断言。

一个拒绝要成为可接受的，被拒者必须无法组织出一个有效的反驳。反驳的组织需要一个对象——某个可以被指认为“错了”或“不公”的东西。外壳通过三重结构消除了这个对象：

第一重，非人格化。 拒绝你的不是人，是分数。你无法怨恨一个数字。

第二重，程序化。 分数不是被判定的，是被计算的。计算意味着，任何人处在评分者的位置上都会得出同一个结果。这切断了“换个人评就不一样”这条反驳路径。

第三重，通约化。 你与其他人被放在同一个标量上。这切断了最后一条反驳路径——“我和他不一样，不能这么比”。通约化的社会功能，正是让这句话变得不可说。埃斯佩兰和史蒂文斯（Espeland & Stevens, 1998）把这称为信息的丢弃；从本文的角度，被丢弃的信息恰恰是**争辩的材料**。丢弃不是通约化的成本，是它的产品。

三重结构合起来，产生了一个被拒者无法着力的表面。他伸手去抓，抓到的只有一个数字、一套程序、一个刻度。这就是不可争辩性。

请注意：这三重结构中，**没有一重需要准确性**。非人格化不需要，程序化不需要，通约化更不需要——它只需要一个刻度存在，不需要这个刻度测量了任何真实的东西。

2. 效度与不可争辩性的系统性冲突

外壳不仅不需要准确，它与准确之间存在结构性冲突。

考虑那些能够真正提高效率的评价方式：长期的过程性观察、多元证据的三角互证、深度的个别面谈、了解学生的导师做出的整体判断。教育测量学在信度效度的技术意义上并不否认这些方式能够更接近“这个人到底怎么样”。

这些方式在升学评价史上被系统性地淘汰。淘汰的理由从来不是“它们测不准”。理由永远是：**可以被操纵，不透明，依赖判断**。

翻译成本文的语言：**它们无法生产不可争辩性**。一个导师的整体判断，无论多么准确，都留下了一个可指认的对象——那个导师。被拒者可以说“他对我有偏见”。这句话一旦可说，拒绝就不再可接受。

因此，评价史上反复上演的是这样一场交易：**用效度换取不可争辩性**。而这场交易的方向是单向的——从来没有一次改革是用不可争辩性换取效度。

这解释了一个既有文献长期无法解释的现象：为什么一个多世纪的测量技术改进，没有带来公众信任的上升？因为技术改进的方向从来不是准确性。它是不可争辩性。而不可争辩性的提高，恰恰以效度

的下降为代价。信任没有上升，是因为改进的东西不是被信任所需要的东西——但这一点从来不重要，因为运作所需要的从来不是信任，是不可争辩。

3. 为什么不干脆抽签

如果外壳不需要准确，为什么社会不采用一个更彻底、更便宜、也更诚实的方案——抽签？

埃尔斯特（Elster, 1989）证明了抽签在许多分配场景中被实际采用，且被接受。抽签生产的不可争辩性是完美的：它没有人格，没有判断，没有可指认的对象，且成本近乎为零。按前述逻辑，抽签应该是最优解。

它不是。这个反例必须被解释，否则本文的机制是不完整的。

答案在于两类可接受性的差别。抽签生产的是**可接受的运气**；现代社会需要的是**可接受的应得**。

这个差别不是道德偏好，是结构需求。一个基于运气的分配可以被单次接受（我这次运气不好），但它无法支撑一个跨代的社会叙事。如果机会分配是抽签，那么：家长无法向孩子解释为什么要读书；学校无法解释自己为何存在；社会无法要求任何人努力；成功者无法解释自己凭什么占据位置。整个合作体系的动员机制会失去着力点。

这一点在关于绩效社会的经典论述中已被从另一个方向触及，只是从未被连到评价装置的机制上。杨格（Young, 1958）在发明“绩效主义”（meritocracy）这个词时是把它当作反乌托邦讽刺来写的：他的虚构社会之所以比世袭社会更残酷，正是因为它成功地让失败者相信失败是自己应得的——世袭社会的底层可以恨贵族，绩效社会的底层只能恨自己。桑德尔（Sandel, 2020）在半个世纪后把这一诊断推到当代：绩效叙事的暴政不在于它分配不公，而在于它剥夺了失败者对自己失败的任何外部解释。

杨格与桑德尔都把这看作绩效社会的**代价**——一个我们应当设法减轻的道德损害。本文的读法相反：**那不是代价，那是产品**。一个让失败者恨自己的装置，正是一个成功地生产了可接受的拒绝的装置；杨格所描述的那种残酷，是这个装置正常工作的标志，不是它的故障。

因此，装置必须生产一种拒绝，它同时满足两个要求：**不可争辩**（否则怨恨有落点）且**可归因于被拒者自身**（否则努力失去意义）。

抽签满足第一条，违反第二条。导师判断满足第二条（他判断的是你），违反第一条。

只有一种东西同时满足这两条：一个非人格的、程序化的、通约化的、且测量某种被拒者自己控制的属性的装置。这就是测度外壳的完整规格。它必须借用测量的语法，不是因为社会想知道什么，而是因为这是唯一能同时满足两个约束的形式。

这是本文对“为什么必须是测量”这个问题的完整回答——第 2.6 节指出，既有四条脉络没有一条能回答它。

4. 最低保真成本：外壳的唯一保真压力

规格的最后一条（测量某种被拒者自己控制的属性）给外壳施加了它唯一的保真压力，本文称之为**最低保真成本**。

外壳必须与某种真实的个人差异保持最低限度的相关。如果分数与考生做过的任何事情都完全无关（比如按身份证尾号排序），表象立刻崩溃，可归因性消失，拒绝变回运气。所以外壳必须真的测量点什么。

但这个”点什么”的要求极低，而且它的方向不是效度。它只要求：**存在一个被拒者可以事后认领为”我没做够”的东西**。

刷题量满足这个要求。记忆强度满足。应试技巧满足。它们全都与”学习”这个装置声称测量的东西关系稀薄，但它们全都完美地满足最低保真成本——因为它们是被拒者自己控制的、可以事后认领的。

这就是脱钩的完整机制，也是 P3 的论证：脱钩不需要坎贝尔定律来解释。坎贝尔定律（Campbell, 1979）说的是”当一个量化指标被用于社会决策，它就会承受腐蚀压力并扭曲它所监测的过程”——这个机制是真的，但它是表层的：它描述了外壳被使用后如何腐蚀，它假设外壳一开始是准的。本文的机制在它之下：**外壳从一开始就只需要满足最低保真成本，而不是效度**。坎贝尔定律解释的是外壳如何从”有点准”滑到”完全不准”；本文解释的是为什么这个滑动不构成问题——因为最低保真成本在滑动全程中都被满足着。刷题量始终是被拒者自己控制的。

由此得到 P3 的完整形式：脱钩是稳态。需要解释的不是脱钩，是耦合。而耦合从来只是最低保真成本的副产品——在装置刚建立的头一两代人里，还没有人知道如何专门优化外壳（应试产业尚未成熟），因此外壳与被测对象碰巧保持了一定相关。这个相关不是装置的成就，是它的**尚未成熟**。

这给了本文对当前危机的完整诊断。人工智能没有揭穿脱钩。脱钩一直在那里，且每一个身处其中的人都以某种方式知道。人工智能揭穿的是**那个尚未成熟期的记忆**——那个”分数曾经是准的、后来变坏了”的集体故事。被摧毁的是这个故事，不是效度。

而这解释了一个用其他框架无法解释的现象：为什么被 AI 冲击得最厉害的，是**教师和家长的信念**，而不是装置本身的运转。装置没事。它照常运转。出事的是那个故事。

七、外壳再分泌律：一条会禁止事情的律

1. 律的推理链

律的核心推理链已在 3.1 给出，此处兑现其每一环：

安抚需求内生于被拒者（3.1 要件三）→ 该需求不因旧装置被废除而消失，因为它的来源不是装置，是稀缺 → 新装置一旦承接稀缺分配功能，立即面对同一需求 → 新装置必须让被拒者接受被拒 → 因此必须提供非人格的、不可争辩的、且可归因于被拒者自身的拒绝理由（5.2.3 的完整规格）→ 因此必

须分泌测度外壳 → 由最低保真成本机制（5.2.4），外壳在应试产业成熟后与它声称测量的对象脱钩。

链条的每一步都不依赖任何人的意图。**这是律的关键性质，也是它区别于一切阴谋论式解释的地方。**设计新装置的人真诚地想要一个更好的评价方式。他们分泌外壳，是因为他们的装置一旦承接了分配功能，就必须回答”凭什么是他不是我”，而这个问题在现代社会只有一种可行的答案格式。

2. 正在发生的再分泌：三个可追踪的案例

案例一：美国大学的 test-optional 转向。2020 年前后，因疫情与公平性争议，美国大量高校取消了 SAT/ACT 要求。这是一次真正的装置废除——外壳被拿掉了。按照”外壳是压迫工具”的理解，其后果应当是阶层偏倚下降。

实际发生的是：录取的权重转移到了课外活动、个人陈述、推荐信、面试、“影响力叙事”。围绕这些维度，一个升学咨询产业在数年内成熟，其单价远高于 SAT 备考（SAT 备考可以靠一本题册与自律，个人陈述的包装不能）。多项研究指出，新组合的阶层偏倚**高于**它所替代的标准化考试——因为标准化考试是三重结构最完整的外壳（非人格、程序化、通约化），而叙事型材料的三重结构全部残缺，从而给资源留下了更大的作用空间。

请注意这个案例的结构：改革的意图是消除外壳的不公，结果是分泌了一层更不公的外壳。这不是执行不力，是律。

案例二：中国的综合素质评价。作为降低”唯分数”的政策工具引入。其后果是可观察的：素质档案的填写迅速标准化，出现了模板、代写服务与量化折算表（志愿服务多少小时折多少分、竞赛奖项如何换算）。**新装置在数年内长出了分数。**它必须长出分数——因为不长出分数，它就无法回答”凭什么是他不是我”。

案例三：开放平台的声誉信号。GitHub 的 star 数、Kaggle 排名、开源贡献记录，曾被广泛论证为”不依赖学历的真实能力证据”。它们一旦被雇主用于筛选（即承接稀缺分配功能），刷星服务、贡献注水、榜单优化立即出现。这一装置正处在再分泌的早期：外壳已经形成，脱钩已经开始，但那个”它曾经是准的”的记忆还在——正如 1980 年代的 SAT。

三个案例的共同结构：**承接分配功能 → 分泌外壳 → 脱钩**。时间尺度从数年（平台信号）到一到两代人（学历装置）不等，取决于优化产业成熟的速度。

3. 跨域兑现：五个满足准入条件的领域

按 4.3 的准入条件（存在承担稀缺分配或不可逆决定功能的装置 + 该装置的测度效度已被独立研究证伪 + 该装置未因此消亡），以下五个领域被纳入。

领域	装置	效度证伪	是否消亡	律的兑现
金融	信用评级	2008 年结构化产品评级的大规模违约	否，制度地位上升	生产的是可接受的资本拒绝：被拒的融资

领域	装置	效度证伪	是否消亡	律的兑现
				方无法指认施害者，只能指认自己的评级
政治	选举	选民信息水平与议题投票一致性的经典研究表明，选举对“选出更善治理者”这一声称目标的达成度远低于其自我表述	否	生产的是可接受的败选：败选者接受结果并准备下一轮，而非诉诸暴力。这正是选举与政变的全部区别
法律	正当程序	冤案率研究表明程序不保证事实准确	否，程序要求持续加严	生产的是可接受的判决：程序的加严方向是消除“法官偏见”而非提高事实发现率
组织管理	绩效考评	绩效评级与实际产出的相关性在大量元分析中偏低	否	生产的是可接受的晋升与解雇：被解雇者面对的是评级，不是主管
医学	部分诊断分类	若干功能性诊断的构念效度长期存疑	否	生产的是可接受的痛苦：一个标签把“我的痛苦是真实的”从人际争辩中移出

五个领域的共同结构：装置的效度被证伪，装置未消亡，且证伪之后**装置的形式化程度反而提高**。最后一点是律最反直觉、也最容易被检验的推论——它预测的是与所有既有框架相反的方向。

选举一行需要单独说明，因为它是本文最容易被误读的一处。 关于“选举型威权主义”的研究（Schedler, 2002; Diamond, 2002; Levitsky & Way, 2010）已经详尽论证了：混合政体中的选举同时承担挑选统治者与宣示合法性两种功能，当它不再产生真实选择时，取消它会引爆合法性危机，维持它则暴露功能空转。这一文献与本文的表面相似度很高，但它有一个自我设限：它把这一结构当作**威权政体的特征**，用以区别于有实质竞争的选举。本文的主张更冒犯：**所有选举首先都是产生可接受的败选的装置**。民主国家的选举与威权国家的选举的区别，不在于前者不生产可接受的败选，而在于前者的外壳保真度更高——它的最低保真成本被支付得更足。一场败选之所以能被接受，从来不是因为败选者相信计票是准确的（他不核对），是因为他找不到一个可以指认的施害者。当他找到了——如同他相信选举被操纵时——外壳就破了，而外壳一破，接受立刻消失，冲突立刻具备落点。近年若干成熟民主国家中围绕选举结果正当性的冲突，在本文的框架下不是“民主的倒退”，是**外壳破裂**：装置照常运转，票照常被计，但那个使败选可接受的表面被戳穿了。这与本文对教育的诊断（P3：被摧毁的是记忆，不是效度）是同一个机制在另一个领域的兑现。

为什么某些常被类比的领域不在表中。 生态防火、核威慑、金本位这类场景常在制度分析中被用作类比，本文将它们排除，因为它们不满足第一条准入条件：它们不生产“可接受的拒绝”，没有一个被排除的个体需要接受一个关于自己的判断。排除它们不是保守，是使地图可被证伪：一个由“什么都像”的类比构成的地图不能被任何证据推翻。

4. 边界条件：排序型与阈值型的分界

律的可证伪性依赖于它有一个明确的边界。本文主张这个边界是拒绝理由的语法。

排序型装置的拒绝理由是相对的：你出局，因为有 N 个人排在你前面。这个理由永远可被争辩，因为它包含一个比较，而任何比较都可以被质疑（“凭什么这么比”）。因此排序型装置必须分泌外壳来切断争辩。

阈值型装置的拒绝理由是绝对的：你出局，因为你没达到标准。这个理由可被拒者自己验证。他不需要相信任何人，他自己知道他不会开飞机。因此阈值型装置不需要外壳。

决定语法的不是装置的意图，是名额。一旦存在名额上限，装置必须排序，无论它自称在做什么。这给出了一个操作化的判别式：

装置的分泌压力 $\propto$ 名额约束的紧度 $\times$ 拒绝的不可逆性

紧度为零（无名额，达标即过）的装置不分泌外壳，其测度可以长期保真。

5. 判决性案例：USMLE Step 1 的改制与压力转移

这一分界不是思辨的产物。它有一个近乎实验室条件的现实案例，且这个案例在本文提出之前就已完整发生。

美国医师执照考试（USMLE）Step 1 在设计上是一个纯粹的阈值型装置：它的功能是判定考生是否具备行医所需的基础医学知识，达标即过，无名额约束。按本文的律，它不应分泌外壳，其测度应长期保真。在其历史的大部分时间里，情况正是如此。

然后发生了一件事：住院医培训项目开始把 Step 1 的**三位数分数**用作申请筛选的排序工具。这一挪用没有改变考试本身的任何技术属性——同一套题库、同一套评分、同一个通过线。它只改变了一件事：**这个装置开始承接稀缺分配功能。**

本文的律对此有一个明确的预测：分泌压力立即出现，外壳开始形成，测度开始与被测对象脱钩。

实际发生的完全是这个：一个被称作“Step 1 mania”的现象出现了——医学生把大量时间从临床学习转向应试训练，围绕 Step 1 的商业备考产业（题库、闪卡、押题课程）迅速成熟，考试分数与临床能力的关联受到医学教育界的持续质疑。2020 年，USMLE 宣布 Step 1 改为通过/不通过（pass/fail），并于 2022 年 1 月实施。改制的官方理由被明确表述为：**降低分数被用作排序筛选所带来的扭曲。**

这是本文的律在现实中被一个完全不知道本文存在的专业共同体所独立执行的一次干预：**切断排序挪用，解除分泌压力。**

但这个案例真正的价值在它的后续。改制之后，住院医申请的排序需求**没有消失**——名额还在那里。压力立即转移到了 Step 2 CK：这门原本地位次要的考试，其分数在改制后迅速成为新的核心筛选指标，围绕它的应试产业开始成熟。

这就是再分泌，而且是在两年内、在一个可以被完整观察的封闭系统里发生的再分泌。 需求没有被消灭，它换了个宿主。

这个案例同时兑现了 P4 与 P5，且它给出了 P6 的具体形式（见 5.5）。本文认为它是这条律目前最硬的经验锚点，也是最容易被用来推翻本文的地方——如果对 USMLE 改制后的追踪数据显示 Step 2 CK 并未成为新的排序装置，或其应试产业并未成熟，本文的再分泌命题就直接受损。

八、与最强对手的正面交锋

1. 竞争解释：波特的机械客观性

本文的最强竞争解释不是路径依赖，也不是批判再生产，而是波特（Porter, 1995）的机械客观性理论。理由在 2.2 已说明：波特已经论证了量化不为准确，本文若不能与他分岔，就只是一次换词。

波特的完整主张可以被表述为：**量化是弱者的策略**。当决策者的权威牢固时，他们凭判断决策，不需要数字；当决策者的权威受到质疑时，他们需要一个看起来不依赖任何人的判断的程序来抵御质疑。因此，量化的厚度与决策者的专业权威负相关。

2. 判决性检验：2×2 设计

两个理论对同一组变量给出相反的预测。这使一次判决性检验成为可能。

- **波特的预测**：外壳厚度 $\propto$ 决策者权威的**脆弱程度**
- **本文的预测**：外壳厚度 $\propto$ 拒绝的**不可逆程度**（与决策者权威无关）

在多数现实场景中，这两个变量共变（权威脆弱的地方往往也是拒绝激烈的地方），因此两个理论无法被区分。判决必须在两个变量分离的格子里进行。

	拒绝可逆性高	拒绝不可逆性高
决策者权威高	德国手工业师傅（Meister）资格：行会权威极高，可重考可转轨。 两说都预测薄。不判决。	法国大学校（Grandes Écoles）入学考试（concours）： 判决格
决策者权威低	美国社区学院开放录取： 两说都预测薄。不判决。	中国高考： 两说都预测厚。不判决。

判决格只有一个：**决策者权威高 $\times$ 拒绝不可逆性高**。

这一格的实例是法国大学校的 concours，而它恰好是波特自己的核心案例国的核心装置。

波特的经验支柱之一，是法国国立路桥学校的工程师：他们的社会权威牢固到不需要成本效益分析，这与被国会质疑的美国陆军工程兵团形成对照。这个对照是波特全书最有力的一笔。

但同一批法国工程师的**入学装置**，是世界上外壳最厚的装置之一：两年的预备班（classes préparatoires）、极度形式化的笔试与口试（colles）、精确到小数位的排名、名次决定校次的刚性对应。这套装置的形式化程度远超美国的大学录取。

波特预测薄。实际是厚。而本文预测厚——因为 concours 的拒绝是法国社会中最不可逆的拒绝之一：大学校的名次在很大程度上决定终身职业轨迹，且几乎没有中途转轨的通道。

这是一次直接的判决，且它发生在竞争理论自己的地盘上。

3. 本文对波特的理论吞并（而非并列）

上一节的结果不应被读为“波特错了”。更准确的读法是：**波特的机制是本文机制的一个特例。**

工兵团为什么需要量化？因为他们的项目可能被国会否决。**他们自己就是潜在的被拒者。**他们需要的，与考场里的学生需要的是同一样东西：一个非人格的、不可争辩的、可归因于自身的拒绝理由。他们不是在用数字说服国会，他们是在为自己制造一个能够接受否决的形式。

而法国路桥工程师在决策时不需要量化，是因为在那个位置上他们不面临拒绝；同一批人在十八岁面对 concours 时，则是纯粹的被拒者，于是外壳达到了极致的厚度。

同一批人，两个位置，两种结果。波特把这两个位置读成了“权威高 vs 权威低”，因此他的变量是决策者的属性。本文认为实际的变量是**位置**：谁在承受拒绝的风险，谁就需要外壳。

由此，本文与波特的关系不是并列的两种解释，而是包含关系：把波特的“弱者”精确化为“面临不可逆拒绝的位置”，他的全部经验发现都可以被本文的框架消化，而本文能够多解释三件他解释不了的事——评级机构在证伪后的强化、法国 concours 的厚度、以及 Step 1 改制后的压力转移。

4. 次要检验：影子排序（排除批判再生产路径）

批判再生产路径预测：排序装置是统治结构施加于被统治者的符号暴力，因此取消该装置的显式度量，被统治者的焦虑应下降。

本文预测相反：安抚需求内生于被拒者，若分配功能未被同时取消，取消显式度量将导致**自发的影子排序**——由参与者自己重建的、非官方的排序装置。

这一分歧有大量现成的经验落点：

- 取消班级排名的学校，家长自建的成绩统计群与私下互换分数的行为
- 社交平台隐藏点赞计数的实验（Instagram 于 2019—2021 年在多个市场测试隐藏点赞数），随后出现的第三方计数工具，以及平台最终改为用户可选而非全面隐藏
- 取消 GPA 排名的高校，用人单位与研究生项目自行重建的院校—课程折算表

三个案例的共同结构：**度量被拿掉，需求还在，参与者自己把度量造回来。**

批判路径无法预测这个结构：如果度量是被施加的，那么施加被撤除后，没有理由预期被施加者自己重建它。脱耦理论也无法预测：如果正式结构是给外部环境看的，那么外部要求撤除后，它应当变为纯粹冗余而被放弃。

只有一个前提能预测影子排序：**需要它的人就是被它拒绝的人。**

5. 本理论的证伪条件

本文在四个层面上是可证伪的，逐条列出：

(1) P1 的证伪：若能证明某个大规模评价装置的诞生场景确实是认知需求而非分配危机——即建立者面对的问题是“我们不知道谁有能力”而非“我们不知道如何让落选者接受落选”——且该装置在无名额约束的条件下仍然发展出了排序与外壳，则产品命题受损。

(2) P4 的证伪（律的核心）：找到一个同时满足以下三条的装置——承担稀缺分配功能、排序型、且其测度外壳在两代人之后仍与它声称测量的对象保持稳定耦合。找到一个，律即被推翻。本文没有找到；这不构成证明，只构成邀请。

(3) P5 的证伪（边界）：若阈值型装置（无名额约束）也系统性地表现出与排序型装置同等的脱钩与应试产业成熟，则排序/阈值的分界不成立，律退化为一句“所有评价都会腐败”的犬儒判断——那样它就失去了全部价值。USMLE 案例的后续追踪是这一条最直接的检验场：若 Step 2 CK 在改制五年后并未成为核心排序装置、其应试产业并未成熟，本文的再分泌命题直接受损。

(4) 判决格的证伪：若对 5.4.2 中判决格的系统测量显示，在控制拒绝不可逆性之后，决策者权威仍对外壳厚度有独立的、显著的预测力，而拒绝不可逆性的独立效应消失，则波特的框架胜出，本文应被放弃。

需要处理的内生性。 5.4.2 的设计有一个必须承认的内生性问题：一个社会的拒绝不可逆性与它的外壳厚度可能互为因果——正因为有了极厚的外壳，社会才把如此多的终身后果押在一次拒绝上。本文无法在观察数据中完全切断这个回路。可行的部分补救是利用外生冲击：某些国家因劳动力市场结构改革（而非教育政策）而改变了转轨的可逆性，可以观察其考试烈度的滞后变化。这一设计的可行性尚待验证，构成本文检验方案的最大弱点。

九、两个落点，都不在评价内部

1. 为什么评价端的一切干预都是同义反复

由 P4，任何在评价端的干预——改进测量、更换指标、引入多元评价、建设替代认证——都只是更换宿主。它们不能不失败，因为它们瞄准的是外壳，而外壳不是承重墙。

这个结论对教育政策具有直接的、且相当难以接受的含义：**教育评价改革是不可能的，因为它不是评价问题。** 过去四十年全球教育改革的反复失败，不是因为改革者不够努力或不够聪明，而是因为他们正在修一个不承重的部件。

这也是本文与其前身框架（把困境诊断为测度与安抚的双重锁定，并主张”先分流安抚、后释放测度”的三阶段改革）的分岔点。那个方案的第一阶段要求在旧系统外建立独立的认可通道，并明确要求该通道必须具备”公平可见”——即**必须提供一种类似旧分数的可比较性**。这一要求在方案内部是自治的：不提供可比较性，新通道就无法分流安抚。但由本文的律，提供可比较性的那一刻，新通道就已经开始分泌外壳，它在一到两代人后就是新的旧系统。**那个方案在自己的第一阶段里埋了自己的反例**。它没有错在执行细节上，它错在它仍然把安抚当作一种可以被”分流”到别处去的负荷，而没有看到安抚会在任何落脚处重新长出同一层壳。

2. 落点一：语法改造（排序 → 阈值）

由 P5，若分泌压力来自名额约束下的相对拒绝，则把装置从排序型改造为阈值型，可以解除分泌压力。这不是取消评价——阈值型装置仍然评价，仍然拒绝，仍然可以很严格。它改变的是拒绝理由的语法：从”你比别人差”改为”你没到线”。

USMLE Step 1 的改制是这一落点的一次真实执行，它同时暴露了这一落点的极限：**压力转移到了 Step 2 CK**。

这个失败给出了一条精确的设计原则，而这条原则只能从本文的律中推出：

阈值化必须是全谱的，否则只是转移。 若一个分配场景中存在任何一个仍然产出连续标量的装置，排序需求会立即在它上面重新落脚。

这条原则对教育政策是可操作的、也是苛刻的：把高考改为等级制而保留其他连续指标（学业水平考试原始分、竞赛名次、学校排名），排序压力会转移到保留的那个上面。真正的阈值化要求在同一分配场景中的**所有**装置同时放弃连续标量。这在名额约束保持不变的条件下几乎不可能实现——因为名额约束本身要求某处必须有一个排序。

由此推出一个更硬的结论：**语法改造的可行性上限，由名额约束决定**。名额不动，语法改造只能转移压力，不能解除它。

这把问题交给了第二个落点。

3. 落点二：需求端（降低拒绝的不可逆性）

安抚需求的产生率是稀缺性与拒绝不可逆性的函数。稀缺性在多数场景中不可由教育政策调整。拒绝的不可逆性可以。

这里必须精确地区分本文的主张与一个近似的、但不同的主张。老左派的方案是”消除不平等”——即降低稀缺性。这不是本文的方案，且本文认为它是本文的一个竞争解释（见 5.4 的处理）。本文的主张更窄、也更可操作：**降低单次拒绝的终身不可逆性**。

这两者可以分离。一个社会可以保持相当程度的不平等，同时使拒绝高度可逆——被拒者在三十岁、四十岁仍有实质性的重新进入通道。也可以相当平等而拒绝极不可逆——所有人得到的差不多，但那一次决定了是哪一份。

可逆性的操作化是可能的，且不依赖任何新的数据基础设施：

- 三十岁及以后完成职业轨道实质性转换者占同龄人的比例
- 通过非传统路径（非全日制、职业教育、成人教育、企业内训）进入高收入职业的比例
- 首次教育分流决定与四十五岁时职业地位的相关系数——**这是最直接的一个指标：它直接测量”那一次”决定了多少**

本文的预测是：这一相关系数与该社会的考试烈度（备考时长、校外辅导支出占家庭可支配收入比、考试相关的青少年心理危机发生率）呈正相关，且在控制人均收入、不平等程度（基尼系数）、教育扩张程度之后仍然显著。

德国的双元制与东亚的单轨升学构成了这一预测的一个粗略对照：德国的分流发生得更早（十岁左右），按”分流早晚决定压力”的常识预测应当更残酷，实际是更温和——因为它的分流是可逆的（职业教育通道与高等教育通道之间存在实质性的横向转换机制，且职业资格在劳动力市场上具有独立的、不被学历折算的价值）。**决定压力的不是分流的早晚，是分流的可逆性。** 这是一个可以用现有的跨国数据直接检验的命题。

4. 这一节的诚实位置

本文的干预建议在实践上是弱的，这一点必须直说。它没有给出”做什么”的清单，它给出的是”不要做什么”的判决——不要在评价端做任何事，那是同义反复。而它指出的两个落点，一个（全谱阈值化）在名额约束下几乎不可行，另一个（可逆性）不在教育部门的管辖范围内，它属于劳动力市场制度、职业资格体系、社会保障结构。

这不是本文的谦虚，是本文的结论：**教育评价的困境不能在教育内部被解决，因为它从来不是一个教育问题。** 一个理论如果诚实，它就必须允许自己得出”你管辖的范围内没有解”这样的结论，而不是为了显得有用而发明一些在自己的框架下注定失败的建议。

十、结论

（一）核心发现

本文的中心判断可以凝缩为一句：

教育评价装置的社会产品不是关于学习的信息，而是可接受的拒绝。测度不是这个产品的目的，是它的分泌物——一层必须看起来像测量、却从不承担测量义务的外壳，它所生产的是不可争辩性而非准确性。因此，分数与能力的脱钩不是病症而是常态，人工智能所摧毁的是”曾经耦合”这一集体

记忆而非效度本身；因此，任何承接稀缺分配功能的替代装置都将在一到两代人内分泌出同构的外壳——替代不是替代，是宿主更换。

这个判断与既有研究的关系不是补充，是方向的调转。技术优化路径要修好测量，批判路径要揭露测量被权力污染，制度惯性路径要解释测量为何难以被重新校准——三者都把测量当作这个装置的目的。本文认为测量从来不是目的。它是一个更基本的社会需求（在稀缺面前产生可被落选者接受的落选）为了运作而必须长出来的东西。

由此，本文对当前危机给出的诊断，与几乎全部现行对策相反：监考、检测、回归纸笔、重设题型这一整类”恢复分数效度”的努力是范畴错误，它们试图修复一个从未存在过的东西；而项目制评价、能力档案、微证书这一整类”更换更好的测量”的努力是同义反复，它们只是给同一个需求更换宿主，并将在可预见的时间内长出它们所要替代的那个东西。

（二）理论贡献

其一，对评价社会学：一条带边界的律，而非又一个诊断。 现有的评价批判——通约化改变被测对象（Espeland & Stevens, 1998）、量化是弱者的策略（Porter, 1995）、指标一旦成为目标就腐败（Campbell, 1979; Muller, 2018）——都是真的，但它们共享一个形态上的弱点：它们什么都能解释，因而什么都不禁止。本文的外壳再分泌律有一个明确的边界条件（排序型必然分泌，阈值型不必），因而它禁止一些事情：它禁止阈值型装置系统性脱钩，它禁止排序型装置在两代人后仍保持耦合。这些禁止使它可被证伪，也使它区别于”评价都是骗人的”这类犬儒判断。

其二，对波特的机械客观性：从并列到包含。 本文不主张波特错了，主张他的机制是本文机制的一个特例。他把变量识别为决策者的权威强度；本文认为实际的变量是**位置**——谁承受拒绝的风险，谁就需要外壳。工兵团需要成本效益分析，是因为他们的项目可能被否决，他们自己就是潜在的被拒者。这一重新定位使波特的全部经验发现被保留，同时使他解释不了的三件事（评级机构在证伪后的强化、法国 concours 的极厚外壳、USMLE 改制后的压力转移）被消化。

其三，对制度分析的一般贡献：分泌关系。 制度理论已有寄生、脱耦、分层、漂移、转化等一系列描述制度部件间关系的概念。本文补充了一种：**分泌**——B 为自身运作而产生 A，A 从未独立存在，A 的形态完全由 B 的功能需求决定。这一关系与脱耦的差别产生可检验的分歧：脱耦预测外部压力消失后正式结构因冗余而被放弃；分泌预测只要 B 的功能需求还在，A 就会被重新长出来。影子排序现象（5.4.4）是这一分歧的经验落点。

（三）政策含义

本文的政策含义主要是**负向**的，且不易被接受：

第一，停止在评价端投入改革资源。 由 P4，评价端的一切干预都是更换宿主。过去四十年全球教育改革的反复失败，不是因为改革者不够努力，而是因为他们正在修一个不承重的部件。这包括本文所批评的、也包括本文所继承的那些方案——包括”先分流安抚、后释放测度”这类看起来已经绕过了正面对抗的精巧设计（5.5.1）。

第二，若要在评价端做事，唯一有意义的动作是语法改造，且它必须全谱。 把排序型改为阈值型可以解除分泌压力，但只要同一分配场景中还剩下任何一个连续标量，压力就会转移到它上面（USMLE 案例）。这条原则是苛刻的，且它的可行性上限由名额约束决定。

第三，实际的落点在教育之外。 降低单次拒绝的终身不可逆性——通过职业资格体系的独立价值、中年转轨通道的实质化、非传统路径的劳动力市场认可——可以降低安抚需求的产生率，从而降低外壳的分泌压力。这不属于教育部门的管辖范围。这是本文最难被接受、也最不可回避的结论：**教育评价的困境不能在教育内部被解决，因为它从来不是一个教育问题。**

（四）局限

其一，历史论证依赖二手研究。 5.1 对三个装置诞生场景的解读建立在既有史学成果之上（Elman, 2000; Miyazaki, 1976; Lemann, 1999; Karabel, 2005），本文未做档案工作。一个持不同框架的史学家可能从同样的材料中读出不同的动机。本文的部分防御是：所使用的史学结论在各自领域内已被广泛接受，且不是由本文的框架所引导产生的——尤其卡拉贝尔的档案发现（5.1.4），是在一个与本文完全无关的问题意识（族裔排斥史）下做出的。

其二，“一到两代人”的时间尺度是归纳，不是推导。 这是本文最脆弱的一处。律的核心内容不依赖这个数字，但它的可证伪性依赖它——一个不给时间窗的“必然”不可证伪。目前这个窗口来自三个案例的粗略归纳，它需要一个机制（应试产业的成熟速度？信息传播的速度？）来支撑，本文没有给出。

其三，判决格的内生性未被切断。 5.4.5 已承认：拒绝不可逆性与外壳厚度可能互为因果。本文提出的外生冲击设计（利用非教育政策导致的转轨可逆性变化）的可行性尚未验证。这是本文检验方案的最大弱点。

其四，排序/阈值在现实中是连续谱。 本文给出了一个操作化的判别式（分泌压力 $\propto$ 名额紧度 $\times$ 拒绝不可逆性），但该判别式的信度未经检验。

其五，本文没有解释稀缺本身。 本文把稀缺当作外生变量。但一个更彻底的追问是：为什么现代社会必须把如此多的终身后果压在如此少的位置上？这个问题在本文的框架之外，且它可能才是根。

十一、自反：这条律适用于评价本文的装置吗

一个关于评价装置的理论，如果能够论证该律适用于一切装置却唯独不适用于评价它自己的那个装置，那么它不是一条律，是一个指向他人的标签。本节承担这一检验。

同行评审是不是排序型装置？ 期刊版面是稀缺的，存在名额约束。因此是。由 P4，它必然分泌外壳。

它的外壳是什么？ 是评审意见。评审意见必须以质量判断的语法呈现——方法论是否严谨、贡献是否充分、文献是否完备、论证是否成立。它必须看起来像一次对学术质量的测量。

它生产的是什么？ 由 P1，是可接受的拒绝：让被拒稿者接受被拒，并**继续投稿**（要件一）、**不指认具体施害者**（要件二——这正是双盲评审的功能，它与糊名制在结构上是同一样东西，且理由完全一致：它不提高判断的准确性，它消除可指认的施害者）、以及**把责任交还给自己**（要件三——“我的方法论确实不够严谨”）。

它脱钩了吗？ 关于同行评审的评审者间信度，已有大量证据表明其水平极低（Cicchetti, 1991）。彼得斯与切奇（Peters & Ceci, 1982）做过一个著名的实验：把已在顶级期刊发表的论文改换作者姓名与机构后重新投给同一批期刊，绝大多数未被识别出是已发表论文，且绝大多数被拒——理由是严重的方法论缺陷。这个实验精确地展示了外壳的性质：**同一份稿件，同一批期刊，相反的判决，且两次判决都以质量测量的语法给出，都不可争辩。**

它是否因此消亡？ 没有。它的形式化程度反而在持续提高——更多的评审人、更结构化的评审表、更细的评分维度、更严的利益冲突声明。**这正是 5.3.3 表格中五个领域的共同结构：效度被证伪之后，形式化程度反而提高。** 同行评审是这条律的第六个兑现，而它是唯一一个本文自己身处其中的。

最后一笔，也是最难的一笔：本文自己在做什么？

本文提出了一条律，给出了判决性检验、 2×2 设计、证伪条件、操作化指标、跨域准入条件。这一整套装备的功能是什么？

它使本文的主张**不可争辩**。它借用了科学的语法——正如外壳借用测量的语法。它做的是它所描述的那件事。

这里必须诚实到底，不能靠一句“但我们是自觉的”脱身。本文的处境是这样的：**按本文自己的边界条件（P5），本文不该分泌外壳——因为本文不分配任何稀缺资源，它不拒绝任何人。但本文确实分泌了。为什么？因为它要在一个分配稀缺版面的装置里活下来。**

这不是本文的失败，恰恰是律的又一次兑现，而且是最干净的一次：**一个自身不分配稀缺的东西，一旦进入一个分配稀缺的场域，就必须分泌外壳。** 本文的外壳不是本文的需求，是它的宿主的需求。

由此，本文能够对自己的命运做出一个可被观察的预测：**如果本文的判断被广泛接受，“外壳再分泌律”会成为一个可被引用的标签，人们会为了发表而使用它，它会与它所指称的东西脱钩。** 这条律预测自己会被吸收并脱钩。

这不是自我拆台。一个预测自己会被免疫的理论才是不可证伪的；一个预测自己会被吸收并脱钩的理论，给出的是一个可以被观察的时间序列。如果二十年后“外壳再分泌律”成为教育社会学论文里一个用来提高录用概率的关键词，而没有任何人再去检验它的边界条件——那就是这条律关于它自己的预言的兑现，也是它作为一条律的最后一次、也是最彻底的一次经验支持。

十二、参考文献

Arthur, W. B. (1994). Increasing returns and path dependence in the economy. University of Michigan Press.

- Au, W. (2009). *Unequal by design: High-stakes testing and the standardization of inequality*. Routledge.
- Black, P., & Wiliam, D. (1998). Assessment and classroom learning. *Assessment in Education: Principles, Policy & Practice*, 5(1), 7–74.
- Bourdieu, P., & Passeron, J.-C. (1977). *Reproduction in education, society and culture* (R. Nice, Trans.). Sage.
- Bowles, S., & Gintis, H. (1976). *Schooling in capitalist America: Educational reform and the contradictions of economic life*. Basic Books.
- Bromley, P., & Powell, W. W. (2012). From smoke and mirrors to walking the talk: Decoupling in the contemporary world. *Academy of Management Annals*, 6(1), 483–530.
- Campbell, D. T. (1979). Assessing the impact of planned social change. *Evaluation and Program Planning*, 2(1), 67–90.
- Cicchetti, D. V. (1991). The reliability of peer review for manuscript and grant submissions: A cross-disciplinary investigation. *Behavioral and Brain Sciences*, 14(1), 119–135.
- Collins, R. (1979). *The credential society: An historical sociology of education and stratification*. Academic Press.
- David, P. A. (1985). Clio and the economics of QWERTY. *American Economic Review*, 75(2), 332–337.
- Diamond, L. (2002). Elections without democracy: Thinking about hybrid regimes. *Journal of Democracy*, 13(2), 21–35.
- Elman, B. A. (2000). *A cultural history of civil examinations in late imperial China*. University of California Press.
- Elster, J. (1989). *Solomonic judgements: Studies in the limitations of rationality*. Cambridge University Press.
- Espeland, W. N., & Sauder, M. (2007). Rankings and reactivity: How public measures recreate social worlds. *American Journal of Sociology*, 113(1), 1–40.
- Espeland, W. N., & Stevens, M. L. (1998). Commensuration as a social process. *Annual Review of Sociology*, 24, 313–343.
- Hirschman, A. O. (1970). *Exit, voice, and loyalty: Responses to decline in firms, organizations, and states*. Harvard University Press.
- Karabel, J. (2005). *The chosen: The hidden history of admission and exclusion at Harvard, Yale, and Princeton*. Houghton Mifflin.
- Lemann, N. (1999). *The big test: The secret history of the American meritocracy*. Farrar, Straus and Giroux.
- Levitsky, S., & Way, L. A. (2010). *Competitive authoritarianism: Hybrid regimes after the Cold War*. Cambridge University Press.
- Mahoney, J., & Thelen, K. (Eds.). (2010). *Explaining institutional change: Ambiguity, agency, and power*. Cambridge University Press.
- Meyer, J. W., & Rowan, B. (1977). Institutionalized organizations: Formal structure as myth and ceremony. *American Journal of Sociology*, 83(2), 340–363.
- Miyazaki, I. (1976). *China's examination hell: The civil service examinations of imperial China* (C. Schirokauer, Trans.). Yale University Press.
- Muller, J. Z. (2018). *The tyranny of metrics*. Princeton University Press.

- Peters, D. P., & Ceci, S. J. (1982). Peer-review practices of psychological journals: The fate of published articles, submitted again. *Behavioral and Brain Sciences*, 5(2), 187–195.
- Pierson, P. (2004). *Politics in time: History, institutions, and social analysis*. Princeton University Press.
- Porter, T. M. (1995). *Trust in numbers: The pursuit of objectivity in science and public life*. Princeton University Press.
- Sandel, M. J. (2020). *The tyranny of merit: What's become of the common good?* Farrar, Straus and Giroux.
- Sauder, M., & Espeland, W. N. (2009). The discipline of rankings: Tight coupling and organizational change. *American Sociological Review*, 74(1), 63–82.
- Schedler, A. (2002). Elections without democracy: The menu of manipulation. *Journal of Democracy*, 13(2), 36–50.
- Scott, J. C. (1998). *Seeing like a state: How certain schemes to improve the human condition have failed*. Yale University Press.
- Spence, M. (1973). Job market signaling. *Quarterly Journal of Economics*, 87(3), 355–374.
- Stiggins, R. J. (2002). Assessment crisis: The absence of assessment FOR learning. *Phi Delta Kappan*, 83(10), 758–765.
- Weber, M. (1978). *Economy and society: An outline of interpretive sociology* (G. Roth & C. Wittich, Eds.). University of California Press.
- Young, M. (1958). *The rise of the meritocracy*. Thames & Hudson.

利益冲突声明 作者声明本文的撰写与发表不涉及任何财务与非财务的利益冲突。